

DEA-C01

亚马逊网络服务认证数据工程师（助理级）

店铺：学习小店66

考试 A

问题 1

一位数据工程师正在配置一个 AWS Glue 作业，以从 Amazon S3 存储桶读取数据。该数据工程师已设置好必要的 AWS Glue 连接详情以及相关联的 IAM 角色。然而，当该数据工程师尝试运行 AWS Glue 作业时，收到了一条错误消息，指出 Amazon S3 VPC 网关端点存在问题。

数据工程师必须解决错误，并将 AWS Glue 作业连接到 S3 存储桶。

哪种解决方案能满足这一要求？

- A. 更新 AWS Glue 安全组，允许来自 Amazon S3 VPC 网关终端节点的入站流量。
- B. 配置 S3 存储桶策略，明确授予 AWS Glue 作业访问该 S3 存储桶的权限。
- C. 检查 AWS Glue 作业代码，确保 AWS Glue 连接详细信息包含完全限定域名。
- D. 确认 VPC 的路由表包含通往 Amazon S3 VPC 网关端点的入站和出站路由。

正确答案：D

部分：（无）

解释/参考：

问题 2

一家零售公司有一个客户数据中心，位于亚马逊 S3 存储桶中。来自多个国家的员工使用该数据中心来支持公司范围内的分析工作。一个治理团队必须确保公司的数据分析师只能访问与其所在国家相同的客户的资料。

哪种解决方案能以最少的操作努力满足这些要求？

- A. 为每个国家的客户数据创建单独的表格。根据分析师所服务的国家为其提供访问权限。
- B. 在 AWS Lake Formation 中将 S3 存储桶注册为数据湖位置。使用 Lake Formation 的行级安全功能来执行公司的访问策略。
- C. 将数据移至靠近客户所在国家的 AWS 区域。根据每位分析师所服务的国家为其提供访问权限。
- D. 将数据加载到 Amazon Redshift 中。为每个国家创建一个视图。为每个国家分别创建单独的 IAM 角色，以提供对每个国家数据的访问权限。将相应的角色分配给分析师。

正确答案：B

部分：（无）

解释/参考：

问题 3

一家媒体公司希望改进其根据用户行为和偏好向客户推荐媒体内容的系统。为了改进推荐系统，该公司需要将第三方数据集的洞察整合到现有的分析平台中。

该公司希望将整合第三方数据集所需的工作量和时间降至最低。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 使用 API 调用访问并整合来自 AWS 数据交换的第三方数据集。
- B. 使用 API 调用访问并整合来自 AWS DataSync 的第三方数据集。
- C. 使用 Amazon Kinesis 数据流访问并整合来自 AWS 的第三方数据集。

CodeCommit 代码库。

D. 使用 Amazon Kinesis 数据流访问并整合来自 Amazon Elastic Container Registry (Amazon ECR) 的第三方数据集。

正确答案：A

部分：（无）

解释/参考：

问题 4

一家金融公司想要实施数据网格。该数据网格必须支持集中式的数据治理、数据分析和数据访问控制。该公司已决定使用 AWS Glue 来进行数据目录管理以及提取、转换和加载（ETL）操作。

哪种 AWS 服务组合可以实现数据网格？（选择两项。）

- A. 使用 Amazon Aurora 进行数据存储。使用 Amazon Redshift 预配置集群进行数据分析。
- B. 使用亚马逊 S3 进行数据存储。使用亚马逊 Athena 进行数据分析。
- C. 使用 AWS Glue DataBrew 进行集中式数据治理和访问控制。
- D. 使用亚马逊 RDS 进行数据存储。使用亚马逊 EMR 进行数据分析。
- E. 使用 AWS Lake Formation 实现集中式数据治理和访问控制。

正确答案：BE

部分：（无）

解释/参考：

问题 5

一位数据工程师维护着一些自定义的 Python 脚本，这些脚本执行着许多 AWS Lambda 函数所使用的的数据格式化过程。当数据工程师需要修改这些 Python 脚本时，必须手动更新所有的 Lambda 函数。

数据工程师需要一种更少人工干预的方式来更新 Lambda 函数。

哪种解决方案能满足这一要求？

- A. 在执行上下文对象中存储指向自定义 Python 脚本的指针，将其保存在共享的 Amazon S3 存储桶中。
- B. 将自定义的 Python 脚本打包成 Lambda 层。将 Lambda 层应用于 Lambda 函数。
- C. 在共享的 Amazon S3 存储桶中的环境变量里存储指向自定义 Python 脚本的指针。
- D. 为每个 Lambda 函数分配相同的别名。通过指定函数的别名来调用每个 Lambda 函数。

正确答案：B

部分：（无）

解释/参考：

问题 6

一家公司在 AWS Glue 中创建了一个提取、转换和加载（ETL）数据管道。一位数据工程师需要爬取位于 Microsoft SQL Server 中的一张表。该数据工程师需要将爬取的结果进行提取、转换，并加载到 Amazon S3 存储桶中。此外，这位数据工程师还必须对数据管道进行编排。

哪种 AWS 服务或功能能以最具成本效益的方式满足这些要求？

- A. AWS 步骤函数

- B. AWS Glue 工作流
- C. AWS Glue Studio
- D. 亚马逊托管的 Apache Airflow 工作流 (Amazon MWAA)

正确答案：B

部分：（无）

解释/参考：

问题 7

一家金融服务公司将财务数据存储在亚马逊 Redshift 中。一位数据工程师希望对财务数据进行实时查询，以支持一个基于网络的交易应用程序。该数据工程师希望在交易应用程序内部运行这些查询。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 建立与 Amazon Redshift 的 WebSocket 连接。
- B. 使用 Amazon Redshift 数据 API。
- C. 建立到 Amazon Redshift 的 Java 数据库连接 (JDBC)。
- D. 将频繁访问的数据存储在 Amazon S3 中。使用 Amazon S3 Select 来运行查询。

正确答案：B

部分：（无）

解释/参考：

问题 8

一家公司使用亚马逊 Athena 对存储在亚马逊 S3 中的数据进行一次性查询。该公司有多个用例。该公司必须实施权限控制，以在同一个 AWS 账户中的用户、团队和应用程序之间分离查询流程和对查询历史的访问。

哪种解决方案能满足这些要求？

- A. 为每个用例创建一个 S3 存储桶。创建一个 S3 存储桶策略，授予适当的 IAM 用户权限。将 S3 存储桶策略应用于 S3 存储桶。
- B. 为每个用例创建一个 Athena 工作组。为工作组应用标签。创建一个 IAM 策略，该策略使用这些标签为工作组应用适当的权限。
- C. 为每个用例创建一个 IAM 角色。为每个用例的角色分配适当的权限。将该角色与 Athena 相关联。
- D. 创建一个 AWS Glue 数据目录资源策略，为每个用例向适当的 IAM 用户授予权限。将资源策略应用于 Athena 使用的特定表。

正确答案：B

部分：（无）

解释/参考：

问题 9

一位数据工程师需要安排一个工作流，使其每天运行一组 AWS Glue 作业。该数据工程师不要求这些 Glue 作业在特定时间运行或完成。

哪种解决方案能以最经济高效的方式运行 Glue 作业？

- A. 在 Glue 作业属性中选择 FLEX 执行类别。
- B. 在 Glue 作业属性中使用按需实例类型。
- C. 在 Glue 作业属性中选择“STANDARD”执行类别。

D. 在 Glue 作业属性的 GlueVersion 字段中选择最新版本。

正确答案：A

部分：（无）

解释/参考：

问题 10

数据工程师需要创建一个 AWS Lambda 函数，将数据格式从 .csv 转换为 Apache Parquet。只有当用户将 .csv 文件上传到 Amazon S3 存储桶时，该 Lambda 函数才运行。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 创建一个 S3 事件通知，其事件类型为 s3:ObjectCreated:*。使用筛选规则，仅在后缀包含.csv 时生成通知。将 Lambda 函数的亚马逊资源名称（ARN）设置为事件通知的目的地。
- B. 创建一个 S3 事件通知，其事件类型为 s3:ObjectTagging:*，针对已设置标签为 .csv 的对象。将 Lambda 函数的亚马逊资源名称（ARN）设置为该事件通知的目的地。
- C. 创建一个 S3 事件通知，其事件类型为 s3:*。使用筛选规则，仅在文件后缀包含.csv 时生成通知。将 Lambda 函数的亚马逊资源名称（ARN）设置为事件通知的目的地。
- D. 创建一个 S3 事件通知，其事件类型为 s3:ObjectCreated:*。使用筛选规则，仅在后缀包含.csv 时生成通知。将 Amazon 简单通知服务（Amazon SNS）主题设置为事件通知的目的地。将 Lambda 函数订阅到 SNS 主题。

正确答案：A

部分：（无）

解释/参考：

问题 1

一位数据工程师希望亚马逊 Athena 查询能更快完成。该工程师注意到，Athena 查询所使用的所有文件目前都以未压缩的.csv 格式存储。工程师还注意到，用户执行的大多数查询都是通过选择特定列来完成的。

哪种解决方案能最大程度地提升 Athena 查询性能？

- A. 将数据格式从 .csv 更改为 JSON 格式。应用 Snappy 压缩。
- B. 使用 Snappy 压缩算法压缩 .csv 文件。
- C. 将数据格式从 .csv 更改为 Apache Parquet 格式。应用 Snappy 压缩。
- D. 使用 gzip 压缩算法对 .csv 文件进行压缩。

正确答案：C

部分：（无）

解释/参考：

问题 12

一家制造企业从其工厂车间收集传感器数据，以监控并提高运营效率。该公司使用亚马逊 Kinesis 数据流将传感器收集的数据发布到数据流中，然后亚马逊 Kinesis Data Firehose 将数据写入亚马逊 S3 存储桶。

该公司需要在制造工厂的大屏幕上实时展示运营效率的情况。

哪种解决方案能在最低延迟的情况下满足这些要求？

- A. 使用亚马逊托管的 Apache Flink 服务（之前称为亚马逊 Kinesis 数据分析）来处理传感器数据。使用 Apache Flink 的连接将数据写入亚马逊 Timestream 数据库。将 Timestream 数据库作为数据源来创建 Grafana 仪表板。
- B. 将 S3 存储桶配置为在创建任何新对象时向 AWS Lambda 函数发送通知。使用该 Lambda 函数将数据发布到 Amazon Aurora。将 Aurora 用作数据源来创建 Amazon QuickSight 仪表板。
- C. 使用亚马逊托管的 Apache Flink 服务（之前称为亚马逊 Kinesis 数据分析）来处理传感器数据。创建一个新的数据流交付流，将数据直接发布到亚马逊 Timestream 数据库。将 Timestream 数据库作为数据源来创建亚马逊 QuickSight 仪表板。
- D. 使用 AWS Glue 作业从 S3 存储桶实时读取传感器数据。将数据发布到 Amazon Timestream 数据库。使用 Timestream 数据库作为数据源创建 Grafana 仪表板。

正确答案：A

部分：（无）

解释/参考：

问题 13

一家公司将投资组合每日财务业绩记录以.csv 格式存储在 Amazon S3 存储桶中。一名数据工程师使用 AWS Glue 爬虫程序来抓取 S3 中的数据。

数据工程师必须每天将 S3 数据在 AWS Glue 数据目录中设置为可访问状态。

哪种解决方案能满足这些要求？

- A. 创建一个包含 AmazonS3FullAccess 策略的 IAM 角色。将该角色与爬虫关联。将源数据的 S3 存储桶路径指定为爬虫的数据存储。设置每日计划来运行爬虫。将输出目的地配置为现有 S3 存储桶中的新路径。
- B. 创建一个包含 AWSGlueServiceRole 策略的 IAM 角色。将该角色与爬虫程序相关联。指定源数据的 S3 存储桶路径作为爬虫程序的数据存储。创建一个每日计划来运行爬虫程序。为输出指定一个数据库名称。
- C. 创建一个包含 AmazonS3FullAccess 策略的 IAM 角色。将该角色与爬虫程序关联。指定源数据的 S3 存储桶路径作为爬虫程序的数据存储。每天分配数据处理单元（DPU）来运行爬虫程序。为输出指定一个数据库名称。
- D. 创建一个包含 AWSGlueServiceRole 策略的 IAM 角色。将该角色与爬虫关联。将源数据的 S3 存储桶路径指定为爬虫的数据存储。每天分配数据处理单元（DPU）来运行爬虫。将输出目的地配置为现有 S3 存储桶中的新路径。

正确答案：B

部分：（无）

解释/参考：

问题 14

该公司每天结束时将当天的交易数据加载到 Amazon Redshift 表中。该公司希望能够追踪哪些表已加载，哪些表仍需加载。

一位数据工程师希望将 Redshift 表的加载状态存储在 Amazon DynamoDB 表中。该数据工程师创建了一个 AWS Lambda 函数，用于将加载状态的详细信息发布到 DynamoDB。

数据工程师应如何调用 Lambda 函数将加载状态写入 DynamoDB 表？

- A. 使用第二个 Lambda 函数根据 Amazon EventBridge 事件来调用第一个 Lambda 函数。

- B. 使用 Amazon Redshift 数据 API 向 Amazon EventBridge 发布事件。配置 EventBridge 规则以调用 Lambda 函数。
- C. 使用 Amazon Redshift 数据 API 向 Amazon Simple Queue Service (Amazon SQS) 队列发布消息。配置 SQS 队列以调用 Lambda 函数。
- D. 使用第二个 Lambda 函数根据 AWS CloudTrail 事件调用第一个 Lambda 函数。

正确答案：B

部分：（无）

解释/参考：

问题 15

一名数据工程师需要将 5TB 的数据从本地数据中心安全地传输到亚马逊 S3 存储桶。每天大约有 5% 的数据会发生变化。需要定期将数据更新同步到 S3 存储桶。这些数据包含多种格式的文件。数据工程师需要将传输过程自动化，并安排该过程定期运行。

数据工程师应使用哪种 AWS 服务以最高效的操作方式传输数据？

- A. AWS 数据同步服务
- B. AWS Glue
- C. AWS 直连服务
- D. 亚马逊 S3 传输加速

正确答案：A

部分：（无）

解释/参考：

问题 16

一家公司使用本地的 Microsoft SQL Server 数据库来存储财务交易数据。该公司每月末将交易数据从本地数据库迁移到 AWS。该公司注意到，从本地数据库向 Amazon RDS for SQL Server 数据库迁移数据的成本最近有所增加。

该公司需要一个经济高效的解决方案，将数据迁移到 AWS。该方案必须对访问数据库的应用程序造成最小的停机影响。

该公司应使用哪种 AWS 服务来满足这些要求？

- A. 亚马逊网络服务（AWS）Lambda
- B. AWS 数据迁移服务（AWS DMS）
- C. AWS 直连服务
- D. AWS DataSync

正确答案：B

部分：（无）

解释/参考：

问题 17

一位数据工程师正在 AWS 上使用 AWS Glue 提取、转换和加载（ETL）作业构建数据管道。该工程师需要处理来自 Amazon RDS 和 MongoDB 的数据，执行转换操作，并将转换后的数据加载到 Amazon Redshift 中以进行分析。数据更新必须每小时进行一次。

哪种任务组合能在运营开销最小的情况下满足这些要求？（选择两项。）

- A. 配置 AWS Glue 触发器，使其每小时运行一次 ETL 作业。
- B. 使用 AWS Glue DataBrew 清理并准备数据以用于分析。
- C. 使用 AWS Lambda 函数每小时安排并运行 ETL 作业。
- D. 使用 AWS Glue 连接在数据源和 Amazon Redshift 之间建立连接。
- E. 使用 Redshift 数据 API 将转换后的数据加载到 Amazon Redshift 中。

正确答案：AD

部分：（无）

解释/参考：

问题 18

一家公司使用运行在 RA3 节点上的 Amazon Redshift 集群。该公司希望扩展读写容量以满足需求。一位数据工程师需要确定一个能够开启并发扩展的解决方案。

哪种解决方案能满足这一要求？

- A. 在 Redshift Serverless 工作组的工作负载管理（WLM）中启用并发扩展。
- B. 在 Redshift 集群的工作负载管理（WLM）队列级别开启并发扩展功能。
- C. 在创建任何新的 Redshift 集群时，在设置中开启并发扩展功能。
- D. 为 Redshift 集群的每日使用配额启用并发扩展。

正确答案：B

部分：（无）

解释/参考：

问题 19

数据工程师必须安排一系列每天运行的 Amazon Athena 查询。每个查询的运行时间可能超过 15 分钟。

哪种步骤组合能以最经济高效的方式满足这些要求？（选择两项。）

- A. 使用 AWS Lambda 函数和 Athena Boto3 客户端的 start_query_execution API 调用以编程方式调用 Athena 查询。
- B. 创建一个 AWS Step Functions 工作流并添加两个状态。在 Lambda 函数之前添加第一个状态。将第二个状态配置为等待状态，使用 Athena Boto3 的 get_query_execution API 调用定期检查 Athena 查询是否已完成。配置工作流，以便在当前查询运行完毕后调用下一个查询。
- C. 使用 AWS Glue Python 脚本作业和 Athena 的 Boto3 客户端的 start_query_execution API 调用以编程方式调用 Athena 查询。
- D. 使用 AWS Glue Python 脚本运行一个睡眠定时器，该定时器每 5 分钟检查一次，以确定当前的 Athena 查询是否已成功完成运行。配置 Python 脚本，使其在当前查询完成后调用下一个查询。
- E. 使用亚马逊托管的 Apache Airflow 工作流（Amazon MWAA）在 AWS Batch 中编排 Athena 查询。

正确答案：AB

部分：（无）

解释/参考：

问题 20

一家公司正在将本地工作负载迁移到 AWS。该公司希望降低整体运营成本。该公司还希望探索无服务器选项。

该公司目前的工作负载使用了 Apache Pig、Apache Oozie、Apache Spark、Apache HBase 和 Apache Flink。本地工作负载能在数秒内处理数 PB 的数据。在迁移到 AWS 之后，该公司必须保持类似或更优的性能。

哪种提取、转换和加载（ETL）服务能满足这些要求？

- A. AWS Glue
- B. 亚马逊 EMR
- C. 亚马逊网络服务（AWS）Lambda
- D. 亚马逊红移（Amazon Redshift）

正确答案：B

部分：（无）

解释/参考：

问题 21

数据工程师必须使用 AWS 服务将数据集导入到 Amazon S3 数据湖中。数据工程师对数据集进行分析，发现其中包含个人身份信息（PII）。数据工程师必须实施解决方案来分析数据集并模糊处理 PII。

哪种解决方案能以最少的操作努力满足这一要求？

- A. 使用 Amazon Kinesis Data Firehose 传输流来处理数据集。创建一个 AWS Lambda 转换函数来识别个人身份信息（PII）。使用 AWS SDK 对 PII 进行模糊处理。将 S3 数据湖设置为传输流的目标。
- B. 在 AWS Glue Studio 中使用“检测 PII”转换来识别 PII。对 PII 进行模糊处理。使用 AWS Step Functions 状态机来编排数据管道，将数据摄取到 S3 数据湖中。
- C. 在 AWS Glue Studio 中使用“检测 PII”转换来识别 PII。在 AWS Glue 数据质量中创建一条规则来模糊处理 PII。使用 AWS Step Functions 状态机来编排数据管道，将数据摄取到 S3 数据湖中。
- D. 将数据集导入到 Amazon DynamoDB 中。创建一个 AWS Lambda 函数来识别并模糊处理 DynamoDB 表中的个人身份信息（PII），并对数据进行转换。使用同一个 Lambda 函数将数据导入到 S3 数据湖中。

正确答案：B C

部分：（无）

解释/参考：

问题 2

一家公司维护着多个提取、转换和加载（ETL）工作流，这些工作流将公司的运营数据库中的数据摄取到基于 Amazon S3 的数据湖中。ETL 工作流使用 AWS Glue 和 Amazon EMR 来处理数据。

该公司希望改进现有的架构，以实现自动化编排，并将人工干预降至最低。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. AWS Glue 工作流
- B. AWS Step Functions 任务
- C. AWS Lambda 函数
- D. 亚马逊托管的 Apache Airflow 工作流（Amazon MWAA 工作流）

正确答案：B
部分：（无）

解释/参考：

问题 23

该公司目前使用 S3 标准存储类别将所有数据存储在亚马逊 S3 中。

一位数据工程师研究了数据访问模式以识别趋势。在最初的 6 个月里，大多数数据文件每天被访问数次。在 6 个月到 2 年之间，大多数数据文件每月被访问一到两次。2 年之后，数据文件每年仅被访问一到两次。

数据工程师需要使用 S3 生命周期策略来制定新的数据存储规则。新的存储方案必须继续提供高可用性。

哪种解决方案能以最经济的方式满足这些要求？

- A. 6 个月后将对象过渡到 S3 一个区域不频繁访问（S3 One Zone-IA）。2 年后将对象转移至 S3 Glacier 随时检索。
- B. 6 个月后将过渡对象移至 S3 标准不频繁访问（S3 标准-IA），2 年后将对象转移至 S3 Glacier 随时检索。
- C. 对象在 6 个月后转至 S3 标准不频繁访问（S3 标准-IA），2 年后转至 S3 冰川深度归档。
- D. 6 个月后将过渡对象移至 S3 一区不频繁访问（S3 One Zone-IA），2 年后将对象转移至 S3 冰川深度归档。

正确答案：C
部分：（无）

解释/参考：

问题 24

一家公司维护着一个亚马逊 Redshift 预配置集群，该公司利用该集群进行提取、转换和加载（ETL）操作，以支持关键的分析任务。该公司内部的一个销售团队维护着一个 Redshift 集群，该团队利用此集群进行商业智能（BI）任务。

销售团队最近请求访问 ETL Redshift 集群中的数据，以便团队能够执行每周的汇总分析任务。销售团队需要将 ETL 集群中的数据与销售团队的 BI 集群中的数据进行关联。

该公司需要一个解决方案，能够在不影响关键分析任务的情况下，将 ETL 集群的数据与销售团队共享。该解决方案必须最大限度地减少对 ETL 集群计算资源的使用。

哪种解决方案能满足这些要求？

- A. 使用 Redshift 数据共享功能将销售团队的 BI 集群设置为 ETL 集群的数据消费者。
- B. 根据销售团队的要求创建物化视图。授予销售团队对 ETL 集群的直接访问权限。
- C. 根据销售团队的要求创建数据库视图。授予销售团队对 ETL 集群的直接访问权限。
- D. 每周从 ETL 集群卸载一份数据副本到 Amazon S3 存储桶。基于 ETL 集群的内容创建一个 Amazon Redshift Spectrum 表。

正确答案：A 部分：
（无）

解释/参考：

问题 25

一名数据工程师需要将来自多个来源的数据进行整合，以完成一次性的分析任务。这些数据分别存储在亚马逊 DynamoDB、亚马逊 RDS、亚马逊 Redshift 和亚马逊 S3 中。

哪种解决方案能以最经济高效的方式满足这一要求？

- A. 使用亚马逊 EMR 配置的集群从所有数据源读取数据。使用 Apache Spark 进行数据连接并执行分析。
- B. 将数据从 DynamoDB、Amazon RDS 和 Amazon Redshift 复制到 Amazon S3 中。直接在 S3 文件上运行 Amazon Athena 查询。
- C. 使用 Amazon Athena 联合查询将来自所有数据源的数据进行连接。
- D. 使用 Redshift Spectrum 直接从 Redshift 查询来自 DynamoDB、Amazon RDS 和 Amazon S3 的数据。

正确答案：C

部分：（无）

解释/参考：

问题 26

一家公司计划使用配置好的 Amazon EMR 集群来运行 Apache Spark 作业，以执行大数据分析。该公司要求具备高可靠性。大数据团队必须遵循在 Amazon EMR 上运行成本优化且长期运行工作负载的最佳实践。该团队必须找到一种解决方案，以维持公司当前的性能水平。

哪种资源组合能以最经济高效的方式满足这些要求？（选择两项。）

- A. 使用 Hadoop 分布式文件系统（HDFS）作为持久化数据存储。
- B. 使用亚马逊 S3 作为持久性数据存储。
- C. 核心节点和任务节点使用基于 x86 的实例。
- D. 使用 Graviton 实例作为核心节点和任务节点。
- E. 对所有主节点使用按需实例。

正确答案：BD

部分：（无）

解释/参考：

问题 27

一家公司希望实现实时分析能力。该公司希望利用亚马逊 Kinesis 数据流和亚马逊 Redshift 以每秒数吉字节的速度摄取和处理流数据。该公司希望通过使用现有的商业智能（BI）和分析工具来获取近乎实时的洞察。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 使用 Kinesis Data Streams 将数据暂存到 Amazon S3 中。使用 COPY 命令直接将数据从 Amazon S3 加载到 Amazon Redshift 中，使数据能够立即用于实时分析。
- B. 使用 SQL 查询从 Kinesis 数据流访问数据。直接在流之上创建物化视图。定期刷新物化视图以查询最新的流数据。
- C. 在 Amazon Redshift 中创建一个外部模式，将来自 Kinesis 数据流的数据映射到 Amazon Redshift 对象。创建一个物化视图以从流中读取数据。将物化视图设置为自动刷新。
- D. 将 Kinesis 数据流连接到 Amazon Kinesis Data Firehose。使用 Kinesis Data Firehose 将数据暂存到 Amazon S3 中。使用 COPY 命令将数据从 Amazon S3 加载到 Amazon Redshift 中的表。

正确答案：C

部分：（无）

解释/参考：

问题 28

一家公司使用亚马逊 QuickSight 仪表板来监控其一款应用程序的使用情况。该公司使用 AWS Glue 作业来处理仪表板所需的数据。该公司将数据存储在一个亚马逊 S3 存储桶中。该公司每天都会添加新的数据。

一位数据工程师发现仪表板查询的速度随着时间的推移变得越来越慢。该数据工程师确定查询速度变慢的根本原因是长时间运行的 AWS Glue 作业。

数据工程师应采取哪些措施来提高 AWS Glue 作业的性能？（选择两项。）

- A. 将 S3 存储桶中的数据进行分区。按年、月、日对数据进行组织。
- B. 通过升级工作节点类型来增大 AWS Glue 实例的大小。
- C. 将 AWS Glue 架构转换为 DynamicFrame 架构类。
- D. 调整 AWS Glue 作业的调度频率，使每个作业每天运行的次数减半。
- E. 修改授予对 AWS Glue 访问权限的 IAM 角色，使其能够访问所有 S3 功能。

正确答案：AB

部分：（无）

解释/参考：

问题 29

数据工程师需要使用 AWS Step Functions 来设计一个编排工作流。该工作流必须并行处理大量数据文件，并对每个文件应用特定的转换。

数据工程师应使用哪个 Step Functions 状态来满足这些要求？

- A. 平行国家
- B. 选择状态
- C. 地图状态
- D. 等待状态

正确答案：C

部分：（无）

解释/参考：

问题 30

一家公司正在将一个旧应用程序迁移到基于亚马逊 S3 的数据湖。一位数据工程师审查了与该旧应用程序相关联的数据。这位工程师发现旧数据中包含一些重复的信息。

数据工程师必须从遗留应用程序的数据中识别并删除重复的信息。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 用 Python 编写一个自定义的提取、转换和加载（ETL）作业。通过导入 Pandas 库并使用 `DataFrame.drop_duplicates()` 函数来执行数据去重操作。
- B. 编写一个 AWS Glue 提取、转换和加载（ETL）作业。使用 FindMatches 机器学习（ML）转换来转换数据以执行数据去重。
- C. 用 Python 编写一个自定义的提取、转换和加载（ETL）作业。导入 Python 的 dedupe 库。使用

使用去重库来执行数据去重。

D. 编写一个 AWS Glue 提取、转换和加载（ETL）作业。导入 Python 的 dedupe 库。使用 dedupe 库执行数据去重操作。

正确答案：B

部分：（无）

解释/参考：

问题 31

一家公司正在构建一个分析解决方案。该方案使用亚马逊 S3 作为数据湖存储，并使用亚马逊 Redshift 作为数据仓库。该公司希望使用亚马逊 Redshift Spectrum 来查询存储在亚马逊 S3 中的数据。

哪些操作能提供最快的查询？（选择两项。）

- A. 使用 gzip 压缩将单个文件压缩至 1GB 至 5GB 之间。
- B. 使用列式存储文件格式。
- C. 根据最常见的查询谓词对数据进行分区。
- D. 将数据拆分成小于 10 千字节的文件。
- E. 使用不可分割的文件格式。

正确答案：BC

部分：（无）

解释/参考：

问题 32

一家公司使用亚马逊 RDS 来存储交易数据。该公司在一个私有子网中运行一个 RDS 数据库实例。一名开发人员编写了一个具有默认设置的 AWS Lambda 函数，用于在该数据库实例中插入、更新或删除数据。

开发人员需要赋予 Lambda 函数通过私有网络连接到数据库实例的能力，而无需使用公共互联网。

哪种步骤组合能在操作开销最小的情况下满足此要求？（选择两项。）

- A. 打开数据库实例的公共访问设置。
- B. 更新数据库实例的安全组，仅允许在数据库端口上由 Lambda 函数发起的调用。
- C. 将 Lambda 函数配置为在与数据库实例相同的子网中运行。
- D. 将相同的安全组附加到 Lambda 函数和数据库实例上。包含一条自引用规则，允许通过数据库端口进行访问。
- E. 更新私有子网的网络访问控制列表（ACL），添加一条允许通过数据库端口访问的自引用规则。

正确答案：CD

部分：（无）

解释/参考：

问题 3

一家公司有一个使用 ReactJS 构建的前端网站，该网站通过亚马逊 API 网关调用 REST API。这些 API 实现了网站的功能。一名数据工程师需要编写一个 Python 脚本，该脚本偶尔会通过 API 网关被调用。该代码必须将结果返回给 API 网关。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 在 Amazon Elastic Container Service (Amazon ECS) 集群上部署自定义的 Python 脚本。
- B. 创建一个具有预配置并发设置的 AWS Lambda Python 函数。
- C. 部署一个自定义的 Python 脚本，该脚本能够与亚马逊弹性 Kubernetes 服务 (Amazon EKS) 上的 API 网关集成。
- D. 创建一个 AWS Lambda 函数。通过安排一个 Amazon EventBridge 规则，使用模拟事件每 5 分钟调用一次该 Lambda 函数，确保该函数处于预热状态。

正确答案：B

部分：（无）

解释/参考：

问题 34

一家公司有一个用于运行公司工作负载的生产 AWS 账户。该公司的安全团队创建了一个安全 AWS 账户，用于存储和分析来自生产 AWS 账户的安全日志。生产 AWS 账户中的安全日志存储在 Amazon CloudWatch Logs 中。

该公司需要使用亚马逊 Kinesis 数据流将安全日志传递到安全的 AWS 账户。

哪种解决方案能满足这些要求？

- A. 在生产 AWS 账户中创建一个目标数据流。在安全 AWS 账户中，创建一个具有跨账户权限以访问生产 AWS 账户中 Kinesis 数据流的 IAM 角色。
- B. 在安全的 AWS 账户中创建一个目标数据流。创建一个 IAM 角色和信任策略，授予 CloudWatch Logs 向该流中写入数据的权限。在安全的 AWS 账户中创建一个订阅过滤器。
- C. 在生产 AWS 账户中创建一个目标数据流。在生产 AWS 账户中，创建一个具有跨账户权限以访问安全 AWS 账户中 Kinesis 数据流的 IAM 角色。
- D. 在安全的 AWS 账户中创建一个目标数据流。创建一个 IAM 角色和信任策略，授予 CloudWatch Logs 向该流写入数据的权限。在生产 AWS 账户中创建一个订阅过滤器。

正确答案：D

部分：（无）

解释/参考：

问题 35

一家公司使用亚马逊 S3 在事务型数据湖中存储半结构化数据。其中一些数据文件很小，但也有其他数据文件达数十太字节。

数据工程师必须执行变更数据捕获（CDC）操作，以从数据源中识别出已更改的数据。数据源每天都会发送一个完整的快照作为 JSON 文件，并将已更改的数据摄取到数据湖中。

哪种解决方案能以最经济高效的方式捕获更改的数据？

- A. 创建一个 AWS Lambda 函数来识别先前数据与当前数据之间的变化。配置该 Lambda 函数将变化的数据摄取到数据湖中。
- B. 将数据导入到 Amazon RDS for MySQL 中。使用 AWS 数据迁移服务（AWS DMS）将更改后的数据写入数据湖。
- C. 使用开源数据湖格式将数据源与 S3 数据湖合并，以插入新数据并更新现有数据。

D. 将数据导入运行 Aurora Serverless 的 Amazon Aurora MySQL 数据库实例。使用 AWS 数据迁移服务 (AWS DMS) 将更改的数据写入数据湖。

正确答案：C

部分：(无)

解释/参考：

问题 36

一位数据工程师在 Amazon S3 存储桶中的数据上运行 Amazon Athena 查询。这些 Athena 查询使用 AWS Glue 数据目录作为元数据表。

数据工程师注意到 Athena 查询计划出现了性能瓶颈。数据工程师确定性能瓶颈的原因是 S3 存储桶中的分区数量过多。数据工程师必须解决性能瓶颈问题并减少 Athena 查询规划时间。

哪些解决方案能满足这些要求？（选择两项。）

- A. 创建一个 AWS Glue 分区索引。启用分区筛选。
- B. 根据用户查询的 WHERE 子句中数据共有的某一列对数据进行分组。
- C. 根据 S3 存储桶前缀使用 Athena 分区投影。
- D. 将 S3 存储桶中的数据转换为 Apache Parquet 格式。
- E. 使用 Amazon EMR 的 S3DistCP 实用程序将 S3 存储桶中的较小对象合并为较大的对象。

正确答案：AC

部分：(无)

解释/参考：

问题 37

数据工程师必须将实时流数据导入 AWS。该数据工程师希望通过基于时间的聚合在长达 30 分钟的时间窗口内对传入的流数据执行实时分析。数据工程师需要一个高度容错的解决方案。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 使用包含业务逻辑和分析逻辑的 AWS Lambda 函数，对 Amazon Kinesis 数据流中数据进行基于时间的聚合操作，聚合窗口最长为 30 分钟。
- B. 使用亚马逊托管的 Apache Flink 服务（之前称为亚马逊 Kinesis 数据分析）通过多种类型的聚合来分析可能偶尔包含重复项的数据。
- C. 使用一个包含业务逻辑和分析逻辑的 AWS Lambda 函数，根据事件时间戳对最多 30 分钟的滚动窗口执行聚合操作。
- D. 使用亚马逊托管的 Apache Flink 服务（之前称为亚马逊 Kinesis 数据分析）对数据进行分析，通过多种类型的聚合在长达 30 分钟的时间窗口内执行基于时间的分析。

正确答案：D

部分：(无)

解释/参考：

问题 38

一家公司计划将其亚马逊弹性块存储（Amazon EBS）通用型 SSD 存储从 gp2 升级到 gp3。该公司希望在将数据迁移到升级后的存储期间，避免其亚马逊 EC2 实例出现任何中断，从而导致数据丢失。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 对 gp2 卷创建快照。从这些快照创建新的 gp3 卷。将新的 gp3 卷挂载到 EC2 实例上。
- B. 创建新的 gp3 卷。逐步将数据转移到新的 gp3 卷。转移完成后，将新的 gp3 卷挂载到 EC2 实例上以替换 gp2 卷。
- C. 将现有 gp2 类型的卷的卷类型更改为 gp3。输入新的卷大小、每秒输入/输出操作数（IOPS）和吞吐量值。
- D. 使用 AWS DataSync 创建新的 gp3 卷。将数据从原来的 gp2 卷传输到新的 gp3 卷。

正确答案：C

部分：（无）

解释/参考：

问题 39

一家公司正在将其数据库服务器从运行 Microsoft SQL Server 的 Amazon EC2 实例迁移到 Amazon RDS for Microsoft SQL Server 数据库实例。在迁移完成之前，该公司的分析团队每天必须导出大量数据元素。这些数据元素是多个表进行 SQL 连接的结果。数据必须采用 Apache Parquet 格式。分析团队必须将数据存储在 Amazon S3 中。

哪种解决方案能以最高效的操作方式满足这些要求？

- A. 在基于 EC2 实例的 SQL Server 数据库中创建一个包含所需数据元素的视图。创建一个 AWS Glue 作业，直接从该视图选择数据，并以 Parquet 格式将数据传输到 S3 存储桶。安排 AWS Glue 作业每天运行一次。
- B. 安排 SQL Server 代理每天运行一个 SQL 查询，从基于 EC2 实例的 SQL Server 数据库中选择所需的数据元素。配置该查询，使其将输出的 .csv 对象定向到 S3 存储桶。创建一个 S3 事件，以调用 AWS Lambda 函数将输出格式从 .csv 转换为 Parquet。
- C. 使用 SQL 查询在基于 EC2 实例的 SQL Server 数据库中创建一个包含所需数据元素的视图。创建并运行一个 AWS Glue 爬虫来读取该视图。创建一个 AWS Glue 作业，以检索数据并将数据以 Parquet 格式传输到 S3 存储桶。安排该 AWS Glue 作业每天运行一次。
- D. 创建一个 AWS Lambda 函数，通过使用 Java 数据库连接（JDBC）查询基于 EC2 实例的数据库。配置该 Lambda 函数以获取所需数据，将数据转换为 Parquet 格式，并将数据传输到 S3 存储桶。使用 Amazon EventBridge 每天安排 Lambda 函数运行。

正确答案：C

A

部分：（无）

解释/参考：

问题 40

一个数据工程团队正在使用亚马逊 Redshift 数据仓库进行运营报告。该团队希望防止因长时间运行的查询而导致的性能问题。一位数据工程师必须在亚马逊 Redshift 中选择一个系统表来记录当查询优化器识别出可能表明性能问题的条件时出现的异常情况。

数据工程师应该使用哪些表视图才能满足这一要求？

- A. STL 使用控制
- B. STL 警报事件日志
- C. STL 查询指标
- D. 标准模板库计划信息

正确答案：B

部分：（无）

解释/参考：

问题 41

数据工程师必须将一个格式为.csv 的结构化数据源导入到亚马逊 S3 数据湖中。这些.csv 文件包含 15 列。数据分析师需要对数据集中的 1 到 2 列运行亚马逊 Athena 查询。数据分析师很少查询整个文件。

哪种解决方案能以最经济高效的方式满足这些要求？

- A. 使用 AWS Glue PySpark 作业将源数据以 .csv 格式摄取到数据湖中。
- B. 创建一个 AWS Glue 提取、转换和加载（ETL）作业，从结构化的 .csv 数据源读取数据。配置该作业，将数据以 JSON 格式加载到数据湖中。
- C. 使用 AWS Glue PySpark 作业将源数据以 Apache Avro 格式摄取到数据湖中。
- D. 创建一个 AWS Glue 提取、转换和加载（ETL）作业，从结构化的 .csv 数据源读取数据。配置该作业将数据以 Apache Parquet 格式写入数据湖。

正确答案：D

部分：（无）

解释/参考：

问题 42

一家公司在不同的 AWS 区域设有五个办事处。每个办事处都有自己的人力资源（HR）部门，使用独特的 IAM 角色。该公司将员工记录存储在基于 Amazon S3 存储的数据湖中。

数据工程团队需要限制对记录的访问权限。每个人力资源部门只能访问其所在区域员工的记录。

数据工程团队应采取哪两种步骤的组合来以最低的操作开销满足此要求？（选择两项。）

- A. 对每个区域使用数据筛选器来将 S3 路径注册为数据位置。
- B. 将 S3 路径注册为 AWS Lake Formation 位置。
- C. 修改 IAM 人力资源部门的职责是为每个部门的区域添加数据筛选器。
- D. 在 AWS Lake Formation 中启用细粒度访问控制。为每个区域添加数据筛选器。
- E. 为每个区域创建一个单独的 S3 存储桶。配置一个 IAM 策略以允许 S3 访问。根据区域限制访问权限。

正确答案：BD

部分：（无）

解释/参考：

问题 43

一家公司使用 AWS Step Functions 来编排数据管道。该管道由从数据源摄取数据并将其存储在 Amazon S3 存储桶中的 Amazon EMR 作业组成。该管道还包括将数据加载到 Amazon Redshift 中的 EMR 作业。

该公司的云基础设施团队手动构建了一个 Step Functions 状态机。云基础设施团队在 VPC 中启动了一个 EMR 集群以支持 EMR 作业。然而，部署的状态机无法运行 EMR 作业。

公司应采取哪些步骤组合来确定 Step Functions 状态的原因？

机器无法运行 EMR 任务？（选择两项。）

- A. 使用 AWS CloudFormation 自动化 Step Functions 状态机的部署。创建一个步骤，在 EMR 作业失败时暂停状态机。配置该步骤等待人工用户通过电子邮件发送批准。在电子邮件中包含 EMR 任务的详细信息，以便进一步分析。
- B. 确认 Step Functions 状态机代码具有创建和运行 EMR 作业所需的全部 IAM 权限。确认 Step Functions 状态机代码还包括访问 EMR 作业所使用的 Amazon S3 存储桶的 IAM 权限。使用 S3 访问分析器检查 S3 访问属性。
- C. 检查新创建的 EMR 集群在 Amazon CloudWatch 中的条目。将 AWS Step Functions 状态机代码修改为使用 Amazon EMR on EKS。更改 Step Functions 状态机代码的 IAM 访问策略和安全组配置，以反映包含 Amazon Elastic Kubernetes Service（Amazon EKS）。
- D. 查询 VPC 的流量日志。确定源自 EMR 集群的流量能否成功到达数据提供方。确定可能附加到 Amazon EMR 集群的任何安全组是否允许连接到数据源服务器的指定端口。
- E. 检查公司为 EMR 作业配置的重试场景。增加每个 EMR 任务之间的间隔秒数。验证每个回退状态是否对每个决策状态都有适当的捕获。配置一个 Amazon 简单通知服务（Amazon SNS）主题来存储错误消息。

正确答案：BD

部分：（无）

解释/参考：

问题 4

一家公司正在开发一款运行于亚马逊 EC2 实例上的应用程序。目前，该应用程序生成的数据是临时性的。然而，该公司需要将数据持久化保存，即使 EC2 实例被终止也不例外。

数据工程师必须从亚马逊机器映像（AMI）启动新的 EC2 实例，并对这些实例进行配置以保存数据。

哪种解决方案能满足这一要求？

- A. 使用由包含应用程序数据的 EC2 实例存储卷支持的 AMI 启动新的 EC2 实例。对 EC2 实例应用默认设置。
- B. 使用由包含应用程序数据的根 Amazon Elastic Block Store（Amazon EBS）卷支持的 AMI 启动新的 EC2 实例。对 EC2 实例应用默认设置。
- C. 使用由 EC2 实例存储卷支持的 AMI 启动新的 EC2 实例。将 Amazon 弹性块存储（Amazon EBS）卷附加到实例以存放应用程序数据。对 EC2 实例应用默认设置。
- D. 使用由 Amazon Elastic Block Store（Amazon EBS）卷支持的 AMI 启动新的 EC2 实例。附加一个额外的 EC2 实例存储卷来存放应用程序数据。对 EC2 实例应用默认设置。

正确答案：C

部分：（无）

解释/参考：

问题 45

一家公司使用亚马逊 Athena 运行 SQL 查询来执行提取、转换和加载（ETL）任务，通过使用创建表作为选择（CTAS）。该公司必须改用 Apache Spark 而不是 SQL 来生成分析结果。

哪种解决方案能让公司具备使用 Spark 访问 Athena 的能力？

- A. 雅典娜查询设置
- B. 雅典娜工作组
- C. 雅典娜数据源
- D. 雅典娜查询编辑器

正确答案：B

部分：（无）

解释/参考：

问题 46

一家公司需要对其用于数据湖的亚马逊 S3 存储进行分区。分区将使用 S3 对象键的路径，格式如下：
s3://bucket/prefix/year=2023/month=01/day=01。

当公司向存储桶添加新的分区时，数据工程师必须确保 AWS Glue 数据目录与 S3 存储保持同步。

哪种解决方案能在延迟最小的情况下满足这些要求？

- A. 安排 AWS Glue 爬虫程序每天早上运行。
- B. 每天手动运行两次 AWS Glue 的 CreatePartition API。
- C. 使用将数据写入 Amazon S3 的代码来调用 Boto3 AWS Glue 的 create_partition API 调用。
- D. 从 AWS Glue 控制台运行 MSCK REPAIR TABLE 命令。

正确答案：C

部分：（无）

解释/参考：

问题 47

一家媒体公司使用软件即服务（SaaS）应用程序通过第三方工具收集数据。该公司需要将数据存储在 Amazon S3 存储桶中。该公司将使用 Amazon Redshift 基于这些数据进行分析。

哪种 AWS 服务或功能能够以最低的操作开销满足这些要求？

- A. 亚马逊托管的 Apache Kafka 流处理服务（Amazon MSK）
- B. 亚马逊 AppFlow
- C. AWS Glue 数据目录
- D. 亚马逊 Kinesis

正确答案：B

部分：（无）

解释/参考：

问题 48

一位数据工程师正在使用亚马逊 Athena 分析存储在亚马逊 S3 中的销售数据。该工程师编写了一个查询，从名为 sales_data 的表中检索 2023 年几种产品的销售金额。然而，该查询并未返回 sales_data 表中所有产品的结果。数据工程师需要对查询进行故障排查以解决此问题。

数据工程师最初的查询如下：

从销售数据中选择产品名称以及销售金额的总和。

WHERE 年份 = 2023

按产品名称分组

数据工程师应如何修改 Athena 查询以满足这些要求？

- A. 将聚合函数中的 sum (sales_amount) 替换为 count (*) 。
- B. 将 WHERE year = 2023 更改为 WHERE extract(year FROM sales_data) = 2023 。
- C. 在 GROUP BY 子句之后添加 HAVING sum(sales_amount) > 0 。
- D. 删除 GROUP BY 子句。

正确答案：B

部分：（无）

解释/参考：

问题 49

一位数据工程师有一项一次性任务，需要从亚马逊 S3 存储桶中以 Apache Parquet 格式存储的对象中读取数据。该数据工程师只需查询数据中的一个列。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 配置一个 AWS Lambda 函数，从 S3 存储桶加载数据到 pandas 数据框中。在该数据框上编写一个 SQL SELECT 语句来查询所需的列。
- B. 使用 S3 Select 编写一条 SQL SELECT 语句，从 S3 对象中检索所需的列。
- C. 准备一个 AWS Glue DataBrew 项目，以使用 S3 对象并查询所需的列。
- D. 在 S3 对象上运行 AWS Glue 爬虫程序。使用 Amazon Athena 中的 SQL SELECT 语句查询所需的列。

正确答案：B

部分：（无）

解释/参考：

问题 50

一家公司使用亚马逊 Redshift 作为其数据仓库。该公司必须为亚马逊 Redshift 的物化视图实现自动刷新计划。

哪种解决方案能以最少的努力满足这一要求？

- A. 使用 Apache Airflow 刷新物化视图。
- B. 在 Amazon Redshift 中使用 AWS Lambda 用户自定义函数（UDF）来刷新物化视图。
- C. 使用 Amazon Redshift 中的查询编辑器 v2 来刷新物化视图。
- D. 使用 AWS Glue 工作流刷新物化视图。

正确答案：C

部分：（无）

解释/参考：

问题 51

数据工程师必须编排一个由一个 AWS Lambda 函数和一个 AWS Glue 作业组成的数据管道。该解决方案必须与 AWS 服务集成。

哪种解决方案能以最低的管理开销满足这些要求？

- A. 使用包含状态机的 AWS Step Functions 工作流。配置状态机以运行 Lambda 函数，然后运行 AWS Glue 作业。
- B. 使用部署在 Amazon EC2 实例上的 Apache Airflow 工作流。定义一个有向无环图（DAG），其中第一个任务是调用 Lambda 函数，第二个任务是调用 AWS Glue 作业。
- C. 使用 AWS Glue 工作流来运行 Lambda 函数，然后再运行 AWS Glue 作业。
- D. 使用部署在亚马逊弹性 Kubernetes 服务（Amazon EKS）上的 Apache Airflow 工作流。定义一个有向无环图（DAG），其中第一个任务是调用 Lambda 函数，第二个任务是调用 AWS Glue 作业。

正确答案：A

部分：（无）

解释/参考：

问题 52

一家公司需要为在 AWS 云中运行的数据源建立数据目录和元数据管理。该公司将使用数据目录来维护一组数据存储中所有对象的元数据。这些数据存储包括结构化数据源，如 Amazon RDS 和 Amazon Redshift，还包括半结构化数据源，例如存储在 Amazon S3 中的 JSON 文件和.xml 文件。

该公司需要一个能定期更新数据目录的解决方案。该方案还必须能够检测源元数据的变化。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 使用 Amazon Aurora 作为数据目录。创建能够连接到数据目录的 AWS Lambda 函数。配置 Lambda 函数从多个来源收集元数据信息并更新 Aurora 数据目录。安排 Lambda 函数定期运行。
- B. 使用 AWS Glue 数据目录作为中央元数据存储库。使用 AWS Glue 爬虫程序连接到多个数据存储，并使用元数据更改更新数据目录。定期安排爬虫程序运行以更新元数据目录。
- C. 使用 Amazon DynamoDB 作为数据目录。创建 AWS Lambda 函数，使其能够连接到数据目录。配置 Lambda 函数从多个来源收集元数据信息，并更新 DynamoDB 数据目录。安排 Lambda 函数定期运行。
- D. 使用 AWS Glue 数据目录作为中央元数据存储库。提取 Amazon RDS 和 Amazon Redshift 数据源的架构，并构建数据目录。使用 AWS Glue 爬虫程序来推断存储在 Amazon S3 中的数据架构，并自动更新数据目录。

正确答案：B

部分：（无）

解释/参考：

问题 53

一家公司将应用程序的数据存储在按需配置容量模式运行的 Amazon DynamoDB 表中。该应用程序的工作负载在固定的时间表上具有可预测的吞吐量负载。每周一清晨，活动量会立即增加。在周末，该应用程序的使用量非常低。

该公司必须确保应用程序在使用高峰期能保持稳定运行。

哪种解决方案能以最经济的方式满足这些要求？

- A. 在高峰负载时段将配置容量增加到当前存在的最大容量。
- B. 将该表拆分为两张表。每张表配置原表配置容量的一半。

表格。将查询均匀地分配到两个表中。

- C. 使用 AWS 应用程序自动扩展功能，在高峰使用时段安排更高的预配置容量，在非高峰时段安排较低的容量。
- D. 将容量模式从预配置更改为按需。根据表的负载配置表以实现自动扩展和收缩。

正确答案：C

部分：（无）

解释/参考：

问题 54

一家公司计划将本地的 Apache Hadoop 集群迁移到 Amazon EMR。该公司还需要将数据目录迁移到持久性存储解决方案中。

该公司目前将数据目录存储在本地 Hadoop 集群上的 Apache Hive 元数据存储中。该公司需要一种无服务器解决方案来迁移数据目录。

哪种解决方案能以最经济高效的方式满足这些要求？

- A. 使用 AWS 数据迁移服务（AWS DMS）将 Hive 元数据存储迁移到 Amazon S3。配置 AWS Glue 数据目录以扫描 Amazon S3 从而生成数据目录。
- B. 在 Amazon EMR 中配置 Hive 元数据存储。将现有的本地 Hive 元数据存储迁移到 Amazon EMR 中。使用 AWS Glue 数据目录来存储公司的数据目录，作为外部数据目录。
- C. 在 Amazon EMR 中配置外部 Hive 元数据存储。将现有的本地 Hive 元数据存储迁移到 Amazon EMR 中。使用 Amazon Aurora MySQL 来存储公司的数据目录。
- D. 在 Amazon EMR 中配置一个新的 Hive 元数据存储。将现有的本地 Hive 元数据存储迁移到 Amazon EMR 中。使用新的元数据存储作为公司的数据目录。

正确答案：B

部分：（无）

解释/参考：

问题 5

一家公司使用亚马逊 Redshift 预留集群作为其数据库。该 Redshift 集群有五个预留的 ra3.4xlarge 节点，并使用键分布。

一位数据工程师注意到其中一个节点的 CPU 负载经常超过 90%。在该节点上运行的 SQL 查询会被排队等候。而在日常操作中，其他四个节点的 CPU 负载通常都在 15% 以下。

数据工程师希望保持当前的计算节点数量不变。数据工程师还希望在所有五个计算节点之间更均匀地分配负载。

哪种解决方案能满足这些要求？

- A. 将排序键更改为在 SQL SELECT 语句的 WHERE 子句中使用最频繁的数据列。
- B. 将分布键更改为具有最大维度的表列。
- C. 将预留节点从 ra3.4xlarge 升级到 ra3.16xlarge。
- D. 将主键更改为在 SQL SELECT 语句的 WHERE 子句中使用最频繁的数据列。

正确答案：B 部分：

（无）

解释/参考：

问题 56

一家安全公司将物联网数据以 JSON 格式存储在 Amazon S3 存储桶中。当公司升级物联网设备时，数据结构可能会发生变化。该公司希望创建一个包含物联网数据的数据目录。公司的分析部门将使用该数据目录对数据进行索引。

哪种解决方案能以最经济高效的方式满足这些要求？

- A. 创建一个 AWS Glue 数据目录。配置一个 AWS Glue 架构注册表。创建一个新的 AWS Glue 工作负载，以协调将分析部门将使用的数据摄取到 Amazon Redshift Serverless 中。
- B. 创建一个亚马逊 Redshift 预配置集群。为分析部门创建一个亚马逊 Redshift Spectrum 数据库，以便其探索存储在亚马逊 S3 中的数据。创建 Redshift 存储过程以将数据加载到亚马逊 Redshift 中。
- C. 创建一个 Amazon Athena 工作组。通过 Athena 使用 Apache Spark 探索 Amazon S3 中的数据。将 Athena 工作组模式和表提供给分析部门。
- D. 创建一个 AWS Glue 数据目录。配置 AWS Glue 架构注册表。使用 Amazon Redshift 数据 API 创建 AWS Lambda 用户定义函数（UDF）。创建一个 AWS Step Functions 作业，以协调将分析部门将使用的数据摄取到 Amazon Redshift Serverless 中。

正确答案：A

部分：（无）

解释/参考：

问题 57

一家公司将交易详情存储在 Amazon S3 存储桶中。该公司希望将对 S3 存储桶的所有写入操作记录到位于同一 AWS 区域的另一个 S3 存储桶中。

哪种解决方案能以最少的操作努力满足这一要求？

- A. 为交易 S3 存储桶上的所有活动配置 S3 事件通知规则，以调用 AWS Lambda 函数。编写 Lambda 函数将事件写入 Amazon Kinesis Data Firehose。配置 Kinesis Data Firehose 将事件写入日志 S3 存储桶。
- B. 在 AWS CloudTrail 中创建管理事件跟踪。配置该跟踪以接收来自交易 S3 存储桶的数据。指定空前缀和写入事件。将日志 S3 存储桶指定为目标存储桶。
- C. 为交易 S3 存储桶上的所有活动配置 S3 事件通知规则，以调用 AWS Lambda 函数。编写 Lambda 函数，将事件写入日志 S3 存储桶。
- D. 在 AWS CloudTrail 中创建数据事件跟踪。配置该跟踪以接收来自交易 S3 存储桶的数据。指定空前缀和写入事件。将日志 S3 存储桶指定为目标存储桶。

正确答案：D

部分：（无）

解释/参考：

问题 58

数据工程师需要维护一个中央元数据存储库，用户通过 Amazon EMR 和 Amazon Athena 查询来访问该存储库。该存储库需要提供许多表的架构和属性。部分元数据存储于 Apache Hive 中。数据工程师需要将 Hive 中的元数据导入到中央元数据存储库中。

哪种解决方案能以最少的开发工作量满足这些要求？

- A. 使用 Amazon EMR 和 Apache Ranger。
- B. 在 EMR 集群上使用 Hive 元数据存储。
- C. 使用 AWS Glue 数据目录。
- D. 在 Amazon RDS for MySQL 数据库实例上使用元数据存储。

正确答案：C

部分：（无）

解释/参考：

问题 59

一家公司需要在 AWS 上构建一个数据湖。该公司必须为特定团队提供行级数据访问和列级数据访问。这些团队将通过使用 Amazon Athena、Amazon Redshift Spectrum 和来自 Amazon EMR 的 Apache Hive 来访问数据。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 使用 Amazon S3 作为数据湖的存储。使用 S3 访问策略按行和列限制数据访问。通过 Amazon S3 提供数据访问。
- B. 使用 Amazon S3 作为数据湖存储。通过 Amazon EMR 使用 Apache Ranger 按行和列限制数据访问。使用 Apache Pig 提供数据访问。
- C. 使用 Amazon Redshift 作为数据湖存储。利用 Redshift 安全策略按行和列限制数据访问。通过使用 Apache Spark 和 Amazon Athena 联合查询提供数据访问。
- D. 使用 Amazon S3 作为数据湖存储。使用 AWS Lake Formation 按行和列限制数据访问权限。通过 AWS Lake Formation 提供数据访问。

正确答案：D

部分：（无）

解释/参考：

问题 60

一家航空公司正在收集有关航班活动的指标以进行分析。该公司正在进行概念验证（POC）测试，以展示分析如何提供公司可用来提高航班准点率的见解。

该概念验证测试使用亚马逊 S3 中包含以 .csv 格式存储的指标的对象。该概念验证测试使用亚马逊 Athena 来查询数据。数据在 S3 存储桶中按日期分区。

随着数据量的增加，该公司希望优化存储方案以提高查询性能。

哪种解决方案的组合能满足这些要求？（选择两项。）

- A. 在 Amazon S3 中的键开头添加一个随机字符串，以在各个分区之间实现更高的吞吐量。
- B. 使用与使用 Athena 查询数据的账户相同的账户中的 S3 存储桶。
- C. 使用与公司运行 Athena 查询所在的 AWS 区域相同的 S3 存储桶。
- D. 通过仅获取查询所需的文档键，将.csv 数据预处理为 JSON 格式。
- E. 通过仅获取用于谓词的数据块，将.csv 数据预处理为 Apache Parquet 格式。

正确答案：CE

部分：（无）

解释/参考：

问题 61

一家公司使用亚马逊 RDS 的 MySQL 版本作为关键应用程序的数据库。该数据库的工作负载主要是写入操作，读取操作较少。

一位数据工程师注意到数据库实例的 CPU 利用率非常高。高 CPU 利用率正在拖慢应用程序的运行速度。这位数据工程师必须降低数据库实例的 CPU 利用率。

数据工程师应采取哪些行动来满足此要求？（选择两项。）

- A. 使用 Amazon RDS 的性能洞察功能来识别 CPU 利用率高的查询。优化有问题的查询。
- B. 修改数据库模式以包含额外的表和索引。
- C. 每周重启一次 RDS 数据库实例。
- D. 升级到更大的实例规格。
- E. 实现缓存以降低数据库查询负载。

正确答案：AD

部分：（无）

解释/参考：

问题 62

一家公司已使用名为“Orders”的 Amazon Redshift 表 6 个月。该公司每周对该表进行更新和删除操作。该表在包含 AWS 区域的列上具有交错排序键。

该公司希望回收磁盘空间，以免存储空间耗尽。该公司还希望分析排序键列。

哪个 Amazon Redshift 命令能满足这些要求？

- A. 真空完整订单
- B. 仅执行真空删除的订单
- C. 真空重索引订单
- D. 仅真空分拆订单

正确答案：C 部分：

（无）

解释/参考：

问题 63

一家制造公司想要从传感器收集数据。一位数据工程师需要实现一个解决方案，以近乎实时的方式获取传感器数据。

该解决方案必须将数据存储到持久化数据存储中。该解决方案必须以嵌套的 JSON 格式存储数据。该公司必须能够以小于 10 毫秒的延迟从数据存储中进行查询。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 使用自托管的 Apache Kafka 集群来捕获传感器数据。将数据存储到 Amazon S3 中以供查询。
- B. 使用 AWS Lambda 处理传感器数据。将数据存储到 Amazon S3 中以供查询。
- C. 使用亚马逊 Kinesis 数据流来捕获传感器数据。将数据存储到亚马逊 DynamoDB 中以便查询。
- D. 使用亚马逊简单队列服务（Amazon SQS）缓冲传入的传感器数据。使用 AWS Glue 来

将数据存储存储在 Amazon RDS 中以供查询。

正确答案：C

部分：（无）

解释/参考：

问题 64

一家公司将数据存储存储在亚马逊 S3 中的数据湖里。该公司存储在数据湖中的部分数据包含个人身份信息（PII）。多个用户组需要访问原始数据。公司必须确保用户组只能访问他们所需的 PII。

哪种解决方案能以最少的努力满足这些要求？

- A. 使用亚马逊 Athena 查询数据。设置 AWS Lake Formation 并创建数据过滤器，为公司的 IAM 角色建立访问级别。将每个用户分配到与其 PII 访问要求相匹配的 IAM 角色。
- B. 使用 Amazon QuickSight 访问数据。利用 QuickSight 中的列级安全功能限制用户通过 Amazon Athena 从 Amazon S3 中检索到的个人身份信息（PII）。根据用户对 PII 的访问需求定义 QuickSight 的访问级别。
- C. 构建一个自定义的查询构建器用户界面，该界面将在后台运行 Athena 查询以访问数据。在 Amazon Cognito 中创建用户组。根据用户对个人身份信息（PII）的访问要求为用户组分配访问级别。
- D. 创建具有不同粒度访问权限级别的 IAM 角色。将 IAM 角色分配给 IAM 用户组。使用基于身份的策略在列级别为用户组分配访问级别。

正确答案：A

部分：（无）

解释/参考：

问题 65

数据工程师必须构建一个提取、转换和加载（ETL）管道，将来自 10 个源系统的数据处理并加载到亚马逊 Redshift 数据库中的 10 个表中。所有源系统每 15 分钟都会生成.csv、JSON 或 Apache Parquet 格式的文件。所有源系统都将文件交付到一个亚马逊 S3 存储桶中。文件大小从 10MB 到 20GB 不等。ETL 管道必须能够在数据模式发生变化的情况下正常运行。

哪些数据管道解决方案能满足这些要求？（选择两项。）

- A. 使用 Amazon EventBridge 规则每 15 分钟运行一次 AWS Glue 作业。配置 AWS Glue 作业以处理数据并将其加载到 Amazon Redshift 表中。
- B. 使用 Amazon EventBridge 规则每 15 分钟调用一次 AWS Glue 工作流作业。配置 AWS Glue 工作流，使其具有按需触发器，在成功运行 AWS Glue 爬虫后运行 AWS Glue 作业。配置 AWS Glue 作业以处理数据并将其加载到 Amazon Redshift 表中。
- C. 配置一个 AWS Lambda 函数，在文件加载到 S3 存储桶时调用 AWS Glue 爬虫。配置一个 AWS Glue 作业来处理数据并将其加载到 Amazon Redshift 表中。创建第二个 Lambda 函数来运行 AWS Glue 作业。创建一个 Amazon EventBridge 规则，在 AWS Glue 爬虫成功运行完毕时调用第二个 Lambda 函数。
- D. 配置一个 AWS Lambda 函数，以便在文件加载到 S3 存储桶时调用 AWS Glue 工作流。配置 AWS Glue 工作流，使其具有按需触发器，在 AWS Glue 爬虫成功运行后运行 AWS Glue 作业。配置 AWS Glue 作业以处理数据并将其加载到 Amazon Redshift 表中。
- E. 配置一个 AWS Lambda 函数，以便在文件加载到 S3 存储桶时调用 AWS Glue 作业。配置 AWS Glue 作业，从 S3 存储桶读取文件到 Apache Spark 数据框。配置 AWS Glue 作业，还将数据框的较小分区放入 Amazon Kinesis Data Firehose 交付流。配置交付流将数据加载到 Amazon Redshift 表中。

正确答案：BD

部分：（无）

解释/参考：

问题 6

一家金融公司希望使用亚马逊 Athena 对 PB 级的数据集按需运行 SQL 查询，以支持商业智能（BI）应用程序。一个在非营业时间运行的 AWS Glue 作业每天更新一次数据集。该 BI 应用程序的标准数据刷新频率为每小时一次，以符合公司政策。

一位数据工程师希望在不增加任何额外基础设施成本的情况下，优化公司对亚马逊 Athena 的使用成本。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 配置一个 Amazon S3 生命周期策略，在 1 天后将数据移至 S3 Glacier Deep Archive 存储类别。
- B. 对于 SQL 查询，请使用 Amazon Athena 的查询结果重用功能。
- C. 在 BI 应用程序和 Athena 之间添加一个 Amazon ElastiCache 集群。
- D. 将数据集中文件的格式更改为 Apache Parquet 格式。

正确答案：B

部分：（无）

解释/参考：

问题 67

一家公司的数据工程师需要优化表 SQL 查询的性能。该公司将数据存储于亚马逊 Redshift 集群中。由于预算限制，数据工程师无法扩大集群的规模。

该公司将数据存储于多个表中，并使用“EVEN”分布样式加载数据。有些表的大小达数百吉字节，而其他表的大小则不足 10 兆字节。

哪种解决方案能满足这些要求？

- A. 对所有表继续使用均匀分布方式。为所有表指定主键和外键。
- B. 对于大型表，请使用 ALL 分布方式。为所有表指定主键和外键。
- C. 对于很少更新的小表，请使用 ALL 分布方式。为所有表指定主键和外键。
- D. 为所有表指定分布键、排序键和分区键的组合。

正确答案：C

部分：（无）

解释/参考：

问题 68

一家公司收到包含物理地址数据的.csv 文件。数据位于以下名称的列中：门牌号（Door_No）、街道名称（Street_Name）、城市（City）和邮政编码（Zip_Code）。该公司希望创建一个单一的列，以以下格式存储这些值：

```
{
  "Door_No": "24",
  "Street_Name": "AAA street",
  "City": "BBB",
  "Zip_Code": "111111"
}
```

哪种解决方案能以最少的编码工作满足这一要求？

- A. 使用 AWS Glue DataBrew 读取文件。使用 NEST_TO_ARRAY 转换来创建新列。
- B. 使用 AWS Glue DataBrew 读取文件。使用 NEST_TO_MAP 转换来创建新列。
- C. 使用 AWS Glue DataBrew 读取文件。使用 PIVOT 转换创建新列。
- D. 用 Python 编写一个 Lambda 函数来读取文件。使用 Python 的数据字典类型来创建新列。

正确答案：B

部分：（无）

解释/参考：

问题 69

一家公司会收到包含敏感客户信息的亚马逊 S3 对象形式的通话记录。该公司必须通过加密来保护这些 S3 对象，并且必须使用只有特定员工才能访问的加密密钥。

哪种解决方案能以最少的努力满足这些要求？

- A. 使用 AWS CloudHSM 集群来存储加密密钥。配置向 Amazon S3 写入数据的流程，使其调用 CloudHSM 来加密和解密对象。部署一个 IAM 策略以限制对 CloudHSM 集群的访问。
- B. 使用客户提供的密钥进行服务器端加密（SSE-C）来加密包含客户信息的对象。限制对加密对象的密钥的访问。
- C. 使用 AWS KMS 密钥的服务器端加密（SSE-KMS）来加密包含客户信息的对象。配置一个 IAM 策略，限制对加密对象的 KMS 密钥的访问。
- D. 使用带有 Amazon S3 管理密钥的服务器端加密（SSE-S3）来加密包含客户信息的对象。配置一个 IAM 策略，限制对加密这些对象的 Amazon S3 管理密钥的访问。

正确答案：C

部分：（无）

解释/参考：

问题 70

一家公司在数千个亚马逊 S3 存储桶中存储了数 PB 的数据，这些数据存放在 S3 标准存储类别中。这些数据支持具有不可预测和多变的数据访问模式的分析工作负载。

该公司数月都不会访问某些数据。然而，公司必须能够在毫秒内检索到所有数据。该公司需要优化 S3 存储成本。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 使用 S3 存储透镜标准指标来确定何时将对象移动到成本优化型存储类别。为 S3 存储桶创建 S3 生命周期策略，将对象移动到成本优化型存储类别。未来继续完善 S3 生命周期策略，以优化存储成本。
- B. 利用 S3 存储透镜活动指标来识别公司访问频率较低的 S3 存储桶。根据数据的年龄配置 S3 生命周期规则，将对象从 S3 标准存储类别移动到 S3 标准-不频繁访问（S3 标准-IA）和 S3 冰川存储类别。
- C. 使用 S3 智能分层。激活深度存档访问层。
- D. 使用 S3 智能分层。使用默认访问层级。

正确答案：D

部分：（无）

解释/参考：

问题 71

在一次安全审查中，一家公司发现其 AWS Glue 作业存在漏洞。该公司发现访问 Amazon Redshift 集群的凭证被硬编码在作业脚本中。

数据工程师必须修复 AWS Glue 作业中的安全漏洞。解决方案必须安全地存储凭证。

数据工程师应采取哪些步骤组合来满足这些要求？（选择两项。）

- A. 将凭证存储在 AWS Glue 作业参数中。
- B. 将凭证存储在 Amazon S3 存储桶中的配置文件里。
- C. 使用 AWS Glue 作业从位于 Amazon S3 存储桶中的配置文件中获取凭证。
- D. 将凭证存储在 AWS Secrets Manager 中。
- E. 授予 AWS Glue 作业 IAM 角色访问存储的凭证的权限。

正确答案：DE

部分：（无）

解释/参考：

问题 72

一位数据工程师每月使用 Amazon Redshift 运行一次资源密集型的分析流程。每个月，该数据工程师都会创建一个新的 Redshift 预配置集群。在每个月的分析流程完成后，该数据工程师会删除 Redshift 预配置集群。在每个月删除集群之前，该数据工程师会将备份数据从集群卸载到 Amazon S3 存储桶。

数据工程师需要一个解决方案来运行每月的分析流程，该方案无需数据工程师手动管理基础设施。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 使用 Amazon Step Functions 在分析流程完成后暂停 Redshift 集群，并每月恢复集群以运行新的流程。
- B. 使用 Amazon Redshift Serverless 自动处理分析工作负载。
- C. 使用 AWS 命令行界面（CLI）自动处理分析工作负载。
- D. 使用 AWS CloudFormation 模板自动处理分析工作负载。

正确答案：B

部分：（无）

解释/参考：

问题 73

一家公司每天会收到一个包含客户数据的 .xls 格式文件。该公司将该文件存储在亚马逊 S3 中。每日文件的大小约为 2GB。

一位数据工程师将文件中包含客户名和姓氏的两列合并在一起。该数据工程师需要确定文件中不同客户的数量。

哪种解决方案能以最少的操作努力满足这一要求？

- A. 在 AWS Glue 笔记本中创建并运行一个 Apache Spark 作业。配置该作业以读取 S3 文件并计算不同客户的数量。
- B. 创建一个 AWS Glue 爬虫程序，以在 S3 文件上创建 AWS Glue 数据目录。使用 Amazon Athena 运行 SQL 查询来计算不同客户的数量。
- C. 在 Amazon EMR Serverless 中创建并运行一个 Apache Spark 作业，以计算不同客户的数量。
- D. 使用 AWS Glue DataBrew 创建一个配方，该配方使用 COUNT_DISTINCT 聚合函数来计算不同客户的数量。

正确答案：D

部分：（无）

解释/参考：

问题 74

一家医疗保健公司使用亚马逊 Kinesis 数据流来实时传输来自可穿戴设备、医院设备和患者记录的健康数据。

数据工程师需要找到一种解决方案来处理流数据。该工程师需要将数据存储在亚马逊 Redshift Serverless 数据仓库中。该解决方案必须支持对流数据和前一天数据进行近乎实时的分析。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 将数据加载到 Amazon Kinesis Data Firehose 中。将数据加载到 Amazon Redshift 中。
- B. 使用 Amazon Redshift 的流式数据摄取功能。
- C. 将数据加载到 Amazon S3 中。使用 COPY 命令将数据加载到 Amazon Redshift 中。
- D. 使用 Amazon Aurora 与 Amazon Redshift 的零 ETL 集成。

正确答案：B

部分：（无）

解释/参考：

问题 75

一名数据工程师需要使用基于对存储在 Amazon S3 存储桶中的数据执行的 Amazon Athena 查询的 Amazon QuickSight 控制面板。当该数据工程师连接到 QuickSight 控制面板时，收到了一条错误消息，表明其权限不足。

哪些因素可能导致权限相关的错误？（选择两项。）

- A. QuickSight 与 Athena 之间没有关联。
- B. 雅典娜系列的表格未被编目。
- C. QuickSight 无法访问该 S3 存储桶。
- D. QuickSight 无法访问解密 S3 数据。

E. QuickSight 未分配 IAM 角色。

正确答案：CD

部分：（无）

解释/参考：

问题 76

一家公司将数据集以 JSON 格式和.csv 格式存储在 Amazon S3 存储桶中。该公司拥有 Amazon RDS for Microsoft SQL Server 数据库、处于预置容量模式的 Amazon DynamoDB 表以及一个 Amazon Redshift 集群。数据工程团队必须开发一种解决方案，使数据科学家能够使用类似于 SQL 的语法查询所有数据源。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 使用 AWS Glue 爬取数据源。将元数据存储在 AWS Glue 数据目录中。使用 Amazon Athena 查询数据。对于结构化数据源，使用 SQL。对于存储在 JSON 格式中的数据，使用 PartiQL。
- B. 使用 AWS Glue 爬取数据源。将元数据存储在 AWS Glue 数据目录中。使用 Redshift Spectrum 查询数据。对于结构化数据源，使用 SQL。对于存储在 JSON 格式中的数据，使用 PartiQL。
- C. 使用 AWS Glue 爬取数据源。将元数据存储在 AWS Glue 数据目录中。使用 AWS Glue 作业将 JSON 格式的数据转换为 Apache Parquet 或 .csv 格式。将转换后的数据存储在 S3 存储桶中。使用 Amazon Athena 从 S3 存储桶中查询原始数据和转换后的数据。
- D. 使用 AWS Lake Formation 创建数据湖。使用 Lake Formation 作业将来自所有数据源的数据转换为 Apache Parquet 格式。将转换后的数据存储在 S3 存储桶中。使用 Amazon Athena 或 Redshift Spectrum 查询数据。

正确答案：A

部分：（无）

解释/参考：

问题 7

一位数据工程师正在配置亚马逊 SageMaker Studio，以便使用 AWS Glue 交互式会话来为机器学习（ML）模型准备数据。

当数据工程师尝试使用 SageMaker Studio 准备数据时，收到了访问被拒绝的错误。

工程师应该做出哪项更改才能访问 SageMaker Studio？

- A. 将 AWSGlueServiceRole 管理策略添加到数据工程师的 IAM 用户。
- B. 在数据工程师的 IAM 用户中添加一项策略，在信任策略中包含对 AWS Glue 和 SageMaker 服务主体的 sts:AssumeRole 操作。
- C. 将 AmazonSageMakerFullAccess 管理策略添加到数据工程师的 IAM 用户。
- D. 在数据工程师的 IAM 用户策略中添加一项，允许在信任策略中对 AWS Glue 和 SageMaker 服务主体执行 sts:AddAssociation 操作。

正确答案：B

部分：（无）

解释/参考：

问题 78

一家公司每天从诸如 SAP HANA、微软 SQL Server、MongoDB、Apache Kafka 和亚马逊 DynamoDB 等数据源中提取约 1TB 的数据。部分数据源具有

未定义的数据模式或不断变化的数据模式。

数据工程师必须实现一种能够检测这些数据源模式的解决方案。该解决方案必须将数据提取、转换并加载到 Amazon S3 存储桶中。该公司与客户签订了服务水平协议（SLA），要求在数据创建后的 15 分钟内将其加载到 S3 存储桶中。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 使用 Amazon EMR 来检测模式，并将数据提取、转换并加载到 S3 存储桶中。在 Apache Spark 中创建一个管道。
- B. 使用 AWS Glue 检测模式，并将数据提取、转换并加载到 S3 存储桶中。在 Apache Spark 中创建一个管道。
- C. 在 AWS Lambda 中创建一个 PySpark 程序，用于提取、转换并将数据加载到 S3 存储桶中。
- D. 在 Amazon Redshift 中创建一个存储过程，用于检测架构并提取、转换和加载数据到 Redshift Spectrum 表中。从 Amazon S3 访问该表。

正确答案：B

部分：（无）

解释/参考：

问题 79

一家公司拥有多个应用程序，这些应用程序使用的数据集存储在亚马逊 S3 存储桶中。该公司有一个电子商务应用程序，会生成包含个人身份信息（PII）的数据集。该公司还有一个内部分析应用程序，无需访问这些个人身份信息。

为遵守相关规定，公司不得无故分享个人身份信息（PII）。数据工程师需要实施一种解决方案，能够根据访问数据集的每个应用程序的需求动态地对 PII 进行脱敏处理。

哪种解决方案的运行开销最小，又能满足要求？

- A. 创建一个 S3 存储桶策略以限制每个应用程序的访问权限。创建数据集的多个副本。为每个数据集副本赋予访问该副本的应用程序所需的适当级别脱敏处理。
- B. 创建一个 S3 对象 Lambda 端点。使用 S3 对象 Lambda 端点从 S3 存储桶读取数据。在 S3 对象 Lambda 函数内实现数据遮蔽逻辑，根据访问数据的每个应用程序的需求动态遮蔽个人身份信息（PII）。
- C. 使用 AWS Glue 对每个应用程序的数据进行转换。创建数据集的多个副本。为每个数据集副本赋予访问该副本的应用程序所需的适当级别的脱敏处理。
- D. 创建一个具有自定义授权器的 API 网关端点。使用该 API 网关端点从 S3 存储桶读取数据。发起 REST API 调用，根据访问数据的每个应用程序的需求动态屏蔽个人身份信息（PII）。

正确答案：B

部分：（无）

解释/参考：

问题 80

数据工程师需要构建一个提取、转换和加载（ETL）作业。该 ETL 作业将处理用户每天上传到亚马逊 S3 存储桶的 .csv 文件。每个 S3 对象的大小均小于 100MB。

哪种解决方案能以最经济高效的方式满足这些要求？

- A. 编写一个自定义的 Python 应用程序。将该应用程序部署在 Amazon Elastic Kubernetes Service（Amazon EKS）集群上。

- B. 编写一个 PySpark ETL 脚本。将该脚本托管在 Amazon EMR 集群上。
- C. 编写一个 AWS Glue PySpark 作业。使用 Apache Spark 对数据进行转换。
- D. 编写一个 AWS Glue Python 脚本作业。使用 pandas 对数据进行转换。

正确答案：D

部分：（无）

解释/参考：

问题 81

一位数据工程师使用名为“Orders”的 AWS Glue 爬虫创建了一个 AWS Glue 数据目录表。该数据工程师想要添加以下新分区：

```
s3://transactions/orders/order_date=2023-01-01 s3://  
transactions/orders/order_date=2023-01-02
```

数据工程师必须编辑元数据，将新分区添加到表中，而无需扫描表所在位置的所有文件夹和文件。

数据工程师在 Amazon Athena 中应使用哪种数据定义语言（DDL）语句？

- A. 修改表 Orders，添加分区（order_date = '2023-01-01'），位置为 's3://transactions/orders/order_date=2023-01-01' ；
修改表“Orders”，添加分区（order_date = '2023-01-02'），位置为 's3://transactions/orders/order_date=2023-01-02' 。
- B. 修复表 Orders：MSCK REPAIR TABLE Orders
- C. 修复表 Orders
- D. 修改表 Orders 中分区 order_date = '2023-01-01' 的位置为 's3://transactions/orders/2023-01-01' ；
修改表“Orders”中分区“order_date=' 2023-01-02' ”的位置为“s3://transactions/orders/2023-01-02” ；

正确答案：A

部分：（无）

解释/参考：

参考：

问题 82

一家公司将其 10 至 15 TB 的未压缩的.csv 文件存储在亚马逊 S3 中。该公司正在评估亚马逊 Athena 作为一次性查询引擎。

该公司希望转换数据以优化查询运行时间和存储成本。

哪种文件格式和压缩方案能满足 Athena 查询的这些要求？

- A. 用 zip 压缩的.csv 格式文件
- B. 用 bzip2 压缩的 JSON 格式
- C. 使用 Snappy 压缩的 Apache Parquet 格式
- D. 使用 LZO 压缩的 Apache Avro 格式

正确答案：C

部分：（无）

解释/参考：

参考：

问题 83

一家公司使用 Apache Airflow 来编排公司当前本地的数据管道。这

该公司在其工作流中运行 SQL 数据质量检查任务。该公司希望将工作流迁移到 AWS，并使用 AWS 管理的服务。

哪种解决方案在满足这些要求的同时需要的重构工作最少？

- A. 在距离使用 Airflow 的公司所在地最近的 AWS 区域设置 AWS Outposts。将服务器迁移到 Outposts 托管的 Amazon EC2 实例中。更新管道以与 Outposts 托管的 EC2 实例交互，而非与本地管道交互。
- B. 创建一个自定义的亚马逊机器映像（AMI），其中包含 Airflow 应用程序以及公司需要迁移的代码。使用自定义的 AMI 部署亚马逊 EC2 实例。更新网络连接以与新部署的 EC2 实例进行交互。
- C. 将现有的 Airflow 工作流配置迁移到 Amazon Managed Workflows for Apache Airflow（Amazon MWAA）。在数据摄取期间创建数据质量检查，通过在 Airflow 中使用 SQL 任务来验证数据质量。
- D. 将管道转换为 AWS Step Functions 工作流。将数据质量检查从 SQL 重写为基于 Python 的 AWS Lambda 函数。

正确答案：C

部分：（无）

解释/参考：

参考：

问题 84

一家公司使用亚马逊 EMR 作为提取、转换和加载（ETL）管道来转换来自多个来源的数据。数据工程师必须协调该管道以实现性能最大化。

哪种 AWS 服务能以最具成本效益的方式满足这一要求？

- A. 亚马逊 EventBridge
- B. 亚马逊托管的 Apache Airflow 工作流（Amazon MWAA）
- C. AWS 步骤函数
- D. AWS Glue 工作流

正确答案：C

部分：（无）

解释/参考：

问题 85

一家在线零售公司将应用负载均衡器（ALB）的访问日志存储在 Amazon S3 存储桶中。该公司希望使用 Amazon Athena 查询这些日志以分析流量模式。

一位数据工程师在 Athena 中创建了一个未分区的表。随着数据量逐渐增加，查询的响应时间也随之延长。该数据工程师希望提高 Athena 中的查询性能。

哪种解决方案能以最少的操作努力满足这些要求？

- A. 创建一个 AWS Glue 作业，用于确定所有 ALB 访问日志的架构，并将分区元数据写入 AWS Glue 数据目录。
- B. 创建一个 AWS Glue 爬虫，其中包含一个分类器，用于确定所有 ALB 访问日志的架构，并将分区元数据写入 AWS Glue 数据目录。
- C. 创建一个 AWS Lambda 函数来转换所有 ALB 访问日志。将结果以 Apache Parquet 格式保存到 Amazon S3 中。对元数据进行分区。使用 Athena 查询转换后的数据。
- D. 使用 Apache Hive 创建分桶表。使用 AWS Lambda 函数转换所有 ALB 访问日志。

正确答案：B

部分：（无）

解释/参考：

参考：

问题 86

一家公司在 AWS 上拥有一个商业智能平台。该公司使用 AWS 存储网关的 Amazon S3 文件网关将文件从公司的本地环境传输到 Amazon S3 存储桶。

数据工程师需要设置一个流程，以便在每次文件传输成功完成后，自动启动 AWS Glue 工作流来运行一系列的 AWS Glue 作业。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 根据之前成功的文件传输情况确定文件传输通常完成的时间。设置一个 Amazon EventBridge 定时事件，在每天的那个时间点启动 AWS Glue 作业。
- B. 设置一个 Amazon EventBridge 事件，在每次成功的 S3 文件网关文件传输事件之后启动 AWS Glue 工作流。
- C. 设置一个按需的 AWS Glue 工作流，以便数据工程师在每次文件传输完成后启动 AWS Glue 工作流。
- D. 创建一个 AWS Lambda 函数，用于调用 AWS Glue 工作流。为 S3 对象的创建设置一个事件，作为触发 Lambda 函数的触发器。

正确答案：B

部分：（无）

解释/参考：

问题 87

一家零售公司使用亚马逊 Aurora PostgreSQL 来处理和存储实时交易数据。该公司使用亚马逊 Redshift 集群作为数据仓库。

每天早上都会运行一次提取、转换和加载（ETL）作业，将 PostgreSQL 数据库中的新数据更新到 Redshift 集群中。该公司发展迅速，需要对 Redshift 集群进行成本优化。

数据工程师需要创建一个解决方案来归档历史数据。该工程师必须能够运行分析查询，有效地将 PostgreSQL 中的实时事务数据、Redshift 中的当前数据以及归档的历史数据结合起来。该解决方案必须仅在 Amazon Redshift 中保留最近 15 个月的数据，以降低成本。

哪两种步骤的组合能满足这些要求？（选择两项。）

- A. 配置 Amazon Redshift 联合查询功能，以查询存储在 PostgreSQL 数据库中的实时事务数据。
- B. 配置 Amazon Redshift Spectrum 以查询存储在 PostgreSQL 数据库中的实时事务数据。
- C. 每月安排一次作业，使用 UNLOAD 命令将超过 15 个月的数据复制到 Amazon S3 中，然后从 Redshift 集群中删除旧数据。配置 Amazon Redshift Spectrum 以访问 Amazon S3 中的历史数据。
- D. 安排每月执行一次作业，使用 UNLOAD 命令将超过 15 个月的数据复制到 Amazon S3 Glacier Flexible Retrieval 中，然后从 Redshift 集群中删除旧数据。配置 Redshift Spectrum 以从 S3 Glacier Flexible Retrieval 访问历史数据。
- E. 在 Amazon Redshift 中创建一个物化视图，将来自不同来源的实时、当前和历史数据进行整合。

正确答案：CD

部分：（无）

解释/参考：

问题 8

一家制造公司在世界各地的设施中部署了众多物联网设备。该公司利用亚马逊 Kinesis 数据流来收集这些设备的数据。所收集的数据包括设备 ID、采集日期、测量类型、测量值以及设施 ID。该公司将设施 ID 用作分区键。

该公司运营团队近期发现出现了许多 “WriteThroughputExceeded” 异常。运营团队还发现，部分分片使用频繁，而其他分片则基本处于闲置状态。

公司应如何解决运营团队所发现的问题？

- A. 将分区键从设施 ID 更改为随机生成的键。
- B. 增加分片的数量。
- C. 在生产者一方存档数据。
- D. 将分区键从设施 ID 更改为捕获日期。

正确答案：A

部分：（无）

解释/参考：

参考：

问题 89

一位数据工程师希望提升在 Amazon Athena 中针对销售数据表运行的 SQL 查询的性能。

数据工程师想要了解特定 SQL 语句的执行计划。数据工程师还希望查看 SQL 查询中每个操作的计算成本。

数据工程师需要运行哪条语句才能满足这些要求？

- A. `EXPLAIN SELECT * FROM sales;`
- B. `EXPLAIN ANALYZE FROM sales;`
- C. `EXPLAIN ANALYZE SELECT * FROM sales;`
- D. `EXPLAIN FROM sales;`

正确答案：C

部分：（无）

解释/参考：

参考：

问题 90

一家公司计划在虚拟私有云（VPC）内配置日志传输流。该公司已将 VPC 流日志配置为发布到 Amazon CloudWatch Logs。该公司需要近乎实时地将流日志发送到 Splunk 以进行进一步分析。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 配置一个 Amazon Kinesis Data Streams 数据流，将其目的地设置为 Splunk。创建一个 CloudWatch Logs 订阅过滤器，将日志事件发送到该数据流。
- B. 创建一个 Amazon Kinesis Data Firehose 传输流，将其目的地设置为 Splunk。创建一个 CloudWatch Logs 订阅筛选器，将日志事件发送到该传输流。
- C. 创建一个 Amazon Kinesis Data Firehose 传输流，将 Splunk 用作目标。创建一个 AWS Lambda 函数，将 CloudWatch Logs 中的流日志发送到传输流。
- D. 配置一个 Amazon Kinesis Data Streams 数据流，将其目的地设置为 Splunk。创建一个 AWS Lambda 函数，将 CloudWatch Logs 中的流日志发送到该数据流。

正确答案：B

部分：（无）

解释/参考：

参考：

问题 91

一家公司在 AWS 上拥有一个数据湖。该数据湖从各业务部门获取数据源。该公司使用亚马逊 Athena 进行查询。存储层是亚马逊 S3，元数据存储库为 AWS Glue 数据目录。

该公司希望将数据提供给数据科学家和业务分析师。然而，公司首先需要根据用户的角色和职责来管理 Athena 的细粒度、列级数据访问权限。

哪种解决方案能满足这些要求？

- A. 设置 AWS Lake Formation。通过 Lake Formation 中的 IAM 角色为用户和应用程序定义基于安全策略的规则。
- B. 为 AWS Glue 表定义基于资源的 IAM 策略。将相同的策略附加到 IAM 用户组。
- C. 为 AWS Glue 表定义基于身份的 IAM 策略。将相同的策略附加到 IAM 角色。将 IAM 角色与包含用户的 IAM 组相关联。
- D. 在 AWS 资源访问管理器（AWS RAM）中创建资源共享，以授予 IAM 用户访问权限。

正确答案：A

部分：（无）

解释/参考：

参考：

问题 92

一家公司开发了多个 AWS Glue 提取、转换和加载（ETL）作业，用于验证和转换来自 Amazon S3 的数据。这些 ETL 作业每天批量将数据加载到 Amazon RDS 的 MySQL 中。ETL 作业使用 DynamicFrame 读取 S3 中的数据。

目前，ETL 作业处理 S3 存储桶中的所有数据。然而，公司希望这些作业仅处理每日的增量数据。

哪种解决方案能以最少的编码工作满足这一要求？

- A. 创建一个 ETL 作业，读取 S3 文件的状态，并将状态记录在 Amazon DynamoDB 中。
- B. 为 ETL 作业启用作业书签，以便在运行后更新状态，从而跟踪先前处理的数据。
- C. 为 ETL 作业启用作业指标，以便在 Amazon CloudWatch 中跟踪已处理的对象。
- D. 配置 ETL 作业，使其在每次运行后从 Amazon S3 中删除已处理的对象。

正确答案：B

部分：（无）

解释/参考：

参考：

问题 93

一家在线零售公司有一个运行在亚马逊 EC2 实例上的应用程序，这些实例位于一个虚拟私有云（VPC）中。该公司希望收集 VPC 的流量日志并分析网络流量。

哪种解决方案能以最经济高效的方式满足这些要求？

- A. 将流日志发布到 Amazon CloudWatch Logs。使用 Amazon Athena 进行分析。
- B. 将流日志发布到 Amazon CloudWatch Logs。使用 Amazon OpenSearch Service 集群进行分析。

- C. 将流日志以文本格式发布到 Amazon S3。使用 Amazon Athena 进行分析。
- D. 将流日志以 Apache Parquet 格式发布到 Amazon S3。使用 Amazon Athena 进行分析。

正确答案：D

部分：（无）

解释/参考：

参考：

问题 94

一家零售公司将交易记录、门店位置和客户信息表存储在四个预留的 ra3.xlarge Amazon Redshift 集群节点中。这三个表均采用均匀表分布。

该公司每隔几年才更新一次或两次店铺位置表。

一位数据工程师注意到，Redshift 队列运行速度变慢，原因是整个店铺位置表在大多数查询中都会不断广播到所有四个计算节点。该数据工程师希望通过减少店铺位置表的广播来提高查询性能。

哪种解决方案能以最经济的方式满足这些要求？

- A. 将店铺位置表的分布样式从均匀分布更改为全部分布。
- B. 将店铺位置表的分布样式更改为基于维度最高的列的键分布。
- C. 在所有表的排序键中添加一个名为 store_id 的连接列。
- D. 将 Redshift 预留节点升级为同一实例系列中的更大实例类型。

正确答案：A

部分：（无）

解释/参考：

参考：

问题 95

一家公司有一个数据仓库，其中包含一个名为“Sales”的表。该公司将此表存储在 Amazon Redshift 中。该表包含一个名为“city_name”的列。该公司希望查询此表，找出所有“city_name”以“San”或“El”开头的行。

哪个 SQL 查询能满足这一要求？

- A. 从“Sales”表中选择所有列，其中“city_name”列的值匹配正则表达式“\$(San|El)*”；
- B. 从“Sales”表中选择所有列，其中“city_name”以“San”或“El”开头；
- C. 从“Sales”表中选择所有列，其中“city_name”列的值匹配正则表达式“\$(San&El)*”；
- D. 从“Sales”表中选择所有列，其中“city_name”列的值以“^(San&El)*”开头；

正确答案：B

部分：（无）

解释/参考：

问题 96

一家公司需要将其本地 PostgreSQL 数据库中的客户呼叫数据发送到 AWS，以生成近乎实时的洞察。该解决方案必须捕获并加载运行在 PostgreSQL 数据库中的操作数据存储的更新。数据在不断变化。

一位数据工程师配置了 AWS 数据迁移服务（AWS DMS）的持续复制任务。该任务近乎实时地从 PostgreSQL 源数据库的事务日志中读取每个表的更改，然后将数据发送到 Amazon Redshift 集群进行处理。

数据工程师在任务的变更数据捕获（CDC）过程中发现了延迟问题。数据

工程师认为高延迟是由 PostgreSQL 源数据库造成的。

哪种解决方案能确认高延迟是由 PostgreSQL 数据库引起的？

- A. 使用 Amazon CloudWatch 监控 DMS 任务。检查 CDCIncomingChanges 指标，以识别源数据库 CDC 的延迟情况。
- B. 确认在 postgresql.conf 配置文件中已配置源数据库的逻辑复制。
- C. 为源数据库的 DMS 端点启用 Amazon CloudWatch 日志。检查错误消息。
- D. 使用 Amazon CloudWatch 监控 DMS 任务。检查 CDCLatencySource 指标以识别源数据库 CDC 的延迟情况。

正确答案：D

部分：（无）

解释/参考：

参考：

问题 97

一个实验室使用物联网传感器来监测一个项目中的湿度、温度和压力。这些传感器每 10 秒发送 100KB 的数据。下游流程每 30 秒从亚马逊 S3 存储桶读取一次数据。

哪种解决方案能以最低的延迟将数据传输到 S3 存储桶？

- A. 使用 Amazon Kinesis Data Streams 和 Amazon Kinesis Data Firehose 将数据传输至 S3 存储桶。对于 Kinesis Data Firehose，使用默认的缓冲间隔。
- B. 使用 Amazon Kinesis 数据流将数据传输到 S3 存储桶。将流配置为使用 5 个预留分片。
- C. 使用 Amazon Kinesis Data Streams 并调用 Kinesis 客户端库将数据传送到 S3 存储桶。从应用程序端设置 5 秒的缓冲间隔。
- D. 使用亚马逊托管的 Apache Flink 服务（之前称为亚马逊 Kinesis 数据分析）和亚马逊 Kinesis 数据火线将数据传输到 S3 存储桶。为 Kinesis 数据火线设置 5 秒的缓冲间隔。

正确答案：C

部分：（无）

解释/参考：

问题 98

一家公司希望利用机器学习（ML）对存储在亚马逊 S3 数据湖中的数据进行分析。该公司有两个数据转换需求，这将使公司内部的用户能够创建报告。

该公司必须每天对 300GB 的各种格式的数据进行转换，这些数据必须在预定时间到达亚马逊 S3 存储桶。该公司还必须对存储在 S3 数据湖中的数太字节的归档数据进行一次性转换。该公司使用亚马逊托管的 Apache Airflow 工作流（Amazon MWAA）有向无环图（DAG）来协调处理流程。

为了以最经济高效的方式满足这些要求，公司应在 Amazon MWAA DAG 中安排哪两项任务组合？（选择两项。）

- A. 对于每日传入的数据，使用 AWS Glue 爬虫进行扫描并识别模式。
- B. 对于每日传入的数据，使用亚马逊 Athena 进行扫描并识别其模式。
- C. 对于每日传入的数据，使用亚马逊 Redshift 进行转换。
- D. 对于日常数据和存档数据，使用 Amazon EMR 来执行数据转换。
- E. 对于存档数据，请使用亚马逊 SageMaker 来执行数据转换。

正确答案：AD

部分：（无）

解释/参考：

参考：

问题 9

一家零售公司使用 AWS Glue 对包含客户订单信息的数据集执行提取、转换和加载（ETL）操作。该公司希望实施特定的验证规则以确保数据的准确性和一致性。

哪种解决方案能满足这些要求？

- A. 使用 AWS Glue 作业书签来跟踪数据以确保其准确性和一致性。
- B. 创建自定义的 AWS Glue 数据质量规则集以定义特定的数据质量检查。
- C. 使用内置的 AWS Glue 数据质量转换功能来进行标准的数据质量验证。
- D. 使用 AWS Glue 数据目录来维护一个集中的数据模式和元数据存储库。

正确答案：B

部分：（无）

解释/参考：

问题 10

一家保险公司存储了该公司用 gzip 压缩的交易数据。

该公司需要查询交易数据以进行不定期审计。

哪种解决方案能以最经济的方式满足这一要求？

- A. 将数据存储在 Amazon Glacier 灵活检索中。使用 Amazon S3 Glacier Select 查询数据。
- B. 将数据存储在亚马逊 S3 中。使用亚马逊 S3 Select 来查询数据。
- C. 将数据存储在亚马逊 S3 中。使用亚马逊 Athena 来查询数据。
- D. 将数据存储在 Amazon Glacier 即时检索中。使用 Amazon Athena 查询数据。

正确答案：B

部分：（无）

解释/参考：

参考：

问题 101

一位数据工程师完成了对亚马逊 Redshift 存储过程的测试，该存储过程用于处理数据并将其插入到一个非关键任务的表中。这位工程师希望每天自动运行该存储过程。

哪种解决方案能以最经济的方式满足这一要求？

- A. 创建一个 AWS Lambda 函数，安排一个 cron 作业来运行存储过程。
- B. 使用 Amazon EC2 Spot 实例中的 Amazon Redshift Data API 调度并运行存储过程。
- C. 使用查询编辑器 v2 按计划运行存储过程。
- D. 安排一个 AWS Glue Python 脚本作业来运行存储过程。

正确答案：C 部分：

（无）

解释/参考：

问题 102

一家营销公司收集点击流数据。该公司将点击流数据发送至亚马逊 Kinesis Data Firehose，并将其存储在亚马逊 S3 中。该公司希望构建一系列仪表板，供来自多个部门的数百名用户使用。

该公司将使用亚马逊 QuickSight 来开发仪表板。该公司希望找到一种可扩展且能提供每日点击流活动更新的解决方案。

哪种步骤组合能以最经济高效的方式满足这些要求？（选择两项。）

- A. 使用 Amazon Redshift 来存储和查询点击流数据。
- B. 使用 Amazon Athena 查询点击流数据
- C. 使用亚马逊 S3 分析功能查询点击流数据。
- D. 通过 QuickSight 直接 SQL 查询访问查询数据。
- E. 通过 QuickSight SPICE（超快速、并行、内存计算引擎）访问查询数据。为数据集配置每日刷新。

正确答案：BE

部分：（无）

解释/参考：

参考：

问题 103

一位数据工程师正在构建一个数据编排 workflow。该数据工程师计划采用一种混合模式，其中包括一些本地资源和一些云端资源。这位数据工程师希望优先考虑可移植性和开源资源。

数据工程师在本地环境和基于云的环境中都应使用哪种服务？

- A. 亚马逊网络服务数据交换
- B. 亚马逊简单工作流服务（Amazon SWF）
- C. 亚马逊托管的 Apache Airflow 工作流（Amazon MWAA）
- D. AWS Glue

正确答案：C

部分：（无）

解释/参考：

参考：

问题 104

一家游戏公司使用 NoSQL 数据库来存储客户信息。该公司正计划迁移到 AWS。

该公司需要一个由 AWS 全面管理的解决方案，能够处理高在线事务处理（OLTP）工作负载，提供单位数毫秒级的性能，并在全球范围内提供高可用性。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 亚马逊密钥空间（适用于 Apache Cassandra）
- B. Amazon DocumentDB（兼容 MongoDB）
- C. 亚马逊 DynamoDB
- D. 亚马逊 Timestream

正确答案：C

部分：（无）

解释/参考：

参考：

问题 105

一位数据工程师创建了一个 AWS Lambda 函数，该函数将由 Amazon EventBridge 事件触发。当这位数据工程师尝试使用 EventBridge 事件调用 Lambda 函数时，出现了一条“访问被拒绝”的错误消息。

数据工程师应如何解决这个异常？

- A. 确保 Lambda 函数执行角色的信任策略允许 EventBridge 假定该执行角色。
- B. 确保 EventBridge 使用的 IAM 角色以及 Lambda 函数的基于资源的策略都具有必要的权限。
- C. 确保部署 Lambda 函数的子网配置为私有子网。
- D. 确保 EventBridge 模式有效且事件映射配置正确。

正确答案：B

部分：（无）

解释/参考：

问题 106

一家公司使用基于亚马逊 S3 存储桶的数据湖。为符合法规要求，该公司必须对上传至 S3 存储桶的文件应用两层服务器端加密。该公司希望使用 AWS Lambda 函数来实施必要的加密。

哪种解决方案能满足这些要求？

- A. 同时使用带有 AWS KMS 密钥的服务器端加密（SSE-KMS）和 Amazon S3 加密客户端。
- B. 使用带有 AWS KMS 密钥的双层服务器端加密（DSSE-KMS）。
- C. 在上传文件之前使用服务器端加密（SSE-C）并采用客户提供的密钥。
- D. 使用 AWS KMS 密钥进行服务器端加密（SSE-KMS）。

正确答案：B

部分：（无）

解释/参考：

参考：

问题 107

一位数据工程师注意到，在亚马逊 Athena 中，查询在运行前会被放入一个队列中。

数据工程师如何防止查询排队？

- A. 提高查询结果的限制。
- B. 为现有工作组配置预配容量。
- C. 使用联合查询。
- D. 允许运行 Athena 查询的用户加入现有工作组。

正确答案：B

部分：（无）

解释/参考：

参考：<https://docs.aws.amazon.com/athena/latest/ug/performance-tuning.html>

问题 108

一位数据工程师需要调试一个从亚马逊 S3 读取数据并写入亚马逊 Redshift 的 AWS Glue 作业。该数据工程师为 AWS Glue 作业启用了书签功能。

数据工程师已将 AWS Glue 作业的最大并发度设置为 1。

AWS Glue 作业已成功将输出写入 Amazon Redshift。然而，在 AWS Glue 作业之前运行期间加载的 Amazon S3 文件在后续运行中会被重新处理。

AWS Glue 作业重新处理这些文件的可能原因是什么？

- A. AWS Glue 作业没有正常运行书签所需的 s3:GetObjectAcl 权限。
- B. AWS Glue 作业的最大并发度设置为 1。
- C. 数据工程师为 Glue 作业错误地指定了较旧版本的 AWS Glue。
- D. AWS Glue 作业缺少必需的提交语句。

正确答案：D

部分：（无）

解释/参考：

问题 109

一家电子商务公司希望利用 AWS 将数据管道从本地环境迁移到 AWS 云。该公司目前在本地环境中使用第三方工具来协调数据摄取流程。

该公司希望采用一种无需自行管理服务器的迁移方案。该方案必须能够协调 Python 和 Bash 脚本。并且该方案不能要求公司对任何代码进行重构。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 亚马逊网络服务（AWS）Lambda
- B. 亚马逊托管的 Apache Airflow 工作流（Amazon Managed Workflows for Apache Airflow，简称 Amazon MWAA）
- C. AWS 步骤函数
- D. AWS Glue

正确答案：B

部分：（无）

解释/参考：

问题 110

一家零售公司将产品生命周期管理（PLM）应用程序的数据存储在本地的 MySQL 数据库中。每当有交易发生时，PLM 应用程序就会频繁更新该数据库。

该公司希望近乎实时地从产品生命周期管理（PLM）应用程序中获取洞察信息。该公司希望将这些洞察信息与其他业务数据集整合，并使用亚马逊红移数据仓库对整合后的数据集进行分析。

该公司已经在本地基础设施与 AWS 之间建立了 AWS Direct Connect 连接。

哪种解决方案能以最少的开发工作量满足这些要求？

- A. 运行一个计划好的 AWS Glue 提取、转换和加载（ETL）作业，通过使用 Java 数据库连接（JDBC）连接获取 MySQL 数据库的更新。将 Amazon Redshift 设置为 ETL 作业的目标。
- B. 在 AWS 数据迁移服务（AWS DMS）中运行完整负载加上持续数据捕获（CDC）任务以持续进行

复制 MySQL 数据库的更改。将 Amazon Redshift 设置为任务的目标。

- C. 使用 Amazon AppFlow SDK 构建一个针对 MySQL 数据库的自定义连接器，以持续复制数据库更改。将 Amazon Redshift 设置为连接器的目标。
- D. 运行计划的 AWS DataSync 任务以同步来自 MySQL 数据库的数据。将 Amazon Redshift 设置为任务的目标。

正确答案：B

部分：（无）

解释/参考：

问题 11

一家营销公司使用亚马逊 S3 来存储点击流数据。该公司每天结束时通过在存储于不同存储桶中的 S3 对象上使用 SQL JOIN 子句来查询这些数据。

该公司根据对象创建关键绩效指标（KPI）。该公司需要一种无服务器解决方案，使用户能够通过分区查询数据。该解决方案必须保持数据的原子性、一致性、隔离性和持久性（ACID）属性。

哪种解决方案能以最经济高效的方式满足这些要求？

- A. 亚马逊 S3 选择功能
- B. 亚马逊红移光谱
- C. 亚马逊 Athena
- D. 亚马逊 EMR

正确答案：C

部分：（无）

解释/参考：

问题 112

一家公司希望将数据从名为 Account_A 的 AWS 账户的 eu-east-1 区域中的 Amazon RDS for PostgreSQL 数据库实例迁移到名为 Account_B 的 AWS 账户的 eu-west-1 区域中的 Amazon Redshift 集群。

哪种解决方案能让 AWS 数据库迁移服务（AWS DMS）具备在两个数据存储之间复制数据的能力？

- A. 在 Account_B 的 eu-west-1 区域设置一个 AWS DMS 复制实例。
- B. 在 Account_B 的 eu-east-1 区域设置一个 AWS DMS 复制实例。
- C. 在位于 eu-west-1 区域的新 AWS 账户中设置一个 AWS DMS 复制实例。
- D. 在 Account_A 的 eu-east-1 区域设置一个 AWS DMS 复制实例。

正确答案：A

部分：（无）

解释/参考：

问题 113

一家公司使用亚马逊 S3 作为数据湖。该公司通过使用多节点的亚马逊 Redshift 集群来搭建数据仓库。该公司根据每个数据文件的数据来源对数据湖中的数据文件进行组织。

该公司通过为每个数据文件位置使用单独的 COPY 命令，将所有数据文件加载到 Redshift 集群中的一个表中。这种方法加载所有数据文件到表中需要很长时间。该公司必须提高数据摄取的速度。该公司不想增加

该过程的成本。

哪种解决方案能满足这些要求？

- A. 使用已配置的 Amazon EMR 集群将所有数据文件复制到一个文件夹中。使用 COPY 命令将数据加载到 Amazon Redshift 中。
- B. 并行加载所有数据文件到 Amazon Aurora 中。运行一个 AWS Glue 作业将数据加载到 Amazon Redshift 中。
- C. 使用 AWS Glue 作业将所有数据文件复制到一个文件夹中。使用 COPY 命令将数据加载到 Amazon Redshift 中。
- D. 创建一个清单文件，其中包含数据文件的位置。使用 COPY 命令将数据加载到 Amazon Redshift 中。

正确答案：D

部分：（无）

解释/参考：

问题 114

一家公司计划使用亚马逊 Kinesis Data Firehose 将数据存储存储在亚马逊 S3 中。源数据由 2MB 的.csv 文件组成。该公司必须将.csv 文件转换为 JSON 格式。该公司必须以 Apache Parquet 格式存储这些文件。

哪种解决方案能以最少的开发工作量满足这些要求？

- A. 使用 Kinesis Data Firehose 将 .csv 文件转换为 JSON 格式。使用 AWS Lambda 函数将文件存储为 Parquet 格式。
- B. 使用 Kinesis Data Firehose 将 .csv 文件转换为 JSON 格式，并将文件以 Parquet 格式存储。
- C. 使用 Kinesis Data Firehose 调用 AWS Lambda 函数，将 .csv 文件转换为 JSON 格式，并将文件以 Parquet 格式存储。
- D. 使用 Kinesis Data Firehose 调用 AWS Lambda 函数将 .csv 文件转换为 JSON 格式。使用 Kinesis Data Firehose 将文件以 Parquet 格式存储。

正确答案：D

部分：（无）

解释/参考：

问题 115

一家公司正在使用 AWS 传输系列服务器将本地环境中的数据迁移到 AWS。公司政策规定必须使用 TLS 1.2 或更高版本对传输中的数据进行加密。

哪种解决方案能满足这些要求？

- A. 为 Transfer Family 服务器生成新的 SSH 密钥。使旧密钥和新密钥均可使用。
- B. 更新本地网络的安全组规则，仅允许使用 TLS 1.2 或更高版本的连接。
- C. 将 Transfer Family 服务器的安全策略更新为指定最低协议版本为 TLS 1.2
- D. 在 Transfer Family 服务器上安装 SSL 证书，以使用 TLS 1.2 加密数据传输。

正确答案：C

部分：（无）

解释/参考：

问题 116

一家公司希望将一个应用程序和本地的 Apache Kafka 服务器迁移到 AWS。该应用程序处理本地 Oracle 数据库发送到 Kafka 服务器的增量更新。该公司希望采用重新构建迁移策略，而非重构策略。

哪种解决方案能以最低的管理开销满足这些要求？

- A. 亚马逊 Kinesis 数据流
- B. 针对 Apache Kafka 的亚马逊托管流处理（Amazon MSK）预配置集群
- C. 亚马逊 Kinesis 数据火线
- D. 亚马逊托管的 Apache Kafka 无服务器流处理（Amazon MSK 无服务器）

正确答案：D

部分：（无）

解释/参考：

问题 117

一位数据工程师正在使用 AWS Glue 构建一个自动化的提取、转换和加载（ETL）摄取管道。该管道从 Amazon S3 存储桶中摄取压缩文件。摄取管道必须支持增量数据处理。

数据工程师应使用 AWS Glue 的哪项功能来满足此要求？

- A. 工作流程
- B. 触发因素
- C. 工作书签
- D. 分类器

正确答案：C

部分：（无）

解释/参考：

问题 118

一家银行公司使用一款应用程序来收集大量的交易数据。该公司使用亚马逊 Kinesis 数据流进行实时分析。该公司的应用程序使用 PutRecord 操作将数据发送到 Kinesis 数据流。

一位数据工程师注意到在一天中的某些时段会出现网络中断的情况。该数据工程师希望为整个处理流程配置精确一次的交付机制。

哪种解决方案能满足这一要求？

- A. 设计应用程序，使其在处理过程中能够去除重复项，方法是在源数据的每条记录中嵌入一个唯一标识符。
- B. 更新 Amazon Managed Service for Apache Flink（之前称为 Amazon Kinesis Data Analytics）数据收集应用程序的检查点配置，以避免对事件进行重复处理。
- C. 设计数据源，确保事件不会多次被摄入到 Kinesis 数据流中。
- D. 停止使用 Kinesis 数据流。改用 Amazon EMR。在 Amazon EMR 中使用 Apache Flink 和 Apache Spark Streaming。

正确答案：A

部分：（无）

解释/参考：

问题 119

一家公司将日志存储在亚马逊 S3 存储桶中。当一名数据工程师试图访问几个日志文件时，发现有些文件被意外删除了。

这位数据工程师需要一个解决方案，以防止将来无意中删除文件。

哪种解决方案能在操作开销最小的情况下满足这一要求？

- A. 定期手动备份 S3 存储桶。
- B. 为 S3 存储桶启用 S3 版本控制功能。
- C. 为 S3 存储桶配置复制功能。
- D. 使用 Amazon S3 Glacier 存储类别来归档 S3 存储桶中的数据。

正确答案：B

部分：（无）

解释/参考：

问题 120

一家电信公司每天每秒以数千个数据点的速度收集网络使用数据。该公司运行一个应用程序来实时处理这些使用数据。该公司将数据汇总并存储在 Amazon Aurora 数据库实例中。

网络使用量的突然下降通常表明网络中断。公司必须能够识别网络使用量的突然下降，以便公司能够立即采取补救措施。

哪种解决方案能以最低的延迟满足这一要求？

- A. 创建一个 AWS Lambda 函数，用于查询 Aurora 中网络使用量的下降情况。使用 Amazon EventBridge 每分钟自动调用该 Lambda 函数。
- B. 修改处理应用程序，将数据发布到 Amazon Kinesis 数据流。创建一个 Amazon Managed Service for Apache Flink（之前称为 Amazon Kinesis Data Analytics）应用程序来检测网络使用量的下降。
- C. 用 Amazon DynamoDB 表替换 Aurora 数据库。创建一个 AWS Lambda 函数，每分钟查询 DynamoDB 表以获取网络使用量的下降情况。在处理应用程序和 DynamoDB 表之间使用 DynamoDB 加速器（DAX）。
- D. 在 Aurora 的数据库活动流功能内创建一个 AWS Lambda 函数，以检测网络使用量的下降。

正确答案：B

部分：（无）

解释/参考：

问题 121

一位数据工程师正在处理和分析存储在亚马逊 S3 中的数太字节的原始数据。该工程师需要对数据进行清理和准备，然后将其加载到亚马逊 Redshift 中进行分析。

数据工程师需要一种解决方案，使数据分析师能够执行复杂的查询。该解决方案必须消除执行复杂的提取、转换和加载（ETL）流程或管理基础设施的需求。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 使用 Amazon EMR 准备数据。使用 AWS Step Functions 将数据加载到 Amazon Redshift 中。使用 Amazon QuickSight 运行查询。
- B. 使用 AWS Glue DataBrew 准备数据。使用 AWS Glue 将数据加载到 Amazon Redshift 中。

使用 Amazon Redshift 运行查询。

- C. 使用 AWS Lambda 准备数据。使用 Amazon Kinesis Data Firehose 将数据加载到 Amazon Redshift 中。使用 Amazon Athena 运行查询。
- D. 使用 AWS Glue 准备数据。使用 AWS 数据迁移服务（AWS DMS）将数据加载到 Amazon Redshift 中。使用 Amazon Redshift Spectrum 运行查询。

正确答案：B

部分：（无）

解释/参考：

问题 12

一家公司使用 AWS Lambda 函数将文件从传统的 SFTP 环境传输到 Amazon S3 存储桶。该 Lambda 函数启用了 VPC，以确保 Lambda 函数与位于同一 VPC 环境中的其他 AWS 服务之间的所有通信都通过安全网络进行。

Lambda 函数能够成功连接到 SFTP 环境。然而，当该 Lambda 函数尝试将文件上传到 S3 存储桶时，会返回超时错误。数据工程师必须以安全的方式解决超时问题。

哪种解决方案能以最经济的方式满足这些要求？

- A. 在 VPC 的公共子网中创建一个 NAT 网关。将网络流量路由到该 NAT 网关。
- B. 为 Amazon S3 创建一个 VPC 网关端点。将网络流量路由到 VPC 网关端点。
- C. 为 Amazon S3 创建一个 VPC 接口端点。将网络流量路由到 VPC 接口端点。
- D. 使用 VPC 互联网网关连接到互联网。将网络流量路由到 VPC 互联网网关。

正确答案：B

部分：（无）

解释/参考：

问题 123

一家公司从运行在亚马逊 RDS 上的客户数据库中读取数据。这些数据库包含许多不一致的字段。例如，在一个数据库中名为 place_id 的客户记录字段，在另一个数据库中则被命名为 location_id。该公司需要在不同数据库之间关联客户记录，即使客户记录字段不匹配。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 创建一个配置好的 Amazon EMR 集群来处理和分析数据库中的数据。连接到 Apache Zeppelin 笔记本。使用 FindMatches 转换来查找数据中的重复记录。
- B. 创建一个 AWS Glue 爬虫来爬取数据库。使用 FindMatches 转换来查找数据中的重复记录。通过评估性能和结果来评估和调整该转换。
- C. 创建一个 AWS Glue 爬虫来抓取数据库。使用 Amazon SageMaker 构建 Apache Spark ML 管道以查找数据中的重复记录。
- D. 创建一个配置好的 Amazon EMR 集群来处理和分析数据库中的数据。连接到 Apache Zeppelin 笔记本。使用 Apache Spark ML 模型查找数据中的重复记录。通过评估性能和结果来评估和调整模型。

正确答案：B

部分：（无）

解释/参考：

问题 124

一家金融公司从第三方数据提供商处接收数据，并将这些数据以对象的形式存储在亚马逊 S3 存储桶中。

该公司在这些对象上运行了 AWS Glue 爬虫程序以创建数据目录。AWS Glue 爬虫程序创建了多个表。然而，该公司原本期望爬虫程序仅创建一个表。

该公司需要一个解决方案，以确保 AWS Glue 爬虫仅创建一张表。

哪种解决方案的组合能满足这一要求？（选择两项。）

- A. 确保每个对象的格式、压缩类型和模式都相同。
- B. 确保每个对象的格式和架构相同。不要强制要求每个对象的压缩类型一致。
- C. 确保每个对象的架构相同。不要强制要求每个对象的文件格式和压缩类型保持一致。
- D. 确保每个 S3 对象名称的前缀结构保持一致。
- E. 确保所有 S3 对象名称遵循类似的模式。

正确答案：AD

部分：（无）

解释/参考：

问题 125

一个应用程序从亚马逊简单队列服务（Amazon SQS）队列中获取消息。该应用程序偶尔会出现停机情况。由于停机，队列中的消息会在 1 天后过期并被删除。消息的删除导致应用程序的数据丢失。

哪些解决方案能将应用程序的数据丢失降至最低？（选择两项。）

- A. 延长消息保留期限
- B. 增加超时可见性。
- C. 将死信队列（DLQ）附加到 SQS 队列。
- D. 使用延迟队列来延迟消息的传递
- E. 减少消息处理时间。

正确答案：AC

部分：（无）

解释/参考：

问题 126

一家公司正在创建近乎实时的仪表板来可视化时间序列数据。该公司将数据摄入到亚马逊托管的 Apache Kafka 流服务（Amazon MSK）中。一个定制的数据管道会消费这些数据。然后，该管道将数据写入亚马逊密钥空间（适用于 Apache Cassandra）、亚马逊 OpenSearch 服务以及存储在亚马逊 S3 中的 Apache Avro 对象。

哪种解决方案能让数据以最低的延迟用于数据可视化？

- A. 使用 OpenSearch 服务中的数据创建 OpenSearch 仪表板。
- B. 使用带有 Apache Hive 元数据存储的 Amazon Athena 查询 Amazon S3 中的 Avro 对象。使用 Amazon Managed Grafana 连接到 Athena 并创建仪表板。
- C. 使用 Amazon Athena 查询存储在 Amazon S3 中的 Avro 对象中的数据。将 Amazon Keyspaces 配置为数据目录。将 Amazon QuickSight 连接到 Athena 以创建仪表板。
- D. 使用 AWS Glue 对数据进行编目。使用 S3 Select 查询 Amazon S3 中的 Avro 对象。将 Amazon QuickSight 连接到 S3 存储桶以创建仪表板。

正确答案：A

部分：（无）

解释/参考：

问题 127

一家媒体公司希望使用亚马逊 OpenSearch 服务来分析有关热门音乐艺人和歌曲的实时数据。该公司预计每天将接收数百万条新的数据事件。新的数据事件将通过亚马逊 Kinesis 数据流传入。该公司必须对数据进行转换，然后将其导入 OpenSearch 服务域。

公司应采用哪种方法来以最低的操作开销摄取数据？

- A. 使用 Amazon Kinesis Data Firehose 和 AWS Lambda 函数来转换数据，并将转换后的数据交付给 OpenSearch Service。
- B. 使用具有预构建过滤器的 Logstash 管道来转换数据，并将转换后的数据传递给 OpenSearch 服务。
- C. 使用 AWS Lambda 函数调用 Amazon Kinesis Agent 来转换数据，并将转换后的数据交付给 OpenSearch 服务。
- D. 使用 Kinesis 客户端库（KCL）来转换数据，并将转换后的数据传递给 OpenSearch 服务。

正确答案：A

部分：（无）

解释/参考：

问题 128

一家公司将包含客户地址的客户数据表存储在 AWS Lake Formation 数据湖中。为了遵守新的法规，该公司必须确保用户无法访问加拿大客户的任何数据。

该公司需要一个解决方案，以阻止用户访问加拿大客户的行数据。

哪种解决方案能以最少的操作努力满足这一要求？

- A. 设置行级筛选条件，以阻止用户访问国家为加拿大的行。
- B. 创建一个 IAM 角色，限制用户仅能访问国家为加拿大的地址。
- C. 设置列级筛选条件，以阻止用户访问“国家”为加拿大的行。
- D. 对所有国家为加拿大的行应用一个标签。禁止用户访问标签等于“加拿大”的行。

正确答案：A

部分：（无）

解释/参考：

问题 129

一家公司在亚马逊 Redshift 中实施了湖仓架构。该公司需要让用户能够通过第三方身份提供商（IdP）对 Redshift 查询编辑器进行身份验证。

数据工程师必须设置认证机制。

数据工程师为满足这一要求应采取的第一步是什么？

- A. 在 Redshift 集群的配置设置中将第三方身份提供程序注册为身份提供方。
- B. 在 Amazon Redshift 内将第三方身份提供商注册为身份提供程序。
- C. 将第三方身份提供商（IdP）注册为 AVS Secrets Manager 的身份提供商。配置亚马逊

Redshift 使用 Secrets Manager 来管理用户凭证。

D. 将第三方身份提供商注册为 AWS 证书管理器 (ACM) 的身份提供商。配置 Amazon Redshift 使用 ACM 来管理用户凭证。

正确答案：A

部分：（无）

解释/参考：

问题 130

该公司目前使用的是一个配置好的 Amazon EMR 集群，其中包括通用型的 Amazon EC2 实例。该 EMR 集群为公司的长期运行的 Apache Spark 提取、转换和加载 (ETL) 作业使用了 EMR 管理的缩放功能，任务节点数量在 1 到 5 之间。该公司每天都会运行 ETL 作业。

当公司运行 ETL 作业时，EMR 集群会迅速扩展到五个节点。EMR 集群的 CPU 使用率经常达到峰值，但内存使用率仍低于 30%。

该公司希望修改 EMR 集群配置，以降低运行每日 ETL 作业的 EMR 成本。

哪种解决方案能以最经济高效的方式满足这些要求？

- A. 将 EMR 管理的自动扩展的最大任务节点数增加到 10 个。
- B. 将任务节点类型从通用型 EC2 实例更改为内存优化型 EC2 实例。
- C. 将任务节点类型从通用型 EC2 实例切换为计算优化型 EC2 实例。
- D. 缩短已配置的 EMR 集群的缩放冷却期。

正确答案：C

部分：（无）

解释/参考：

问题 131

一家公司将.csv 文件上传至亚马逊 S3 存储桶。该公司的数据平台团队已设置了一个 AWS Glue 爬虫来执行数据发现，并创建表和模式。

一个 AWS Glue 作业将表中的处理数据写入 Amazon Redshift 数据库。该 AWS Glue 作业处理列映射，并在 Redshift 数据库中适当地创建 Amazon Redshift 表。

如果公司因任何原因重新运行 AWS Glue 作业，就会在 Amazon Redshift 表中引入重复记录。该公司需要一种解决方案，能够更新 Redshift 表且不产生重复记录。

哪种解决方案能满足这些要求？

- A. 修改 AWS Glue 作业，将行复制到暂存 Redshift 表中。添加 SQL 命令，使用暂存 Redshift 表中的新值更新现有行。
- B. 修改 AWS Glue 作业，将之前插入的数据加载到 MySQL 数据库中。在 MySQL 数据库中执行更新或插入操作。将结果复制到 Amazon Redshift 表中。
- C. 使用 Apache Spark 的 DataFrame 的 dropDuplicates() API 来消除重复项。将数据写入 Redshift 表中。
- D. 使用 AWS Glue 内置的 ResolveChoice 转换功能，从最新记录中选择该列的值。

正确答案：A

部分：（无）

解释/参考：

问题 132

一家公司正在使用亚马逊 Redshift 构建数据仓库解决方案。该公司正在将数百个文件加载到 Redshift 集群中的一个事实表中。

该公司希望数据仓库解决方案能够实现尽可能高的吞吐量。在将数据加载到事实表时，该解决方案必须能够最优地利用集群资源。

哪种解决方案能满足这些要求？

- A. 使用多个 COPY 命令将数据加载到 Redshift 集群中。
- B. 使用 S3DistCp 将多个文件加载到 Hadoop 分布式文件系统（HDFS）中。使用 HDFS 连接器将数据摄取到 Redshift 集群中。
- C. 使用与 Redshift 集群节点数量相等的多个 INSERT 语句。并行地将数据加载到每个节点中。
- D. 使用单个 COPY 命令将数据加载到 Redshift 集群中。

正确答案：D

部分：（无）

解释/参考：

问题 13

一家公司从多个数据源获取数据，并将数据存储到 Amazon S3 存储桶中。该公司使用 AWS Glue 提取、转换和加载（ETL）作业对数据进行转换，并将转换后的数据写入基于 Amazon S3 的数据湖。该公司使用 Amazon Athena 对数据湖中的数据进行查询。

即使记录没有共同的唯一标识符，公司也需要识别出匹配的记录。

哪种解决方案能满足这一要求？

- A. 在 ETL 作业中使用 Amazon Macie 的模式匹配功能。
- B. 在 ETL 作业中训练并使用 AWS Glue PySpark 过滤器类。
- C. 创建分区表，并使用 ETL 作业根据唯一标识符对数据进行分区。
- D. 在 ETL 作业中训练并使用 AWS Lake Formation 的 FindMatches 转换。

正确答案：D

部分：（无）

解释/参考：

问题 134

一位数据工程师正在使用 AWS Glue 爬虫程序对存储在 Amazon S3 存储桶中的数据进行编目。该 S3 存储桶中同时包含.csv 和.json 文件。数据工程师配置了爬虫程序，使其在编目时排除.json 文件。

当数据工程师在 Amazon Athena 中运行查询时，这些查询也会处理被排除的 .json 文件。数据工程师希望解决这个问题。数据工程师需要一个不会影响源 S3 存储桶中 .csv 文件访问要求的解决方案。

哪种解决方案能以最短的查询时间满足这一要求？

- A. 调整 AWS Glue 爬虫的设置，确保 AWS Glue 爬虫也将 .json 文件排除在外。
- B. 使用 Athena 控制台确保 Athena 查询也排除 .json 文件。
- C. 将 .json 文件重新定位到 S3 存储桶内的不同路径。
- D. 使用 S3 存储桶策略阻止对 .json 文件的访问。

正确答案：C

部分：（无）

解释/参考：

问题 135

一位数据工程师设置了一个 AWS Lambda 函数来读取存储在 Amazon S3 存储桶中的对象。该对象由 AWS KMS 密钥进行加密。

数据工程师为 Lambda 函数配置了执行角色以访问 S3 存储桶。然而，Lambda 函数遇到了错误，未能检索到对象的内容。

错误的可能原因是什么？

- A. 数据工程师错误配置了 S3 存储桶的权限。Lambda 函数无法访问该对象。
- B. 该 Lambda 函数使用的是过时的 SDK 版本，这导致了读取失败。
- C. S3 存储桶位于数据工程师所在区域之外的另一个 AWS 区域。由于延迟问题，Lambda 函数遇到了错误。
- D. Lambda 函数的执行角色没有访问能够解密 S3 对象的 KMS 密钥所需的权限。

正确答案：D

部分：（无）

解释/参考：

问题 136

一位数据工程师已在 1000 个 AWS Glue 数据目录表中实施了数据质量规则。由于近期业务需求发生变化，该数据工程师必须编辑这些数据质量规则。

数据工程师应如何以最低的操作开销来满足这一要求？

- A. 在 AWS Glue ETL 中创建一个管道，用于编辑 1000 个数据目录表中的每一张表的规则。使用 AWS Lambda 函数为每个数据目录表调用相应的 AWS Glue 作业。
- B. 创建一个 AWS Lambda 函数，通过调用 AWS Glue 数据质量 API 来进行编辑。
- C. 创建一个 Amazon EMR 集群。在 Amazon EMR 上运行一个管道，为每个数据目录表编辑规则。使用 AWS Lambda 函数来运行 EMR 管道。
- D. 使用 AWS 管理控制台编辑数据目录中的规则。

正确答案：B

部分：（无）

解释/参考：

问题 137

两名开发人员正在分别开发不同的应用程序版本。他们以 GitHub 代码库的主分支为源创建了名为分支 A 和分支 B 的功能分支。

A 分支的开发人员已将代码部署到生产系统。B 分支的代码将在下周计划的应用程序发布中合并到主分支。

在分支 B 的开发人员向主分支提出拉取请求之前，应该运行哪个命令？

- A. `git diff branchB master`
`git commit -m <消息>`

B. git 拉取 master 分支

git rebase master

D. git fetch -b master（注：此命令为原样保留，无需翻译。）

正确答案：C

部分：（无）

解释/参考：

问题 138

一家公司将员工数据存储在 Amazon Redshift 中。一张名为“Employee”的表使用名为“Region ID”（地区 ID）、“Department ID”（部门 ID）和“Role ID”（职位 ID）的列作为复合排序键。

使用表的复合排序键，哪些查询将最能提高查询速度？（选择两项。）

- A. 从“Employee”表中选择所有列，其中“Region ID”为“North America”。
- B. 从“员工”表中选择所有列，条件为“地区 ID”为“北美”且“部门 ID”为 20；
- C. 从“员工”表中选择所有列，条件为部门 ID 为 20 且地区 ID 为“北美”。
- D. 从“员工”表中选择所有字段，其中“角色 ID”等于 50；
- E. 从“员工”表中选择所有列，条件为“地区 ID”为“北美”且“角色 ID”为 50；

正确答案：BE

部分：（无）

解释/参考：

问题 139

一家公司从世界各地的测试机构接收测试结果。该公司将测试结果存储在数百万个 1KB 的 JSON 文件中，这些文件存放在一个 Amazon S3 存储桶里。一位数据工程师需要处理这些文件，将其转换为 Apache Parquet 格式，并加载到 Amazon Redshift 表中。这位数据工程师使用 AWS Glue 来处理文件，使用 AWS Step Functions 来编排流程，并使用 Amazon EventBridge 来安排任务。

该公司最近增加了更多的测试设施。处理文件所需的时间在增加。数据工程师必须减少数据处理时间。

哪种解决方案能最大程度地减少数据处理时间？

- A. 使用 AWS Lambda 将原始输入文件合并为较大的文件。将较大的文件写回 Amazon S3。使用 AWS Glue 处理这些文件。将文件加载到 Amazon Redshift 表中。
- B. 使用 AWS Glue 动态框架文件分组选项来摄取原始输入文件。处理这些文件。将文件加载到 Amazon Redshift 表中。
- C. 使用 Amazon Redshift 的 COPY 命令将原始输入文件直接从 Amazon S3 移动到 Amazon Redshift 表中。在 Amazon Redshift 中处理这些文件。
- D. 使用 Amazon EMR 而非 AWS Glue 对原始输入文件进行分组。在 Amazon EMR 中处理这些文件。将文件加载到 Amazon Redshift 表中。

正确答案：B

部分：（无）

解释/参考：

问题 140

一位数据工程师使用亚马逊托管的 Apache Airflow 工作流（Amazon MWAA）在 AWS 账户中运行数据管道。

最近有一个工作流未能运行。数据工程师需要使用 Apache Airflow 日志来诊断工作流的故障。

数据工程师应该使用哪种日志类型来诊断故障原因？

- A. 您的环境名称 - 网络服务器
- B. 您的环境名称 - 调度程序
- C. 您的环境名称 - 数据处理工作流（DAG）处理
- D. 您的环境名称 - 任务

正确答案：D

部分：（无）

解释/参考：

问题 141

一家金融公司使用亚马逊 Redshift 作为数据仓库。该公司将数据存储在与共享的亚马逊 S3 存储桶中。该公司使用亚马逊 Redshift Spectrum 来访问存储在 S3 存储桶中的数据。这些数据来自经过认证的第三方数据提供商。每个第三方数据提供商都有独特的连接详情。

为遵守相关规定，公司必须确保所有数据均无法从公司 AWS 环境之外访问。

公司应采取哪些步骤的组合来满足这些要求？（选择两项。）

- A. 用位于私有子网中的新 Redshift 集群替换现有的 Redshift 集群。使用接口 VPC 终端节点连接到 Redshift 集群。使用 NAT 网关为 Redshift 提供对 S3 存储桶的访问权限。
- B. 为每个数据提供者创建一个 AWS 云 HSM 硬件安全模块（HSM）。使用每个数据提供者对应的 HSM 对每个数据提供者的数据进行加密。
- C. 为 Amazon Redshift 集群启用增强型 VPC 路由。设置 AWS Direct Connect 连接，并在每个数据提供方与金融公司的 VPC 之间配置连接。
- D. 为表的主键和外键定义约束条件。
- E. 使用联合查询从每个数据提供方访问数据。不要将数据上传到 S3 存储桶。通过网关 VPC 终端节点执行联合查询。

正确答案：AC

部分：（无）

解释/参考：

问题 142

来自多个数据源的文件会定期存入亚马逊 S3 存储桶。一位数据工程师希望在新文件到达 S3 存储桶时，能够近乎实时地将其导入到亚马逊 Redshift 中。

哪种解决方案能满足这些要求？

- A. 使用查询编辑器 v2 来安排一个 COPY 命令，将新文件加载到 Amazon Redshift 中。
- B. 利用 Amazon Aurora 与 Amazon Redshift 之间的零 ETL 集成将新文件加载到 Amazon Redshift 中。
- C. 使用 AWS Glue 作业从新文件中提取、转换和加载（ETL）数据到 Amazon Redshift 中。
- D. 使用 S3 事件通知来调用一个 AWS Lambda 函数，将新文件加载到 Amazon Redshift 中。

正确答案：D

部分：（无）

解释/参考：

问题 143

一家科技公司目前使用亚马逊 Kinesis 数据流实时收集日志数据。该公司希望使用亚马逊 Redshift 进行下游的实时查询，并丰富日志数据。

哪种解决方案能以最低的操作开销将数据加载到 Amazon Redshift 中？

- A. 设置一个 Amazon Kinesis Data Firehose 交付流，将数据发送到 Redshift 预配置集群表。
- B. 设置一个 Amazon Kinesis Data Firehose 交付流，将数据发送到 Amazon S3。配置一个 Redshift 预留集群，每分钟加载一次数据。
- C. 配置 Amazon 管理的 Apache Flink 服务（之前称为 Amazon Kinesis Data Analytics）将数据直接发送到 Redshift 预配置集群表。
- D. 使用来自 Kinesis 数据流的 Amazon Redshift 流式数据摄取，并将数据以物化视图的形式呈现。

正确答案：D

部分：（无）

解释/参考：

问题 14

一家公司在本地 Oracle 数据库中维护着一个数据仓库。该公司希望在 AWS 上构建一个数据湖。该公司希望将数据仓库中的表加载到 Amazon S3 中，并每天同步从数据仓库传来的增量数据。

每张表都有一列包含单调递增的值。每张表的大小都小于 50GB。数据仓库中的表每天凌晨 1 点到 2 点之间进行刷新。业务智能团队每天上午 10 点到晚上 8 点之间查询这些表。

哪种解决方案能以最高效的操作方式满足这些要求？

- A. 使用 AWS 数据迁移服务（AWS DMS）的全量加载加持续数据复制（CDC）作业，将包含单调递增数据列的表从本地数据仓库加载到 Amazon S3 中。使用 AWS Glue 中的自定义逻辑将每日增量数据追加到位于 Amazon S3 中的全量加载副本中。
- B. 使用 AWS Glue 的 Java 数据库连接（JDBC）连接。为包含单调递增值的列配置作业书签。编写自定义逻辑，将每日增量数据追加到位于 Amazon S3 中的全量副本中。
- C. 每天使用 AWS 数据迁移服务（AWS DMS）的全量加载迁移将数据仓库表加载到 Amazon S3 中。每天覆盖前一天的全量加载副本。
- D. 每天使用 AWS Glue 将数据仓库表的完整副本加载到 Amazon S3 中。每天覆盖前一天的完整加载副本。

正确答案：A

部分：（无）

解释/参考：

问题 145

一家公司正在为新的分析团队构建一个数据湖。该公司使用亚马逊 S3 进行存储，并使用亚马逊 Athena 进行查询分析。亚马逊 S3 中的所有数据均采用 Apache Parquet 格式。

该公司正在其数据中心运行一个新的甲骨文数据库作为源系统。该数据库中有 70 个表，所有表都有主键。源系统中的数据偶尔会发生变化。该公司希望每天将这些表的数据导入数据湖。

哪种解决方案能以最少的努力满足这一要求？

- A. 在 Amazon EMR 中创建一个 Apache Sqoop 作业，从 Oracle 数据库读取数据。配置该 Sqoop 作业，将数据以 Parquet 格式写入 Amazon S3。
- B. 创建一个连接到 Oracle 数据库的 AWS Glue 连接。创建一个 AWS Glue 书签作业，以增量方式摄取数据，并将数据以 Parquet 格式写入 Amazon S3。
- C. 创建一个 AWS 数据迁移服务（AWS DMS）任务以进行持续复制。将 Oracle 数据库设置为源。将 Amazon S3 设置为目标。配置任务以 Parquet 格式写入数据。
- D. 在亚马逊 RDS 中创建一个 Oracle 数据库。使用 AWS 数据库迁移服务（AWS DMS）将本地的 Oracle 数据库迁移到亚马逊 RDS。在表上配置触发器以调用 AWS Lambda 函数，将更改后的记录以 Parquet 格式写入亚马逊 S3。

正确答案：C

部分：（无）

解释/参考：

问题 146

一家运输公司希望通过获取地理位置记录来追踪车辆的移动情况。这些记录每条大小为 10 字节。该公司每秒最多会收到 10000 条记录。由于网络状况不稳定，数据传输延迟几分钟是可以接受的。

这家运输公司希望使用亚马逊 Kinesis 数据流来接收地理定位数据。该公司需要一种可靠的机制将数据发送到 Kinesis 数据流。该公司需要最大限度地提高 Kinesis 分区的吞吐量效率。

哪种解决方案将以最高效的操作方式满足这些要求？

- A. Kinesis 代理
- B. Kinesis 生产者库（KPL）
- C. 亚马逊 Kinesis 数据火线
- D. Kinesis 软件开发工具包

正确答案：B

部分：（无）

解释/参考：

问题 147

一家投资公司需要管理和从不断增长的大量半结构化数据中提取有价值的信息。

数据工程师需要对半结构化数据进行去重处理，删除重复的记录，并去除重复记录中常见的拼写错误。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 使用 AWS Glue 的 FindMatches 功能来删除重复记录。
- B. 在 Amazon Athena 中使用非 Windows 函数来删除重复记录。
- C. 使用 Amazon Neptune ML 和 Apache Gremlin 脚本删除重复记录。
- D. 使用亚马逊 DynamoDB 的全局表功能来防止数据重复。

正确答案：A

部分：（无）

解释/参考：

问题 148

一家公司正在构建一个库存管理系统和一个库存自动补货系统。这两个系统都使用亚马逊 Kinesis 数据流。库存管理系统使用亚马逊 Kinesis 生产者库（KPL）将数据发布到流中。库存自动补货系统使用亚马逊 Kinesis 客户端库（KCL）从流中获取数据。该公司将流配置为根据需要进行扩展和收缩。

在公司把系统部署到生产环境之前，公司发现库存补货系统收到了重复的数据。

哪些因素可能导致重新排序系统收到重复的数据？（选择两项。）

- A. 生产者遇到了与网络相关的超时问题。
- B. 该流对于“IteratorAgeMilliseconds”指标的值过高。
- C. 分片数量、记录处理器数量或两者都发生了变化。
- D. “聚合启用”配置属性已设置为“真”。
- E. “max_records”配置属性被设置为一个过高的数值。

正确答案：AC

部分：（无）

解释/参考：

问题 149

一家电子商务公司运营着一个复杂的订单履行流程，该流程跨越了托管在 AWS 上的多个运营系统。每个运营系统都有一个 Java 数据库。

符合连接性（JDBC）规范的关系型数据库，其中捕获了最新的处理状态。

该公司需要赋予运营团队能力，使其能够每小时追踪整个订单履行流程中的订单情况。

哪种解决方案能在开发成本最低的情况下满足这些要求？

- A. 使用 AWS Glue 从运营系统构建数据摄取管道到 Amazon Redshift 中，并在 Amazon QuickSight 中构建跟踪订单的仪表板。
- B. 使用 AWS Glue 构建从运营系统到 Amazon DynamoDB 的数据摄取管道。在 Amazon QuickSight 中构建仪表板以跟踪订单。
- C. 使用 AWS 数据迁移服务（AWS DMS）捕获运营系统中的变更记录。将变更发布到与源数据库位于不同 AWS 区域的 Amazon DynamoDB 表中。构建 Grafana 仪表板以跟踪订单。
- D. 使用 AWS 数据迁移服务（AWS DMS）捕获运营系统中的变更记录。将变更发布到与源数据库位于不同 AWS 区域的 Amazon DynamoDB 表中。构建 Amazon QuickSight 仪表板以跟踪订单。

正确答案：D

部分：（无）

解释/参考：

问题 150

一名数据工程师需要使用亚马逊 Neptune 来开发图应用程序。

工程师应使用哪些编程语言来开发图形应用程序？（选择两项。）

- A. 小精灵
- B. SQL

- C. 美国国家标准协会 SQL (ANSI SQL)
- D. SPARQL
- E. Spark SQL

正确答案：AD

部分：（无）

解释/参考：

问题 151

一家移动游戏公司希望从其游戏应用程序中获取数据。该公司希望将这些数据提供给三个内部数据使用者。数据记录的大小约为 20KB。

该公司希望从运行游戏应用程序的每台设备中实现最佳吞吐量。此外，该公司还希望开发一个用于处理数据流的应用程序。流处理应用程序必须为每个内部消费者提供专用的吞吐量。

哪种解决方案能满足这些要求？

- A. 配置移动应用程序以调用 PutRecords API 操作将数据发送到 Amazon Kinesis 数据流。为每个内部消费者使用具有增强扇出功能的数据流。
- B. 配置移动应用程序以调用 PutRecordBatch API 操作将数据发送到 Amazon Kinesis Data Firehose。提交 AWS 支持案例为公司的 AWS 账户开启专用吞吐量。允许每个内部使用者访问该流。
- C. 配置移动应用程序使用 Amazon Kinesis 生产者库（KPL）将数据发送到 Amazon Kinesis Data Firehose。为每个内部消费者使用流的增强型扇出功能。
- D. 配置移动应用程序以调用 PutRecords API 操作将数据发送到 Amazon Kinesis 数据流。在 Amazon EC2 实例上为每个内部消费者托管流处理应用程序。为 EC2 实例配置自动扩展。

正确答案：A

部分：（无）

解释/参考：

问题 152

一位数据工程师维护着一个基于亚马逊 Redshift 数据库的物化视图。该视图有一个名为 load_date 的列，用于存储每行数据的加载日期。

数据工程师需要通过从物化视图中删除所有行来回收数据库存储空间。

哪个命令能回收最多的数据库存储空间？

- A. `DELETE FROM materialized_view_name where 1=1`
- B. `TRUNCATE materialized_view_name`
- C. `VACUUM table_name where load_date<=current_date`
`materializedview`
- D. `DELETE FROM materialized_view_name where load_date<=current_date`

正确答案：B

部分：（无）

解释/参考：

问题 153

一家零售公司使用亚马逊 Redshift 数据仓库和亚马逊 S3 存储桶。该公司每天将零售订单数据导入 S3 存储桶。

该公司将所有订单数据存储存储在 S3 存储桶内的单一路径中。这些数据包含超过 100 个字段。该公司从第三方应用程序中获取订单数据，该应用程序每天生成超过 30 个 CSV 格式的文件。每个 CSV 文件的大小在 50 到 70MB 之间。

该公司使用亚马逊 Redshift Spectrum 来运行选择列集的查询。用户根据每日订单来汇总指标。最近，用户报告称这些查询的性能有所下降。一名数据工程师必须解决这些查询的性能问题。

哪种组合 哪些步骤能以最少的开发工作满足此要求？（选择两项。）

- A. 将第三方应用程序配置为以列式格式创建文件。
- B. 开发一个 AWS Glue ETL 作业，将每天的多个 CSV 文件转换为每天一个文件。
- C. 根据订单日期对 S3 存储桶中的订单数据进行分区。
- D. 将第三方应用程序配置为以 JSON 格式创建文件。
- E. 将 JSON 数据加载到 Amazon Redshift 表的 SUPER 类型列中。

正确答案：AC

部分：（无）

解释/参考：

解释：

像 Parquet 或 ORC 这样的列式格式能够优化查询性能，尤其是在使用 Redshift Spectrum 等服务时。Redshift Spectrum 允许直接在 S3 中查询数据，而列式格式有助于减少查询期间扫描的数据量，因为只需读取所需的列。这减少了 I/O 操作并加快了查询速度，无需加载数据集中的所有列。这种改变在查询具有众多列的大型数据集时尤其有益，就像在此场景中一样。

在 Amazon S3 中对数据进行分区有助于 Redshift Spectrum 剔除不必要的数据，从而提高查询性能。按照诸如订单日期这样经常用于筛选的列进行分区，Redshift Spectrum 只需扫描相关分区，减少了需要处理的数据量，从而加快了查询速度。

虽然合并文件可能会减少文件数量并略微提高性能，但这并不能解决优化数据格式和分区这一核心问题，而后者对性能的影响要大得多。

JSON 不是大规模分析的高效格式，与列式格式相比，其性能往往更差。在这种情况下，Parquet 或 ORC 等列式格式更可取。

在 Redshift 中，SUPER 类型对于半结构化数据很有用，但在这种情况下，它与提高查询性能并无直接关系，而列式格式和分区则会带来更大的益处。

问题 154

该公司将客户记录存储在亚马逊 S3 中。每条记录创建后的 7 年内，公司不得删除或修改客户记录数据。根用户也不得拥有删除或修改这些数据的权限。

一位数据工程师想要使用 S3 对象锁定功能来保护数据。

哪种解决方案能满足这些要求？

- A. 在 S3 存储桶上启用治理模式。使用默认的 7 年保留期。
- B. 在 S3 存储桶上启用合规模式。使用默认的 7 年保留期。
- C. 对 S3 存储桶中的单个对象设置法律保留。将保留期限设置为 7 年。
- D. 将 S3 存储桶中单个对象的保留期设置为 7 年。

正确答案：B

部分：（无）

解释/参考：

解释：

合规模式是 S3 对象锁定的更严格模式。启用后，即使根用户也无法在保留期结束前修改或删除对象。在这种情况下，为了满足 7 年内不得删除或修改数据的要求，合规模式是正确的选择。

治理模式允许具有特殊权限的某些用户（例如 root 用户）绕过锁定并删除或修改数据，这不符合即使 root 用户也不应具备此能力的严格要求。

法律保留用于防止在未指定基于时间的保留期的情况下删除对象，但拥有足够权限的用户可以将其移除，而根用户仍可能删除数据。

可以为单个对象设置保留期限，但启用合规模式能提供更可靠的解决方案，通过在整个存储桶内应用相同的 7 年保留策略，确保在此期间内不会发生任何修改或删除操作。

问题 15

一位数据工程师需要在 Amazon Athena 中创建一个全新的空表，该表的架构与现有名为 old_table 的表相同。

数据工程师应该使用哪条 SQL 语句来满足此要求？

- A. `CREATE TABLE new_table AS SELECT * FROM old_tables;`
- B. `INSERT INTO new_table SELECT * FROM old_table;`
- C. `CREATE TABLE new_table (LIKE old_table);`
- D. `CREATE TABLE new_table AS (SELECT * FROM old_table) WITH NO DATA;`

正确答案：D

部分：（无）

解释/参考：

问题 156

一位数据工程师需要基于现有名为 “cities_world” 的 Amazon Athena 表中的部分数据创建一个新的 Athena 表。该 “cities_world” 表包含了世界各地的城市。数据工程师必须创建一个名为 “cities_us” 的新表，其中仅包含 “cities_world” 表中位于美国的城市。

数据工程师应该使用哪条 SQL 语句来满足此要求？

- A. 将 cities_world 表中的 city 和 state 列插入到 cities_usa 表中
国家为 “usa” 的记录；
- B. 将 cities_world 表中 country 为 ‘usa’ 的 city 和 state 字段移动到 cities_usa 表中；
- C. 将以下语句插入到 cities_usa 表中： `SELECT city, state FROM cities_world WHERE 国家 = '美国'`
- D. 将表 `cities\_usa` 中的 `city` 和 `state` 列更新为从 `cities\_world` 表中 `country` 为 ‘usa’ 的行所对应的 `city` 和 `state` 值。

正确答案：A

部分：（无）

解释/参考：

问题 157

一家公司实施了一个具有中央治理账户的数据网格。该公司需要对治理账户中的所有数据进行编目。治理账户使用 AWS Lake Formation 来集中共享数据并授予访问权限。

该公司开发了一款新的数据产品，其中包含一组亚马逊 Redshift 无服务器表。一名数据工程师需要与营销团队共享此数据产品。营销团队只能访问其中的一部分列。该数据工程师还需要与合规团队共享同一数据产品，但合规团队需要访问的列与营销团队需要访问的列不同。

数据工程师应采取哪些步骤组合来满足这些要求？（选择两项。）

- A. 创建需要共享的表的视图。仅包含所需的列。
- B. 创建一个包含需要共享的表的 Amazon Redshift 数据共享。
- C. 在营销团队的账户中创建一个亚马逊 Redshift 管理的 VPC 端点。授予营销团队对视图的访问权限。
- D. 将 Amazon Redshift 数据共享分享到治理账户中的 Lake Formation 目录。
- E. 将 Amazon Redshift 数据共享分享给营销团队账户中的 Amazon Redshift Serverless 工作组。

正确答案：BD

部分：（无）

解释/参考：

问题 158

一家公司在亚马逊 S3 上拥有一个数据湖。该公司使用 AWS Glue 来编目数据，并使用 AWS Glue Studio 来实现数据提取、转换和加载（ETL）管道。

公司需要确保每次管道运行时都检查数据质量问题。数据工程师必须改进现有的管道，以便根据预定义的阈值评估数据质量规则。

哪种解决方案能以最少的实施工作量满足这些要求？

- A. 在每个 Glue ETL 作业中添加一个由 SQL 查询定义的新转换。使用该 SQL 查询来实现包含需要评估的数据质量规则的规则集。
- B. 在每个 Glue ETL 作业中添加一个新的“评估数据质量”转换。使用数据质量定义语言（DQDL）实现一个规则集，其中包含需要评估的数据质量规则。
- C. 在每个 Glue ETL 作业中添加一个新的自定义转换。使用 PyDeequ 库来实现一个规则集，其中包含需要评估的数据质量规则。
- D. 在每个 Glue ETL 作业中添加一个新的自定义转换。使用 Great Expectations 库来实现一个规则集，其中包含需要评估的数据质量规则。

正确答案：B

部分：（无）

解释/参考：

解释：

在 AWS Glue 中评估数据质量转换是一项内置功能，它允许应用数据质量定义语言（DQDL）直接在 AWS Glue ETL 作业中定义和应用数据质量规则。此选项实施工作量最小，因为它利用了 AWS Glue 的原生功能，使数据工程师能够轻松添加和执行数据质量检查，而无需编写自定义代码或使用外部库。

虽然 SQL 可以实现数据质量规则，但这种方法需要在每个作业中手动编写和管理 SQL 查询，与使用内置的 Glue 功能相比，实施起来更为费力。

PyDeequ 是一个外部库，需要自定义编码和额外的集成工作。尽管它很有效，但与使用 AWS Glue 的内置功能相比，它需要更多的实现工作。

《远大前程》是另一个外部数据质量库。虽然它很强大，但也需要自定义编码。

并且与 AWS Glue 的原生数据质量评估工具相比，维护工作量更大。

问题 159

一家公司拥有一款采用微服务架构的应用程序。该公司将该应用程序部署在亚马逊弹性 Kubernetes 服务（Amazon EKS）集群上。

该公司希望为应用程序建立一个强大的监控系统。公司需要分析来自 EKS 集群和应用程序的日志。公司需要将集群的日志与应用程序的跟踪信息关联起来，以确定整个应用程序请求流程中的故障点。

哪种步骤组合能以最少的开发工作量满足这些要求？（选择两项。）

- A. 使用 FluentBit 收集日志。使用 OpenTelemetry 收集跟踪信息。
- B. 使用 Amazon CloudWatch 收集日志。使用 Amazon Kinesis 收集跟踪信息。
- C. 使用 Amazon CloudWatch 收集日志。使用 Amazon 管理的 Apache Kafka 流服务（Amazon MSK）收集跟踪信息。
- D. 使用 Amazon OpenSearch 来关联日志和跟踪信息。
- E. 使用 AWS Glue 来关联日志和跟踪信息。

正确答案：AD

部分：（无）

解释/参考：

解释：

FluentBit 是一款轻量级且高效的工具，用于从 EKS 集群收集、处理和转发日志。它能很好地与 CloudWatch 或 OpenSearch 等 AWS 服务集成，以存储和分析日志。OpenTelemetry 是一个用于收集分布式跟踪的开源标准，非常适合在微服务架构中监控和分析应用程序性能。使用这些工具所需的开发工作量极小，因为它们已被广泛采用，并且与 AWS 具有强大的集成能力。

亚马逊 OpenSearch（原名 Elasticsearch）是一项完全托管的服务，可轻松存储、搜索和分析日志数据，包括分布式系统的跟踪信息。它通常用于关联日志和跟踪信息，因为它提供了强大的查询功能和可视化特性（通过 Kibana 或 OpenSearch Dashboards 实现）。此解决方案提供了进行日志跟踪关联所需的工具，且所需的自定义开发工作量极小。

虽然 CloudWatch 适合收集日志，但 Amazon Kinesis 更适合实时数据流处理，而非用于收集跟踪信息以进行关联。与 OpenTelemetry 追踪相比，Kinesis 还需要更多的配置和开发工作。

与 Kinesis 类似，Amazon MSK 主要用于数据流传输而非跟踪收集。与 FluentBit 和 OpenTelemetry 提供的更直接的集成相比，它需要额外的设置和自定义开发才能实现关联。

AWS Glue 主要用于数据湖中的 ETL（提取、转换、加载）操作。它并非为实时日志和跟踪关联而设计，与 OpenSearch 的内置功能相比，需要投入大量的开发工作。

问题 160

一家公司拥有一款游戏应用程序，其数据存储在 Amazon DynamoDB 表中。一名数据工程师需要将游戏数据导入到 Amazon OpenSearch Service 集群中。数据更新必须近乎实时地进行。

哪种解决方案能满足这些要求？

- A. 使用 AWS Step Functions 定期将数据从 Amazon DynamoDB 表导出到 Amazon S3 存储桶。使用 AWS Lambda 函数将数据加载到 Amazon OpenSearch Service 中。
- B. 配置一个 AWS Glue 作业，使其数据源为 Amazon DynamoDB，目标为 Amazon OpenSearch Service，以近乎实时的方式传输数据。
- C. 使用 Amazon DynamoDB Streams 捕获表的变化。使用 AWS Lambda 函数进行处理

并更新亚马逊 OpenSearch 服务中的数据。

D. 使用自定义的 OpenSearch 插件从 Amazon DynamoDB 表中同步数据。

正确答案：C

部分：（无）

解释/参考：

解释：

DynamoDB 流可以在近乎实时的情况下捕获 DynamoDB 表中项目的更改（例如插入、更新和删除）。AWS Lambda 函数可以由这些流触发，该函数可以处理这些更改并更新 Amazon OpenSearch Service 中的数据。此解决方案满足了近乎实时更新且延迟极小的要求。

“使用 AWS Step Functions 定期将数据从 Amazon DynamoDB 表导出到 Amazon S3 存储桶，然后使用 AWS Lambda 函数将数据加载到 Amazon OpenSearch Service 中。”此解决方案涉及定期导出数据，无法满足近乎实时更新的要求。定期导出可能会导致延迟。

AWS Glue 通常用于批处理，它并非为近实时数据摄取而设计。对于实时或低延迟需求而言，它并非理想之选。

“使用自定义的 OpenSearch 插件从 Amazon DynamoDB 表同步数据”这一选项意味着要构建一个自定义解决方案，这将需要大量的开发工作。此外，OpenSearch 本身并不支持此类插件，因此与使用专门设计为协同工作的 DynamoDB Streams 和 Lambda 相比，此方案的实用性较低。

问题 161

一家公司使用亚马逊 Redshift 作为其数据仓库服务。一名数据工程师需要设计一个物理数据模型。

数据工程师遇到了一张不断增大的非规范化表。这张表没有合适的列可用作分布键。

数据工程师应采用哪种分发方式才能以最低的维护开销满足这些要求？

- A. 全部分发
- B. 均匀分布
- C. 自动分配
- D. 密钥分发

正确答案：C

部分：（无）

解释/参考：

解释：

AUTO 分布方式允许 Amazon Redshift 根据表的大小自动管理分布样式。使用此选项，Redshift 会选择最优的分布方法，并且随着表的增长，它会调整分布样式以保持性能。这最大限度地减少了维护开销，因为系统会自动适应而无需手动调整。

ALL 分布方式会将整个表复制到所有节点。对于小型的静态表，这种方式可能有用，但对于大型或不断增长的表来说，这种方式效率低下，因为它会显著增加存储和 I/O 成本。

EVEN 分布会将行均匀地分布在所有节点上。虽然它减少了数据倾斜，但对于较大的表来说，某些查询可能受益于将数据本地化以减少跨节点流量，因此这种分布方式可能并非最优。

KEY 分布方式是根据特定列（分布键）中的值来分布数据的。由于问题中提到不存在合适的列作为分布键，因此这种方法并不适用。

问题 162

一家零售公司正在全球范围内拓展业务。该公司需要使用亚马逊 QuickSight 准确计算货币汇率以编制财务报告。该公司现有的仪表板中包含一个基于包含全球货币价值和汇率数据集的分析的可视化图表。

数据工程师需要确保汇率计算精确到小数点后四位。计算结果必须预先计算好。数据工程师必须将结果在 QuickSight 的超快速、并行、内存计算引擎（SPICE）中进行固化。

哪种解决方案能满足这些要求？

- A. 在数据集中定义并创建计算字段。
- B. 在分析中定义并创建计算字段。
- C. 在视觉对象中定义并创建计算字段。
- D. 在仪表板中定义并创建计算字段。

正确答案：A

部分：（无）

解释/参考：

解释：

在数据集中定义并创建计算字段，可确保汇率计算在存储到 SPICE（QuickSight 的超快速、并行、内存计算引擎）之前预先完成。这使得计算结果得以固化，并能在不同的分析和可视化中重复使用，从而保证精度并优化性能。

在分析中创建计算字段会在分析级别计算结果，而不是在数据集内计算。这种方法无法保证在 SPICE 中预先计算，并且可能会增加每次分析的计算开销。

在视觉对象中定义字段意味着每次渲染视觉对象时都会动态执行计算，这无法利用 SPICE 的预计算优势，可能会导致性能变慢。

在仪表板级别创建计算字段与在可视化级别创建类似，这意味着计算不会预先在 SPICE 中计算并存储，从而可能导致性能问题，并且在不同分析或可视化中对计算的复用性降低。

问题 163

一家公司有三个子公司。每个子公司使用不同的数据仓库解决方案。第一个子公司将其数据仓库托管在亚马逊 Redshift 上。第二个子公司在 AWS 上使用 Teradata Vantage。第三个子公司使用谷歌 BigQuery。

该公司希望将所有数据聚合到一个中央的亚马逊 S3 数据湖中。该公司希望使用 Apache Iceberg 作为表格式。

数据工程师需要构建一条新的数据管道，以连接到所有数据源，使用每个源引擎运行转换操作，合并数据，并将数据写入 Iceberg。

哪种解决方案能以最少的操作努力满足这些要求？

- A. 在 AWS Glue 中使用原生的 Amazon Redshift、Teradata 和 BigQuery 连接器构建管道。使用原生的 AWS Glue 转换功能来连接数据。在数据湖 Iceberg 表上运行合并操作。
- B. 使用 Amazon Athena 的 Amazon Redshift、Teradata 和 BigQuery 联合查询连接器在 Athena 中构建管道。编写一个 SQL 查询，从所有数据源读取数据，将数据进行连接，并在数据湖 Iceberg 表上运行合并操作。
- C. 使用原生的 Amazon Redshift 连接器、Teradata 的 Java 数据库连接（JDBC）连接器以及开源的 Apache Spark BigQuery 连接器在 Amazon EMR 中构建管道。使用 PySpark 编写代码来连接数据。在数据湖 Iceberg 表上运行合并操作。
- D. 使用 Amazon Appflow 中的原生 Amazon Redshift、Teradata 和 BigQuery 连接器将数据写入 Amazon S3 和 AWS Glue 数据目录。使用 Amazon Athena 来合并数据。运行合并操作。

对数据湖中的 Iceberg 表进行操作。

正确答案：B

部分：（无）

解释/参考：

解释：

亚马逊 Athena 联合查询功能支持从多个数据源（包括亚马逊 Redshift、Teradata 和谷歌 BigQuery）查询数据，使用其联合查询连接器即可实现。该解决方案采用无服务器模式，减少了管理基础设施的运营开销，同时允许在所有数据源之间进行基于 SQL 的转换。读取并合并数据后，Athena 可以通过合并操作将结果写回亚马逊 S3 中的 Iceberg 表格式。

这种方法将操作工作降至最低，因为 Athena 通过其连接器管理连接到不同数据库的复杂性，您可以使用熟悉的 SQL 执行必要的转换和数据连接操作。

虽然 AWS Glue 是一款强大的 ETL 工具，但在多个系统间管理复杂的转换操作需要投入更多的运维精力，而且在 Glue 中管理针对不同引擎（如 Redshift、Teradata、BigQuery）的原生转换也会带来额外的复杂性。

使用 Amazon EMR 和 PySpark 可以完成这项任务，但管理维护 EMR 集群需要投入更多的运营精力。编写和维护 PySpark 代码相比在 Athena 中使用 SQL 也会更复杂。

Appflow 主要用于在 SaaS 应用程序和 AWS 服务之间进行简单的数据迁移，但它无法提供此场景所需的复杂转换和连接功能。在 Appflow 之后使用 Athena 进行连接操作，相比直接在 Athena 中使用联邦查询，会增加不必要的复杂性。

问题 164

一家公司正在构建一个数据流处理应用程序。该应用程序在亚马逊弹性 Kubernetes 服务（Amazon EKS）集群中运行。应用程序将处理后的数据存储在 Amazon DynamoDB 表中。

该公司希望 EKS 集群中的应用容器能够安全访问 DynamoDB 表，但又不想在容器中嵌入 AWS 凭证。

哪种解决方案能满足这些要求？

- A. 将 AWS 凭证存储在 Amazon S3 存储桶中。授予 EKS 容器访问该 S3 存储桶的权限，以便其获取凭证。
- B. 将一个 IAM 角色附加到 EKS 工作节点，授予该 IAM 角色对 DynamoDB 的访问权限。使用该 IAM 角色设置 IAM 角色服务账户（IRSA）功能。
- C. 创建一个具有访问密钥以访问 DynamoDB 表的 IAM 用户。在 EKS 容器中使用环境变量来存储 IAM 用户访问密钥数据。
- D. 创建一个具有访问密钥以访问 DynamoDB 表的 IAM 用户。使用挂载在 EKS 集群节点卷中的 Kubernetes 密钥来存储用户访问密钥数据。

正确答案：B

部分：（无）

解释/参考：

解释：

服务账户的 IAM 角色（IRSA）允许根据 Kubernetes 服务账户为 EKS Pod 分配细粒度权限。这种方法确保 AWS 凭证不会被硬编码或存储在环境变量中，从而提高了安全性。相反，在 EKS 集群中运行的 Pod 会承担具有安全访问 Amazon DynamoDB 权限的 IAM 角色。

此解决方案满足了在不将 AWS 凭证嵌入容器的情况下提供安全访问的要求，同时还允许在 Pod 级别实现更精细的访问控制，而非依赖于节点级别的 IAM 角色。

将 AWS 凭证存储在 S3 中是不安全的，也不推荐这样做。这种方法不符合避免嵌入 AWS 凭证的安全要求。

将 AWS 凭证存储在环境变量中是不安全的，也不建议这样做。这会使凭证在容器内暴露，从而增加凭证泄露的风险。

尽管 Kubernetes 密钥可以提供一定的保护，但将长期的 AWS 凭证（访问密钥和秘密密钥）存储在密钥中仍存在安全风险。推荐的方法是通过 IAM 角色（IRSA）使用临时凭证，这些凭证会自动轮换。

问题 165

一位数据工程师需要将新的数据生产者引入 AWS。该数据生产者需要将数据产品迁移到 AWS 上。

数据生产者维护着许多支持业务应用程序的数据管道。每个管道都必须有服务账户及其相应的凭证。数据工程师必须从数据生产者的本地数据中心与 AWS 建立安全连接。数据工程师不得使用公共互联网将数据从本地数据中心传输到 AWS。

哪种解决方案能满足这些要求？

- A. 指示新的数据生成方在亚马逊弹性容器服务（Amazon ECS）上创建亚马逊机器映像（AMIs）以存储应用程序的代码库。在公共子网中创建安全组，仅允许与本地数据中心建立连接。
- B. 创建一条连接到本地数据中心的 AWS Direct Connect 连接。将服务账户凭证存储在 AWS Secrets Manager 中。
- C. 在公共子网中创建一个安全组。将该安全组配置为仅允许来自与数据生产者对应的 CIDR 块的连接。创建包含具有 1 天有效期的预签名 URL 的 Amazon S3 存储桶。
- D. 创建一条连接到本地数据中心的 AWS Direct Connect 连接。将应用程序密钥存储在 AWS Secrets Manager 中。创建包含有效期为一天的预签名 URL 的 Amazon S3 存储桶。

正确答案：B

部分：（无）

解释/参考：

解释：

AWS 直连服务（AWS Direct Connect）提供了一条专用的私有网络连接，将本地数据中心与 AWS 相连，确保数据不会通过公共互联网传输。这满足了安全、私有连接的要求。

AWS Secrets Manager 可安全地存储、轮换和管理对敏感信息（如服务账户凭证）的访问，从而减少在代码或配置文件中嵌入凭证的需求。

问题 16

一位数据工程师为存储在 Amazon S3 存储桶中的数据配置了 AWS Glue 数据目录。该数据工程师需要配置数据目录以接收增量更新。

数据工程师为 S3 存储桶设置事件通知，并创建一个亚马逊简单队列服务（Amazon SQS）队列来接收 S3 事件。

数据工程师应采取哪两种步骤的组合来以最低的操作开销满足这些要求？（选择两项。）

- A. 创建一个基于 S3 事件的 AWS Glue 爬虫，以从 SQS 队列中获取事件。
- B. 定义一个基于时间的计划来运行 AWS Glue 爬虫程序，并对数据目录执行增量更新。
- C. 使用 AWS Lambda 函数根据 SQS 队列接收到的 S3 事件直接更新数据目录。

- D. 当 S3 存储桶发生变化时，手动启动 AWS Glue 爬虫程序以对数据目录执行更新操作。
- E. 使用 AWS Step Functions 来编排基于 SQS 队列接收到的 S3 事件来更新数据目录的流程。

正确答案：AC

部分：（无）

解释/参考：

解释：

AWS Glue 爬虫可以配置为与 S3 事件通知配合使用，并从 SQS 队列中获取事件。这使得爬虫能够自动检测 S3 存储桶中的更改，并对数据目录进行增量更新，通过自动化更新来最大程度地减少操作开销。

您可以使用 AWS Lambda 处理从 SQS 队列接收的 S3 事件。Lambda 函数可以配置为自动更新 Glue 数据目录，从而确保更改几乎实时反映出来，无需人工干预，这也有助于降低运营成本。

基于时间的调度无法满足实时接收增量更新的要求。与事件驱动的更新相比，调度会增加不必要的延迟和操作复杂性。

手动触发爬虫会带来很高的操作开销，也不符合减少更新数据目录所需人工流程的要求。

虽然可以使用 Step Functions 进行编排，但与使用事件驱动的 Lambda 函数相比，这会增加复杂性，而 Lambda 函数为处理 S3 事件提供了更简单、更直接的解决方案。

问题 167

一家公司使用 AWS Glue 数据目录来索引每天上传到 Amazon S3 存储桶的数据。该公司使用每日批处理流程在提取、转换和加载（ETL）管道中将来自外部源的数据上传到 S3 存储桶。

该公司每天都会对 S3 数据生成一份报告。有时，该公司在所有每日数据尚未上传至 S3 存储桶时就运行了报告。数据工程师必须能够向现有的亚马逊简单通知服务（Amazon SNS）主题发送一条消息，以标识任何不完整的数据。

哪种解决方案能在操作开销最小的情况下满足这一要求？

- A. 为每日报告所使用的源数据集创建数据质量检查。创建一个新的 AWS 管理的 Apache Airflow 集群。通过使用 Airflow 任务运行数据质量查询来执行数据质量检查，这些任务会检查列的数据类型以及空值的存在情况。配置 Airflow 有向无环图（DAG），以便向 SNS 主题发送电子邮件通知，告知数据工程师有关不完整的数据集的情况。
- B. 在每日报告所使用的源数据集上创建数据质量检查。创建一个新的 Amazon EMR 集群。使用 Apache Spark SQL 在 EMR 集群中创建 Apache Spark 作业，对列的数据类型和空值的存在情况进行数据质量查询。通过使用 AWS Step Functions 工作流来编排 ETL 管道。配置工作流，使其向 SNS 主题发送电子邮件通知，告知数据工程师有关不完整的数据集的情况。
- C. 在每日报告所使用的源数据集上创建数据质量检查。使用 AWS Glue 工作流创建数据质量操作，以确认数据集的完整性和一致性。配置数据质量操作，如果数据集不完整则在 Amazon EventBridge 中创建一个事件。配置 EventBridge 将有关不完整数据集的通知事件发送到 Amazon SNS 主题，以告知数据工程师。
- D. 创建 AWS Lambda 函数，对列的数据类型和空值的存在情况进行数据质量查询。使用 AWS Step Functions 工作流来编排 ETL 管道，运行这些 Lambda 函数。配置 Step Functions 工作流，向 SNS 主题发送电子邮件通知，告知数据工程师有关不完整数据集的信息。

正确答案：C

部分：（无）

解释/参考：

解释：

AWS Glue 工作流和数据质量操作可与 AWS Glue 无缝集成，确保在 ETL 作业完成后自动执行数据质量检查。该解决方案利用现有的 AWS Glue 基础设施和 EventBridge 来触发通知，无需使用像 Apache Airflow 或 EMR 这样复杂的编排工具，从而降低了运营开销。

亚马逊 EventBridge 可以轻松配置为在数据集不完整时触发向亚马逊 SNS 发送通知，从而提供一种高度自动化且维护成本低的解决方案。

Airflow 需要管理单独的集群并配置有向无环图（DAG），这比 AWS Glue 工作流引入了更多的操作复杂性和开销。

使用 Amazon EMR 会带来不必要的复杂性和更高的运营开销，因为它需要为 Spark 作业配置和管理一个集群，这比使用 AWS Glue 和 EventBridge 更复杂。

虽然 Lambda 可以是一种轻量级的选择，但使用 Step Functions 来编排 Lambda 函数以进行数据质量检查会增加不必要的复杂性，而 AWS Glue 工作流已经提供了内置的数据质量操作功能，且开销更低。

问题 168

一家公司将包含个人身份信息（PII）的客户数据存储于亚马逊 Redshift 集群中。该公司的市场营销、理赔和分析团队需要能够访问这些客户数据。

营销团队应能获取脱敏后的理赔信息，但应能全面访问客户联系信息。理赔团队应能获取其处理的每笔理赔的客户信息。分析团队只能访问脱敏后的个人身份信息。

哪种解决方案能以最低的管理开销来强制执行这些数据访问要求？

- A. 为每个团队创建单独的 Redshift 集群。仅加载每个团队所需的数据。根据团队限制对集群的访问。
- B. 创建包含每个数据需求中所需字段的视图。仅授予每个团队访问其所需视图的权限。
- C. 为每个团队创建单独的 Amazon Redshift 数据库角色。分别为每个团队定义掩码策略。将适当的掩码策略附加到每个团队角色。
- D. 将客户数据迁移到 Amazon S3 存储桶。使用 AWS Lake Formation 创建数据湖。利用精细的权限控制功能为每个团队授予访问数据的适当权限。

正确答案：C

部分：（无）

解释/参考：

问题 169

一家金融公司最近为其移动应用程序增加了更多功能。这些新功能要求该公司在现有的亚马逊托管 Apache Kafka（Amazon MSK）集群中创建一个新的主题。

在公司添加了新主题几天后，亚马逊 CloudWatch 对 MSK 集群的 RootDiskUsed 指标发出了警报。

公司应该如何处理 CloudWatch 警报？

- A. 扩展 MSK 代理的存储。配置 MSK 集群存储以实现自动扩展。
- B. 扩大 Apache ZooKeeper 节点的存储空间。
- C. 将 MSK 代理实例更新为更大的实例类型。重启 MSK 集群。
- D. 为现有主题指定目标容量（GiB）参数。

正确答案：A

部分：（无）

解释/参考：

解释：

Amazon MSK 中的 RootDiskUsed 指标表明代理节点的磁盘存储空间即将用尽。为解决此问题，公司可以为 MSK 代理节点扩展存储空间，以防止其耗尽磁盘空间。

亚马逊 MSK 支持自动存储扩展，可进行配置以避免未来出现类似问题。启用自动扩展后，MSK 会在需要时自动增加存储空间，确保代理有足够的空间来处理新主题或更多数据。

ZooKeeper 用于管理 Kafka 代理的状态，但 RootDiskUsed 指标与 Kafka 代理有关，而非 ZooKeeper 节点。扩大 ZooKeeper 存储空间无法解决此问题。

虽然增大实例大小可能会提升性能，但这并不能解决代理根卷磁盘空间不足的问题，而正是该问题导致了 CloudWatch 警报的触发。

Kafka 主题没有直接的容量规格。Kafka 的存储是在代理级别进行管理的，而非在单个主题级别。因此，此选项不适用于磁盘使用情况的问题。

问题 170

数据工程师需要基于公司的亚马逊 S3 存储桶和亚马逊 RDS 数据库构建企业数据目录。该数据目录必须包含目录中数据的存储格式元数据。

哪种解决方案能以最少的努力满足这些要求？

- A. 使用 AWS Glue 爬虫扫描 S3 存储桶和 RDS 数据库，并构建数据目录。使用数据管理员检查数据，并根据数据格式更新数据目录。
- B. 使用 AWS Glue 爬虫程序构建数据目录。使用 AWS Glue 爬虫程序分类器识别数据格式，并将格式存储在目录中。
- C. 使用 Amazon Macie 构建数据目录并识别敏感数据元素。从 Macie 收集数据格式信息。
- D. 使用脚本扫描数据元素，并根据数据格式分配数据分类。

正确答案：B

部分：（无）

解释/参考：

解释：

AWS Glue 爬虫能够自动扫描 Amazon S3 存储桶和 Amazon RDS 数据库中的数据以构建数据目录。Glue 爬虫还具有分类器，能够自动检测数据格式（例如 CSV、JSON、Parquet 等），并将此信息作为元数据存储于数据目录中。此解决方案实现了目录编制和格式识别的自动化，以最小的努力满足了需求。

“使用 AWS Glue 爬虫扫描 S3 存储桶和 RDS 数据库并构建数据目录。使用数据管理员检查数据并更新数据目录中的数据格式。”这一选项需要数据管理员手动检查并更新数据目录，这会增加大量工作量，而且没有必要，因为 Glue 爬虫可以自动检测格式。

亚马逊 Macie 主要用于识别敏感数据（例如个人身份信息），而非用于构建全面的数据目录或识别数据格式。它无法满足存储格式元数据编目的要求。

编写自定义脚本来扫描和根据格式对数据进行分类，与使用自动化的 Glue 爬虫相比，要耗费多得多的时间。Glue 爬虫完成这项任务所需的工作量要少得多。

问题 171

一家公司每季度都会在数据湖中分析数据以进行库存评估。一名数据工程师

该公司使用 AWS Glue DataBrew 来检测数据中有关客户的任何个人身份信息（PII）。该公司的隐私政策将某些自定义信息类别视为 PII，但这些类别并未包含在标准的 DataBrew 数据质量规则中。

数据工程师需要修改当前流程，以便在数据湖内的多个数据集里扫描自定义的个人身份信息类别。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 手动审查自定义个人身份信息类别的数据。
- B. 在 DataBrew 中实现自定义数据质量规则。将自定义规则应用于各个数据集。
- C. 开发自定义的 Python 脚本以检测自定义的个人身份信息类别。从 DataBrew 中调用这些脚本。
- D. 在提取、转换和加载（ETL）操作期间，实施正则表达式模式从字段中提取个人身份信息（PII），并将其加载到数据湖中。

正确答案：B

部分：（无）

解释/参考：解释：

AWS Glue DataBrew 允许用户创建自定义数据质量规则，包括用于检测非标准个人身份信息（PII）类别的规则。通过实施自定义规则，数据工程师能够自动检测多个数据集中的 PII（包括自定义类别），而无需手动审查或开发自定义脚本。这提供了一种操作开销最小的解决方案，因为它利用了现有的 DataBrew 框架和自动化功能。

人工审核数据工作量极大、容易出错且不具备可扩展性，尤其是在涉及多个数据集的情况下。

虽然可行，但编写自定义 Python 脚本会增加操作负担，因为这需要开发、维护脚本，并将其与 DataBrew 集成。与直接在 DataBrew 中实现自定义规则相比，这会增加复杂性。

虽然正则表达式可能有用，但将其直接纳入 ETL 流程会增加操作复杂性，并且无法充分利用 DataBrew 的功能，而 DataBrew 本身就是为了数据清理和质量验证而设计的。

问题 172

一家公司每天都会从合作伙伴处收到一个数据文件，该文件存放在亚马逊 S3 存储桶中。该公司使用每日的 AWS Glue 提取、转换和加载（ETL）管道来清理和转换每个数据文件。ETL 管道的输出结果会被写入第二个 S3 存储桶中名为 Daily.csv 的 CSV 文件。

有时，每日数据文件为空，或者缺少必填字段的数据。当文件缺少数据时，公司可以使用前一天的 CSV 文件。

数据工程师需要确保只有在新的每日数据文件完整且有效的情况下，才覆盖前一天的数据文件。

哪种解决方案能以最少的努力满足这些要求？

- A. 调用 AWS Lambda 函数检查文件中是否存在缺失数据，并在必填字段中填充缺失值。
- B. 配置 AWS Glue ETL 管道以使用 AWS Glue 数据质量规则。使用数据质量定义语言（DQDL）开发规则，以检查必填字段中的缺失值和空文件。
- C. 使用 AWS Glue Studio 更改 ETL 管道中的代码，用每个字段中最常见的值填充所需字段中的任何缺失值。
- D. 在 Amazon Athena 中运行 SQL 查询以读取 CSV 文件并删除缺失行。将修正后的 CSV 文件复制到第二个 S3 存储桶。

正确答案：B

部分：（无）

解释/参考：

解释：

AWS Glue 数据质量规则可以直接集成到 AWS Glue ETL 管道中，自动检查每日文件中是否存在缺失或无效的数据。您可以使用数据质量定义语言（DQDL）定义规则，在管道写入输出之前验证数据的完整性和有效性。此解决方案确保只有在新数据完整且有效的情况下才会覆盖前一天的文件，从而最大程度地减少人工干预和运营工作。

虽然可以使用 Lambda，但这需要在现有的 Glue ETL 管道之外进行额外的开发和集成。这会增加复杂性和运营开销。

“使用 AWS Glue Studio 更改 ETL 管道中的代码，用每个字段中最常见的值填充所需字段中的任何缺失值”这种方法假定用最常见的值填充缺失值是可以接受的，但这在所有情况下可能并非总是正确的解决方案。要求规定只有在文件完整且有效的情况下才进行验证和替换。

使用 Athena 删除缺失的行并不能完全解决问题，因为这可能会导致数据丢失，并且在复制文件之前仍需要人工干预来验证文件。此外，与使用 AWS Glue 数据质量的内置功能相比，这会引入不必要的步骤。

问题 173

一家营销公司使用亚马逊 S3 存储营销数据。该公司在某些存储桶中启用了版本控制功能。该公司运行多个作业来读取数据并将其加载到存储桶中。

为了优化存储成本，该公司希望收集有关 S3 存储桶中不完整的多部分上传和过时版本的信息。

哪种解决方案能以最少的操作努力满足这些要求？

- A. 使用 AWS CLI 收集信息。
- B. 使用 Amazon S3 存储清单配置报告来收集信息。
- C. 使用 Amazon S3 存储透镜控制面板来收集信息。
- D. 使用亚马逊 S3 的 AWS 使用报告来收集信息。

正确答案：C

部分：（无）

解释/参考：

解释：

亚马逊 S3 存储透镜提供了 S3 存储使用情况和活动的全面视图。它包含诸如未完成的多部分上传数量和非当前对象版本数量等指标，是收集有关存储效率低下（如过时版本和未完成上传）的见解的理想工具。此解决方案所需的运营工作量极小，因为它已内置于 S3 中，并提供了一个用户友好的仪表板，其中包含详细的信息。

使用 AWS 命令行界面（AWS CLI）手动列出和检查多部分上传以及对象版本需要编写脚本并定期执行，这会导致更高的运营开销。

S3 存储清单会提供您存储桶中对象的报告，但它不会直接提供有关不完整的分段上传或过时版本的信息。您需要进一步处理数据才能获取具体的洞察。

AWS 使用报告更侧重于账单和使用情况，而非诸如不完整的多部分上传和过时对象版本之类的详细存储优化指标。

问题 174

一家游戏公司使用亚马逊 Kinesis 数据流来收集点击流数据。该公司使用亚马逊数据火流交付流将数据以 JSON 格式存储在亚马逊 S3 中。公司的数据科学家使用亚马逊 Athena 查询最新数据以获取业务洞察。

该公司希望降低 Athena 的成本，但又不想重新创建数据管道。

哪种解决方案能以最少的管理精力满足这些要求？

- A. 将 Firehose 输出格式更改为 Apache Parquet。提供自定义的 S3 对象前缀表达式 YYYYMMDD 并指定较大的缓冲区大小。对于现有数据，创建一个 AWS Glue 提取、转换和加载（ETL）作业。配置 ETL 作业以合并小的 JSON 文件，将 JSON 文件转换为大的 Parquet 文件，并添加 YYYYMMDD 前缀。使用 ALTER TABLE ADD PARTITION 语句在现有的 Athena 表中反映分区。
- B. 创建一个 Apache Spark 作业，用于合并 JSON 文件并将这些 JSON 文件转换为 Apache Parquet 文件。每天启动一个 Amazon EMR 临时集群来运行 Spark 作业，在不同的 S3 位置创建新的 Parquet 文件。使用 ALTER TABLE SET LOCATION 语句将现有 Athena 表的新 S3 位置进行更新。
- C. 创建一个 Kinesis 数据流作为 Firehose 的交付目的地。使用 Amazon Managed Service for Apache Flink（之前称为 Amazon Kinesis Data Analytics）在 Kinesis 数据流上运行 Apache Flink。使用 Flink 聚合数据，并以 Apache Parquet 格式将数据保存到 Amazon S3 中，自定义 S3 对象的前缀为 YYYYMMDD。使用 ALTER TABLE ADD PARTITION 语句在现有的 Athena 表中反映分区。
- D. 将 AWS Lambda 函数与 Firehose 集成，将源记录转换为 Apache Parquet 格式并写入 Amazon S3。同时运行 AWS Glue 提取、转换和加载（ETL）作业，将 JSON 文件合并并转换为大型 Parquet 文件。创建自定义的 S3 对象 YYYYMMDD 前缀。使用 ALTER TABLE ADD PARTITION 语句在现有的 Athena 表中反映分区。

正确答案：A

部分：（无）

解释/参考：

解释：

将 Firehose 输出格式更改为 Apache Parquet 可以降低 Amazon Athena 查询成本，因为 Parquet 是一种列式存储格式，与 JSON 等行式格式相比，其查询效率更高。Parquet 有助于减少 Athena 扫描的数据量，从而降低成本。

将 Firehose 配置为使用较大的缓冲区大小可确保生成更少但更大的文件，这也有助于提高 Athena 中的查询性能。

对于现有的 JSON 数据，使用 AWS Glue ETL 作业将其转换为 Parquet 格式并应用必要的分区（例如，YYYYMMDD），这将有助于优化未来的查询，而无需重新创建数据管道。在 Athena 中使用 ALTER TABLE ADD PARTITION 语句，可使现有表反映新的分区。

此解决方案通过重新配置 Amazon Kinesis Data Firehose 并使用 AWS Glue 处理现有数据来最大程度地减少管理工作，且无需对现有管道进行重大更改。

在 Amazon EMR 上运行 Apache Spark 作业需要更多的操作管理，因为您每天都需要启动和管理临时的 EMR 集群，这会增加复杂性。

亚马逊托管的 Apache Flink 服务引入了额外的组件（Kinesis 数据流和 Flink），这与使用现有的 Firehose 并仅更改其输出格式相比，增加了复杂性和管理开销。

使用 Lambda 进行实时转换并将其与 Glue ETL 作业相结合会引入不必要的复杂性。Firehose 已经支持直接输出为 Parquet 格式，这使得 Lambda 函数变得多余。

问题 175

一家公司需要一个解决方案来管理现有 Amazon DynamoDB 表的成本。该公司还需要控制表的大小。该解决方案不得中断任何正在进行的读取或写入操作。该公司希望使用一种能自动在 1 个月后从表中删除数据的解决方案。

哪种解决方案在满足这些要求的同时，后续维护工作最少？

- A. 使用 DynamoDB 的 TTL 功能，根据时间戳自动使数据过期。
- B. 配置一个计划的 Amazon EventBridge 规则，以调用 AWS Lambda 函数来检查数据

超过 1 个月的数据。配置 Lambda 函数以删除旧数据。

- C. 在 DynamoDB 表上配置一个流以调用 AWS Lambda 函数。配置该 Lambda 函数以删除表中超过 1 个月的数据。
- D. 使用 AWS Lambda 函数定期扫描 DynamoDB 表，查找超过 1 个月的数据。配置 Lambda 函数以删除旧数据。

正确答案：A

部分：（无）

解释/参考：

解释：

DynamoDB 的 TTL（生存时间）是一项内置功能，它允许您根据时间戳属性自动从表中删除过期项目。启用 TTL 后，DynamoDB 会在项目达到过期时间后自动将其移除，而不会中断任何正在进行的读取或写入操作。此解决方案需要的持续维护最少，因为它完全由 DynamoDB 管理，无需手动干预或额外的 Lambda 函数。

问题 176

一家公司使用亚马逊 S3 存储数据，并使用亚马逊 QuickSight 创建可视化图表。

该公司在名为 Hub-Account 的 AWS 账户中有一个 S3 存储桶，该存储桶由 AWS 密钥管理服务（AWS KMS）密钥进行加密。公司的 QuickSight 实例位于一个名为 BI-Account 的单独账户中。

该公司更新了 S3 存储桶策略，以授予 QuickSight 服务角色访问权限。该公司希望启用跨账户访问，以便 QuickSight 能够与 S3 存储桶进行交互。

哪两种步骤的组合能满足这一要求？（选择两项。）

- A. 使用现有的 AWS KMS 密钥对 QuickSight 与 S3 存储桶之间的连接进行加密。
- B. 将 S3 存储桶添加为 QuickSight 服务角色可访问的资源。
- C. 使用 AWS 资源访问管理器（AWS RAM）与 BI-Account 账户共享 S3 存储桶。
- D. 向 QuickSight 服务角色添加一个 IAM 策略，以授予 QuickSight 访问加密 S3 存储桶的 KMS 密钥的权限。
- E. 将 KMS 密钥添加为 QuickSight 服务角色可访问的资源。

正确答案：E

部分：（无）

解释/参考：

问题 17

一家汽车销售公司保存着某一地区待售汽车的相关数据。该公司每天都会从供应商处收到新上市汽车的数据，供应商会将这些数据压缩成文件上传至亚马逊 S3。这些压缩文件的大小不超过 5KB。该公司希望在数据上传至亚马逊 S3 后能尽快看到最新的上市信息。

数据工程师必须对房源数据处理 workflow 进行自动化和编排，以向仪表板提供数据。数据工程师还必须提供执行一次性查询和分析报告的能力。查询解决方案必须具有可扩展性。

哪种解决方案能以最经济高效的方式满足这些要求？

- A. 使用 Amazon EMR 集群处理传入的数据。使用 AWS Step Functions 来编排 workflow。使用 Apache Hive 进行一次性查询和分析报告。使用 Amazon OpenSearch Service 将数据批量导入计算优化实例。在 OpenSearch Service 中使用 OpenSearch Dashboards 作为仪表板。
- B. 使用预配置的 Amazon EMR 集群处理传入的数据。使用 AWS Step Functions 来编排 workflow。使用 Amazon Athena 进行一次性查询和分析报告。使用 Amazon QuickSight 构建仪表板。

- C. 使用 AWS Glue 处理传入的数据。使用 AWS Step Functions 进行工作流编排。使用 Amazon Redshift Spectrum 进行一次性查询和分析报告。使用 Amazon OpenSearch Service 中的 OpenSearch Dashboards 作为仪表板。
- D. 使用 AWS Glue 处理传入的数据。使用 AWS Lambda 和 S3 事件通知来编排工作流。使用 Amazon Athena 进行一次性查询和分析报告。使用 Amazon QuickSight 生成仪表板。

正确答案：D

部分：（无）

解释/参考：

解释：

AWS Glue 是一项完全托管的 ETL（提取、转换、加载）服务，经济高效且可扩展，适用于处理传入的数据。它能够高效处理压缩的数据文件。

S3 事件通知和 AWS Lambda 提供了一种低成本、无服务器的编排解决方案，能够在新文件上传到 S3 后立即触发工作流。这确保了数据能够得到实时或近乎实时的处理，而无需管理像 EMR 这样的长期运行服务。

亚马逊 Athena 是一项无服务器、可扩展的查询服务，允许用户直接在 S3 中运行 SQL 查询，非常适合一次性查询和分析报告，无需配置基础设施。

亚马逊 QuickSight 提供了一种经济高效、完全托管的服务来可视化数据，非常适合仪表板的需求。

此解决方案具有成本效益，因为它最大限度地减少了对预配置基础设施的需求，并使用了诸如 Lambda、Glue、Athena 和 QuickSight 等无服务器和托管服务，所有这些服务都能根据需求自动扩展。

问题 178

一家公司在多个 AWS 区域拥有 AWS 资源。该公司在每个运营区域都设有 Amazon EFS 文件系统。该公司的数据科学团队仅在一个区域内开展工作。数据科学团队所处理的数据必须留在该团队所在的区域内。

一位数据工程师需要通过处理公司每个区域 EFS 文件系统上的文件来创建一个单一的数据集。该数据工程师希望使用 AWS Step Functions 状态机来编排 AWS Lambda 函数以处理数据。

哪种解决方案能以最少的努力满足这些要求？

- A. 查看每个区域中托管 EFS 文件系统的 VPC 与数据科学团队所在区域的 VPC。启用 EFS 文件锁定。在数据科学团队所在区域配置 Lambda 函数以挂载每个区域特定的文件系统。使用 Lambda 函数处理数据。
- B. 配置每个区域的 EFS 文件系统，将数据复制到数据科学团队所在的区域。在数据科学团队所在的区域，配置 Lambda 函数以挂载副本文件系统。使用 Lambda 函数处理数据。
- C. 将 Lambda 函数部署到每个区域。将区域 EFS 文件系统挂载到 Lambda 函数。使用 Lambda 函数处理数据。将输出存储在数据科学团队所在区域的 Amazon S3 存储桶中。
- D. 使用 AWS DataSync 将每个区域的 EFS 文件系统上的文件传输到数据科学团队所在区域的文件系统。在数据科学团队所在区域配置 Lambda 函数以挂载同区域的文件系统。使用 Lambda 函数处理数据。

正确答案：D

部分：（无）

解释/参考：

解释：

AWS DataSync 旨在跨区域在 AWS 存储服务之间传输数据，例如

EFS、S3 以及其他存储系统。通过使用 DataSync，您可以高效地将每个区域的 EFS 文件系统的数据传输到数据科学团队所在区域的 EFS 文件系统。这样，在处理数据时，数据可以保留在数据科学团队所在的区域内，从而满足数据不能离开该区域的要求。

一旦数据传输完成，与数据科学团队处于同一区域的 Lambda 函数就可以挂载本地 EFS 文件系统并处理数据，从而最大程度地降低复杂性以及跨区域数据处理带来的网络延迟或故障风险。

这种方法能确保运营工作量最小化，因为 DataSync 可自动执行传输过程，并与 EFS 协同工作，同时将数据本地化，以便在同一区域内的 Lambda 函数进行处理。

问题 179

一家公司将其应用程序托管在亚马逊 EC2 实例上。该公司必须使用 SSL/TLS 连接来加密传输中的数据，以便与由客户管理的 AWS 基础设施进行安全通信。

数据工程师需要实施一种解决方案，以简化数字证书的生成、分发和轮换。该解决方案必须能够自动续订和部署 SSL/TLS 证书。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 在 EC2 实例上存储自行管理的证书。
- B. 使用 AWS 证书管理器（ACM）。
- C. 在 AWS Secrets Manager 中实现自定义自动化脚本。
- D. 使用亚马逊弹性容器服务（Amazon ECS）服务连接。

正确答案：B

部分：（无）

解释/参考：

解释：

AWS 证书管理器（ACM）简化了生成、分发和管理 SSL/TLS 证书的过程。ACM 可以自动续订和部署证书，操作开销极小。一旦与 EC2 等服务集成，ACM 就可以处理证书的整个生命周期，从创建到续订和部署，无需人工干预。

手动管理证书会带来巨大的运营负担。您需要手动处理证书的生成、部署、更新和轮换，这既容易出错又耗时。

虽然您可以将证书存储在 AWS Secrets Manager 中，但仍需要为证书的生成、轮换和部署实现自定义脚本，这会比使用 ACM 增加操作复杂性。

Amazon ECS 服务连接用于简化 ECS 内的服务发现和通信。虽然它可以保护 ECS 服务之间的流量，但它并非用于管理 EC2 实例上的 SSL/TLS 证书。

问题 180

一家公司将客户数据保存到亚马逊 S3 存储桶中。该公司使用带有 AWS KMS 密钥的服务器端加密（SSE-KMS）来加密该存储桶。数据集包含个人身份信息（PII），例如社会安全号码和账户详情。

被标记为个人身份信息（PII）的数据在公司使用客户数据进行分析之前必须进行脱敏处理。在预处理阶段，某些用户必须能够安全访问 PII 数据。公司需要一种维护成本低的解决方案，在整个工程流程中对 PII 数据进行脱敏和保护。

哪种解决方案的组合能满足这些要求？（选择两项。）

- A. 使用 AWS Glue DataBrew 执行提取、转换和加载（ETL）任务，在分析前对个人身份信息（PII）数据进行脱敏处理。

- B. 使用亚马逊 GuardDuty 监控工程流水线中所用个人身份信息（PII）数据的访问模式。
- C. 为 S3 存储桶配置 Amazon Macie 发现任务。
- D. 使用 AWS 身份和访问管理（IAM）来管理权限并控制对个人身份信息（PII）数据的访问。
- E. 在应用程序中编写自定义脚本以屏蔽个人身份信息（PII）数据并控制访问权限。

正确答案：AD

部分：（无）

解释/参考：

解释：

AWS Glue DataBrew 是一项数据准备服务，可简化数据清理和规范化流程，包括对个人身份信息（PII）数据进行屏蔽处理。它允许您在将数据用于分析之前以可视化方式转换数据并应用屏蔽规则。此解决方案易于维护，并且可与 S3 无缝集成以处理数据。

AWS 身份和访问管理（IAM）可用于管理权限并控制对个人身份信息（PII）数据的访问。IAM 提供了必要的细粒度访问控制，以确定在预处理和分析阶段哪些用户或角色可以查看或修改 PII 数据。

GuardDuty 主要是一项威胁检测服务。虽然它可以监控异常的访问模式，但并不提供在工程流水线中对个人身份信息（PII）数据进行屏蔽或保护所需的工具。

亚马逊 Macie 有助于在 S3 存储桶中发现和分类个人身份信息（PII），但它并不处理 PII 数据的实际屏蔽或保护工作。它更多地用于分类和监控，而非处理或访问控制。

自定义脚本容易出错、耗时且需要持续维护。与 AWS Glue DataBrew 提供的托管解决方案相比，这种方法会带来不必要的复杂性。

问题 181

一位数据工程师正在启动一个 Amazon EMR 集群。该数据工程师需要加载到新集群中的数据目前存放在一个 Amazon S3 存储桶中。这位数据工程师需要确保数据在静止和传输过程中都经过加密。

S3 存储桶中的数据由 AWS 密钥管理服务（AWS KMS）密钥进行加密。数据工程师有一个包含隐私增强邮件（PEM）文件的 Amazon S3 路径。

哪种解决方案能满足这些要求？

- A. 创建一个 Amazon EMR 安全配置。为 S3 存储桶的静态加密指定适当的 AWS KMS 密钥。创建第二个安全配置。为传输中的加密指定 PEM 文件的 Amazon S3 路径。创建 EMR 集群，并将这两个安全配置都附加到该集群。
- B. 创建一个 Amazon EMR 安全配置。为 S3 存储桶指定用于本地磁盘加密的适当 AWS KMS 密钥。指定用于传输中加密的 PEM 文件的 Amazon S3 路径。在创建 EMR 集群时使用该安全配置。
- C. 创建一个 Amazon EMR 安全配置。为 S3 存储桶的静态加密指定适当的 AWS KMS 密钥。为传输中的加密指定 PEM 文件的 Amazon S3 路径。在创建 EMR 集群时使用该安全配置。
- D. 创建一个 Amazon EMR 安全配置。为 S3 存储桶指定适当的 AWS KMS 密钥以实现静态加密。指定用于传输加密的 PEM 文件的 Amazon S3 路径。创建 EMR 集群，并将安全配置附加到该集群。

正确答案：C

部分：（无）

解释/参考：解释：

Amazon EMR 安全配置允许您为静态和传输中的数据定义加密设置。

在这种情况下，S3 存储桶中的数据已使用 AWS KMS 密钥进行了加密，因此您需要确保 EMR 集群在访问 S3 存储桶时使用相同的密钥进行静态加密。

要实现传输加密，您需要提供一个包含 SSL/TLS 证书的 PEM 文件，以确保与集群之间传输的数据是加密的。

通过在单个安全配置中指定用于静态加密的 KMS 密钥和用于传输加密的 PEM 文件，您可以确保数据在存储和传输过程中均受到加密。

问题 182

一家零售公司正在使用亚马逊 Redshift 集群来支持实时库存管理。该公司已在亚马逊 SageMaker 的实时端点上部署了一个机器学习模型。

该公司希望提供实时库存建议。该公司还希望预测未来的库存需求。

哪些解决方案能满足这些要求？（选择两项。）

- A. 使用 Amazon Redshift ML 生成库存推荐。
- B. 使用 SQL 调用远程 SageMaker 端点进行预测。
- C. 使用 Amazon Redshift ML 定期安排数据导出，以用于离线模型训练。
- D. 使用 SageMaker Autopilot 在 Amazon Redshift 中创建库存管理仪表盘。
- E. 使用 Amazon Redshift 作为文件存储系统来归档旧的库存管理报告。

正确答案：AB

部分：（无）

解释/参考：

解释：

亚马逊 Redshift ML 将机器学习（ML）直接集成到 Redshift 环境中，使您能够使用 SQL 命令构建和使用 ML 模型。借助 Redshift ML，该公司能够直接在 Redshift 内基于历史和当前数据进行实时库存推荐。

Redshift 可以通过 SQL 查询调用外部服务，例如 SageMaker 的实时端点。这使得公司能够将 Redshift 中的实时数据发送到 SageMaker，并实时接收预测结果（例如库存预测），满足了实时预测的需求。

问题 183

一家公司将 CSV 文件存储在亚马逊 S3 存储桶中。一名数据工程师需要处理这些 CSV 文件中的数据，并将处理后的数据存储到一个新的 S3 存储桶中。

该过程需要重命名一列，删除特定的列，忽略每个文件的第二行，根据数据第一行的值创建新列，并按某一列的数值对结果进行筛选。

哪种解决方案能以最少的开发工作量满足这些要求？

- A. 使用 AWS Glue Python 作业来读取和转换 CSV 文件。
- B. 使用 AWS Glue 自定义爬虫来读取和转换 CSV 文件。
- C. 使用 AWS Glue 工作流构建一组作业来抓取和转换 CSV 文件。
- D. 使用 AWS Glue DataBrew 配方来读取和转换 CSV 文件。

正确答案：D

部分：（无）

解释/参考：

解释：

AWS Glue DataBrew 是一款可视化数据准备工具，可让您无需编写代码即可清理、规范化和转换数据。借助 DataBrew 配方，您可以轻松执行诸如重名列、删除特定列、忽略某些行、创建新列以及基于列值筛选数据等转换操作。此解决方案所需的开发工作量最少，因为它提供了无需编程的体验。

用于执行这些任务的代码/低代码界面。

虽然 AWS Glue Python 作业可以处理这些转换，但需要编写自定义代码，这比使用 DataBrew 所需的开发工作更多。

AWS Glue 爬虫用于编目数据，不适合执行诸如忽略行、重命名列或创建新列之类的复杂转换。

使用 AWS Glue 工作流来构建一组爬取和转换 CSV 文件的任务会增加不必要的复杂性。您需要协调多个任务和工作流，这与使用 DataBrew 进行转换相比，需要更多的设置和开发工作。

问题 184

一家公司使用亚马逊 Redshift 作为其数据仓库。对数据仓库中现有的表应用了数据编码。一位数据工程师发现，对某些表应用的压缩编码并非最适合这些数据的编码方式。

数据工程师需要改进那些编码效果不佳的表的数据编码。

哪种解决方案能满足这一要求？

- A. 对已识别的表运行 ANALYZE 命令。根据该命令的输出结果手动更新列的压缩编码。
- B. 对已识别的表运行 ANALYZE COMPRESSION 命令。根据该命令的输出结果手动更新列的压缩编码。
- C. 对已识别的表运行 VACUUM REINDEX 命令。
- D. 对已识别的表运行 VACUUM RECLUSTER 命令。

正确答案：B

部分：（无）

解释/参考：

解释：

在 Amazon Redshift 中，ANALYZE COMPRESSION 命令会对表中的现有数据进行评估，并为每个列推荐最优化的压缩编码。运行此命令后，数据工程师可以手动更新表以应用推荐的压缩编码。这种方法确保了数据压缩的最佳适配，从而提高了存储效率和查询性能。

ANALYZE 命令用于收集查询优化的统计信息，但它不提供压缩编码建议。其重点在于查询性能，而非数据压缩。

在 Amazon Redshift 中不存在 VACUUM REINDEX 命令。VACUUM 命令通常用于回收磁盘空间和对表进行排序，而不是用于压缩优化。

在 Amazon Redshift 中不存在 VACUUM RECLUSTER 操作。VACUUM 操作侧重于重新组织和排序数据，但不涉及压缩编码。

问题 185

该公司在亚马逊 S3 中存储了大量客户记录。为遵守法规，该公司必须能够在客户记录创建后的前 30 天内立即访问这些新记录。对于超过 30 天的记录，该公司访问的频率较低。

该公司需要优化其在亚马逊 S3 上的存储成本。

哪种解决方案能以最经济高效的方式满足这些要求？

- A. 应用生命周期策略，在 30 天后将记录过渡到 S3 标准不频繁访问（S3 标准-IA）存储。
- B. 使用 S3 智能分层存储。
- C. 30 天后将记录转存至 S3 Glacier Deep Archive 存储。
- D. 对所有客户记录使用 S3 标准不频繁访问（S3 标准-IA）存储。

正确答案：A

部分：（无）

解释/参考：

解释：

S3 标准-IA（不频繁访问）非常适合那些访问频率较低但需要随时可访问的数据。由于该公司在最初的 30 天内需要随时访问客户记录，之后访问频率较低，因此应用 S3 生命周期策略，在 30 天后自动将数据转移到 S3 标准-IA，这提供了一种经济高效的解决方案。这样一来，记录在最初的 30 天内仍可轻松访问，而在访问频率降低后则会转移到成本更低的存储层级。

S3 智能分层存储会根据访问模式自动在频繁访问层和不频繁访问层之间移动数据，但会产生额外的监控和自动化费用。如果访问模式明确（比如在这种情况下，数据在前 30 天内频繁访问，之后访问频率降低），那么与 S3 标准-不频繁访问相比，此选项通常更昂贵。

S3 Glacier Deep Archive 是一种针对存档数据的低成本存储选项，这些数据很少被访问，且检索需要数小时。它无法满足 30 天后立即访问记录的要求。

在数据频繁访问的前 30 天内，将所有数据存储在 S3 标准-IA 中的成本更高。在此期间，对于频繁访问的数据，S3 标准更具成本效益。

问题 186

一位数据工程师正在使用亚马逊 QuickSight 构建一个仪表板，以报告一家公司在多个 AWS 区域的收入情况。该数据工程师希望仪表板能够显示某个区域的总收入，而不论可视化中显示的钻取层级如何。

哪种解决方案能满足这些要求？

- A. 创建一个表计算。
- B. 创建一个简单的计算字段。
- C. 创建一个层级感知计算聚合（LAC-A）函数。
- D. 创建一个具有层级感知的计算窗口（LAC-W）函数。

正确答案：C

部分：（无）

解释/参考：

解释：

在亚马逊 QuickSight 中，级别感知计算（LAC）允许用户创建与可视化中的聚合级别无关的计算。具体而言，LAC-A（聚合）函数可让您计算诸如某个区域的总收入之类的指标，而无需考虑显示的钻取级别。这意味着即使用户深入查看更详细的数据，区域的总收入仍会在仪表板中显示，从而满足要求。

表计算是依赖于上下文的，这意味着它们会根据可视化内容当前的粒度和钻取级别来计算值。这无法满足无论钻取到何种级别都显示总收入的要求。

一个简单的计算字段在当前视觉对象的详细级别上运行，并且在您向下钻取时会发生变化。它不会在向下的钻取时保持某个区域的总收入不变。

LAC-W（窗口）函数通常用于计算运行总计、移动平均值或排名，这些计算是在数据范围内进行的，但仍会受到钻取级别影响。这无法确保无论钻取到何种级别，总收入都能正确显示。

问题 187

一家零售公司将客户数据存储在亚马逊 S3 存储桶中。部分客户数据包含有关客户的个人身份信息（PII）。该公司不得与业务合作伙伴共享 PII 数据。

数据工程师必须在将数据集中的对象提供给业务合作伙伴之前，确定该数据集是否包含个人信息（PII）。

哪种解决方案能以最少的人工干预满足这一要求？

- A. 配置 S3 存储桶和 S3 对象以允许 Amazon Macie 访问。使用 Macie 中的自动敏感数据发现功能。
- B. 配置 AWS CloudTrail 以监控 S3 的 PUT 操作。检查 CloudTrail 跟踪记录以识别保存个人信息（PII）的操作。
- C. 创建一个 AWS Lambda 函数来识别 S3 对象中的个人信息（PII）。安排该函数定期运行。
- D. 在 AWS Glue 数据目录中创建一个表。编写自定义的 SQL 查询以识别表中的个人信息（PII）。使用 Amazon Athena 运行这些查询。

正确答案：A

部分：（无）

解释/参考：

解释：

亚马逊 Macie 是一项完全托管的数据安全服务，能够自动发现、分类和保护亚马逊 S3 中的敏感数据，例如个人信息（PII）。Macie 的自动敏感数据发现功能可以扫描 S3 对象中的 PII，无需人工干预，是与业务伙伴共享数据前识别敏感数据的最高效、最自动化的解决方案。

CloudTrail 有助于监控 API 调用，但其并非用于检查 S3 对象中是否包含个人信息（PII）。若要检查 S3 中保存的数据，需要人工进行，这既费时又低效。

虽然可以使用 Lambda 来扫描个人信息（PII），但需要编写自定义代码来识别敏感数据。与使用像 Macie 这样的完全托管服务相比，这种方法会增加开发和维护的人工工作量。

编写自定义的 SQL 查询来识别个人信息（PII）是一个手动过程，需要创建和管理 Glue 表以及 Athena 查询。与 Macie 的自动化功能相比，这种方法增加了复杂性和人工干预。

问题 18

一位数据工程师需要在亚马逊 Athena 中创建现有表的一个空副本以执行数据处理任务。Athena 中现有的表包含 1000 行数据。

哪个查询能满足这一要求？

- A. 创建新表 new_table
像 old_table 一样；
- B. 创建新表 new_table 作为以下查询的结果：SELECT *
从旧表中复制结构但不复制数据；
- C. 创建新表 new_table
如需查询所有列，请使用 `SELECT \*`。
来自旧表；
- D. 创建新表 new_table
如 SELECT *
来自旧表
1 = 1;

正确答案：B

部分：（无）

解释/参考：

问题 189

一家公司在亚马逊 S3 上拥有一个数据湖。该公司为多个应用程序收集 AWS CloudTrail 日志。该公司将日志存储在数据湖中，在 AWS Glue 中对日志进行编目，并根据年份对日志进行分区。该公司使用 Amazon Athena 来分析这些日志。

最近，有客户报告称对 Athena 表中的一条查询没有返回任何数据。数据工程师必须解决此问题。

数据工程师应该采取哪两种故障排除步骤的组合？（选择两项。）

- A. 确认 Athena 指向的是正确的 Amazon S3 位置。
- B. 增加查询超时时间。
- C. 使用 MSCK REPAIR TABLE 命令。
- D. 重启雅典娜。
- E. 删除并重新创建有问题的 Athena 表。

正确答案：AC

部分：（无）

解释/参考：

解释：

一个常见的问题可能是表的 S3 位置不正确或已更改。数据工程师应检查 Athena 表是否正确引用了存储 CloudTrail 日志的 S3 存储桶或路径。

如果向 S3 存储桶添加了新的分区（例如新一年的日志），但这些分区尚未反映在 Athena 表中，运行 MSCK REPAIR TABLE 命令将把新分区加载到表的元数据中，从而确保 Athena 能够查询新数据。

查询超时不会导致结果中缺少数据。此选项无法解决查询结果中数据缺失的问题。

Athena 是一项无服务器查询服务，因此不存在“重启”Athena 的选项。这不适用。

虽然删除并重新创建表可以解决该问题，但通常没有必要，而且这种做法更具破坏性。通常可以通过一些干扰性较小的步骤来解决，比如检查 S3 位置和修复分区。

问题 190

一位数据工程师希望在 AWS 上编排一组提取、转换和加载（ETL）作业。这些 ETL 作业包含的任务必须在 Amazon EMR 上运行 Apache Spark 作业、向 Salesforce 发出 API 调用，并将数据加载到 Amazon Redshift 中。

ETL 作业需要能够自动处理故障和重试。数据工程师需要使用 Python 来编排这些作业。

哪种服务能满足这些要求？

- A. 亚马逊托管的 Apache Airflow 工作流（Amazon MWAA）
- B. AWS 步骤函数
- C. AWS Glue
- D. 亚马逊 EventBridge

正确答案：A

部分：（无）

解释/参考：

解释：

亚马逊托管的 Apache Airflow 工作流服务（Amazon MWAA）是一项完全托管的服务，可让您轻松大规模运行 Apache Airflow。Airflow 是一种流行的工具，用于编排复杂的作业流，包括 ETL 作业，并且能够处理各种任务类型，例如在 Amazon EMR 上运行 Apache Spark 作业，从而实现

与 Salesforce 等外部系统的 API 调用以及将数据加载到 Amazon Redshift 中。Airflow 允许您使用 Python 定义工作流，并提供内置机制来处理故障、重试以及自动重试，因此非常适合这种用例。

虽然 AWS Step Functions 能够编排工作流并处理重试和错误，但与 Airflow 相比，它不太适合基于 Python 的编排。此外，Step Functions 更适合 AWS 服务，对于像 Salesforce 这样的外部系统没有内置支持，这需要进行自定义集成。

AWS Glue 是一项无服务器的 ETL 服务，但它主要侧重于数据转换任务。Glue 在处理涉及非 Glue 作业的复杂工作流（例如调用 Salesforce API 或在 EMR 上运行 Spark 作业）的编排方面，不如 Airflow 那样有效。

EventBridge 是一项事件驱动服务，而非编排服务。它专为基于事件的工作流而设计，但不具备处理诸如重试、错误处理以及跨不同系统运行复杂工作流等任务所需的流程编排能力。

问题 191

一位数据工程师维护着一些自定义的 Python 脚本，这些脚本执行着许多 AWS Lambda 函数所使用的的数据格式化过程。当数据工程师需要修改这些 Python 脚本时，必须手动更新所有的 Lambda 函数。

数据工程师需要一种更少人工干预的方式来更新 Lambda 函数。

哪种解决方案能满足这一要求？

- A. 将自定义的 Python 脚本存储在共享的 Amazon S3 存储桶中。在执行上下文对象中存储指向自定义脚本的指针。
- B. 将自定义的 Python 脚本打包成 Lambda 层。将 Lambda 层应用于 Lambda 函数。
- C. 将自定义的 Python 脚本存储在共享的 Amazon S3 存储桶中。在环境变量中存储指向客户脚本的指针。
- D. 为每个 Lambda 函数分配相同的别名。通过指定函数的别名来调用每个 Lambda 函数。

正确答案：B

部分：（无）

解释/参考：

解释：

Lambda 层允许您将外部库、自定义脚本或依赖项（例如 Python 脚本）与 Lambda 函数代码分开打包。通过使用 Lambda 层，您可以在一个中心位置（即层）更新自定义 Python 脚本，而无需手动更新每个 Lambda 函数。当层更新时，使用该层的所有 Lambda 函数都会自动获得脚本的最新版本。

问题 192

一家公司将客户数据存储在亚马逊 S3 存储桶中。该公司内的多个团队希望使用这些客户数据进行下游分析。公司需要确保这些团队无法访问客户的个人身份信息（PII）。

哪种解决方案能在操作开销最小的情况下满足这一要求？

- A. 使用 Amazon Macie 创建并运行敏感数据发现任务，以检测并移除个人身份信息（PII）。
- B. 使用 S3 对象 Lambda 访问数据，并使用 Amazon Comprehend 检测并移除个人身份信息（PII）。
- C. 使用亚马逊数据火管和亚马逊理解服务来检测并移除个人身份信息。
- D. 使用 AWS Glue DataBrew 作业将个人身份信息（PII）数据存储到第二个 S3 存储桶中。对仍保留在原始 S3 存储桶中的数据进行分析。

正确答案：B

部分：（无）

解释/参考：

问题 193

一家公司将处理后的数据存储存储在 S3 存储桶中。该公司有严格的数据访问政策。该公司使用 IAM 角色为公司内部的不同团队授予对 S3 存储桶的不同访问级别。

该公司希望在用户违反数据访问政策时收到通知。每条通知都必须包含违反政策的用户名。

哪种解决方案能满足这些要求？

- A. 使用 AWS Config 规则检测数据访问策略的违规行为。设置合规性警报。
- B. 使用 Amazon CloudWatch 指标来收集对象级别的指标。设置 CloudWatch 警报。
- C. 使用 AWS CloudTrail 来跟踪 S3 存储桶的对象级事件。将事件转发到 Amazon CloudWatch 以设置 CloudWatch 警报。
- D. 使用 Amazon S3 服务器访问日志来监控对存储桶的访问。将访问日志转发到 Amazon CloudWatch 日志组。在日志组上使用指标筛选器来设置 CloudWatch 警报。

正确答案：C

部分：（无）

解释/参考：

解释：

AWS CloudTrail 提供了对 AWS API 调用的详细日志记录，包括 Amazon S3 的对象级事件。您可以配置 CloudTrail 来跟踪 S3 存储桶的数据事件，这将记录对存储桶中对象的每次访问，包括访问数据的 IAM 实体（用户或角色）的用户名。通过将这些 CloudTrail 事件转发到 Amazon CloudWatch，您可以设置警报，在检测到策略违规时触发通知，并包含违规用户的标识。

AWS Config 主要用于监控资源配置，而非追踪诸如数据访问违规之类的真实访问事件。它无法直接提供哪些用户访问了 S3 对象的相关信息。

CloudWatch 指标可以监控 S3 存储或请求指标，但它无法提供对象级访问的详细日志记录，包括违规者的用户名。您需要使用 CloudTrail 来获取详细的事件信息。

虽然 S3 服务器访问日志可以追踪对象的访问情况，但它们缺乏实时处理能力，并且提供的详细程度也不如 CloudTrail。此外，使用 CloudWatch 指标过滤器处理访问日志比使用专门为此用例设计的 CloudTrail 更复杂。

问题 194

一家公司需要将来自第三方的客户数据加载到亚马逊 Redshift 数据仓库中。该公司将订单数据和产品数据存储在同一个数据仓库中。该公司希望利用合并后的数据集来识别潜在的新客户。

一位数据工程师注意到源数据中的一个字段包含的是 JSON 格式的值。

数据工程师应如何以最小的努力将 JSON 数据加载到数据仓库中？

- A. 使用 SUPER 数据类型在 Amazon Redshift 表中存储数据。
- B. 使用 AWS Glue 展平 JSON 数据，并将其加载到 Amazon Redshift 表中。
- C. 使用 Amazon S3 存储 JSON 数据。使用 Amazon Athena 查询数据。
- D. 使用 AWS Lambda 函数将 JSON 数据展平。将数据存储在 Amazon S3 中。

正确答案：A

部分：（无）

解释/参考：

解释：

在 Amazon Redshift 中，SUPER 数据类型允许您原生存储诸如 JSON 这样的半结构化数据。通过使用 SUPER 数据类型，您可以将 JSON 数据直接存储到 Redshift 表中，而无需事先进行展平或转换。这种方法所需的工作量最少，因为它允许您直接加载 JSON 数据，并使用 Redshift 的 JSONPath 和 PARTITION BY 功能对其进行查询，而无需额外的 ETL 处理。

问题 195

一家公司希望分析其存储在 MySQL 数据库中的销售记录，并将这些记录与 Salesforce 确定的销售机会相关联。

该公司每天接收 2GB 的销售记录。该公司有 100GB 的已识别销售机会。一名数据工程师需要开发一个流程，用于分析并关联销售记录和销售机会。该流程必须每晚运行一次。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 使用亚马逊托管的 Apache Airflow 工作流（Amazon MWAA）获取两个数据集。使用 AWS Lambda 函数关联数据集。使用 AWS Step Functions 进行流程编排。
- B. 使用 Amazon AppFlow 从 Salesforce 获取销售机会。使用 AWS Glue 从 MySQL 数据库获取销售记录。将销售记录与销售机会进行关联。使用 Amazon Managed Workflows for Apache Airflow（Amazon MWAA）来编排整个流程。
- C. 使用 Amazon AppFlow 从 Salesforce 获取销售机会。使用 AWS Glue 从 MySQL 数据库获取销售记录。将销售记录与销售机会进行关联。使用 AWS Step Functions 来编排整个流程。
- D. 使用 Amazon AppFlow 从 Salesforce 获取销售机会。使用 Amazon Kinesis Data Streams 从 MySQL 数据库获取销售记录。使用 Amazon Managed Service for Apache Flink 对数据集进行关联。使用 AWS Step Functions 进行流程编排。

正确答案：C

部分：（无）

解释/参考：

解释：

此解决方案通过利用 AWS 管理服务来简化数据摄取、转换和编排流程，以最低的操作开销满足了要求。

Amazon AppFlow 是一项完全托管的集成服务，无需自定义连接器或手动 ETL 流程即可从 Salesforce 中摄取数据。

AWS Glue 提供无服务器数据集成服务，适合从 MySQL 数据库中提取数据并根据需要进行转换。

然后可以使用 **AWS Step Functions** 来编排和自动化夜间流程，从而最大程度减少复杂的管理工作。

问题 196

一家公司将服务器日志存储在亚马逊 S3 存储桶中。该公司需要将日志保留 1 年。1 年后这些日志就不再需要了。

一位数据工程师需要一个解决方案，用于自动删除超过 1 年的旧日志。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 定义一个 S3 生命周期配置，在 1 年后删除日志。
- B. 创建一个 AWS Lambda 函数，在 1 年后删除日志。
- C. 在 Amazon EC2 实例上安排一个 cron 任务，在一年后删除日志。
- D. 配置一个 AWS Step Functions 状态机，在 1 年后删除日志。

正确答案：A

部分：（无）

解释/参考：

解释：

对于此需求，**S3 生命周期配置**是最佳选择，因为它允许公司定义一条规则，在指定时间（本例为 1 年）过后自动删除 S3 存储桶中的对象。此解决方案的**运营开销最小**，因为它是亚马逊 S3 的内置功能，无需额外的基础设施或管理，并且专门用于管理对象的生命周期。

问题 197

一家公司正在 AWS Step Functions 中设计一个无服务器的数据处理工作流，该工作流包含多个步骤。处理工作流从外部 API 中获取数据，使用多个 AWS Lambda 函数对数据进行转换，并将转换后的数据加载到 Amazon DynamoDB 中。

该公司需要工作流程根据传入数据的内容执行特定步骤。

该公司应使用哪种 Step Functions 状态类型来满足此要求？

- A. 平行的
- B. 选择
- C. 任务
- D. 地图

正确答案：B

部分：（无）

解释/参考：

解释：

AWS Step Functions 中的“**选择**”状态旨在实现工作流中的条件分支。它允许工作流评估数据并根据特定条件做出决策。这使其非常适合在工作流中的某些步骤需要根据传入数据的内容来执行的情况。

问题 198

一位数据工程师在 Amazon Athena 中创建了一个名为 cloudtrail_logs 的表，用于查询 AWS CloudTrail 日志并为审计准备数据。该数据工程师需要编写一个查询，以显示自 2024 年初以来出现的带有错误代码的错误，并且查询结果必须返回最近的 10 个错误。

哪个查询能满足这些要求？

- A. 选择总数 (*) 作为总事件数，事件名称，错误代码，错误消息，从 cloudtrail_logs 表中，其中错误代码不为空，且事件时间大于等于 '2024-01-01T00:00:00Z'，按事件名称、错误代码、错误消息分组，按总事件数降序排列，限制结果为 10 条。
- B. 选择事件总数（计数（*））作为 TotalEvents，事件名称、错误代码、错误消息，从 cloudtrail_logs 表中选取，其中事件时间大于等于 '2024-01-01T00:00:00Z'，按事件名称、错误代码、错误消息分组，按 TotalEvents 降序排列，限制结果为前 10 条。
- C. 选择事件总数（count（*））作为 TotalEvents，事件名称（eventname）、错误代码（errorcode）、错误消息（errormessage）从 cloudtrail_logs 表中，其中事件时间（eventtime）大于等于 '2024-01-01T00:00:00Z'，按事件名称（eventname）升序排列，按事件名称（eventname）、错误代码（errorcode）、错误消息（errormessage）分组。
限制 10；
- D. 选择 count（*）作为 TotalEvents，eventname，errorcode，errormessage 从 cloudtrail_logs 中
错误代码不为空且事件时间大于等于 '2024-01-01T00:00:00Z' 的记录，按事件名称、错误代码、错误消息分组，结果限制为 10 条；

正确答案：A

部分：（无）

解释/参考：

解释：

```
select count(*) as TotalEvents, eventname, errorcode, errormessage
from cloudtrail_logs
where errorcode is not null
and eventtime >= '2024-01-01T00:00:00Z'
group by eventname, errorcode, errormessage
order by TotalEvents desc
limit 10;
```

此查询符合要求，具体表现为：

1. 筛选出错误码不为空的结果，因此仅包含错误事件。
2. 通过事件时间进行筛选，以包含自 2024 年初以来发生的事件。
3. 按事件名称、错误代码和错误消息进行分组，以汇总错误事件。
4. 按“总事件数”降序排列，以显示最近的错误。
5. 仅显示最近的 10 个错误结果。

问题 19

一家在线零售商使用多个配送合作伙伴向客户配送产品。配送合作伙伴将订单摘要发送给零售商。零售商将订单摘要存储在亚马逊 S3 中。

部分订单摘要包含客户的个人身份信息（PII）。数据工程师需要在订单摘要中检测出 PII，以便公司对其进行屏蔽处理。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 亚马逊 Textract
- B. 亚马逊 S3 存储透镜
- C. 亚马逊 Macie
- D. 亚马逊 SageMaker 数据抓取器

正确答案：C

部分：（无）

解释/参考：

解释：

Amazon Macie 是一项完全托管的数据安全和隐私服务，它利用机器学习和模式匹配来发现和保护存储在 Amazon S3 中的敏感数据，例如个人身份信息（PII）。Macie 可以自动扫描订单摘要中的 PII，使公司能够检测并按要求删除 PII。

问题 20

一家公司拥有一个亚马逊 Redshift 数据仓库，用户通过多种 IAM 角色来访问该数据仓库。每天有超过 100 名用户访问该数据仓库。

该公司希望根据每个用户的职位、权限以及数据的敏感程度来控制用户对这些对象的访问。

哪种解决方案能满足这些要求？

- A. 使用 Amazon Redshift 的基于角色的访问控制（RBAC）功能。
- B. 使用 Amazon Redshift 的行级安全（RLS）功能。
- C. 使用 Amazon Redshift 的列级安全（CLS）功能。
- D. 在 Amazon Redshift 中使用动态数据屏蔽策略。

正确答案：A 部分：

（无）

解释/参考：

解释：

亚马逊 Redshift 中**基于角色的访问控制（RBAC）**使管理员能够根据工作职能定义角色，然后将这些角色分配给用户。RBAC 支持基于工作角色进行精细的权限管理，这与根据每个用户的角色、权限以及数据敏感度来控制访问的需求十分契合。通过使用预定义的角色而非单独的权限来管理大量用户的访问，这种方法简化了访问管理。

问题 201

一家公司使用亚马逊 DataZone 作为数据治理和业务目录解决方案。该公司将数据存储于亚马逊 S3 数据湖中。该公司使用 AWS Glue 及其 AWS Glue 数据目录。

数据工程师需要将 AWS Glue 数据质量得分发布到 Amazon DataZone 门户。

哪种解决方案能满足这一要求？

- A. 使用数据质量定义语言（DQDL）规则创建适用于特定 AWS Glue 表的数据质量规则集。安排该规则集每天运行。配置 Amazon DataZone 项目以包含 Amazon Redshift 数据源。为该数据源启用数据质量配置。
- B. 配置 AWS Glue ETL 作业以使用“评估数据质量”转换。在作业内定义数据质量规则集。配置 Amazon DataZone 项目以具有 AWS Glue 数据源。为该数据源启用数据质量配置。
- C. 使用数据质量定义语言（DQDL）规则创建适用于特定 AWS Glue 表的数据质量规则集。安排该规则集每天运行。配置 Amazon DataZone 项目以具有 AWS Glue 数据源。为该数据源启用数据质量配置。
- D. 配置 AWS Glue ETL 作业以使用“评估数据质量”转换。在作业中定义数据质量规则集。配置 Amazon DataZone 项目以包含 Amazon Redshift 数据源。为该数据源启用数据质量配置。

正确答案：C

部分：（无）

解释/参考：

解释：

数据质量规则集：使用数据质量定义语言（DQDL）规则创建规则集，能够针对特定的 AWS Glue 表定义和评估数据质量，从而实现对数据质量的自动化检查。

计划执行：每天运行规则集可确保定期更新数据质量得分。

在亚马逊数据区中使用 AWS Glue 数据源：通过使用 AWS Glue 数据源配置亚马逊数据区，可以实现无缝集成，从而将来自 AWS Glue 数据质量的数据质量评分发布到亚马逊数据区门户。

问题 202

一家公司在亚马逊 Redshift 上拥有一个数据仓库。为了遵守安全规定，该公司需要记录并存储数据仓库中所有用户活动和连接活动。

哪种解决方案能满足这些要求？

- A. 创建一个 Amazon S3 存储桶。为 Amazon Redshift 集群启用日志记录功能。在日志记录配置中指定 S3 存储桶以存储日志。
- B. 创建一个亚马逊弹性文件系统（Amazon EFS）文件系统。为亚马逊 Redshift 集群启用日志记录功能。将日志写入 EFS 文件系统。
- C. 创建一个 Amazon Aurora MySQL 数据库。为 Amazon Redshift 集群启用日志记录。将日志写入 Aurora MySQL 数据库中的一个表。
- D. 创建一个亚马逊弹性块存储（Amazon EBS）卷。为亚马逊 Redshift 集群启用日志记录功能。将日志写入 EBS 卷。

正确答案：A

部分：（无）

解释/参考：

解释：

Amazon Redshift 提供了一项选项，用于记录和存储所有用户活动及连接活动，以满足合规性和审计需求。将日志配置到 **Amazon S3 存储桶** 是推荐的做法，原因在于：

亚马逊 S3 存储服务经济实惠、可扩展且持久耐用，适合长期存储大量日志。

Amazon Redshift 原生支持将日志记录到 S3，允许用户和连接日志轻松启用并直接存储在指定的 S3 存储桶中。

将日志存储在 S3 中符合合规要求，并为日志的管理、归档和检索提供了高效的方式，以便进行安全审查或审计。

问题 203

一家公司想要将数据仓库从 Teradata 迁移到 Amazon Redshift。

哪种解决方案能以最少的操作努力满足这一要求？

- A. 使用 AWS 数据迁移服务（AWS DMS）的架构转换功能迁移架构。使用 AWS DMS 迁移数据。
- B. 使用 AWS 架构转换工具（AWS SCT）迁移架构。使用 AWS 数据库迁移服务（AWS DMS）迁移数据。
- C. 使用 AWS 数据迁移服务（AWS DMS）迁移数据。使用自动模式转换。
- D. 手动从 Teradata 导出模式定义。将该模式应用于 Amazon Redshift 数据库。使用 AWS 数据迁移服务（AWS DMS）迁移数据。

正确答案：B

部分：（无）

解释/参考：

解释：

此解决方案通过使用专门针对模式和数据迁移而设计的 AWS 服务，为将数据仓库从 Teradata 迁移到 Amazon Redshift 提供了**最少的操作工作量**：

AWS 架构转换工具（SCT） 用于将架构从 Teradata 转换并迁移到 Amazon Redshift，自动处理架构差异，减少人工工作。

然后使用 **AWS 数据迁移服务（DMS）** 将数据从 Teradata 迁移到 Redshift，从而实现高效的数据迁移。

问题 204

一家公司使用了多种 AWS 和第三方数据存储。该公司希望将所有数据整合到一个中央数据仓库中以进行分析。用户需要分析查询的快速响应时间。

该公司使用亚马逊 QuickSight 的直接查询模式来可视化数据。用户通常每天运行几个小时的查询，期间会出现不可预测的峰值。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 使用 Amazon Redshift Serverless 将所有数据加载到 Amazon Redshift 管理存储（RMS）中。
- B. 使用 Amazon Athena 将所有数据以 Apache Parquet 格式加载到 Amazon S3 中。
- C. 使用亚马逊 Redshift 预配置集群将所有数据加载到亚马逊 Redshift 管理存储（RMS）中。
- D. 使用 Amazon Aurora PostgreSQL 将所有数据加载到 Aurora 中。

正确答案：A

部分：（无）

解释/参考：

解释：

亚马逊 Redshift Serverless 非常适合这种情况，因为它提供了一种完全托管的无服务器数据仓库解决方案，具有高性能的分析查询能力。它符合要求且**运营开销最小**的关键原因在于：

无服务器配置：Redshift 无服务器会根据查询需求自动扩展容量，因此非常适合应对难以预测的使用高峰，无需手动调整。

托管存储（RMS）：将数据加载到 Amazon Redshift 托管存储中可为分析提供优化存储，并与 Amazon QuickSight 集成，在直接查询模式下实现快速查询性能。

成本效益高且管理简便：由于数据仓库每天仅在几个小时内被积极使用，Redshift Serverless 通过动态扩展资源提供了一种经济高效的选项，从而消除了管理闲置基础设施和为其付费的需求。

问题 205

一位数据工程师每天使用亚马逊 Kinesis 数据流来摄取和处理来自应用程序的包含用户行为数据的记录。

数据工程师注意到数据流出现了节流现象，因为热门分片接收到的数据量远远多于数据流中的其他分片。

数据工程师应如何解决限流问题？

- A. 使用随机分区键来分配摄入的记录。
- B. 增加数据流中的分片数量。将记录分配到各个分片中。
- C. 限制生产者每秒发送的记录数量，使其与流的容量相匹配。
- D. 减小生产者发送的记录大小，使其与流的容量相匹配。

正确答案：B

部分：（无）

解释/参考：

解释：

亚马逊 Kinesis 数据流会在多个分片间分配数据，每个分片都有其自身的读写操作容量。当一个或多个分片（称为“热点分片”）接收到的数据量远超其处理能力时，就会发生限流。为解决此问题，增加数据流中的分片数量，并将记录重新分配到各个分片，是恰当的解决办法。这种方法能确保工作负载更均匀地分布，从而避免单个分片出现限流情况。

问题 206

一家公司拥有一条包含数十个步骤的数据处理流水线。该数据处理流水线需要在某个步骤失败或成功时实时发送警报。该数据处理流水线使用了亚马逊 S3 存储桶、AWS Lambda 函数以及 AWS Step Functions 状态机的组合。

数据工程师需要创建一个解决方案来监控整个流程。

哪种解决方案能满足这些要求？

- A. 将 Step Functions 状态机配置为在状态机运行结束时将通知存储在 Amazon S3 存储桶中。在 S3 存储桶上启用 S3 事件通知。
- B. 配置 AWS Lambda 函数，以便在状态机运行结束时将通知存储在 Amazon S3 存储桶中。在 S3 存储桶上启用 S3 事件通知。
- C. 使用 AWS CloudTrail 向 Amazon Simple Notification Service（Amazon SNS）主题发送消息，当状态机运行失败或成功运行时发送通知。
- D. 配置一个 Amazon EventBridge 规则，以便在状态机的执行状态发生变化时做出反应。

将规则配置为向发送通知的 Amazon 简单通知服务（Amazon SNS）主题发送消息。

正确答案：D

部分：（无）

解释/参考：解释：

亚马逊 EventBridge 可以监控 AWS Step Functions 状态机的执行状态，并根据状态变化触发特定操作，例如状态机成功或失败时。通过配置 EventBridge 规则来捕获这些执行状态变化并将详细信息转发到 Amazon SNS 主题，可以实时发送通知以提醒用户。此解决方案确保了采用可扩展且事件驱动的方法来实时监控整个数据处理管道。

问题 207

一家公司有一个应用程序，该程序使用亚马逊 API 网关 REST API 和 AWS Lambda 函数从亚马逊 DynamoDB 实例中检索数据。最近用户报告称该应用程序的响应时间间歇性出现高延迟。一位数据工程师发现，当公司的其他 Lambda 函数调用次数增加时，该 Lambda 函数经常出现调用限制的情况。

该公司希望确保其 API 的 Lambda 函数能够独立运行，不受其他 Lambda 函数的影响。

哪种解决方案能以最经济高效的方式满足这一要求？

- A. 增加 DynamoDB 中的读取容量单位（RCU）数量。
- B. 为 Lambda 函数配置预置并发。
- C. 为 Lambda 函数配置预留并发量。
- D. 增加 Lambda 函数的超时时间和分配的内存。

正确答案：C

部分：（无）

解释/参考：

解释：

预留并发量可确保特定的 Lambda 函数具有固定数量的并发执行次数，不会因其他 Lambda 函数消耗共享并发量限制而受到节流。通过配置预留并发量，API 的 Lambda 函数始终拥有执行所需的资源，不会受到其他函数的影响，从而避免节流并确保性能稳定。

问题 208

一家公司有一个包含个人身份信息（PII）数据和非 PII 数据的 JSON 文件。该公司需要使这些数据可供查询和分析。

非个人身份信息数据必须向公司全体员工开放。个人身份信息数据只能提供给有限的员工群体。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 将 JSON 文件存储在 Amazon S3 存储桶中。配置 AWS Glue 将文件拆分为一个包含个人身份信息（PII）数据的文件和一个包含非个人身份信息（非 PII）数据的文件。将输出文件存储在不同的 S3 存储桶中。根据用户类型授予对存储桶的相应访问权限。
- B. 将 JSON 文件存储在 Amazon S3 存储桶中。使用 Amazon Macie 来识别个人身份信息（PII）数据，并根据用户类型授予访问权限。
- C. 将 JSON 文件存储在 Amazon S3 存储桶中。在 AWS Lake Formation 中对文件模式进行编目。使用 Lake Formation 权限根据用户类型提供对所需数据的访问权限。
- D. 创建两个 Amazon RDS PostgreSQL 数据库。将包含个人身份信息（PII）的数据和不包含个人身份信息（非 PII）的数据分别加载到不同的数据库中。根据用户类型授予对数据库的访问权限。

正确答案：C

部分：（无）

解释/参考：

解释：

AWS Lake Formation 可让您将 JSON 文件注册为数据目录中的表，并应用细粒度权限（细至列或行），而无需移动或转换底层数据。您可以授予所有员工对非个人身份信息（PII）列的访问权限，同时将 PII 列的访问权限限制在小范围内，从而以最小的运营开销满足您的安全要求。

问题 209

一家公司使用 AWS 密钥管理服务（AWS KMS）对 Amazon Redshift 集群进行加密。该公司希望将 Redshift 集群的跨区域快照配置为灾难恢复（DR）策略的一部分。

数据工程师需要使用 AWS 命令行界面（CLI）来创建跨区域快照。

哪两种步骤的组合能满足这些要求？（选择两项。）

- A. 在源 AWS 区域创建一个 KMS 密钥，并配置快照副本授权。
- B. 在源 AWS 区域中，启用快照复制。指定在目标 AWS 区域中创建的快照复制授权的名称。
- C. 在源 AWS 区域中，启用快照复制。指定在源 AWS 区域中创建的快照复制授权的名称。
- D. 在目标 AWS 区域创建一个 KMS 密钥并配置快照副本授权。
- E. 将集群转换为多可用区部署。

正确答案：BD

部分：（无）

解释/参考：

解释：

您必须在目标区域创建一个客户管理的 KMS 密钥，然后针对该密钥创建一个快照复制授权，这样 Redshift 才能使用目标 CMK 对传入的快照重新加密。

在源区域，您随后启用跨区域快照复制，并引用在目标区域创建的授权名称。这会告知 Redshift 在将加密快照复制到灾难恢复区域时使用哪个 CMK（通过授权）。

问题 210

一家公司正在使用亚马逊 S3 构建数据湖。该公司需要将来自多个源数据库的记录复制为 Apache Parquet 格式。

大多数源数据库托管在亚马逊 RDS 上。然而，有一个源数据库是本地的 Microsoft SQL Server 企业版实例。该公司需要实施一个解决方案，以将所有源数据库中的现有数据以及未来的所有变更复制到目标 S3 数据湖中。

哪种解决方案能以最经济高效的方式满足这些要求？

- A. 使用一个 AWS Glue 作业来复制现有数据。使用第二个 AWS Glue 作业来复制未来的变更。
- B. 使用 AWS 数据迁移服务（AWS DMS）复制现有数据。使用 AWS Glue 作业复制未来的变更。
- C. 使用 AWS 数据迁移服务（AWS DMS）来复制现有数据和未来的变更。
- D. 使用 AWS Glue 作业来复制现有数据。使用 Amazon Kinesis 数据流来复制未来的变更。

正确答案：C

部分：（无）

解释/参考：

解释：

亚马逊数据库迁移服务（Amazon DMS）能够对每个源（包括本地的 SQL Server）执行一次性全量加载，然后捕获持续变化（CDC），并直接以 Apache Parquet 格式交付至 S3。每个源使用一个 DMS 复制任务，可最大限度地减少基础设施、运营开销和成本。

问题 21

一位数据工程师需要优化处理零售订单的数据管道的性能。有关订单的数据每天都会被导入到一个亚马逊 S3 存储桶中。

数据工程师每周运行一次查询，根据订单日期从订单数据中提取多个日期范围内的指标。数据工程师需要一个优化方案，以确保在数据量增加时查询性能不会下降。

哪种解决方案能以最经济高效的方式满足这一要求？

- A. 按订单日期对数据进行分区。使用 Amazon Athena 查询数据。
- B. 按订单日期对数据进行分区。使用 Amazon Redshift 查询数据。
- C. 按加载日期对数据进行分区。使用 Amazon EMR 查询数据。
- D. 根据加载日期对数据进行分区。使用亚马逊 Aurora 查询数据。

正确答案：A

部分：（无）

解释/参考：

解释：

按照订单日期对 S3 数据进行分区，可让 Athena 只扫描相关的日期文件夹，从而在数据增长时保持查询时间稳定。由于 Athena 是一种无服务器、按查询付费的服务，您只需为扫描的数据付费，因此这是运行每周日期范围指标最经济高效的方式。

问题 212

一位数据工程师有两个包含多个城市和州销售信息的数据集。其中一个数据集名为“参考”，另一个数据集名为“主要”。

数据工程师需要一个解决方案来确定主数据集中的城市和州列中的特定值集是否与参考数据集中的相同特定值完全匹配。数据工程师希望在 AWS Glue 数据质量作业中使用数据质量定义语言（DQDL）规则。

哪条规则能满足这些要求？

- A. 数据集匹配 “参考” “城市->ref_城市，州->ref_州” = 1.0
- B. 引用完整性 “城市，州” “引用.{引用城市，引用州}” = 1.0
- C. 数据集匹配 “参考” “城市->参考城市，州->参考州” = 10
- D. 引用完整性 “城市，州” “引用.{引用城市，引用州}” = 10

正确答案：B

部分：（无）

解释/参考：

解释：

参照完整性规则会检查主数据集中的每个（城市，州）对在参考数据集中都有一个匹配的（参考城市，参考州）对，并将阈值设置为 1.0 可强制实现 100% 的匹配率。这直接验证了这些列的精确对应关系，且无需额外开销。

问题 213

一家公司拥有一个本地的 PostgreSQL 数据库，其中包含客户数据。该公司希望将客户数据迁移到 Amazon Redshift 数据仓库。该公司已在本地数据库与 AWS 之间建立了 VPN 连接。

本地数据库会持续更新。公司必须确保亚马逊 Redshift 中的数据能尽快更新。

哪种解决方案能满足这些要求？

- A. 使用 `pg_dump` 实用程序生成 PostgreSQL 数据库的备份。使用 AWS 架构迁移工具（AWS SCT）将备份上传到 Amazon Redshift。设置一个 cron 作业来执行备份。每晚将备份上传到 Amazon Redshift。
- B. 创建一个 AWS 数据迁移服务（AWS DMS）的全量加载任务。将 Amazon Redshift 设定为目标。配置任务以使用变更数据捕获（CDC）功能。
- C. 使用 `pg_dump` 实用程序生成 PostgreSQL 数据库的备份。将备份上传到 Amazon S3 存储桶。使用 COPY 命令将数据导入 Amazon Redshift。
- D. 创建一个 AWS 数据库迁移服务（AWS DMS）的全量加载任务。将 Amazon Redshift 设定为目标。配置该任务，使其每晚将数据库的全量数据加载到 Amazon Redshift 中。

正确答案：B

部分：（无）

解释/参考：

解释：

AWS DMS 可以将您本地的 PostgreSQL 数据一次性完整加载到 Redshift 中，然后通过 VPN 持续捕获并应用更改（CDC）。这种方法能够以最小的延迟和运营开销使您的 Redshift 表保持最新。

问题 214

一家公司有若干新的 CSV 和 JSON 格式的数据集。一名数据工程师需要将这些数据提供给一个数据分析师团队，以便他们通过使用 SQL 查询来分析这些数据。

哪种解决方案能以最经济的方式满足这些要求？

- A. 创建一个 Amazon RDS MySQL 集群。使用 AWS Glue 将 CSV 和 JSON 文件转换并加载到数据库表中。为数据分析师提供对 MySQL 集群的访问权限。
- B. 创建一个包含新数据的 AWS Glue DataBrew 项目，并将该项目提供给数据分析师。
- C. 将数据存储在 Amazon S3 存储桶中。使用 AWS Glue 爬虫程序将 S3 存储桶编目为表。创建一个具有数据使用阈值的 Amazon Athena 工作组。授予数据分析师对 Athena 工作组的访问权限。
- D. 将数据加载到亚马逊 QuickSight 中的超快速并行内存计算引擎（SPICE）中。允许数据分析师在 QuickSight 中创建分析和仪表板。

正确答案：C

部分：（无）

解释/参考：解释：

通过将 CSV 和 JSON 文件存储在 Amazon S3 中并运行 AWS Glue 爬虫程序，您可以自动将它们编目为表，而无需预先进行 ETL 操作。然后，Amazon Athena 允许分析师直接对这些表运行 SQL 查询，按查询付费。使用具有使用阈值的 Athena 工作组可控制成本，使其成为最具成本效益且操作开销最低的解决方案。

问题 215

一家零售公司将订单信息存储在名为“Orders”的 Amazon Aurora 表中。该公司需要从“Orders”表中生成操作报告，且要求延迟最小。该表包含数十亿行数据，每秒会发生超过 10 万笔交易。

营销团队需要将其订单数据与营销团队数据仓库中名为“Campaigns”的 Amazon Redshift 表连接起来。操作型的 Aurora 数据库不得受到影响。

哪种解决方案能以最少的操作努力满足这些要求？

- A. 使用 AWS 数据库迁移服务（AWS DMS）无服务器功能将“订单”表复制到 Amazon Redshift 中。在 Amazon Redshift 中创建一个物化视图，用于与“活动”表进行连接。
- B. 使用 Aurora 的零 ETL 集成功能将“订单”表复制到 Amazon Redshift 中。在 Amazon Redshift 中创建一个物化视图，以便与“活动”表进行连接。
- C. 使用 AWS Glue 将“订单”表复制到 Amazon Redshift 中。在 Amazon Redshift 中创建一个物化视图。

将 Redshift 与 Campaigns 表连接。

D. 使用联合查询直接从 Aurora 查询“订单”表。在 Amazon Redshift 中创建一个物化视图以与“活动”表进行连接。

正确答案：B

部分：（无）

解释/参考：

解释：

Aurora 与 Redshift 的零 ETL 集成可自动且持续地将 Orders 表中的数据变更流式传输到 Redshift 表中，几乎无需任何设置或维护。然后，您可以在 Redshift 中定义一个物化视图，将复制的 Orders 表与 Campaigns 表进行连接。这种方法对生产 Aurora 工作负载的影响极小，并且所需的运营工作量远少于自行构建和管理 ETL 或复制管道。

问题 216

一家公司正在开发一款新的应用程序，该程序将 CSV 文件导入到亚马逊 Redshift 中。该公司已经开发出了该应用程序的前端。

这些文件存储在亚马逊 S3 存储桶中。文件大小均不超过 5MB。

一位数据工程师正在为 CSV 文件开发提取、转换和加载（ETL）管道。该数据工程师配置了一个 Redshift 集群和一个 AWS Lambda 函数，用于将文件中的数据复制到 Redshift 集群中。

数据工程师还应采取哪些额外步骤才能满足这些要求？

- A. 将存储桶配置为向 Amazon EventBridge 发送 S3 事件通知。配置一个与 S3 新对象创建事件匹配的 EventBridge 规则。将 Lambda 函数设置为目标。
- B. 将 S3 存储桶配置为向 Amazon Simple Queue Service（Amazon SQS）队列发送 S3 事件通知。配置 Lambda 函数以处理该队列。
- C. 配置 AWS 数据迁移服务（AWS DMS），将新的 S3 对象流式传输到 Amazon Kinesis Data Streams 中的数据流。将 Lambda 函数设置为数据流的目标。
- D. 配置一个与 S3 新对象创建事件匹配的 Amazon EventBridge 规则。将 Amazon Simple Queue Service（Amazon SQS）队列设置为该规则的目标。配置 Lambda 函数来处理该队列。

正确答案：A

部分：（无）

解释/参考：解释：

通过将 S3 的“对象创建”事件发送到 EventBridge，并使用一条规则将这些事件与您的 Lambda 函数相匹配，每当新的 CSV 文件上传到 S3 时，您就可以触发 ETL，无需额外的轮询或队列管理。这种直接的事件驱动模式将运营开销降至最低。

问题 217

一家公司将敏感数据存储在亚马逊 Redshift 表中。该公司需要赋予特定用户访问这些敏感数据的权限。同时，公司不能造成数据的重复。

客户支持用户必须能够看到敏感数据的最后四位字符。审计用户必须能够看到敏感数据的完整值。其他用户均无权访问敏感信息。

哪种解决方案能满足这些要求？

- A. 创建一个动态数据屏蔽策略，根据每个用户角色允许访问。创建具有特定访问权限的 IAM 角色。将屏蔽策略附加到包含敏感数据的列上。
- B. 在 Redshift 集群上启用元数据安全。为客户支持用户和审计用户创建 IAM 用户和 IAM 角色。授予 IAM 用户和 IAM 角色查看 Redshift 集群中元数据的权限。

- C. 创建行级安全策略，以根据每个用户角色允许访问。创建具有特定访问权限的 IAM 角色。将安全策略附加到表。
- D. 创建一个 AWS Glue 作业来对敏感数据进行脱敏处理，并将数据加载到新的 Redshift 表中。

正确答案：A

部分：（无）

解释/参考：

解释：

亚马逊 Redshift 的动态数据屏蔽功能让您能够在不复制数据的情况下为敏感列定义屏蔽策略。您可以为客户提供支持的 IAM 角色附加仅显示最后四位字符的屏蔽策略，而审计 IAM 角色则能看到完整值。这满足了基于角色的列级访问要求，且无需数据复制。

问题 218

一位数据工程师使用 AWS Lake Formation 来管理存储在 Amazon S3 存储桶中的数据的访问权限。该数据工程师配置了一个 AWS Glue 爬虫程序来发现存储桶中特定文件位置（s3://examplepath）的数据。爬虫程序执行失败，并出现以下错误：“S3 位置：s3://examplepath 未注册。”

数据工程师需要解决这个错误。

哪种解决方案能满足这一要求？

- A. 将适当的 IAM 策略附加到 AWS Glue 爬虫的 IAM 角色，以授予爬虫读取 S3 位置的权限。
- B. 在 Lake Formation 中注册 S3 位置，以允许爬虫访问数据。
- C. 创建一个新的 AWS Glue 数据库。为爬虫程序为该数据库分配正确的权限。
- D. 配置 S3 存储桶策略以允许跨账户访问。

正确答案：B

部分：（无）

解释/参考：

解释：

在 Lake Formation 中，您必须先明确将每个 S3 路径注册为数据位置，然后任何 Glue 爬虫或用户才能访问它。在 Lake Formation 中注册 s3://examplepath 会授予爬虫访问该位置所需的元数据权限。

问题 219

该公司在 AWS 上构建了一个数据湖和一个数据仓库。该公司希望实施一个数据目录以增强当前的数据存储服务解决方案。该公司希望具备为数据目录中的每个资产添加业务元数据和术语表信息的能力。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 使用 AWS Glue 数据目录。为业务术语表创建一个用户表。使用 AWS Glue API 更改表属性以添加业务元数据。创建一个网络应用程序来访问元数据。
- B. 使用 Apache Hive 元数据存储。为业务术语表创建一个用户表。使用 ALTER TABLE 命令更改表属性以添加业务元数据。创建一个网络应用程序来访问元数据。
- C. 使用亚马逊数据区。创建业务术语表。创建元数据表单。使用亚马逊数据区数据门户访问元数据。
- D. 使用亚马逊 OpenSearch 服务。为业务术语表创建一个索引。为业务元数据创建第二个索引。使用 OpenSearch 服务控制面板访问元数据。

正确答案：C

部分：（无）

解释/参考：

解释：

亚马逊 DataZone 提供了一个完全托管的数据目录和治理服务，内置了对业务术语表、自定义元数据表单以及用户友好型数据门户的支持。您可以将现有的数据资产引入系统，定义术语表，并捕获业务元数据，而无需构建或维护自定义表、API 或应用程序，从而最大程度地减少运营开销。

问题 220

一位数据工程师正在使用 AWS Glue ETL 作业从包含客户账户信息的表中删除过时的客户记录。该数据工程师正在使用以下 SQL 命令从名为 `monthly_accounts_update` 的表中删除客户账户表中存在的客户：

```
将 monthly_accounts_update 表中的数据合并到 accounts 表中，  
合并条件为 t.customer = s.customer 。  
匹配时  
删除
```

当数据工程师运行该 SQL 命令时会发生什么？

- A. 存在于客户账户表和每月账户更新表中的所有客户记录都将从账户表中删除。
- B. 只有同时存在于这两个表中的客户记录才会保留在客户账户表中。
- C. 每月账户更新表将被删除。
- D. 由于命令语法在 AWS Glue 中无效，因此不会删除任何记录。

正确答案：A

部分：（无）

解释/参考：

解释：

该 MERGE 语句会删除 accounts 表中所有客户值与 monthly_accounts_update 表中某一行相匹配的行。所有重叠的客户记录都将从 accounts 表中移除。

问题 221

一家公司从供应商处接收营销活动数据。该公司每 40 至 60 分钟将数据导入一个亚马逊 S3 存储桶。数据为 CSV 格式。文件大小在 100 千字节到 300 千字节之间。

数据工程师需要设置一个提取、转换和加载（ETL）管道，将每个文件的内容上传到 Amazon Redshift。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 创建一个 AWS Lambda 函数，使其连接到 Amazon Redshift 并运行 COPY 命令。使用 Amazon EventBridge 根据 Amazon S3 上传触发器调用该 Lambda 函数。
- B. 创建一个 Amazon Data Firehose 流。将流配置为使用 AWS Lambda 函数作为源从 S3 存储桶中提取数据。将 Amazon Redshift 设置为目的地。
- C. 使用 Amazon Redshift Spectrum 查询 S3 存储桶。为 S3 存储桶配置一个 AWS Glue 爬虫，以更新 AWS Glue 数据目录中的元数据。
- D. 创建一个 AWS 数据迁移服务（AWS DMS）任务。指定要迁移的适当数据架构。指定要使用的适当迁移类型。

正确答案：A

部分：（无）

解释/参考：

解释：

将您的 S3 存储桶配置为向 EventBridge 发送“对象创建”事件，并使用规则调用轻量级的 Lambda 函数，这样每当有新的 CSV 文件时，即可自动运行 Redshift COPY 操作。这种无服务器、事件驱动的模式无需持续运行的基础设施，且运营开销极低。

问题 22

一家公司希望在亚马逊 S3 存储桶中构建一个维度表。该存储桶包含 1000 万条记录的历史数据，这些历史数据的大小为 1TB。

一名数据工程师需要一个解决方案，以便每天更新基础表中多达 10,000 条记录的变更。

哪种解决方案能在运行时间最短的情况下满足这一要求？

- A. 在 Amazon EMR 中开发一个 Apache Spark 作业，将历史数据和新变更读入两个 Spark 数据框。使用 Spark 的更新方法来更新基础表。
- B. 开发一个 AWS Glue Python 作业，将历史数据和新变更读入两个 Pandas 数据框。使用 Pandas 的 update 方法更新基础表。
- C. 开发一个 AWS Glue Apache Spark 作业，将历史数据和新变更读入两个 Spark 数据框。使用 Spark 的更新方法来更新基础表。
- D. 开发一个 Amazon EMR 作业，将新变更读入 Apache Spark 数据框。使用 Apache Hudi 框架在 Amazon S3 中创建基础表。使用 Spark 更新方法更新基础表。

正确答案：D

部分：（无）

解释/参考：

解释：

在 EMR 上使用 Apache Hudi 可以对您的 S3 “基础表”提供原生的更新插入支持。Hudi 的索引和元数据管理功能使其仅重写少量更改的文件（您每天约 10,000 条记录），而不是扫描并重写整个 1TB 的数据。这最大限度地减少了处理时间，并实现了每日更新的最短运行时间。

问题 223

一位数据工程师开发了一个 AWS Glue Apache Spark ETL 作业，用于对数据集进行转换。当该工程师运行此作业时，作业返回了一个错误，内容为：“设备上没有空间。”

数据工程师需要找出错误的根源并提供解决方案。

哪些步骤组合能以最经济高效的方式满足这一要求？（选择两项。）

- A. 纵向扩展工作节点以解决数据倾斜问题。
- B. 使用 Spark UI 和 AWS Glue 指标来监控 Spark 执行器中的数据倾斜情况。
- C. 通过横向扩展工人的数量来解决数据倾斜问题。
- D. 启用 --write-shuffle-files-to-s3 作业参数。使用加盐技术。
- E. 使用 Amazon CloudWatch 中的错误日志来监控数据倾斜。

正确答案：BD

部分：（无）

解释/参考：解释：

使用 Spark UI 和 AWS Glue 公开的 Spark 指标来查明分区大小不均衡（数据倾斜）的位置以及溢出文件填满执行器磁盘的位置。

启用 --write-shuffle-files-to-s3 作业参数，这样在本地磁盘空间不足时，溢出数据将写入 S3，同时对倾斜键应用加盐技术，以使数据在分区之间分布得更均匀。

问题 224

一家公司拥有数据管道，该管道使用一个亚马逊 RDS 实例、AWS Glue 作业以及一个亚马逊 S3 存储桶。RDS 实例和 AWS Glue 作业运行在 VPC 的一个私有子网中，并且处于同一个安全组内。

一位用户对安全组进行了更改，导致 AWS Glue 作业无法连接到 RDS 实例。更改后，该安全组仅包含一条规则，允许来自特定 IP 地址的入站 SSH 流量。

公司必须解决连接问题。

哪种解决方案能满足这一要求？

- A. 添加一条入站规则，允许所有 TCP 端口上的所有 TCP 流量。将安全组设置为源。
- B. 添加一条入站规则，允许所有 TCP 流量通过所有 UDP 端口。将 RDS 实例的私有 IP 地址设为源地址。
- C. 添加一条入站规则，允许所有 TCP 端口上的所有 TCP 流量。将 RDS 实例的 DNS 名称设置为源。
- D. 将现有 SSH 规则的源地址替换为 RDS 实例的私有 IP 地址。创建一个出站规则，其源地址、目标地址和协议与入站 SSH 规则相同。

正确答案：A

部分：（无）

解释/参考：

解释：

由于 RDS 实例和 Glue 作业共享同一个安全组，因此允许该安全组作为入站 TCP 流量（所有端口）的源，即可立即恢复 Glue 附加的 ENI 与数据库之间的连接。这一单个规则更改无需额外的基础设施，也不会产生额外的维护成本。

问题 225

一家公司新建了一条数据处理管道，用于生成商业智能报告。用户们发现报告中缺失了一些数据。

数据工程师需要在将数据添加到存储之前的一个阶段，为包含空值的列以及参照完整性添加数据质量检查。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 使用 Amazon SageMaker Data Wrangler 创建数据质量与洞察报告。
- B. 使用 AWS Glue ETL 作业对数据执行数据质量评估转换。对请求的列使用 IsComplete 规则。对每个连接使用 ReferentialIntegrity 规则。
- C. 使用 AWS Glue ETL 作业对数据执行 SQL 转换，以确定请求的列是否包含空值。使用第二个 SQL 转换检查参照完整性。
- D. 使用 Amazon SageMaker Data Wrangler 和自定义 Python 转换来创建自定义规则，以检查空值和参照完整性。

正确答案：B

部分：（无）

解释/参考：

解释：

AWS Glue 内置的数据质量评估转换功能让您能够直接在 ETL 作业中声明式地应用 DQDL 规则，例如用于空值检查的 IsComplete 和用于连接的 ReferentialIntegrity。这只需极少的自定义代码，且无需单独的报告或分析基础设施，从而以最小的运营开销实现加载前的验证。

问题 226

一家公司正在 AWS 中搭建数据管道。该管道从亚马逊 S3 存储桶中提取客户数据，进行质量检查，并对数据进行转换。处理后的数据将存储在关系型数据库中。该公司将使用这些处理后的数据进行未来的查询。

哪种解决方案能以最经济高效的方式满足这些要求？

- A. 使用 AWS Glue ETL 从 S3 存储桶中提取数据并执行转换操作。使用 AWS Glue 数据质量功能来强制执行建议的质量规则。将数据和质量检查结果加载到 Amazon RDS for MySQL 实例中。
- B. 使用 AWS Glue Studio 从 S3 存储桶中提取数据。使用 AWS Glue DataBrew 执行转换和质量检查。将处理后的数据加载到 Amazon RDS for MySQL 中。

例如。将质量检查结果加载到一个新的 S3 存储桶中。

- C. 使用 AWS Glue ETL 从 S3 存储桶中提取数据并执行转换操作。使用 AWS Glue DataBrew 进行质量检查。将处理后的数据和质量检查结果加载到新的 S3 存储桶中。
- D. 使用 AWS Glue Studio 从 S3 存储桶中提取数据。使用 AWS Glue DataBrew 执行转换和质量检查。将处理后的数据和质量检查结果加载到 Amazon RDS for MySQL 实例中。

正确答案：A

部分：（无）

解释/参考：

解释：

使用单个 AWS Glue ETL 作业来转换数据并调用 Glue 数据质量检查，可让您声明性地强制执行推荐规则，而无需启动单独的工具。然后，您可以将清理后的数据直接写入您的 Amazon RDS for MySQL 实例，如果需要，还可以将质量指标写入其中。这种无服务器的端到端方法可最大程度减少服务蔓延，并且仅产生 Glue 和 RDS 费用，因此是最具成本效益且运营开销最小的方法。

问题 227

一家公司使用亚马逊 Redshift 作为数据仓库解决方案。该公司存储在亚马逊 Redshift 中的一个数据集包含某个供应商的数据。

最近，供应商要求该公司每周将供应商的数据转存到供应商的亚马逊 S3 存储桶中一次。

哪种解决方案能满足这一要求？

- A. 创建一个 AWS Lambda 函数以连接到 Redshift 数据仓库。配置该 Lambda 函数，使其按照计划使用 Redshift 的 COPY 命令将所需数据复制到供应商的 S3 存储桶中。
- B. 创建一个 AWS Glue 作业以连接到 Redshift 数据仓库。配置 AWS Glue 作业，使其使用 Redshift 的 UNLOAD 命令按计划将所需数据加载到供应商的 S3 存储桶中。
- C. 使用 Amazon Redshift 的数据共享功能。将供应商的 S3 存储桶设置为目的地。将源配置为自定义 SQL 查询，以选择所需的数据。
- D. 配置 Amazon Redshift Spectrum 使用供应商的 S3 存储桶作为目标，启用双向数据查询。

正确答案：B

部分：（无）

解释/参考：

解释：

AWS Glue 作业可以连接到您的 Amazon Redshift 集群，并执行 UNLOAD 命令，将指定的供应商数据直接导出到供应商的 S3 存储桶中。将 Glue 作业安排为每周运行一次所需的运营工作量极小，而且 UNLOAD 已针对高效导出大型结果集进行了优化。

问题 228

一家公司使用亚马逊 Redshift 集群作为数据仓库，供两个部门共享。为遵守一项安全政策，每个部门都必须拥有独特的访问权限。

部门 A 必须能够访问部门 A 的表和视图。部门 B 必须能够访问部门 B 的表和视图。

该公司经常运行使用来自两个部门的对象的 SQL 查询。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 将每个部门的表和视图分组到专用模式中。在模式级别管理权限。

模式级别。

- B. 将每个部门的表和视图分组到专用数据库中。在数据库级别管理权限。
- C. 将表和视图的名称更新为包含部门名称的命名约定。根据新的命名约定管理权限。
- D. 为每个部门创建一个 IAM 用户组。使用基于身份的 IAM 策略，根据 IAM 用户组授予表和视图的权限。

正确答案：A

部分：（无）

解释/参考：

解释：

通过将每个部门的表和视图组织到其自身的模式中（例如，dept_a 和 dept_b），您可以在模式级别授予使用权限和对象权限。部门 A 的角色在模式 dept_a 上获得使用权限以及必要的选择权限（并且在 dept_b 上没有任何权限），反之亦然。由于两个模式都在同一个数据库中，分析师仍然可以通过模式限定对象来运行跨部门查询，并且您避免了使用多个数据库或复杂 IAM 策略所带来的额外复杂性。

问题 229

一家公司希望将流数据从 Amazon Managed Streaming for Apache Kafka（Amazon MSK）集群导入到 Amazon Redshift 数据仓库中。一位数据工程师需要开发一种解决方案，以实现低数据访问时间和优化存储成本。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 创建一个映射到 MSK 集群的外部模式。创建一个引用该外部模式的物化视图，以从 MSK 主题中消费流数据。
- B. 开发一个 AWS Glue 流处理提取、转换和加载（ETL）作业来处理来自 Amazon MSK 的传入数据。将数据加载到 Amazon S3 中。使用 Amazon Redshift Spectrum 从 Amazon S3 中读取数据。
- C. 创建一个映射到流数据源的外部模式。创建一个引用该外部模式的新 Amazon Redshift 表。
- D. 创建一个 Amazon S3 存储桶。从 Amazon MSK 中摄取数据。创建一个事件驱动的 AWS Lambda 函数，将数据从 S3 存储桶加载到新的 Amazon Redshift 表中。

正确答案：B

部分：（无）

解释/参考：

解释：

通过使用无服务器的 Glue 流处理作业持续拉取您的 MSK 记录，根据需要对其进行转换，并将其保存为 Parquet（或其他列式）文件到 S3 中，您可以：

1. 优化存储成本——您的数据存放在 S3 中，您只需按每月每 GB 支付少量费用，并且可以使用生命周期规则进一步分级存储。
2. 获得低延迟访问——Redshift Spectrum 可让您以毫秒级的规划时间查询基于 S3 的表，因此新上传的数据几乎可以立即进行查询。
3. 降低运维开销——您无需搭建或管理任何基于 EC2 的代理、Lambda 拉取循环或自定义连接器基础设施。Glue 的托管流处理运行时会为您处理检查点、自动扩展和容错。

一旦数据进入 S3，您只需在 Redshift 中定义一个指向 Glue 数据目录数据库的外部模式，您的流处理作业会将表写入该数据库。这样，分析师就可以通过 Spectrum 查询“实时”数据集，就好像这些数据在 Redshift 内部一样，从而以最小的运营工作量实现性能和成本目标。

问题 230

一家销售公司使用 AWS Glue ETL 来收集、处理数据，并将其导入到 Amazon S3 存储桶中。AWS Glue 管道每小时在 S3 存储桶中创建一个新文件。文件大小从 200KB 到 300KB 不等。该公司希望利用过去 5 年的数据构建一个销售预测模型。历史数据

数据包含 44,000 个文件。

该公司使用最小的工人类型构建了第二个 AWS Glue ETL 管道。第二个管道从 S3 存储桶中检索历史文件，并对这些文件进行处理以供下游分析。该公司注意到第二个 ETL 管道存在严重的性能问题。

公司需要提高第二条管道的性能。

哪种解决方案能以最经济高效的方式满足这一要求？

- A. 使用更大的工作类型。
- B. 增加 AWS Glue ETL 作业中的工人数量。
- C. 使用 AWS Glue 的 DynamicFrame 分组选项。
- D. 启用 AWS Glue 自动扩展。

正确答案：C

部分：（无）

解释/参考：解释：

使用 AWS Glue 的 DynamicFrame 分组选项（例如，设置 groupFiles=True 并指定适当的 groupSize）可以在读取时将许多小的输入文件合并为较大的分区。这减少了每个文件的任务初始化和元数据操作的开销，从而在不增加更多或更大工作节点成本的情况下显著加快 ETL 运行速度。

问题 231

一家公司希望将来自多个软件即服务（SaaS）应用程序的数据整合起来进行分析。

一个数据工程团队需要使用亚马逊 QuickSight 来执行分析并构建仪表板。数据工程师需要从 SaaS 应用程序中提取数据，并使这些数据可供 QuickSight 查询使用。

哪种解决方案能以最高效的操作方式满足这些要求？

- A. 创建调用所需 API 以从应用程序中提取数据的 AWS Lambda 函数。将数据存储在 Amazon S3 存储桶中。使用 AWS Glue 对 S3 存储桶中的数据进行编目。在 QuickSight 中创建数据源和数据集。
- B. 使用 AWS Lambda 函数作为 Amazon Athena 数据源连接器，以对 SaaS 应用程序运行联合查询。在 QuickSight 中创建一个 Athena 数据源和一个数据集。
- C. 使用 Amazon AppFlow 为每个 SaaS 应用程序创建一个流。将 Amazon S3 存储桶设置为目的地。安排流将数据提取到存储桶中。使用 AWS Glue 对 S3 存储桶中的数据进行编目。在 QuickSight 中创建数据源和数据集。
- D. 从 SaaS 应用程序中导出数据为 Microsoft Excel 文件。通过上传 Excel 文件在 QuickSight 中创建数据源和数据集。

正确答案：C

部分：（无）

解释/参考：

解释：

亚马逊 AppFlow 提供了全面托管且无需编写代码的连接器，可连接到众多 SaaS 应用程序。通过安排将数据导入 S3 的流程，您无需构建和维护自定义的 API 调用代码。Glue 爬虫可以对文件进行编目，并使其可供 QuickSight 使用，从而为您提供一条几乎无需操作维护的端到端管道。

问题 232

一家公司在 AWS 上运行多个应用程序。该公司为每个应用程序配置了日志输出。该公司希望近乎实时地查询和可视化应用程序日志。

哪种解决方案能满足这些要求？

- A. 将应用程序配置为将日志输出到 Amazon CloudWatch Logs 日志组。创建一个 Amazon S3 存储桶。创建一个按计划运行的 AWS Lambda 函数，将所需的日志组导出到 S3 存储桶。使用 Amazon Athena 查询 S3 存储桶中的日志数据。
- B. 创建一个 Amazon OpenSearch 服务域。配置应用程序将日志输出到 Amazon CloudWatch Logs 日志组。为每个日志组创建一个 OpenSearch 服务订阅过滤器，以将数据流式传输到 OpenSearch。在 OpenSearch 服务中创建所需的查询和仪表板，以分析和可视化数据。
- C. 将应用程序配置为将日志输出到 Amazon CloudWatch Logs 日志组。使用 CloudWatch 日志异常检测来查询和可视化日志数据。
- D. 更新应用程序代码，通过使用超级快速、并行、内存计算引擎（SPICE）将日志数据发送到 Amazon QuickSight。在 QuickSight 中创建所需的分析和仪表板。

正确答案：B

部分：（无）

解释/参考：

解释：

通过订阅过滤器将 CloudWatch Logs 日志组直接流式传输到 Amazon OpenSearch Service 域，您可以实现近乎实时的索引，并构建 Kibana 仪表板以进行查询和可视化，几乎不存在批处理延迟。这种完全托管的管道最大程度地减少了自定义胶合代码，并以低运营开销满足您的需求。

问题 23

一家电子商务公司每天处理数百万份订单。该公司使用 AWS Glue ETL 从多个来源收集数据，清理数据，并使用 S3 标准存储类别将数据以 CSV 格式存储在 Amazon S3 存储桶中。该公司利用存储的数据进行日常分析。

该公司希望优化数据存储和检索的成本。

哪种解决方案能满足这一要求？

- A. 将数据迁移到亚马逊 S3 Glacier 随时检索存储类。
- B. 将数据从 Amazon S3 迁移到 Amazon Aurora 集群。
- C. 配置 AWS Glue ETL 将传入的数据转换为 Apache Parquet 格式。
- D. 配置 AWS Glue ETL 使用 Amazon EMR 并行处理传入的数据。

正确答案：C

部分：（无）

解释/参考：解释：

在您的 Glue ETL 作业中将 CSV 文件转换为 Apache Parquet 格式，可大幅减少存储空间（因为 Parquet 是一种压缩的列式格式），同时降低查询成本（因为分析引擎仅扫描您所需的列）。此更改无需新的基础设施，且能立即为您的日常分析工作负载带来回报。

问题 234

一位数据工程师正在优化使用 Apache Spark 分析存储在 Amazon S3 中的大型数据集的 Amazon Athena 笔记本的查询性能，这些数据已进行了分区。

AWS Glue 爬虫会更新分区。

数据工程师希望将扫描的数据量降至最低，以提高 Athena 查询的效率。

哪种解决方案能满足这些要求？

- A. 在查询中应用分区筛选器。
- B. 提高 AWS Glue 爬虫的调用频率，以便更频繁地更新数据目录。
- C. 使用嵌套目录结构对 Amazon S3 中的数据进行组织。

D. 配置 Spark 使用内存缓存来存储频繁访问的数据。

正确答案：A

部分：（无）

解释/参考：

解释：

通过在每个 Athena 查询中包含分区列的谓词（例如，WHERE year = '2025' AND month = '05'），Athena 在优化级别修剪分区，并仅读取匹配的 S3 文件夹。这直接减少了扫描的数据量，提高了查询效率，无需进行额外的基础设施更改。

问题 235

一家公司管理着一个亚马逊 Redshift 数据仓库。该数据仓库位于自定义 VPC 内的一个公共子网中。一个安全组仅允许来自自身的流量。访问控制列表（ACL）对所有流量开放。

该公司希望为即将举行的销售活动在亚马逊 QuickSight 中生成多个可视化图表。该公司将在第二个 AWS 账户内的第二个自定义 VPC 的公共子网中运行 QuickSight 企业版。新的公共子网有一个安全组，允许向外连接到现有的 Redshift 集群。

数据工程师需要在 Amazon Redshift 和 QuickSight 之间建立连接。QuickSight 必须通过查询 Redshift 集群来刷新仪表板。

哪种解决方案能满足这些要求？

- A. 将 Redshift 安全组配置为允许来自 QuickSight 安全组的 Redshift 端口的入站流量。
- B. 将弹性 IP 地址分配给 QuickSight 可视化内容。配置 QuickSight 安全组，允许来自弹性 IP 地址的 Redshift 端口的入站流量。
- C. 确认 Redshift VPC 和 QuickSight VPC 的 CIDR 范围相同。如果 CIDR 范围不同，请重新配置其中一个 CIDR 范围以与另一个匹配。在 VPC 之间建立网络对等连接。
- D. 在 Redshift VPC 中创建一个 QuickSight 网关端点。将端点策略附加到网关端点，以确保只有特定的 QuickSight 账户可以使用该端点。

正确答案：A

部分：（无）

解释/参考：解释：

由于您的 Redshift 集群在 VPC 中是公开可访问的，而 QuickSight 运行在单独的 VPC 和账户中，您只需允许 QuickSight 的出站连接通过 Redshift 安全组即可。通过在 Redshift 安全组上添加一条入站规则，允许来自 QuickSight 安全组的 5439 端口（或您的集群端口）的流量，QuickSight 就可以刷新仪表板，而无需进行任何额外的基础设施更改。

问题 236

一位数据工程师正在构建一个数据管道。每天都会在不可预测的时间将一个大型数据文件上传到亚马逊 S3 存储桶。一个 AWS Glue 工作流会使用数百个工人来处理该文件，并将数据加载到 Amazon Redshift 中。该公司希望尽可能快地处理该文件。

哪种解决方案能满足这些要求？

- A. 创建一个按需的 AWS Glue 触发器来启动工作流。创建一个每 15 分钟运行一次的 AWS Lambda 函数，用于检查 S3 存储桶中的每日文件。如果文件存在，则配置该函数启动 AWS Glue 工作流。
- B. 创建一个基于事件的 AWS Glue 触发器以启动工作流。配置 Amazon S3 将事件记录到 AWS CloudTrail。在 Amazon EventBridge 中创建一条规则，将 PutObject 事件转发到 AWS Glue 触发器。
- C. 创建一个计划的 AWS Glue 触发器来启动工作流。创建一个 cron 作业来运行 AWS Glue。

每 15 分钟运行一次作业。设置 AWS Glue 作业以检查 S3 存储桶中的每日文件。如果文件不存在，则配置作业停止运行。

- D. 创建一个按需的 AWS Glue 触发器以启动工作流。创建一个 AWS 数据迁移服务（AWS DMS）迁移任务。将 DMS 源设置为 S3 存储桶。将目标端点设置为 AWS Glue 工作流。

正确答案：B

部分：（无）

解释/参考：

解释：

由亚马逊 EventBridge 驱动的基于事件的触发器提供了在文件到达后立即启动 Glue 工作流的最低延迟和最低开销的方式。通过在 CloudTrail 中启用 S3 数据事件，并编写一个简单的 EventBridge 规则来匹配您的存储桶的 PutObject 事件，您可以直接将目标指向 Glue 工作流的触发器，从而消除持续轮询或额外的 Lambda 或 DMS 基础设施。

问题 237

数据工程师需要在用户向亚马逊 S3 存储桶添加文件时运行数据转换任务。该任务的运行时间将少于 1 分钟。任务必须通过电子邮件将输出发送给数据工程师。数据工程师预计用户每天每小时都会添加一个文件。

哪种解决方案能以最高效的操作方式满足这些要求？

- A. 创建一个小型的亚马逊 EC2 实例，用于轮询 S3 存储桶中的新文件。按照计划运行转换代码以生成输出。使用操作系统命令发送电子邮件。
- B. 运行 Amazon Elastic Container Service（Amazon ECS）任务，轮询 S3 存储桶以查找新文件。按照计划运行转换代码以生成输出。使用操作系统命令发送电子邮件。
- C. 创建一个 AWS Lambda 函数来转换数据。使用 Amazon S3 事件通知在创建新对象时调用 Lambda 函数。将输出发布到 Amazon 简单通知服务（Amazon SNS）主题。将数据工程师的电子邮件账户订阅到该主题。
- D. 部署一个 Amazon EMR 集群。使用 EMR 文件系统（EMRFS）访问 S3 存储桶中的文件。按照计划运行转换代码，将输出生成到第二个 S3 存储桶。创建一个 Amazon 简单通知服务（Amazon SNS）主题。配置 Amazon S3 事件通知，在创建新对象时通知该主题。

正确答案：C

部分：（无）

解释/参考：

解释：

当有新文件到达时，S3 对象创建事件通知可直接调用 Lambda 函数。Lambda 函数可以执行您的 1 分钟以内转换操作，然后将结果发布到 SNS 主题。数据工程师通过电子邮件订阅该主题，输出结果会自动送达——无需管理服务器，无需轮询，且后续操作极少。

问题 238

一家公司使用亚马逊 S3 和 AWS Glue 数据目录来管理一个包含客户联系信息的数据湖。该公司使用 PySpark 和 AWS Glue 作业以及 DynamicFrame 来运行一个工作流，以处理数据湖中的数据。

一位数据工程师注意到，由于客户邮政编码在数据湖中的存储方式，工作流出现了错误。一些邮政编码包含不必要的数字或无效字符。

数据工程师需要一个解决方案来处理错误并修正数据湖中的邮政编码。

- A. 为 PySpark 创建一个与处理工作流对邮政编码格式要求相匹配的模式定义。在处理过程中将该模式传递给 DynamicFrame。
- B. 使用 AWS Glue 工作流属性来实现作业状态共享。通过使用先前成功运行作业时的属性，配置 AWS Glue 作业从邮政编码列读取值。

- C. 配置 DynamicFrame 中邮政编码列的 column.push_down_predicate 设置和 catalogPartitionPredicate 设置。
- D. 将 DynamicFrame 的附加选项参数 “useS3ListImplementation” 设置为 True。

正确答案：A

部分：（无）

解释/参考：

解释：

通过在 PySpark 中定义并强制执行严格的模式，指定您期望的邮政编码的确切格式（例如，五位数字的字符串），Spark 将自动标记或强制转换任何不符合该格式的值。将该模式传递到您的 Glue 动态框架中，可以确保识别出格式错误的邮政编码，并作为 ETL 逻辑的一部分进行纠正或过滤，从而消除下游错误。

问题 239

一位数据工程师正在排查一个偶尔会失败的 AWS Glue 工作流的问题。工程师确定失败的原因是数据质量问题。业务报告团队需要在今后工作流出现故障时收到电子邮件通知。

哪种解决方案能满足这一要求？

- A. 创建一个亚马逊简单通知服务（Amazon SNS）FIFO 主题。将团队的电子邮件账户订阅到 SNS 主题。创建一个 AWS Lambda 函数，当 AWS Glue 作业状态变为“失败”时启动该函数。将 SNS 主题设置为目标。
- B. 创建一个亚马逊简单通知服务（Amazon SNS）标准主题。将团队的电子邮件账户订阅到该 SNS 主题。创建一个亚马逊事件总线规则，当 AWS Glue 作业状态变为“失败”时触发该规则。将 SNS 主题设置为目标。
- C. 创建一个亚马逊简单队列服务（Amazon SQS）FIFO 队列。将团队的电子邮件账户订阅到 SQS 队列。创建一个 AWS 配置规则，当 AWS Glue 作业状态变为“失败”时触发。将 SQS 队列设置为目标。
- D. 创建一个亚马逊简单队列服务（Amazon SQS）标准队列。将团队的电子邮件账户订阅到该 SQS 队列。创建一个亚马逊事件总线规则，当 AWS Glue 作业状态变为“失败”时触发。将 SQS 队列设置为目标。

正确答案：B

部分：（无）

解释/参考：

解释：

Amazon EventBridge 可以原生检测 AWS Glue 作业状态变更事件。您可以配置一条规则，用于匹配作业状态转变为“失败”的情况，并将标准的 Amazon SNS 主题设置为目标。通过将业务报告团队的电子邮件地址订阅到该 SNS 主题，每当工作流失败时，他们都会自动收到电子邮件通知，无需自定义轮询或 Lambda 函数。

问题 240

一家公司使用 AWS Glue 作业来实现多个数据管道。这些管道对公司至关重要。

该公司需要建立一个监测机制，一旦管道出现故障，就能向利益相关者发出警报。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 创建一个 Amazon EventBridge 规则以匹配 AWS Glue 作业失败事件。配置该规则以将目标指向一个 AWS Lambda 函数来处理事件。配置该函数向 Amazon 简单通知服务（Amazon SNS）主题发送通知。
- B. 为 AWS Glue 作业配置一个 Amazon CloudWatch Logs 日志组。创建一个 Amazon EventBridge 规则以匹配日志组中新日志创建事件。配置该规则，使其目标指向一个 AWS Lambda 函数，该函数读取日志并在存在 AWS Glue 作业失败日志时向 Amazon Simple Notification Service（Amazon SNS）主题发送通知。
- C. 创建一个 Amazon EventBridge 规则以匹配 AWS Glue 作业失败事件。基于该 EventBridge 规则定义一个 Amazon CloudWatch 指标。根据该指标设置一个 CloudWatch 警报以

向亚马逊简单通知服务（Amazon SNS）主题发送通知。

- D. 为 AWS Glue 作业配置一个 Amazon CloudWatch Logs 日志组。创建一个 Amazon EventBridge 规则以匹配日志组中新日志创建事件。配置该规则，使其向 Amazon Simple Notification Service（Amazon SNS）主题发送通知。

正确答案：C

部分：（无）

解释/参考：

解释：

通过创建一个匹配 Glue 作业状态变更事件（其中状态为“失败”）的 EventBridge 规则，您可以无需编写任何代码即可发出自定义的 CloudWatch 指标。然后，您可以在该指标上定义一个 CloudWatch 警报，在指标超出阈值时通知 SNS 主题。这种方法无需使用 Lambda 函数或日志解析（只需规则、指标和警报），从而最大程度地减少了运营开销。

问题 241

一家公司使用 AWS Glue Apache Spark 作业来处理提取、转换和加载（ETL）工作负载。该公司已为所有 AWS Glue 作业启用了日志记录和监控功能。

其中一个 AWS Glue 作业开始失败。一位数据工程师调查了错误，并想要查看该作业中所有单独阶段的指标。

数据工程师如何访问阶段指标？

- A. 在 Spark UI 中检查 AWS Glue 作业和阶段的详细信息。
- B. 在 Amazon CloudWatch 中检查 AWS Glue 作业和阶段指标。
- C. 检查 AWS Glue 作业和阶段日志在 AWS CloudTrail 日志中。
- D. 使用作业的运行洞察功能检查 AWS Glue 作业和阶段的详细信息。

正确答案：A

部分：（无）

解释/参考：

解释：

AWS Glue 提供了一个内置的 Spark 用户界面（可通过 Glue 控制台的作业运行详细信息访问），该界面会显示每个 Spark 阶段的各阶段指标，例如任务数量、洗牌读/写大小以及执行时间。这是在排查 Glue Spark 作业失败问题时深入了解各个阶段的最直接方式。

问题 242

一位数据工程师注意到在亚马逊 Athena 中一张高度分区的表查询性能缓慢。该表包含过去 5 年的每日数据，按日期进行了分区。

数据工程师希望提高查询性能并实现分区管理的自动化。

哪种解决方案能满足这些要求？

- A. 使用每天运行一次的 AWS Lambda 函数。将该函数配置为每天手动在 AWS Glue 中为当天的数据创建新的分区。
- B. 在 Athena 中使用分区投影。通过配置表属性，使用从 5 年前到现在的日期范围。
- C. 通过将分区模式从按日粒度改为按月粒度来减少分区数量。
- D. 通过分配更多的计算资源来提高 Athena 查询的处理能力。

正确答案：B

部分：（无）

解释/参考：

解释：

分区投影消除了对 AWS Glue 数据目录中频繁查找元数据或显式注册分区的需求。通过在表属性中定义日期范围（例如，

projection.enabled=true, projection.order_date.type=DATE, projection.order_date.range=2020/01/01, NOW (以及适当的格式), Athena 将会动态计算分区。这既加快了查询速度 (避免了对数千个分区进行目录调用), 又无需任何外部分区管理任务。

问题 243

一位数据工程师正在使用 Apache Iceberg 框架构建一个包含 100 太字节数据的数据湖。该数据工程师希望运行使用 Iceberg 框架的 AWS Glue Apache Spark 作业。

哪些步骤组合能满足这些要求? (选择两项。)

- A. 为 AWS Glue 作业创建一个名为 --conf 的键。将 Iceberg 设置为 --datalakeformats 作业参数的值。
- B. 使用 -extra-jars 作业参数指定 Iceberg 的特定版本的路径。将 Iceberg 设置为 datalake-formats 作业参数的值。
- C. 将 Iceberg 设置为 --datalake-formats 作业参数的值。
- D. 将 --enable-auto-scaling 参数设置为 true。
- E. 在 AWS Glue 作业中添加 --job-bookmark-option: job-bookmark-enable 参数。

正确答案: BC

部分: (无)

解释/参考:

解释:

要使用 Apache Iceberg 框架运行 AWS Glue Apache Spark 作业, 您必须:

- 将 --datalake-formats 设置为 iceberg, 这样 Glue 就会知道使用 Iceberg 格式。
- 使用 --extra-jars 参数指定 Iceberg 库, 以包含 Glue 访问 Iceberg 表格式所需的适当 Iceberg JAR 文件。

问题 24

一位数据工程师正在配置一个 AWS Glue Apache Spark 提取、转换和加载 (ETL) 作业。该作业包含两个大小相同的大 DataFrame 的排序合并连接。

该任务因以下错误而失败: 设备上没有可用空间。

哪种解决方案能解决这个问题?

- A. 使用 AWS Glue Spark 洗牌管理器。
- B. 为作业部署一个亚马逊弹性块存储 (Amazon EBS) 卷供其使用。
- C. 将作业中的排序合并连接转换为广播连接。
- D. 将数据框转换为动态帧, 并在作业中执行动态帧连接操作。

正确答案: A

部分: (无)

解释/参考:

解释:

在 Spark 作业的洗牌阶段, 如果出现 “设备上没有空间” 的错误, 通常是因为磁盘空间不足。使用 AWS Glue Spark 洗牌管理器 (优化的洗牌管理器) 有助于减少磁盘使用量, 并通过优化中间数据的写入和读取来提高洗牌性能。这直接解决了该问题, 无需更改作业逻辑或进行手动资源管理。

问题 245

一家公司需要实施一个工作流程来处理交易。每笔交易都要经过多个层级的验证。每个验证层级都依赖于前一个验证层级。

工作流程必须在 24 小时内处理或拒绝每笔交易。工作流程的总运行时间必须少于 24 小时。

哪种解决方案能在运营成本最低的情况下满足这些要求？

- A. 在 AWS Step Functions 中创建一个标准工作流。实现一个“等待回调”模式以等待验证步骤完成。
- B. 在 AWS Step Functions 中创建一个快速工作流。实现一个“等待回调”模式以等待验证步骤完成。
- C. 使用 AWS Lambda 函数来实现工作流。使用 Amazon EventBridge 来调用验证步骤。
- D. 使用亚马逊托管的 Apache Airflow 工作流（Amazon MWAA）来实现工作流。

正确答案：A

部分：（无）

解释/参考：

解释：

标准步骤函数支持长时间运行的顺序工作流和等待回调模式，且不会对空闲等待时间收费，从而在确保 24 小时内完成任务的同时将成本降至最低。而 Express 会对长时间等待计费，Lambda+EventBridge 则会增加复杂性和限制，MWAA 则具有更高的运营成本和开销。

问题 246

一位数据工程师配置了大量 AWS Glue 作业，这些作业都在大致相同的时间启动。所有作业都在同一 VPC 的同一子网中运行，且运行时间均不足 1 小时。所有 AWS Glue 作业均使用 G1.X 工作节点类型运行。

有些任务偶尔会因以下错误而失败：“指定的子网没有足够的空闲地址来满足请求”。

错误的可能根源是什么？

- A. 子网中的 IP 地址不够。
- B. G1.X 类型的工人无法访问该子网。
- C. AWS Glue 没有正确的 IAM 权限来向子网添加额外的 IP 地址。
- D. 该虚拟私有云（VPC）中的 IP 地址不足。

正确答案：A

部分：（无）

解释/参考：

解释：

每个 AWS Glue 工作节点都需要一个弹性网络接口（ENI），并会占用子网中的一个 IP 地址。当大量 Glue 作业同时启动时，子网可能会耗尽可用的 IP 地址，从而导致错误“指定的子网没有足够的空闲地址”。根本原因是子网中的 IP 地址不足，而非整个 VPC 的 IP 地址不足。

问题 247

该公司每天晚上都在亚马逊 EMR 集群中运行一个 Apache Spark 应用程序。该公司使用亚马逊 EC2 实例为 EMR 集群提供计算能力。该公司以集群模式部署了 Spark 应用程序。

在 Spark 应用程序中出现了一个错误。该错误的日志已存储在应用程序的 Spark 驱动程序的标准错误日志中。一位数据工程师需要对错误进行调查。

数据工程师在哪里能找到这个错误日志？

- A. 工程师可以连接到实时集群的 Web 用户界面查看 YARN 资源管理器日志。
- B. 工程师可以连接到持久的应用程序用户界面，在 Spark 用户界面中查看第一个 YARN 容器的日志。
- C. 工程师可以连接到 Amazon EMR 控制台查看存档在 Amazon S3 中的 Amazon EMR 步骤日志。
- D. 工程师可以通过使用 SSH 连接到集群的主节点来查看 Spark 历史服务器的日志。

正确答案：C

部分：（无）

解释/参考：

解释：

在 EMR 集群模式下，Spark 驱动程序在集群内部运行，其标准错误日志会被捕获为步骤日志。这些日志会自动归档到 Amazon S3，并可通过 Amazon EMR 控制台中的步骤日志进行访问。这是调查 Spark 驱动程序错误的正确位置。

问题 248

该公司每天处理 500GB 的观众和广告数据，将 CSV 文件存储在亚马逊 S3 中，并在 AWS Glue 数据目录中注册模式。他们需要将文件转换为 Apache Parquet 格式，并存储在 S3 存储桶中。

该解决方案需要一个长期运行的工作流，其内存容量为 15GB，用于并行处理数据，随后是一个关联过程，该过程仅在前两个过程完成后才开始。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 使用亚马逊托管的 Apache Airflow 工作流（Amazon MWAA）通过 AWS Glue 来编排工作流。配置 AWS Glue，使其在前两个流程完成后启动第三个流程。
- B. 使用 Amazon EMR 运行工作流中的每个进程。创建一个 Amazon 简单队列服务（Amazon SQS）队列来处理表明前两个进程已完成的消息。配置一个 AWS Lambda 函数来处理 SQS 队列，通过运行第三个进程来实现。
- C. 使用 AWS Glue 工作流并行运行前两个流程。确保在前两个流程完成后启动第三个流程。
- D. 使用 AWS Step Functions 来编排一个工作流，该工作流使用多个 AWS Lambda 函数。确保在前两个进程完成后，第三个进程才开始。

正确答案：C

部分：（无）

解释/参考：

解释：

AWS Glue 工作流原生支持并行编排多个 Glue 作业，并支持依赖触发，因此只有在前两个作业完成后，第三个作业才会开始。Glue 作业提供所需的约 15 GiB 内存容量，并且能够轻松地使用 Glue 数据目录将 CSV 转换为 Parquet，从而提供一种完全托管且低运维的解决方案。

问题 249

一家公司使用 AWS Organizations 中的一个组织来管理多个 AWS 账户。该公司使用亚马逊 Kinesis 数据流中的增强扇出数据流从多个生产者接收流数据。该公司在名为 Account A 的账户中运行数据流。该公司希望在名为 Account B 的账户中使用 AWS Lambda 函数来处理来自 Account A 中数据流的数据。该公司在 Account B 中创建了一个 Lambda 执行角色，该角色具有访问 Account A 中数据流数据的权限。

公司还必须采取什么额外措施才能满足这一要求？

- A. 创建一个服务控制策略（SCP），授予跨账户的 Lambda 执行角色读取数据流的权限。将该 SCP 附加到账户 A。
- B. 向数据流添加基于资源的策略，以允许跨账户的 Lambda 执行角色具有读取访问权限。
- C. 创建一项服务控制策略（SCP），授予数据流对跨账户 Lambda 执行角色的读取访问权限。将该 SCP 附加到账户 B。
- D. 向跨账户的 Lambda 函数添加基于资源的策略，以授予该函数对数据流的读取访问权限。

正确答案：B

部分：（无）

解释/参考：

解释：

若要实现跨账户处理 Kinesis 数据流的 Lambda 函数，账户 A 中的数据流必须明确允许账户 B 中的 Lambda 执行角色。这可通过在 Kinesis 数据流上添加基于资源的策略来实现，授予跨账户角色 `kinesis:SubscribeToShard` 及相关读取权限。若未添加此基于资源的策略，账户 B 中的 Lambda 函数将无法消费数据。

问题 250

一家公司需要使用亚马逊 Athena 来分析存储在亚马逊 S3 存储桶中的数据。一位数据工程师需要为年、月和日配置 AWS Glue 表分区。该数据工程师需要每天创建分区以适应数据模式的变化。

哪种解决方案能满足这些要求？

- A. 使用 AWS Glue DataBrew 为 AWS Glue 表创建分区。
- B. 使用 AWS Lambda 函数为 AWS Glue 表创建分区。
- C. 为 AWS Glue 表设置分区投影属性。
- D. 配置一个 AWS Glue 爬虫程序，使其按照设定的时间表运行。

正确答案：C

部分：（无）

解释/参考：解释：

在 AWS Glue 中的分区投影功能可让 Athena 根据表属性自动计算分区，无需每天手动创建分区。这消除了对爬虫或 Lambda 作业的需求，降低了运营开销，并能适应模式变更，同时高效支持年、月和日分区。

问题 251

一家酒店管理公司每天都会从旗下各酒店接收数据文件。该公司希望将数据上传至 AWS。公司计划使用 Amazon Athena 来访问这些文件。公司需要防止文件意外被删除。公司将在其本地服务器上开发一个应用程序，以自动将文件转发至 AWS 的一项完全托管的摄取服务。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 使用 AWS DataSync 将本地服务器的数据复制到 Amazon Elastic File System（Amazon EFS）。在 AWS Backup 中配置自动备份。
- B. 在本地服务器上使用 Amazon Kinesis 代理将数据发送到 Amazon Data Firehose。将数据存储在启用了版本控制功能的 Amazon S3 存储桶中。
- C. 使用 AWS Glue 作业将本地服务器的数据导入到 Amazon RDS 中。启用自动备份以保护数据。
- D. 在本地服务器上使用自行管理的 Apache Kafka 代理将数据流式传输到 Amazon Managed Streaming for Apache Kafka（Amazon MSK）。将数据存储在 Amazon S3 存储桶中，并

已启用版本控制。

正确答案：B

部分：（无）

解释/参考：

解释：

本地的 Kinesis Agent 将文件发送至完全托管的 Kinesis Data Firehose，后者将文件交付至 Amazon S3。启用 S3 版本控制可防止意外删除，而 Athena 可直接从 S3 进行查询——以最小的运营开销满足了需求。

问题 252

一家公司希望利用在亚马逊 EMR 集群上运行的 Apache Spark 作业来处理流数据。这些 Spark 作业将对数据进行转换并将其存储在亚马逊 S3 存储桶中。该公司将使用亚马逊 Athena 进行分析。

该公司需要优化用于分析查询的数据格式。

哪些解决方案能在最短的查询时间内满足这些要求？（选择两项。）

- A. 使用 Avro 格式。使用 AWS Glue 数据目录来跟踪模式变更。
- B. 使用 ORC 格式。使用 AWS Glue 数据目录来跟踪模式变更。
- C. 使用 Apache Parquet 格式。使用外部的 Amazon DynamoDB 表来跟踪模式变更。
- D. 使用 Apache Parquet 格式。使用 AWS Glue 数据目录来跟踪模式变更。
- E. 使用 ORC 格式。将模式定义存储在 Amazon S3 中的单独文件中。

正确答案：BD

部分：（无）

解释/参考：

解释：

ORC 是一种针对 Athena 进行优化的列式格式，具有高压缩率和谓词下推功能，可加快查询速度；Glue 数据目录管理架构演进。

Parquet 是一种针对 Athena 进行优化的列式格式，具有高效的压缩和谓词下推功能；Glue 数据目录会跟踪模式变更。

问题 253

一家公司每天都会向其位于亚马逊 S3 存储桶中的一个大型 CSV 文件添加新的数据。该文件包含了公司过去 5 年的销售数据。目前该文件已包含超过 5000 行数据。CSV 文件的结构如下，附带示例数据：

ID	SALE_DATE	ITEM_SOLD	SALE_PRICE	SALES_REP	STORE_NAME
1	01-Jan-2024	TV	1000	Terry	Alaska
2	02-Jan-2024	DVD player	100	Diego	Boston

该公司需要使用亚马逊 Athena 对 CSV 文件运行查询，以获取特定时间段内的数据。

哪种解决方案能以最经济高效的方式满足这一要求？

- A. 编写一个 Apache Spark 脚本，将 CSV 数据转换为 JSON 格式。创建一个 AWS Glue 作业，每天运行该脚本。在 AWS Glue 中对 JSON 数据进行编目。在 JSON 数据上运行 Athena 查询。
- B. 使用前缀对 S3 存储桶中的数据进行分区。使用 SALE_DATE 列为每一天创建一个分区。在 AWS Glue 中对数据进行编目，并确保添加分区。更新 Athena 查询以使用新的分区。
- C. 启动一个 Amazon EMR 集群。指定 AWS Glue 数据目录作为默认的 Apache Hive 元数据存储。使用 Trino 中的 Presto 对数据运行查询。
- D. 创建一个亚马逊 RDS 数据库。创建一个名为 SALES 的表，使其与 CSV 文件的架构相匹配。

创建一个文件。在 SALE_DATE 列上创建索引。创建一个 AWS Lambda 函数将 CSV 数据加载到 RDS 数据库中。使用 S3 事件通知来调用 Lambda 函数。

正确答案：B

部分：（无）

解释/参考：

解释：

按照销售日期（每日前缀）对 S3 数据进行分区，这样 Athena 就能剔除不匹配的分区，仅扫描请求的时间范围，从而最大限度地减少扫描的字节数和成本，同时直接在现有的 CSV 文件上进行操作。在 AWS Glue 中对分区进行编目，能够实现高效查询，且操作开销极小。

问题 254

数据工程师必须实施一种数据编目解决方案，以跟踪 Amazon Redshift 表中的模式变更。

哪种解决方案能满足这些要求？

- A. 使用 Java 数据库连接（JDBC）驱动程序安排 AWS Glue 爬虫每天在表上运行。配置爬虫以更新 AWS Glue 数据目录。
- B. 使用 AWS DataSync 将表元数据记录到 AWS Glue 数据目录中。使用 AWS Glue 爬虫每天更新数据目录。
- C. 使用 AWS 架构转换工具（AWS SCT）将表元数据记录到 Apache Hive 元数据存储中。使用 Amazon EventBridge 调度器每天更新元数据存储。
- D. 安排 AWS Glue 爬虫每天运行一次以扫描该表。配置爬虫以更新 Apache Hive 元数据存储。

正确答案：A

部分：（无）

解释/参考：解释：

AWS Glue 爬虫可以通过 JDBC 连接到 Amazon Redshift，检测模式更改，并按照计划自动更新 AWS Glue 数据目录，从而提供所需的持续模式跟踪。

问题 25

一位数据工程师正在构建一个解决方案，用于检测存储在多个亚马逊 S3 存储桶中的数据湖里的敏感信息。该解决方案必须能够检测出以专有数据格式存在的个人身份信息（PII）。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 使用 AWS Glue 的 PII 检测转换功能，并指定特定模式。
- B. 使用亚马逊托管数据标识符。
- C. 使用带有自定义正则表达式的 AWS Lambda 函数。
- D. 使用 Amazon Athena 和 SQL 查询来匹配自定义格式。

正确答案：A

部分：（无）

解释/参考：

解释：

AWS Glue 的 PII 检测转换是一项内置功能，能够使用预定义模式或自定义正则表达式自动识别个人身份信息（PII）。它直接在 AWS Glue 作业中处理专有数据格式，并与 Glue 数据目录集成，与构建和维护自定义 Lambda 或基于 SQL 的检测方法相比，提供了一种管理方便、开销低的解决方案。

问题 256

一位数据工程师正在构建一个新的数据管道，该管道将元数据存储存储在亚马逊 DynamoDB 表中。这位数据工程师必须确保每天从 DynamoDB 表中移除所有超过指定年龄的项目。

哪种解决方案能以最少的配置工作量满足这一要求？

- A. 在 DynamoDB 表上启用 DynamoDB TTL。调整应用程序源代码以适当设置 TTL 属性。
- B. 创建一个 Amazon EventBridge 规则，该规则使用每日的 cron 表达式来触发一个 AWS Lambda 函数，以删除超过指定年龄的项目。
- C. 向 DynamoDB 表添加生命周期配置，以删除超过指定年龄的项目。
- D. 创建一个 DynamoDB 流，该流关联一个 AWS Lambda 函数，用于响应数据修改。配置该 Lambda 函数，使其删除超过指定年龄的数据项。

正确答案：A

部分：（无）

解释/参考：

解释：

DynamoDB 生存时间（TTL）是一项完全托管的功能，它会根据您定义的时间戳属性自动过期并删除项目。通过启用 TTL 并在应用程序代码中设置 TTL 属性，超过指定年龄的项目将被移除，无需自定义调度或 Lambda 函数，从而实现最少的配置工作。

问题 257

一家拼车公司将其所有行程记录存储在 Amazon DynamoDB 表中。该表包含以下列及其值类型：

RideID	RiderID	DriverID	RideStatus	TripStartTime	TripEndTime
XA1231	AXEF1	BN123	Active	2025-02-11 12:23:34:00	NULL
XA1232	AXEF2	BN124	Completed	2025-02-11 08:36:12:00	2025-02-11 08:55:02:00

该表目前包含数十亿条记录。表按照 RideID 进行分区，并使用 TripStartTime 作为排序键。该公司希望利用这些数据构建一个个人界面，使司机能够根据 RideStatus 查看每位司机已完成的行程。解决方案必须能够访问所需的数据，而无需扫描整个表。

哪种解决方案能满足这些要求？

- A. 在 DriverID 上创建一个本地二级索引（LSI）。
- B. 创建一个全局二级索引（GSI），使用 RiderID 作为分区键，RideStatus 作为排序键。
- C. 创建一个全局二级索引（GSI），使用 DriverID 作为分区键，RideStatus 作为排序键。
- D. 创建一个使用 RiderID 和 RideStatus 的筛选表达式。

正确答案：C

部分：（无）

解释/参考：

解释：

为了让司机能够高效地查询其已完成的行程，您需要一个全局二级索引（GSI），其中司机 ID 作为分区键（这样查询就可以针对每个司机进行），行程状态作为排序键（这样您就可以查询“已完成”的行程而无需扫描整个表）。这可以避免昂贵的扫描操作，并支持大规模的快速、有针对性的查找。

问题 258

一家公司将其订阅用户的信息存储在亚马逊 S3 存储桶中。每当有订阅用户结束订阅时，该公司都会进行一次分析。该公司使用 AWS Lambda 函数来

通过执行分析来响应来自 S3 存储桶的事件。

Lambda 函数会清理 S3 存储桶中的数据，并启动 AWS Glue 工作流。这些 Lambda 函数具有 128MB 内存和 512MB 临时存储空间。Lambda 函数的超时时间为 15 秒。

这三个功能均成功运行完毕。然而，CPU 使用率常常接近 100%，这导致了性能缓慢。公司希望提升这些功能的性能，并缩短整个流程的运行时间。

哪种解决方案能满足这些要求？

- A. 将 Lambda 函数的内存增加到 512MB。
- B. 通过使用“最大重试次数”设置来增加重试次数。
- C. 将 Lambda 函数配置为在公司的虚拟私有云（VPC）中运行。
- D. 将 Lambda 函数的超时值从 15 秒增加到 30 秒。

正确答案：A

部分：（无）

解释/参考：

解释：

在 AWS Lambda 中，增加内存也会相应地增加分配的 CPU 资源。将 Lambda 函数的内存从 128MB 提升到 512MB，函数会获得更强的 CPU 处理能力，从而缩短执行时间并提升性能，而无需更改逻辑或超时设置。

问题 259

一家公司使用亚马逊 Kinesis 数据流中的数据流从多个来源收集交易数据。该公司使用 AWS Glue 提取、转换和加载（ETL）管道来查找数据流中的异常值。当工作流检测到异常值时，它会向亚马逊简单通知服务（Amazon SNS）主题发送通知。SNS 主题启动第二个工作流以检索异常值的日志，并将日志存储在 Amazon S3 存储桶中。

该公司在数据流处理大量数据期间，向 SNS 主题发送通知时出现延迟。当该公司查看 Amazon CloudWatch 日志时，发现流量高峰时 glue.driver.BlockManager.disk.diskSpaceUsed_MB 指标值很高。该公司必须解决此问题。

哪种解决方案能以最少的操作努力满足这一要求？

- A. 增加 AWS Glue ETL 作业中的数据处理单元（DPU）数量。
- B. 使用 Amazon EMR 来管理 ETL 管道，而非 AWS Glue。
- C. 使用 AWS Step Functions 来编排一个并行工作流状态。
- D. 为 AWS Glue ETL 作业启用自动扩展功能。

正确答案：D

部分：（无）

解释/参考：解释：

BlockManager 磁盘使用率高表明由于 Spark 执行器配置不足导致内存压力和数据溢出。启用 AWS Glue 自动扩展功能，可以让作业在流量高峰时自动添加工作节点，从而缓解内存/磁盘压力并减少延迟，且操作工作量极小。

问题 260

一家公司有一个数据处理管道，该管道按顺序对亚马逊 Redshift 集群执行多个 SQL 查询。该公司与另一家公司合并。原公司修改了一个聚合销售数据的查询，以连接两家公司的销售表。第一家公司的销售表名为表 S1，第二家公司的销售表名为表 S2。表 S1 包含 100 亿条记录，表 S2 包含 9 亿条记录。

修改之后查询变慢了。数据工程师必须提高查询性能。

哪些解决方案能满足这些要求？（选择两项。）

- A. 使用密钥分发 为两个销售表选择相同的样式。选择一个基数较低的列用于连接。
- B. 对两个销售表都使用 KEY 分布样式。选择一个高基数列用于连接。
- C. 对表 S1 使用 EVEN 分布方式。对表 S2 使用 ALL 分布方式。
- D. 使用 Amazon Redshift 查询优化器来审查并选择要实施的优化措施。
- E. 使用 Amazon Redshift Advisor 审查并选择要实施的优化措施。

正确答案：BE

部分：（无）

解释/参考：

解释：

在两个表上选择具有高基数的连接列作为键分布，可以将匹配的行放置在不同的节点上，避免数据倾斜，从而提高连接性能。

Redshift Advisor 提供了自动化且可操作的建议（例如，分布键和排序键、统计信息），只需付出最小的努力即可进一步优化慢查询。

问题 261

一家游戏公司使用 AWS Glue 对 Apache Iceberg 表执行读写操作，以处理实时流数据。Iceberg 表中的数据采用 Apache Parquet 格式。该公司正遭遇查询性能缓慢的问题。

哪些解决方案能提高查询性能？（选择两项。）

- A. 使用 AWS Glue 数据目录按计划为 Iceberg 表生成列级统计信息。
- B. 使用 AWS Glue 数据目录自动压缩 Iceberg 表。
- C. 使用 AWS Glue 数据目录自动优化 Iceberg 表的索引。
- D. 使用 AWS Glue 数据目录为 Iceberg 表启用写时复制功能。
- E. 使用 AWS Glue 数据目录为 Iceberg 表生成视图。

正确答案：BD

部分：（无）

解释/参考：

解释：

压缩将许多小的 Parquet 文件合并为较大的文件，从而减少文件列表和打开/扫描的开销，加快读取速度。

写时复制通过将更新内容写入重写的文件来提升读取性能，从而生成更连续、更利于扫描的文件以供查询使用。

店铺：学习小店66

店铺：学习小店66

店铺：学习小店66

问题 262

一家公司的数据工程师正在优化提取、转换和加载（ETL）工作流。当前架构使用亚马逊 EMR 和 Apache Spark 进行大规模转换，并使用 AWS Glue 处理其他 ETL 任务。这些工作流将处理后的数据加载到基于亚马逊 S3 的数据湖中。

该公司希望迁移到一个完全托管的无服务器解决方案，该方案能够协调多个 ETL 作业并实现自动化执行。新的解决方案必须继续使用 Spark 来处理数据。该公司需要以最少的人工干预来协调和自动化 ETL 工作流。

哪种解决方案能满足这些要求？

- A. 将所有 ETL 作业迁移到 AWS Glue。使用 AWS Glue 工作流来编排管道。
- B. 配置 AWS Step Functions 和 Amazon EventBridge 以在 AWS Glue 和 Amazon EMR 中编排和调用 ETL 工作流。
- C. 配置 AWS Lambda 函数，以便在新数据上传时处理 Amazon S3 事件通知，从而执行数据转换任务。

D. 使用亚马逊托管的 Apache Airflow 工作流进行自动调度，以协调基于 Spark 的 ETL 作业。

正确答案：A

部分：（无）

解释/参考：解释：

AWS Glue 提供了一项完全托管的无服务器 ETL 服务，并原生支持 Spark。通过将所有 ETL 作业迁移到 Glue，该公司无需再管理 Amazon EMR 集群。Glue 工作流能够编排和自动化多个 ETL 作业，确保依赖关系得到尊重，并且执行过程实现自动化，只需极少的人工干预。这满足了对无服务器、基于 Spark 且完全托管的解决方案的需求。

问题 263

一家在全球开展业务的公司必须遵守相关规定，即来自 AWS 区域的数据只能在该区域内访问。

一位数据工程师正在创建一个数据管道，该管道将在其工作的区域创建资源。此数据管道仅应有权访问其所在区域的数据。该管道使用 Active Directory 作为身份和认证系统。该管道使用自定义身份代理应用程序来验证员工是否已登录到 Active Directory，并通过使用 AssumeRole API 操作获取临时凭证。

哪种解决方案能以最少的管理投入满足本地化要求？

- A. 创建一个具有创建资源权限的 IAM 角色。为每个区域创建一项策略，确保用户只能在该区域创建资源。当员工获取临时凭证时，将该策略作为会话策略传递。
- B. 分别在每个区域为数据工程师创建一个 IAM 角色。指示每位数据工程师通过承担相应区域特定的 IAM 角色来获取临时凭证。
- C. 为每个区域创建一个 IAM 组。为每个 IAM 组包含所需的 IAM 策略。将用户添加到每个 IAM 组中，这样当用户通过获取临时凭证登录时，用户将根据其所属的 IAM 组获得相应的访问权限。
- D. 创建单独的 IAM 策略，允许用户在特定区域创建资源。将这些策略分配给每位数据工程师。当用户登录到 AWS 时，允许用户承担为其单独分配的角色。

正确答案：A

部分：（无）

解释/参考：

解释：

使用具有区域范围会话策略（使用 `aws:RequestedRegion` 条件）的单个 IAM 角色，并在 AssumeRole 时应用这些策略，可以让身份提供者授予仅限于工程师所在区域的临时凭证。这样可以在避免使用每个区域的角色或每个用户的策略的同时，实现区域级访问控制，从而减少管理负担。

问题 264

一家公司需要一个解决方案，每天自动将数据从亚马逊 S3 存储桶导入到亚马逊 Redshift 表中。该公司必须对亚马逊 Redshift 中的敏感数据进行模糊处理。用户不得以明文形式查看敏感数据。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 为公司的 AWS 账户启用 Amazon Macie。为 S3 存储桶配置敏感数据发现任务。配置一个 AWS Glue 任务将数据加载到 Amazon Redshift 中。
- B. 为公司的 AWS 账户启用 Amazon Macie。配置一个 AWS Glue 作业，根据 Macie 分析标记并模糊处理数据列。将数据加载到 Amazon Redshift 中。
- C. 配置一个 AWS Glue 作业，从 S3 存储桶读取数据，检测并模糊处理敏感数据，然后将数据加载到 Amazon Redshift 中。

D. 配置一个 AWS Glue 作业将数据加载到 Amazon Redshift 中。使用 Amazon Redshift 检测敏感数据，创建屏蔽策略并应用动态屏蔽。

正确答案：D

部分：（无）

解释/参考：

解释：

安排一个 AWS Glue 作业将 S3 数据加载到 Amazon Redshift 中，然后使用 Redshift 内置的敏感数据发现和动态数据屏蔽功能来识别敏感列，并在查询时强制执行屏蔽。这样可以在最少的运营开销下满足每日数据摄取和非明文可见性的要求，因为屏蔽是在 Redshift 中原生管理的，无需自定义混淆管道或基于 Macie 的预处理。

问题 265

一家公司需要实时聚合和筛选大量流数据，并且要求延迟低。该公司需要将数据存储在亚马逊 S3 中以进行分析。

哪种解决方案能以最高效的操作方式满足这些要求？

- A. 使用具有预配置容量的 Amazon Kinesis 数据流和 AWS Lambda 函数执行自定义转换，并与 Amazon S3 集成。
- B. 使用内置数据转换功能的 Amazon Data Firehose。直接将数据传输至 Amazon S3。
- C. 使用 Amazon Kinesis Data Streams 和 Amazon Flink 管理服务来执行复杂处理，并与 Amazon S3 集成。
- D. 使用 Amazon Data Firehose 和 AWS Lambda 函数执行自定义转换，并将数据交付至 Amazon S3。

正确答案：C

部分：（无）

解释/参考：

解释：

亚马逊 Kinesis 数据流与亚马逊托管的 Apache Flink 服务结合使用，可大规模执行有状态、低延迟的流式聚合和筛选操作，然后将结果写入 Amazon S3，满足实时需求的同时保持完全托管和高效运营。

问题 26

一家公司正在开发机器学习（ML）模型。一名数据工程师需要将数据质量规则应用于训练数据。该公司将训练数据存储在亚马逊 S3 存储桶中。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 创建一个 AWS Lambda 函数来检查数据质量并在代码中引发异常。当数据添加到 S3 存储桶时运行该函数。为代码中的异常创建一个 Amazon CloudWatch 警报。
- B. 为 S3 存储桶中的数据创建一个 AWS Glue DataBrew 项目。创建一个规则集以定义数据质量规则。创建一个配置文件作业来运行数据质量规则。使用 Amazon EventBridge 在向 S3 存储桶添加数据时运行配置文件作业。
- C. 创建一个亚马逊 EMR 预配置集群。向 EMR 集群添加一个 Python 开源数据质量包。使用 Python 包编写数据质量规则代码，并将数据从 S3 存储桶复制到 EMR 集群。将数据从 S3 存储桶复制到 EMR 集群。运行数据质量规则。
- D. 创建 AWS Lambda 函数来评估数据质量规则。使用 AWS Step Functions 来编排 workflow，当数据未满足数据质量规则时发布通知。

正确答案：B

部分：（无）

解释/参考：

解释：

AWS Glue DataBrew 是一项完全托管的无服务器服务，内置数据质量规则集和可直接在 S3 数据上运行的分析作业。通过 EventBridge 在对象创建时触发分析作业，只需少量代码和管理开销即可应用规则。

问题 267

一位数据工程师需要分析具有时效性的销售数据。该公司将数据存储于亚马逊 S3 存储桶中。这位数据工程师使用 AWS Glue 数据目录来访问这些数据。

当数据工程师进行分析时，发现有些记录缺失或已过时。

这些问题的可能原因是什么？

- A. AWS Glue 数据目录未与最新的 S3 分区更改保持同步。
- B. 为 AWS Glue 作业分配了错误的 IAM 角色。
- C. S3 存储桶未启用版本控制。
- D. AWS Glue 作业的调度时间相互重叠。

正确答案：A

部分：（无）

解释/参考：

解释：

当 AWS Glue 数据目录未更新以反映 Amazon S3 存储桶中的最新分区时，通常会出现缺少或过时的记录。必须对目录进行爬取或更新，以便查询和分析能够看到最新的数据。

问题 268

一家零售公司将销售点交易数据存储于 Amazon RDS for MySQL 数据库中。该公司在 Amazon Redshift 中保存历史销售分析数据。该公司需要创建每日报告，将当天的交易与历史销售模式相结合以进行趋势分析。该公司需要一种解决方案，能够提供近乎实时的洞察，同时将数据传输成本和维护开销降至最低。

哪种解决方案能满足这些要求？

- A. 配置 AWS 数据迁移服务（AWS DMS），持续将 RDS for MySQL 中的数据复制到 Amazon Redshift 中。使用 Redshift 查询来创建综合报告。
- B. 实施 Amazon Redshift 联合查询，直接访问 RDS 中的 MySQL 数据，并将其与现有的 Redshift 表在单个查询中进行连接。
- C. 使用 AWS Glue 创建每小时运行一次的提取、转换和加载（ETL）管道，将 MySQL 的 RDS 中的增量数据复制到 Amazon Redshift 中。生成报告。
- D. 按照固定的时间表将 RDS for MySQL 数据导出到 Amazon S3 存储桶。使用 COPY 命令将数据加载到 Amazon Redshift 阶段表中。将数据与历史数据进行合并。

正确答案：A

部分：（无）

解释/参考：解释：

使用持续复制（CDC）功能的 AWS DMS 可以将 RDS for MySQL 中的新事务持续流式传输到 Amazon Redshift 中，从而提供近乎实时的数据新鲜度，且维护工作量极小，仅传输变更数据而非完整批次。这样，报告就可以在 Redshift 中运行，将当前数据与历史数据进行关联，而无需每小时执行 ETL 作业或使用 S3 中转。

问题 269

一家公司正在创建一个新的数据管道以填充数据湖。数据分析师需要在数据工程团队执行高级数据转换之前准备并标准化数据。数据分析师需要一个无需编写新代码即可处理数据的解决方案。

哪种解决方案能以最少的操作努力满足这些要求？

- A. 在 AWS Glue Studio 笔记本中使用 Python 和 Pandas。确保数据工程师添加额外的转换以完成管道。
- B. 使用 Amazon SageMaker Canvas 和 SageMaker Data Wrangler 将数据写入新的数据集。确保数据工程师使用 AWS Glue 添加额外的转换以完成整个流程。
- C. 使用 AWS Glue Studio 及其数据准备配方转换功能。确保数据工程师添加额外的转换操作以完成整个流程。
- D. 创建一份包含数据准备规则的文档。确保数据工程师在 AWS Glue 中实施这些规则。

正确答案：C

部分：（无）

解释/参考：解释：

AWS Glue Studio 让分析师能够构建无需代码或少量代码的可视化 ETL（提取、转换、加载），内置准备转换（配方式），生成的 Glue 作业工程师可以扩展，从而最大程度减少编码和运营开销。

问题 270

一家公司使用亚马逊 RDS 的 Oracle 数据库来存储其电子商务应用程序的数据。该公司需要一个解决方案，以便将所有表中的数据用于未来的分析。该解决方案必须通过使用 REST API 实现近乎实时地处理名为 customer_complaints 的表中的数据。

哪种解决方案能以最经济高效的方式满足这些要求？

- A. 使用 AWS 数据迁移服务（AWS DMS）将 Oracle 数据库复制到 Amazon RDS for PostgreSQL 数据库实例。创建一个 AWS Lambda 函数来处理来自 PostgreSQL 的 customer_complaints 表的数据，并调用 REST API。
- B. 在 AWS 数据迁移服务（AWS DMS）中创建一个任务，将 Oracle 数据库复制到 Amazon Redshift。将 Oracle 数据库设置为源。配置一个 AWS Lambda 函数，使用 Amazon Redshift Data API 从 customer_complaints 表中查询数据，并调用 REST API。将数据从 Amazon Redshift 卸载到 Amazon S3。
- C. 设置一个 AWS 数据迁移服务（AWS DMS）任务，将 customer_complaints 表的数据流式传输到 Amazon Kinesis 数据流。设置第二个 AWS DMS 任务，将数据发送到 Amazon S3 存储桶。配置一个 AWS Lambda 函数来处理 Kinesis 数据并调用 REST API。
- D. 创建 Amazon RDS for Oracle 数据库的只读副本。配置一个 AWS Lambda 函数来处理来自只读副本 customer_complaints 表的数据，并调用 REST API。

正确答案：C

部分：（无）

解释/参考：解释：

AWS DMS 可以将 Oracle 客户投诉表中的变更数据流式传输到 Kinesis 数据流，以便由调用 REST API 的 Lambda 函数进行近实时处理，同时另一个 DMS 任务将所有表交付到 Amazon S3 以供未来分析。这样只需少量基础设施和成本即可同时满足流处理和批处理的需求。

问题 271

一家公司维护着一个中央的 Amazon Redshift 数据仓库，该仓库汇总了来自 Amazon RDS for PostgreSQL 和 Amazon Aurora MySQL 的每日事务数据。一位数据工程师注意到一些复杂的转换查询需要数小时才能完成。这位数据工程师希望优化查询性能，尽可能减少查询执行时间。

哪种解决方案能满足这一要求？

- A. 提高 Redshift 集群的并发扩展配额。
- B. 将表导出到 Amazon S3 存储桶。使用 Amazon Athena 查询存储桶中的数据。
- C. 使用 Amazon Redshift Spectrum 根据 Redshift 表创建外部表。

D. 在 Amazon Redshift 中为频繁查询的数据模式使用物化视图。

正确答案：D

部分：（无）

解释/参考：

解释：

亚马逊 Redshift 物化视图会预先计算并存储复杂查询的结果，后续查询可通过读取这些预先计算的数据来大幅提高运行速度。这显著减少了常用转换模式的执行时间。

问题 272

一家公司使用亚马逊 S3 存储桶将多个数据源整合到一个中央数据湖中。该公司需要对数据执行多项转换和数据清理操作，以便让业务合作伙伴能够访问这些数据。

该公司需要一个解决方案，以便多个业务合作伙伴能够在正常工作时间内对中央数据湖执行 SQL 查询。

哪种解决方案能以最经济高效的方式满足这些要求？

- A. 在正常工作时间之外使用已配置的 Amazon EMR 集群处理前一天的数据，应用所有必要的转换，并将准备好的数据加载到 Amazon Redshift Serverless 中。
- B. 在正常工作时间之外使用 AWS Glue Flex 作业处理前一天的数据，应用所有必要的转换，并将准备好的数据加载到 Amazon Redshift Serverless 中。
- C. 在正常工作时间之外使用 AWS Lambda 函数处理前一天的数据，应用所有必要的转换，并将准备好的数据加载到 Amazon Redshift 预配置的集群中。
- D. 在正常工作时间之外使用 AWS Glue Flex 作业处理前一天的数据，应用所有必要的转换，并将准备好的数据加载到 Amazon Redshift 预留集群中。

正确答案：B

部分：（无）

解释/参考：

解释：

AWS Glue Flex Jobs 提供了在非高峰时段以折扣价进行批量 ETL 处理以转换 S3 数据的服务，而 Amazon Redshift Serverless 则在工作时间内提供按需 SQL 访问，无需为闲置集群付费，从而最大程度地降低了成本和运营负担。

问题 273

一家公司需要构建一个提取、转换和加载（ETL）管道，该管道应具有独立的批处理数据摄取、转换和存储阶段。该管道必须将转换后的数据存储到 Amazon S3 存储桶中。每个阶段都必须能够自动重试失败的操作。该管道必须能够提供各个阶段成功或失败情况的可见性。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 使用作业触发器将执行每个阶段的 AWS Glue 作业链接在一起。将 MaxRetries 字段设置为 0。
- B. 部署 AWS Step Functions 工作流来编排用于摄取数据的 AWS Lambda 函数。使用 AWS Glue 作业转换数据，并将数据存储到 S3 存储桶中。
- C. 构建一个基于 Amazon EventBridge 的流水线，通过调用 AWS Lambda 函数来执行每个阶段的操作。
- D. 在 Amazon Managed Workflows for Apache Airflow（Amazon MWAA）上安排 Apache Airflow 有向无环图（DAG），以协调管道步骤。使用 Amazon Simple Queue Service（Amazon SQS）来摄取数据。使用 AWS Glue 作业转换数据，并将数据存储到 S3 存储桶中。

正确答案：B

部分：（无）

解释/参考:

解释:

AWS Step Functions 提供了具备每步重试、错误处理和执行历史记录的任务编排功能。通过编排 Lambda 用于数据摄取以及 AWS Glue 作业用于将数据转换至 S3，可交付一个无服务器且维护成本低的管道，并且每个阶段的成功或失败情况都具有内置的可见性。

问题 274

一家公司需要实施数据网格架构，其中交易、风险和合规团队各自拥有自己的数据域。这些团队需要相互共享特定的数据视图。这些团队在 AWS Glue 数据目录中有超过 1000 个表，分布在 50 个数据库中。所有三个团队都使用 Amazon Athena 进行按需分析。团队使用 Amazon Redshift 生成复杂报告。合规团队必须审计所有数据访问情况。对个人身份信息（PII）数据的访问必须受到限制。

该公司需要一个可扩展的解决方案来满足团队需求。该解决方案必须具备跨团队领域进行分析的能力。

哪种解决方案能满足这些要求？

- A. 在 Athena 中创建视图以进行按需分析。在 Amazon Redshift 中使用 Athena 视图执行跨域分析。使用 AWS CloudTrail 审计数据访问。使用 AWS Lake Formation 建立细粒度的访问控制。
- B. 使用 AWS Glue 数据目录视图执行分析。使用 AWS CloudTrail 日志审核数据访问。使用 AWS Lake Formation 管理访问权限。使用安全定义视图屏蔽个人身份信息。
- C. 使用 AWS Lake Formation 设置跨域对表的访问权限。设置细粒度的访问控制。
- D. 为每个域创建物化视图并启用 Amazon Redshift 数据共享。配置跨域访问策略。

正确答案: C

部分: (无)

解释/参考:

解释:

AWS Lake Formation 提供跨域的集中式细粒度治理（LF 标签、列/行级权限），与 Athena 和 Redshift 集成以实现跨域分析，并通过 Lake Formation 访问日志和 CloudTrail 支持全面审计，满足可扩展性、个人身份信息限制和审计要求。

问题 275

该公司将数据存储于亚马逊 S3 和亚马逊 RDS 中。该公司需要应用技术控制措施以满足安全要求。该公司必须生成数据备份，并在规定的保留期内保留这些备份。在保留期内，该公司必须保护备份免遭意外或恶意删除。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 创建启用版本控制和多因素身份验证删除功能的 S3 存储桶。为每个 RDS 数据库实例设置备份保留期和备份窗口。使用 Amazon RDS 的自动备份功能，并根据需要额外创建快照。
- B. 创建启用版本控制和同区域复制功能的 S3 存储桶。为每个 RDS 数据库实例设置备份保留期和备份窗口。使用 Amazon RDS 的自动备份功能。根据需要额外创建快照。
- C. 在 AWS 备份中创建备份计划。指定备份计划的时间表，设置窗口和生命周期值，并选择一个备份库。将 Amazon S3 和 Amazon RDS 资源分配给备份计划。以合规模式创建一个库锁定。
- D. 创建启用版本控制和跨区域复制功能的 S3 存储桶。为每个 RDS 数据库实例设置备份保留期和备份窗口。使用 Amazon RDS 自动备份。根据需要额外创建快照。

正确答案: C

部分：（无）

解释/参考：

解释：

AWS Backup 可集中为 S3 和 RDS 自动安排备份计划和生命周期策略，而 Vault Lock（合规模式）则通过实施 WORM 不可变性来防止在保留期内进行修改或删除，从而以最少的管理满足安全和保留要求。

问题 276

一位数据工程师每天都会将机密文件上传至亚马逊 S3 存储桶。该数据工程师需要一个解决方案，能够独立验证所有上传数据的完整性，以确认在传输过程中没有出现损坏。

哪种解决方案能满足这一要求？

- A. 数据上传至 S3 存储桶后，下载部分数据进行验证。手动检查对象的完整性。
- B. 将 S3 存储桶的默认加密方式更改为使用客户提供的密钥的服务器端加密（SSE-C）。启用 S3 存储桶密钥以验证数据完整性。
- C. 在上传对象之前，计算对象的 SHA-256 校验和。在每次上传请求中将计算出的值传递给 AWS SDK。
- D. 数据上传至 S3 存储桶后，下载完整数据。通过编程方式验证对象的完整性。

正确答案：C

部分：（无）

解释/参考：

解释：

通过在上传前计算校验和（例如 SHA-256）并在上传请求中提供该校验和，亚马逊 S3 在接收时会验证校验和，如果数据已损坏则拒绝上传。这提供了自动且独立的数据完整性验证，无需下载全部数据。

店铺：学习小店66

店铺：学习小店66

问题 277

一家公司需要优化其亚马逊 S3 存储桶的存储。超过 1 年的对象必须在 5 小时内可访问。所有对象版本必须保留且不可变 7 年。所有对象版本必须采用一次写入多次读取（WORM）模式。

哪种解决方案能满足这些要求？

- A. 在存储桶上启用 S3 版本控制功能，并使用 S3 智能分层存储类别。为存储桶配置生命周期策略，将超过 1 年的对象转换为 S3 Glacier Flexible Retrieval 类型。将策略设置为删除超过 7 年的对象。
- B. 在存储桶上配置 S3 对象锁定功能，并使用 S3 智能分层存储类别。为存储桶配置生命周期策略，将超过 1 年的对象转换为 S3 深度存档冰川存储。配置策略以删除超过 7 年的对象。
- C. 在存储桶上配置 S3 对象锁定功能，并使用 S3 智能分层存储类别。为存储桶配置生命周期策略，将超过 1 年的对象转换为 S3 Glacier 随时检索。配置策略以删除超过 7 年的对象。
- D. 在存储桶上配置 S3 版本控制，并使用 S3 智能分层存储类别。为存储桶配置生命周期策略，将超过 1 年的对象转换为 S3 深度存档冰川存储。配置策略以删除超过 7 年的对象。

正确答案：C

部分：（无）

解释/参考：

解释：

S3 对象锁定强制执行一次写入多次读取的模型，并确保所有对象版本在所需的 7 年保留期内保持不变。将超过 1 年的对象过渡到 S3 Glacier。

灵活检索满足数据需在 5 小时内可访问的要求，因为此存储类别支持在几分钟到几小时内检索。生命周期策略可在 7 年后使对象过期，这与对象锁定保留期结束后需保留的要求相一致。

问题 278

数据工程师需要部署一个复杂的管道。管道的各个阶段必须能够运行脚本。数据工程师在管道中只能使用完全托管且无服务器的服务。

哪种解决方案能满足这些要求？

- A. 部署 AWS Glue 作业和工作流。使用 AWS Glue 按计划运行这些作业和工作流。
- B. 使用亚马逊托管的 Apache Airflow 工作流（Amazon MWAA）来构建和安排管道。
- C. 将脚本部署到 Amazon EC2 实例上。使用 Amazon EventBridge 按计划运行该脚本。
- D. 使用 AWS Glue DataBrew 构建管道。使用 Amazon EventBridge 按计划运行管道。

正确答案：B

部分：（无）

解释/参考：

解释：

亚马逊托管的 Apache Airflow 工作流是一项完全托管的无服务器服务，旨在编排复杂的管道。它支持将多个阶段定义为任务，这些任务可以运行脚本、管理依赖关系，并处理调度、重试和监控，而无需管理基础设施，完全满足仅使用托管和无服务器服务构建复杂脚本管道的需求。

问题 279

一家公司需要优化其亚马逊 S3 存储桶的存储成本。该 S3 存储桶每天接收 1000 万个对象。这些对象的大小从 2KB 到 5MB 不等。在最初的 60 天内，这些对象需要立即可访问。从第 61 天到第 180 天，用户很少访问这些对象。从第 181 天到第 365 天，这些对象必须在 1 小时内可访问。365 天后，公司可以删除这些对象。

哪种解决方案能满足这些要求？

- A. 使用 S3 智能分层功能自动转换对象。为智能分层选择归档访问层。配置 S3 存储桶策略，使超过 365 天的对象过期。
- B. 创建一个 S3 生命周期策略来移动对象。将策略配置为在 60 天后将对象从 S3 标准存储移动到 S3 标准不频繁访问（S3 标准-IA）存储，在 180 天后移动到 S3 Glacier 随时检索存储，在 365 天后过期对象。
- C. 启用 S3 存储清单。使用每日存储清单报告配置 S3 批量操作任务，将对象在 60 天后从 S3 标准存储类别移至 S3 标准-不频繁访问（S3 标准-IA）存储类别，在 180 天后移至 S3 Glacier 随时检索存储类别，并在 365 天后过期。
- D. 启用 S3 存储清单。每天运行一个 AWS Lambda 函数来获取库存报告，并在 60 天后将对象从 S3 标准存储移动到 S3 标准不频繁访问（S3 标准-IA）存储。180 天后将对象移动到 S3 Glacier 高频检索存储。365 天后使对象过期。

正确答案：B

部分：（无）

解释/参考：

解释：

S3 生命周期策略可按对象的存储时长自动进行分层存储，且无需额外操作，这对于每天新增 1000 万个对象的情况至关重要。将对象在 S3 标准存储中保留 60 天，以满足即时访问需求。从第 61 天到第 180 天转存至 S3 标准-不频繁访问存储，以实现毫秒级检索的不频繁访问。180 天后转存至 S3 冰川灵活检索存储，以满足“一小时内可访问”的要求。365 天后删除对象，以满足删除要求。

问题 280

一家公司需要使用 AWS Glue PySpark 作业从 Amazon DynamoDB 中读取特定数据。

表格。该公司知晓所需记录的分区键值。现有的 AWS Glue PySpark 作业处理逻辑要求数据采用 DynamicFrame 格式。该公司需要一个解决方案，以确保作业仅读取指定的数据。

哪种解决方案能以最少的读取容量单位（RCU）满足此要求？

- A. 使用 AWS Glue DynamoDB ETL 连接器读取 DynamoDB 表。使用筛选选项读取所需的分区键。
- B. 在 AWS Glue 作业中，仅使用排序键在键条件表达式中对 DynamoDB 表执行查询。将数据加载到 DynamicFrame 中。
- C. 在 AWS Glue 作业中对 DynamoDB 表执行扫描操作。将数据放入 DynamicFrame 中。根据分区键对 DynamicFrame 进行筛选。
- D. 在 AWS Glue 作业中对 DynamoDB 表执行查询。在键条件表达式中使用分区键。将数据放入 DynamicFrame 中。

正确答案：D

部分：（无）

解释/参考：解释：

使用分区键作为键条件表达式的 DynamoDB 查询仅读取指定分区中的项目，与任何基于扫描的方法相比，这能最大程度地减少消耗的读取容量单位（RCU）。然后，作业可以将查询结果转换为 DynamicFrame，以满足现有的处理逻辑。

问题 281

一家公司在亚马逊 EC2 实例上运行一个多租户的亚马逊 EMR 集群。多个团队在该 EMR 集群中的数据上执行交互式查询分析和数据转换操作。这些团队只能通过 EMR Studio 工作区和 EMR 步骤来访问该集群。

各团队需要使用 EMR 步骤来运行 Apache Spark 作业，从 Amazon DynamoDB 表中获取数据。DynamoDB 表中包含的机密数据只能由一个特定团队访问。公司需要确保只有适当的团队能够访问 EMR 集群中的机密数据。

哪种解决方案能满足这些要求？

- A. 为 EMR 步骤设置运行时角色。
- B. 设置 AWS Lake Formation 权限。
- C. 为 EMR 文件系统（EMRFS）请求设置 IAM 角色。
- D. 设置一个 DynamoDB 资源策略。

正确答案：A

部分：（无）

解释/参考：

解释：

EMR 步骤的运行时角色允许每个提交的步骤（例如 Spark 作业）在执行时采用不同的 IAM 角色。通过仅向授权团队步骤所使用角色授予 DynamoDB 的读取权限，机密表数据仅对那个团队的 Spark 作业可用，而其他团队的步骤则使用没有访问权限的角色运行。

问题 282

一家公司将 Apache Parquet 格式的文件存储在亚马逊 S3 数据湖中。该数据湖每小时会从多个来源接收数千个文件，文件大小在 50KB 到 100KB 之间。

该公司正在评估在数据湖中实施 Apache Iceberg 表。作为评估的一部分，该公司正在使用 AWS Glue 数据目录。该公司需要一个解决方案来优化 Iceberg 表的查询性能。该解决方案必须确保随着文件数量的增加，Iceberg 表的性能不会下降。

哪种解决方案能满足这些要求？

- A. 每天结束时，使用 AWS Glue 作业将文件压缩为 512MB 的标准大小。运行 AWS Glue 爬虫程序以更新数据目录。
- B. 将数据目录配置为每分钟自动压缩文件。
- C. 配置 Iceberg 表属性，以根据文件大小和文件数量的阈值启用自动合并。
- D. 在 Amazon S3 中实施分区策略。每 5 分钟运行一次 AWS Glue 爬虫程序以更新数据目录。

正确答案：C

部分：（无）

解释/参考：

解释：

Apache Iceberg 旨在通过控制文件布局来管理表的长期性能，具体方式是通过合并操作。通过表属性启用 Iceberg 的自动合并功能，可以让表根据配置的阈值将许多小文件重写为较少的大文件，从而避免“小文件问题”，并防止随着新文件的不断添加而导致查询规划和扫描性能下降。

问题 283

数据工程师必须维护和监控在 AWS 上运行的数据管道，该管道处理来自物联网（IoT）设备的流数据。此管道使用亚马逊 Kinesis 数据流来摄取数据，并使用亚马逊数据火管将数据传送到亚马逊 S3 存储桶。数据工程师需要监控该管道的运行状况。

哪种解决方案能以最少的操作努力满足这些要求？

- A. 使用 Amazon CloudWatch Logs 手动查看由 Kinesis Data Streams 和 Firehose 生成的日志。
- B. 配置 Amazon CloudWatch 警报以监控 Kinesis 数据流和 Firehose 的关键指标，例如 IncomingBytes（进站字节）、OutgoingBytes（出站字节）和 DeliveryToS3.Success（成功交付到 S3）
- C. 使用 AWS Lambda 函数每天检查 Kinesis 数据流和 Firehose 的状态。配置 Lambda 函数使用 Amazon 简单通知服务（Amazon SNS）发送通知。
- D. 使用亚马逊托管的 Apache Flink 服务对流数据执行近实时异常检测，并在检测到异常模式时触发警报。

正确答案：B

部分：（无）

解释/参考：

解释：

Kinesis 数据流和 Firehose 的 CloudWatch 指标会自动提供，可直接查看数据摄取、吞吐量和交付成功率。在关键指标（如流输入/输出和 Firehose 交付成功率）上配置 CloudWatch 警报，即可实现主动、自动的健康监测和警报，无需大量设置，也无需编写自定义代码或使用其他服务来运行。

问题 284

一家公司需要一个解决方案来存储和查询具有可变属性的产品数据。该解决方案必须支持在突发流量高峰期间仍能实现毫秒级延迟的不可预测的高流量查询。该解决方案必须能够通过名为“产品 ID”的主标识符检索项目。该解决方案还必须支持通过名为“类别”和“品牌”的次级属性进行灵活查询。

哪种解决方案能满足这些要求？

- A. 使用按需容量的 Amazon DynamoDB 表来存储产品数据。通过主键存储产品。使用全局二级索引（GSIs）来存储次要属性。
- B. 使用具有多可用区部署的 Amazon Aurora 来存储产品数据。使用只读副本。为主属性和次属性创建索引。
- C. 使用具有动态扩展功能的 Amazon OpenSearch 无服务器集群来存储产品数据。按照主要和次要属性对产品数据进行索引。

D. 使用 Amazon ElastiCache (Redis OSS) 和 Amazon S3 存储产品数据。使用 Amazon Athena 运行灵活的二级属性查询。

正确答案：A

部分：(无)

解释/参考：解释：

亚马逊 DynamoDB 的按需容量功能旨在处理不可预测的高流量请求模式和突发流量高峰，同时保持个位数毫秒级的延迟。使用产品 ID 作为表的主键，能够通过主标识符高效检索项目，而基于类别和品牌的全局二级索引则提供了针对这些二级属性的灵活、低延迟查询。

问题 285

一家公司正在将本地服务器的日志文件上传至 Amazon S3 存储桶。该公司需要验证本地服务器的日志与存储在 S3 存储桶中的日志是否一致。

哪种解决方案能满足这一要求？

- A. 使用 AWS SDK 在上传期间自动计算 CRC32 校验和。将校验和存储在 S3 对象的元数据中。
- B. 创建一个 AWS Lambda 函数来计算 SHA-256 校验和。将结果存储在单独的元数据表中。在上传后验证日志。
- C. 在 S3 存储桶上启用符合模式的 S3 对象锁定功能。将对象上传至该存储桶。
- D. 将对象上传到 S3 存储桶后，在 S3 对象上启用治理模式的 S3 对象锁定功能。

正确答案：A

部分：(无)

解释/参考：解释：

在上传期间计算校验和并将校验和与对象一起存储，可提供一个完整性值，之后可将其与原始日志文件进行比较，以确认上传的对象与原始日志文件一致。使用由软件开发工具包管理的 CRC32 校验和，可提供一种简单、自动化的验证方法，无需额外的处理基础设施。

问题 286

一家电子商务公司使用 AWS Glue ETL 来处理和分析订单。该公司希望构建一个提取、转换和加载 (ETL) 管道，对已下单、已发货、已送达和已取消的订单进行不同的处理。

该公司将订单处理系统与亚马逊 EventBridge 集成。该公司为每个订单状态配置 EventBridge 调度程序规则，以调用不同的 AWS Glue 工作流。当该公司检查工作流的亚马逊 CloudWatch 指标时，发现“失败调用”指标对于已取消的订单显示值较高。

公司必须查明调用失败的原因。

哪种解决方案能满足这一要求？

- A. 在 EventBridge 调度器中配置一个死信队列来存储失败的事件。分析失败的订单事件。
- B. 使用 EventBridge 调度器中的存档和重放功能来调查该问题。
- C. 更改重试次数 在 EventBridge 调度器中设置策略以降低最大重试次数的值。
- D. 在 EventBridge 调度器中更改重试策略，以增加事件最大年龄的值。

正确答案：A 部分：

(无)

解释/参考：解释：

为 EventBridge 调度器配置死信队列可以捕获无法传递到目标的事件以及失败上下文。通过查看死信队列中的失败取消订单事件，可以最直接地确定调用失败的原因（例如，有效负载问题、权限错误或目标配置问题），而无需更改重试行为。

问题 287

一家公司需要构建一条数据管道来处理来自亚马逊 S3 存储桶的 1TB 文件。该管道需要根据业务逻辑创建三个数据框。该管道必须并行地将这三个数据框保存到第二个 S3 存储桶中。公司需要将该管道设置为与亚马逊 EventBridge 规则的目标，该规则匹配对源 S3 存储桶的文件上传操作。

哪种解决方案能以最低的维护开销满足这些要求？

- A. 在 Amazon EMR 上配置一个 Apache Spark Streaming 应用程序，以批处理方式处理来自 S3 源存储桶的数据，创建数据框，并将输出保存到目标 S3 存储桶。
- B. 配置三个 AWS Lambda 函数来并行处理业务逻辑，并将 DataFrames 保存到目标 S3 存储桶。
- C. 配置一个 AWS Glue 工作流，使其并行运行三个 AWS Glue 作业来处理该文件。
- D. 配置一个 AWS Step Functions 状态机，以启动一个 AWS Glue 工作流来并行运行三个 AWS Glue 作业以处理该文件。

正确答案：C

部分：（无）

解释/参考：

解释：

当文件上传到源 S3 存储桶时，AWS Glue 工作流可以通过 EventBridge 规则触发，并且可以并行调度三个 AWS Glue 作业。这为基于 Spark 的 DataFrame 处理提供了完全托管的无服务器方法，处理规模可达 1TB，同时将编排和运营管理工作降至最低。

问题 288

一家公司需要在近乎实时的情况下对来自亚马逊 Kinesis 数据流的数据流中的物联网传感器数据进行转换，然后再将这些数据存储到亚马逊 S3 存储桶中。

在存储数据之前，公司需要对数据进行复杂且有状态的转换。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 安排 AWS Glue ETL 作业来处理数据流。
- B. 在 Amazon Managed Service for Apache Flink 中配置一个应用程序来处理数据流。
- C. 配置一个 AWS Lambda 函数来处理数据流。
- D. 在 Amazon EMR 集群上安排 Apache Spark 作业以处理数据流。

正确答案：B

部分：（无）

解释/参考：

解释：

亚马逊托管的 Apache Flink 服务专为在 Kinesis 数据流上进行近实时流处理而设计，支持复杂的有状态转换，并具备托管式扩展、状态管理和检查点功能，从而在该用例中实现最低的运营开销。

问题 289

一家公司将从流媒体服务收集到的时间序列数据存储存储在 Amazon S3 存储桶中。该公司必须确保只有部署在公司 VPC 内的工作负载才能访问这些数据。

哪种解决方案能满足这一要求？

- A. 创建一个 S3 存储桶策略，使用条件仅允许来自公司 VPC 的流量访问。
- B. 为 S3 存储桶应用一个安全组，仅允许来自公司 VPC CIDR 块的连接。
- C. 定义一个 IAM 策略，拒绝所有用户访问，除非请求源自公司 VPC 内部。
- D. 在 VPC 子网中使用网络访问控制列表（ACL），仅允许特定资源访问 S3 存储桶。

正确答案：A

部分：（无）

解释/参考：

解释：

S3 存储桶策略可以通过在 VPC 端点（或 VPC）上下文中使用条件来限制仅通过特定 VPC 端点发出的请求的访问权限，从而确保只有在公司 VPC 内运行的工作负载（使用该端点）才能访问该存储桶。

问题 290

一家公司在 AWS 上运行一个数据平台。该数据平台使用 AWS Glue 来提供数据目录并执行处理操作。该公司注意到数据存在质量问题。

该公司需要实施数据质量验证。验证必须包含针对已知问题的规则。验证还必须具备自动检测意外数据质量问题的能力。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 使用 AWS Glue 作业来实现包含异常检测的 AWS Glue 数据质量验证。
- B. 使用 AWS Glue 作业来实现采用开源数据质量框架的数据质量规则。
- C. 使用 AWS Glue DataBrew 对数据进行分析。根据分析得出的数据质量结果配置数据质量规则。
- D. 使用 AWS Glue 作业来实现使用 SQL 语句的数据质量验证。

正确答案：A

部分：（无）

解释/参考：解释：

AWS Glue 数据质量提供了原生的、托管的数据质量规则，并内置了异常检测功能，能够在验证已知问题的同时，以最小的运营工作量自动识别意外的数据质量问题。

问题 291

一家公司使用亚马逊 S3 标准存储桶来维护一个自行管理的事务型数据湖，该数据湖使用 Apache Iceberg 表。数据湖以实时和批量两种方式摄取数据。

用户报告实时表的性能缓慢。一位数据工程师审查了这些实时表，发现这些表由许多小数据文件组成。该数据工程师必须提高实时表的性能。

哪种解决方案能满足这一要求？

- A. 使历史快照过期。
- B. 存档历史快照。
- C. 删除未在 Iceberg 表中引用的 S3 对象。
- D. 进行压实。

正确答案：D

部分：（无）

解释/参考：

解释：

压缩操作将许多小的数据文件合并为较少的、较大的文件，这减少了 Apache Iceberg 表中的文件数量和元数据开销，从而直接提升了实时工作负载的查询性能。

问题 292

一家电子商务公司每天收集客户交易日志（格式为 CSV），并将这些日志存储在亚马逊 S3 中。该公司使用亚马逊 Athena 在收到每条日志的同一天扫描日志中的部分属性。

由于交易量的增加，查询时间也在延长。公司希望提高查询性能。

哪种解决方案能在最短的查询时间内满足这些要求？

- A. 将 CSV 日志转换为多个 ORC 文件，以提高 Athena 中的并行处理能力。在 Amazon S3 中按日期分区。使用列式下推筛选。
- B. 将 CSV 格式的日志转换为 JSON 格式。在 Amazon S3 中按日期分区。使用 Athena 并结合动态筛选以减少数据扫描量。
- C. 将 CSV 格式的日志转换为 Avro 格式。在 Amazon S3 中按日期分区。使用基于投影的分区功能的 Athena。
- D. 将每天的 CSV 日志转换为单个 Apache Parquet 文件。在 Amazon S3 中按日期对数据进行分区。使用具有谓词下推筛选功能的 Athena。

正确答案：D

部分：（无）

解释/参考：

解释：

按日期分区可将每个查询限制在仅与相关日期的数据进行操作，而 Parquet 格式能够实现高效的列式读取和谓词下推，从而仅扫描所需的列和行组。每天写入一个 Parquet 文件可最大程度减少文件列表和小文件开销，通常能为当天的子集列分析提供最短的 Athena 查询时间。

问题 293

一家公司将客户数据存储存储在亚马逊 S3 存储桶中。该公司必须永久删除所有超过 7 年的客户数据。

哪种解决方案能满足这一要求？

- A. 配置 S3 生命周期策略，永久删除超过 7 年的对象。
- B. 使用 Amazon Athena 查询 S3 存储桶中超过 7 年的对象。配置 Athena 删除查询结果。
- C. 配置 S3 生命周期策略，将超过 7 年的对象移至 S3 深度存档冰川存储。
- D. 配置 S3

生命周期策略：对所有超过 7 年的 S3 对象启用对象锁定功能。

正确答案：A

部分：（无）

解释/参考：

解释：

S3 生命周期策略能够在对象达到 7 年的存储期限后自动且永久地将其过期（删除），从而确保数据被移除，无需持续的人工操作。

问题 294

两个数据工程团队使用不同的 AWS 账户。两个团队都请求访问位于第三个 AWS 账户中的 Amazon Redshift 集群中的同一个数据共享，该数据共享名为 salesshare。

数据工程师必须使用 Amazon Redshift SQL 接口授予两个数据工程团队对数据共享的访问权限。

哪些命令或哪些组合的命令能满足这一要求？

授予 “<账户 ID 1>” 和 “<账户 ID 2>” 对数据共享 “salesshare” 的使用权限；

B. 授予数据共享 salesshare 的使用权限给命名空间 ‘<账户 ID 1>’ 和 ‘<账户 ID 2>’ ；

C. 授予账户 “<账户 ID 1>” 对数据共享 salesshare 的使用权限；授予账户 “<账户 ID 2>” 对数据共享 salesshare 的使用权限；

D. 授予命名空间 “<账户 ID 1>” 对数据共享 salesshare 的使用权限；授予命名空间 “<账户 ID 2>” 对数据共享 salesshare 的使用权限；

正确答案：D

部分：（无）

解释/参考：

解释：

在 Amazon Redshift 数据共享中，数据共享的跨账户权限授予给消费集群/无服务器命名空间。向每个消费命名空间授予数据共享的使用权限，可使两个团队在各自账户中的 Redshift 环境能够创建和查询来自共享数据的数据库。

问题 295

一家公司定期将数据加载到亚马逊 DynamoDB 表中。该公司必须将数据在 DynamoDB 中保留 1 年。1 年后，该公司必须将数据归档保存 5 年。5 年后，该公司必须删除这些数据。

哪种解决方案能以最高效的操作方式满足这些要求？

A. 在加载到 DynamoDB 的数据中包含时间戳。创建一个 AWS Lambda 函数来读取时间戳，并将 1 年前的数据项移至 Amazon S3 Glacier 按需检索存储。创建一个 S3 生命周期策略，在 5 年后删除这些数据项。

B. 启用 Amazon DynamoDB 流。配置一个 TTL 规则，在 1 年后从 DynamoDB 表中删除项目。使用 AWS Lambda 函数来消费流并将项目发送到 Amazon S3 Glacier Flexible Retrieval。5 年后从 S3 Glacier Flexible Retrieval 中删除项目。

C. 将带有时间戳的数据加载到 DynamoDB 中。使用 AWS Lambda 函数读取时间戳，并将 1 年前的数据直接移至 Amazon S3 Glacier 深度存档。配置该函数在 5 年后删除数据。

D. 启用 Amazon DynamoDB 流。配置一个 TTL 规则，在 1 年后从 DynamoDB 表中删除项目。使用 AWS Lambda 函数来消费流并将项目直接发送到 Amazon S3 Glacier 深度存档。创建一个 S3 生命周期策略，在 5 年后删除项目。

正确答案：D

部分：（无）

解释/参考：

解释：

DynamoDB 的 TTL 提供了一种完全托管的方式，在 1 年后自动删除项目，操作工作量极小。DynamoDB Streams 可以捕获项目变更，这样 Lambda 函数就可以在项目从表中删除之前将其过期数据归档到 Amazon S3。使用 S3 Glacier Deep Archive 可以在长期保留的情况下将归档存储成本降至最低，并且 S3 生命周期策略可以在 5 年后自动删除归档对象，从而避免自定义删除逻辑。

问题 296

一家公司必须保留特定数据 1 年。一位数据工程师发现该公司的一个亚马逊 S3 存储桶中有数百万个对象的存储时间已超过 3 年。该存储桶已启用版本控制功能。

为降低成本，数据工程师实施了一项 S3 生命周期规则，将对象在 365 天后过期。这

新的 S3 生命周期规则导致对象数量翻倍，而非减少。

数据工程师必须采取哪项额外步骤才能永久删除旧对象？

- A. 禁用 S3 存储桶的版本控制。
- B. 使用 AWS Lambda 函数运行 Python 任务，以识别并删除超过 365 天的对象。
- C. 暂停 S3 存储桶的版本控制。
- D. 添加一条额外的 S3 生命周期规则，用于删除超过 365 天的当前版本和过期版本的对象。

正确答案：D

部分：（无）

解释/参考：

解释：

启用 S3 版本控制后，对象生命周期过期通常会添加一个删除标记，而不是删除先前的版本，这可能会增加对象版本的总数。要永久删除旧数据，生命周期配置还必须根据时间删除非当前（先前）版本和过期的删除标记，以便实际删除当前和先前的版本。

问题 297

一家制造公司使用 AWS Glue 作业来处理物联网传感器数据，以生成预测性维护模型。一位数据工程师需要实现自动化的数据质量检查，以识别温度读数超出 -50°C 至 150°C 预期范围的情况。数据质量检查还必须识别缺少时间戳值的记录。

数据工程师需要一个解决方案，该方案需要最少的编码，并且能够自动标记出指定的问题。

哪种解决方案能满足这些要求？

- A. 创建一个 AWS Glue DataBrew 项目来分析传感器数据。为时间戳定义完整性规则。为温度值设置数值范围验证。
- B. 使用 AWS Glue 的数据质量规则和基于机器学习（ML）的异常检测来识别缺失的时间戳并检测温度异常。
- C. 创建一个 AWS Lambda 函数来扫描传感器数据文件以验证温度范围。使用 AWS Glue 数据目录表来检查时间戳的完整性。
- D. 创建一个使用自定义数据质量操作符来分析传感器数据的 AWS Glue 动态数据帧。使用 Amazon SageMaker Data Wrangler 转换来验证时间戳和温度范围。

正确答案：A

部分：（无）

解释/参考：解释：

AWS Glue DataBrew 提供了一种低代码方式来实现自动化数据质量检查，包括完整性规则以标记缺失的时间戳值，以及数值范围验证以标记温度读数超出 -50°C 至 150°C 范围的情况。

问题 298

一家媒体公司希望改进其根据用户行为和偏好向客户推荐媒体内容的系统。为了改进推荐系统，该公司需要将第三方数据集的洞察整合到现有的分析平台中。

该公司希望将整合第三方数据集所需的工作量 and 时间降至最低。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 使用 API 调用访问并集成来自 AWS 数据交换的第三方数据集。

- B. 使用 API 调用访问并集成来自 AWS DataSync 的第三方数据集。
- C. 使用 Amazon Kinesis Data Streams 访问并整合来自 Git 代码库的第三方数据集。
- D. 使用 Amazon Kinesis Data Streams 访问并整合来自 Amazon Elastic Container Registry (Amazon ECR) 的第三方数据集。

正确答案：A

部分：（无）

解释/参考：

解释：

AWS 数据交换旨在通过托管服务界面和 API 快速订阅和使用第三方数据集，与从其他来源构建自定义数据摄取相比，可大幅减少集成工作和运营开销。

店铺：学习小店66

店铺：学习小店66

问题 299

一家公司每年为客户生成财务报表，并将报表存储在亚马逊 S3 存储桶中。客户在一周后很少访问这些文件。该公司必须将报表保留 7 年。报表必须随时可供客户访问。

哪种解决方案能以最经济的方式满足这些要求？

- A. 创建一个 S3 生命周期规则，将对象在 7 天后转存至 S3 Glacier Deep Archive 存储类别，并在 7 年后将其过期。
- B. 将 S3 存储桶设置为在上传新对象时使用 S3 智能分层存储功能。将对象设置为 7 年后过期。
- C. 创建一个 S3 生命周期规则，将对象在 7 天后转存至 S3 Glacier 即时检索存储类别，并在 7 年后过期。
- D. 将 S3 存储桶设置为在上传新对象时使用 S3 Glacier 即时检索功能。创建一个每天运行的 AWS Lambda 函数，用于删除超过 7 年的对象。

正确答案：C

部分：（无）

解释/参考：

解释：

S3 Glacier 即时检索是成本效益最高的选项，同时还能保证数据声明随时可访问，因为它专为那些很少访问但必须立即检索的归档数据而设计，可在几毫秒内完成访问。生命周期规则可以将文件在标准 S3 类别中保留 7 天，然后在剩余的 7 年保留期内将其转移到 Glacier 即时检索类别，并在到期时自动过期。S3 Glacier 深度归档更便宜，但无法提供即时访问，而 S3 智能分层在此处的成本效益较低，因为访问模式已知。

参考：<https://aws.amazon.com/ru/s3/storage-classes/glacier/instant-retrieval/><https://aws.amazon.com/ru/s3/storage-classes/glacier/instant-retrieval/>

问题 300

一家公司在 AWS Glue 中运行提取、转换和加载（ETL）作业。该作业处理个人身份信息（PII）数据，并将日志写入 Amazon CloudWatch Logs 日志组。一位数据工程师需要在 CloudWatch 日志组中对 PII 数据进行掩码处理。

哪种解决方案能满足这些要求？

- A. 将 AWS Glue 安全配置附加到 ETL 作业。
- B. 配置数据保护策略。将该策略附加到 CloudWatch 日志组。
- C. 运行 Amazon Macie 敏感数据发现任务。
- D. 在 ETL 作业中调用 AWS Glue 敏感数据检测 API。

正确答案：B

部分：（无）

解释/参考：

解释：

CloudWatch 日志数据保护策略专门用于检测、审核和屏蔽日志事件中诸如个人身份信息（PII）之类的敏感数据，这些日志事件被传入日志组。将该策略直接附加到 CloudWatch 日志组即可满足在日志中屏蔽 PII 的要求，而无需更改 ETL 逻辑本身。

参考：<https://docs.aws.amazon.com/AmazonCloudWatch/latest/logs/mask-sensitive-log-data.html> <https://docs.aws.amazon.com/AmazonCloudWatch/latest/logs/cloudwatch-logs-data-protection-policies.html>

问题 301

一家公司创建了一个新的非生产应用程序，该程序在 Amazon EC2 实例上运行。此应用程序需要使用 Java 数据库连接（JDBC）与位于同一子网中的 Amazon RDS 数据库实例进行通信。

哪种解决方案能满足这一要求？

- A. 修改分配给数据库实例的 IAM 角色，以允许来自 EC2 实例的连接。
- B. 在 RDS 参数组中修改 `ec2_authorized_hosts` 参数以包含 EC2 实例。重启数据库实例。
- C. 更新数据库安全组以允许来自 EC2 实例的连接。
- D. 启用 Amazon RDS 数据 API，并在 JDBC 连接字符串中指定数据库实例的 Amazon 资源名称（ARN）。

正确答案：C

部分：（无）

解释/参考：

解释：

从 Amazon EC2 实例到同一子网或 VPC 中的 Amazon RDS 数据库实例的连接由 VPC 安全组控制。更新数据库安全组以允许来自 EC2 实例的入站连接，即可使应用程序通过 JDBC 连接到数据库。IAM 角色不控制直接的 JDBC 网络访问，而且 RDS Data API 也不能通过 JDBC 连接字符串使用。

参考：https://docs.aws.amazon.com/AmazonRDS/latest/UserGuide/Overview_RDS_Security_Groups.html https://docs.aws.amazon.com/AmazonRDS/latest/UserGuide/USER_VPC_Scenarios.html

问题 302

一家零售公司希望为电子商务平台实施实时分析。该公司需要从其网站和移动应用程序收集点击流数据，并需要存储这些数据以进行分析。

哪种解决方案在满足这些要求的同时，需要的持续维护最少？

- A. 使用 Amazon Data Firehose 接收流数据。将处理后的数据直接传送到已配置的 Amazon Redshift 集群。
- B. 在亚马逊 EC2 实例上部署代理以收集流数据。使用 AWS 命令行界面定期将数据批量上传到亚马逊 S3 存储桶。
- C. 使用 Amazon Kinesis Data Streams 来收集流数据。使用 Amazon Data Firehose 将数据传输到 Amazon S3 存储桶。
- D. 使用 Amazon Managed Streaming for Apache Kafka（Amazon MSK）代理来收集数据。将数据存储在 Amazon RDS 数据库实例中。

正确答案：C

部分：（无）

解释/参考：

解释：

亚马逊 Kinesis 数据流非常适合从各种来源收集高容量的实时点击流数据。

网站和移动应用程序，然后 Amazon Data Firehose 可以将这些流数据以极低的运营成本传输到 Amazon S3。这种方法管理程度很高，避免了基于 EC2 的收集器、自管理的 Kafka 模式或维护预配置的 Redshift 集群以进行原始数据着陆存储所需的持续管理。

参考：<https://docs.aws.amazon.com/firehose/latest/dev/what-is-this-service.html> <https://docs.aws.amazon.com/firehose/latest/dev/basic-deliver.html>

问题 303

一家公司使用 AWS Glue ETL 管道来处理数据。该公司使用 Amazon Athena 来分析存储在 Amazon S3 存储桶中的数据。

为了更好地了解运输时间表，该公司决定除了订单数据外，还收集并存储运输日期和交付日期。该公司增加了一项数据质量检查，以确保运输日期大于订单日期，且交付日期大于运输日期。未能通过质量检查的订单必须存储在第二个 S3 存储桶中。

哪种解决方案能以最经济高效的方式满足这些要求？

- A. 使用 AWS Glue DataBrew 的 DATEDIFF 函数创建两个额外的列。检查新列。
- B. 使用 Athena 查询所有三个日期列，并对这些列进行比较。
- C. 使用 AWS Glue 数据质量功能创建一个自定义规则，该规则使用这三个日期列。
- D. 使用 AWS Glue 爬虫程序填充 AWS Glue 数据目录。使用这三个日期列创建一个筛选器。

正确答案：C

部分：（无）

解释/参考：

解释：

AWS Glue 数据质量是成本效益最高的选择，因为它专为 ETL 数据验证而构建，并支持自定义规则，例如比较多个列，确保发货日期在订单日期之后，交付日期在发货日期之后。它还可以识别未通过验证的具体记录，以便将这些失败的订单作为 ETL 流程的一部分写入单独的 Amazon S3 存储桶。

参考：<https://docs.aws.amazon.com/glue/latest/dg/glue-data-quality.html> <https://docs.aws.amazon.com/glue/latest/dg/tutorial-data-quality.html> <https://docs.aws.amazon.com/glue/latest/dg/dqdl-rule-types-CustomSql.html>

问题 304

一位数据工程师正在为一个需要持续摄取数据的应用程序设计日志表。该应用程序必须为其他应用程序提供基于 API 的可靠访问特定记录的功能。该应用程序每秒必须处理超过 4000 个并发写入操作和 6500 个读取操作。

哪种解决方案能满足这些要求？

- A. 创建一个采用 KEY 分布样式的 Amazon Redshift 表。使用 Amazon Redshift 数据 API 执行所有读写操作。
- B. 将日志文件存储在 Amazon S3 标准存储桶中。在 AWS Glue 数据目录中注册模式。创建一个指向 AWS Glue 模式的外部 Redshift 表。使用该表执行 Amazon Redshift Spectrum 读取操作。
- C. 创建一个采用 EVEN 分布样式的 Amazon Redshift 表。使用 Amazon Redshift Java 数据库连接（JDBC）连接器建立数据库连接。使用该数据库连接执行所有读写操作。
- D. 创建一个具有预配置容量的 Amazon DynamoDB 表，以满足应用程序的容量需求。使用 DynamoDB 表通过 DynamoDB API 执行所有读写操作。

正确答案：D

部分：（无）

解释/参考：

解释：

亚马逊 DynamoDB 是最佳选择，因为它专为基于 API 的可靠访问而设计，能够支持每秒数千次的高请求率，并且可以进行配置以满足每秒数千次的并发读写操作需求。它还支持通过 DynamoDB API 直接检索项目和执行查询操作，这符合其他应用程序可靠访问特定记录的要求。亚马逊 Redshift 是为分析工作负载而设计的，而非为高吞吐量的事务性 API 读写操作而设计。

参 考：<https://docs.aws.amazon.com/amazondynamodb/latest/developerguide/read-writeoperations.html>
<https://docs.aws.amazon.com/amazondynamodb/latest/developerguide/Query.html>

问题 305

一家公司需要存储和分析大量的物联网传感器数据。该公司需要无限期地保留这些数据。该公司在一个亚马逊 Redshift 集群中对数据进行分析。

哪种解决方案能以最经济高效的方式满足这些要求？

- A. 将数据以 JSON 格式存储在 Amazon S3 存储桶中。配置从 S3 存储桶到 Redshift 集群的自动复制数据摄取。
- B. 将数据存储在 Amazon S3 存储桶中，格式为 Apache Parquet。通过 Amazon Redshift Spectrum 配置查询访问权限。
- C. 将数据以 JSON 格式存储在 Amazon S3 存储桶中。通过 Amazon Redshift Spectrum 配置查询访问权限。
- D. 将数据以 Apache Parquet 格式存储在 Amazon S3 存储桶中。配置从 S3 存储桶到 Redshift 集群的自动复制数据摄取。

正确答案：B

部分：（无）

解释/参考：

解释：

将物联网数据以 Apache Parquet 格式存储在 Amazon S3 中，并通过 Amazon Redshift Spectrum 进行查询是最具成本效益的方法，因为数据可以无限期地保留在低成本的 S3 存储中，同时仍可通过 Redshift 进行分析，而无需将所有数据加载到集群中。Parquet 格式进一步降低了成本，因为它是一种列式格式，使 Redshift Spectrum 只能扫描所需的列，从而减少了扫描的数据量并提高了查询效率。

参 考：<https://docs.aws.amazon.com/redshift/latest/dg/c-spectrum-external-tables.html> <https://docs.aws.amazon.com/redshift/latest/dg/c-spectrum-external-performance.html>

问题 306

一家公司拥有基于亚马逊 S3 的数据湖。该数据湖包含多个部门的数据集。数据湖每天会摄取数百万条客户记录。

数据工程师需要设计一种访问和存储方案，使各部门仅能访问其所需的公司数据集的子集。该方案必须遵循最小特权原则。

哪种解决方案能以最少的操作努力满足这些要求？

- A. 为每个部门定义 IAM 策略和 IAM 角色。明确每个团队可以访问的数据湖中的 S3 访问路径。
- B. 将 Amazon Redshift 和 Amazon Redshift Spectrum 设为数据湖的主要入口点。定义一个 Amazon Redshift 可以承担的 IAM 角色。配置该 IAM 角色以授予对 Amazon S3 中数据的访问权限。
- C. 配置 AWS Lake Formation。为 AWS Glue 数据目录资源分配 LF 标签。启用 Lake Formation 基于标签的访问控制（LF-TBAC）。
- D. 部署一个已安装了 aws_s3 扩展的 Amazon RDS for PostgreSQL 数据库。配置

使用 AWS Step Functions 事件来调用 AWS Lambda 函数，以将数据湖与数据库同步。

正确答案：C

部分：（无）

解释/参考：

解释：

AWS Lake Formation 与 LF-Tags 和 LF-TBAC 相结合，旨在实现对共享数据湖资源的细粒度、可扩展的访问控制。它使公司能够仅授予每个部门所需的特定数据集访问权限，同时遵循最小特权原则，并且与为每个团队单独管理 IAM 策略和 S3 路径相比，减少了持续的管理工作。

问题 307

一家医疗保健公司将患者记录存储在本地的 MySQL 数据库中。该公司创建了一个应用程序来访问 MySQL 数据库。该公司必须执行安全协议以保护患者记录。目前，该公司每 30 天轮换一次数据库凭证，以尽量减少未经授权访问的风险。

该公司希望找到一种解决方案，该方案不应要求公司在每次凭证轮换时都修改应用程序代码。

哪种解决方案能在操作开销最小的情况下满足这一要求？

- A. 为数据库分配一个 IAM 角色的访问权限。配置应用程序通过 IAM 角色获取临时凭证。
- B. 使用 AWS 密钥管理服务（AWS KMS）生成加密密钥。配置自动密钥轮换。将加密后的凭证存储在 Amazon DynamoDB 表中。
- C. 使用 AWS Secrets Manager 自动轮换凭证。允许应用程序通过 API 调用获取凭证。
- D. 将凭证存储在加密的 Amazon S3 存储桶中。通过使用 S3 生命周期策略每月轮换凭证。使用存储桶策略来控制访问权限。

正确答案：C

部分：（无）

解释/参考：

解释：

AWS Secrets Manager 专门用于存储敏感凭证，并能自动轮换这些凭证，无需为每次密码更改而更新应用程序代码。应用程序通过 API 调用动态获取当前的密钥，因此凭证轮换过程透明进行，同时将操作开销降至最低。

问题 308

一家零售公司需要实施一个解决方案，以捕获来自多个亚马逊 Aurora MySQL 数据库的数据更新。该公司需要近乎实时地将这些更新提供给分析使用。该解决方案必须是无服务器的，并且需要最少的维护。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 为每个数据库设置执行架构转换的 AWS 数据库迁移服务（AWS DMS）任务。将更改加载到 Amazon Redshift Serverless 中。
- B. 使用 Amazon Managed Streaming for Apache Kafka（Amazon MSK）Connect 与 Debezium 连接器将数据加载到 Amazon Redshift Serverless 中。
- C. 使用 AWS 数据迁移服务（AWS DMS）设置二进制日志复制到 Amazon Kinesis 数据流。在模式转换后将数据加载到 Amazon Redshift Serverless 中。
- D. 使用 Aurora 零 ETL 集成将每个数据库中的 Aurora MySQL 变更加载到 Amazon Redshift Serverless 中。

正确答案：D 部分：

（无）

解释/参考：

解释：

Aurora 零 ETL 与 Amazon Redshift Serverless 的集成是最直接的适配方案，因为它采用完全托管的方式，只需极少维护即可实现近乎实时的数据可用性以供分析。它无需构建和运营自定义的 CDC 管道、流处理基础设施或连接器框架，因此对于多个 Aurora MySQL 数据库而言，其运营开销最小。

问题 309

一位数据工程师正在 Amazon Athena 中编写一个查询以连接两个表。该数据工程师需要为这两个表选择正确的连接顺序，以优化查询性能。

哪种解决方案能满足这些要求？

- A. 请在连接操作中指定左侧为较小的表，右侧为较大的表。
- B. 指定连接左侧较大的表和连接右侧较小的表。
- C. 在执行连接操作之前，使用 AWS Glue 对表进行预处理。
- D. 使用表统计信息自动确定连接顺序。

正确答案：A

部分：（无）

解释/参考：

解释：

亚马逊的 Athena（基于 Presto/Trino）在执行连接操作时，如果较小的表位于左侧，其效率会更高，因为该表会被用作连接操作的构建侧，并可加载到内存中。这样可以最大程度减少数据的重新排序，从而在与右侧较大的表进行连接时提高性能。

问题 310

一家公司从亚马逊 Redshift 数据仓库中的 30 个表生成报告。数据源是包含 100 个表的亚马逊 Aurora MySQL 操作型数据库。目前，该公司每小时将所有数据从 Aurora 刷新到亚马逊 Redshift，这导致了报告生成的延迟。

哪种步骤组合能在操作开销最小的情况下满足这些要求？（选择两项。）

- A. 使用 AWS 数据库迁移服务（AWS DMS）创建一个复制任务。仅选择所需的表。
- B. 在 Amazon Redshift 中创建一个使用该集成的数据库。
- C. 在 Amazon Aurora 中创建零 ETL 集成。仅选择所需的表。
- D. 使用 Amazon Redshift 中的查询编辑器 v2 访问 Aurora 中的数据。
- E. 创建一个 AWS Glue 作业来传输每个所需的表。运行一个 AWS Glue 工作流，每 5 分钟启动一次这些作业。

正确答案：BC

部分：（无）

解释/参考：

解释：

Aurora 零 ETL 集成能够以低延迟和极小的管理开销将操作数据从 Aurora 复制到 Amazon Redshift，而且 AWS 支持筛选功能，因此只需复制所需的表，而非全部 100 张表。创建集成后，Amazon Redshift 需要从该集成创建一个目标数据库，以便对复制的数据进行查询以生成报告。

参考：<https://docs.aws.amazon.com/AmazonRDS/latest/AuroraUserGuide/zero-etl.filtering.html> <https://docs.aws.amazon.com/redshift/latest/mgmt/zero-etl-using-creating-db.html> <https://docs.aws.amazon.com/AmazonRDS/latest/AuroraUserGuide/zero-etl.html>

问题 311

数据工程师需要一个完全自动化的解决方案，用于检查多个数据库中的新数据，并处理该解决方案所发现的数据。该解决方案必须每小时运行一次。该解决方案必须与

亚马逊 RDS、亚马逊 DynamoDB 和亚马逊 OpenSearch 服务。该解决方案必须能够一次处理多达 10MB 的数据。该解决方案必须在成本和运营开销方面进行优化。该解决方案必须具备强大的错误处理能力。

哪种解决方案能满足这些要求？

- A. 使用 Amazon EventBridge 每小时调用一次 AWS Step Functions 来部署一个 AWS Lambda 函数以检查数据。配置 Step Functions 步骤来处理 Lambda 函数找到的数据。在每个状态中实现错误处理。
- B. 使用 Amazon EventBridge 每小时调用一次 AWS Lambda 函数来检查数据。配置该函数，使其在发现新数据时向 Amazon Simple Queue Service (Amazon SQS) 队列发送消息。使用第二个 Lambda 函数读取队列并执行处理。
- C. 配置一个 Apache Spark 应用程序在 Amazon EMR 上运行以检查数据。在应用程序中实现错误处理。使用 Amazon EventBridge 每小时调用该应用程序。
- D. 使用亚马逊托管的 Apache Airflow 工作流 (Amazon MWAA) 创建一个每小时运行一次有向无环图 (DAG) 以检查数据的工作流。配置 DAG 以处理识别出的数据。在 Python 操作符中实现错误处理。

正确答案：A

部分：（无）

解释/参考：

解释：

Amazon EventBridge 可以按照每小时的计划调用 AWS Step Functions，而 Step Functions 是一种无服务器编排服务，非常适合协调跨多个数据源的检查，并且内置了重试和捕获机制，能够实现强大的错误处理。AWS Lambda 可以通过 AWS SDK 连接到 Amazon RDS、Amazon DynamoDB 和 Amazon OpenSearch Service，并且 Lambda 能够处理内存超过 10MB 的工作负载，因此与 EMR 或 MWAA 相比，这种设计能够以较低的成本和最小的运营开销满足处理大小的要求。

参考：<https://docs.aws.amazon.com/step-functions/latest/dg/tutorial-handling-error-conditions.html> <https://docs.aws.amazon.com/opensearch-service/latest/developerguide/configuration-samples.html> <https://docs.aws.amazon.com/lambda/latest/dg/configuration-memory.html> <https://docs.aws.amazon.com/step-functions/latest/dg/workflow-studio-process-error.html>

问题 312

一家公司使用亚马逊 Redshift 集群来管理数据，其中包括供应商销售数据。该公司希望将供应商数据的副本存储在亚马逊 S3 存储桶中。

一位数据工程师设置了一个 AWS Glue 任务，按照计划将数据上传到 S3 存储桶。该数据工程师还建立了一个网络连接，以允许 Amazon Redshift 和 Amazon S3 之间的私有流量传输。

要满足这一要求，接下来需要采取什么步骤？

- A. 创建一个具有向 S3 存储桶写入权限的 IAM 角色。将该 IAM 角色与 Amazon Redshift 集群相关联。
- B. 将 S3 存储桶添加到 AWS Glue 数据目录。配置 Amazon Redshift Spectrum 以访问数据目录。
- C. 启用 Amazon Redshift 的数据共享功能。将 S3 存储桶设置为数据共享的目标存储桶。
- D. 将 Amazon Redshift 的登录凭证存储在 AWS Secrets Manager 中。在 Glue 作业配置中添加对该密钥的引用。

正确答案：A

部分：（无）

解释/参考：

解释：

Amazon Redshift 需要一个 IAM 角色，该角色应具有向目标 Amazon S3 存储桶写入数据的权限。在私有网络路径设置完成后，将该角色与 Redshift 集群关联即可启用导出功能。

将供应商数据存储存储在 S3 中的操作。

问题 313

一家公司将一个 100MB 的数据集以 Apache Parquet 文件的形式存储在 Amazon S3 存储桶中。一名数据工程师需要在对数据执行数据准备步骤之前对数据进行分析。

哪种解决方案能以最高效的操作方式满足这一要求？

- A. 在 AWS Glue DataBrew 中为数据集创建一个分析任务。查看分析任务的结果。
- B. 将数据流式传输到 Amazon Managed Service for Apache Flink 以进行 SQL 查询。使用 Apache Flink 控制面版对数据进行分析。
- C. 将数据导入 Amazon Redshift Spectrum。使用 SQL 查询来分析数据。
- D. 将数据加载到 Amazon QuickSight 数据集中。创建一个主题，通过问题来描述数据。

正确答案：A

部分：（无）

解释/参考：

解释：

AWS Glue DataBrew 提供了专门用于探索数据集结构、数据类型、分布、缺失值和异常值的内置数据剖析功能，以便在准备数据之前进行操作。对于存储在 Amazon S3 中的 100MB Parquet 文件，创建剖析作业是最具操作效率的方法，因为它所需的设置最少，且无需自定义基础设施或查询框架。

问题 314

一家公司需要为零售购物平台实施实时分析。该公司希望捕获点击流数据，处理这些数据，并将其加载到 Amazon Redshift 中进行分析。该解决方案必须每秒处理数百兆字节的数据。

哪种解决方案能以最低的查询延迟满足这些分析需求？

- A. 使用 Amazon Data Firehose 捕获数据。将数据存储在 Amazon S3 存储桶中。使用 COPY 命令将数据加载到 Amazon Redshift 中。
- B. 使用亚马逊托管的 Apache Kafka 流服务（Amazon MSK）来捕获数据。使用亚马逊弹性 MapReduce（Amazon EMR）来处理数据。使用联合查询来访问亚马逊 Redshift 中的数据。
- C. 使用 Amazon Kinesis Data Streams 捕获数据。使用 Amazon Redshift 流式数据摄取将数据直接加载到物化视图中。
- D. 使用 Amazon DynamoDB Streams 捕获数据。使用 AWS Glue 处理数据。使用零 ETL 集成将数据加载到 Amazon Redshift 中。

正确答案：C

部分：（无）

解释/参考：解释：

亚马逊 Kinesis 数据流与亚马逊 Redshift 流式数据摄取相结合，可提供最低的分析延迟，因为亚马逊 Redshift 可以直接将流式数据摄取到物化视图中，而无需先将数据暂存到亚马逊 S3 中。AWS 文档将 Kinesis 到 Redshift 的流式数据摄取描述为低延迟和高速，这使其成为高吞吐量近实时点击流分析的最佳选择。

参考：<https://docs.aws.amazon.com/redshift/latest/dg/materialized-view-streaming-ingestion.html> <https://docs.aws.amazon.com/streams/latest/dev/using-other-services-redshift.html>

问题 315

一家公司拥有一条实时处理交易数据的数据管道。该公司需要一个通知系统，能够根据处理错误的类型即时向不同的团队发出警报，不得有任何延迟。对于与安全相关的错误，该系统必须立即通知安全团队。对于数据验证错误，该系统必须通知数据质量团队。对于系统错误，该系统必须通知运营团队。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 创建一个亚马逊简单通知服务（Amazon SNS）主题，并添加一个 AWS Lambda 函数订阅者，该订阅者会评估错误类型并将错误转发到相应的电子邮件地址。
- B. 为每种错误类型配置具有不同事件模式的 Amazon EventBridge 规则。将每种错误类型定向到特定团队警报的专用 Amazon 简单通知服务（Amazon SNS）主题。
- C. 使用带有消息属性的亚马逊简单队列服务（Amazon SQS）对错误进行分类。允许每个团队轮询其各自的 SQS 队列以获取相关错误。
- D. 为每种错误类型设置具有不同指标的 Amazon CloudWatch 警报。每当指标阈值被跨越时，调用不同的 Amazon 简单通知服务（Amazon SNS）通知。

正确答案：B

部分：（无）

解释/参考：

解释：

亚马逊 EventBridge 旨在根据匹配规则和事件模式来路由事件，因此公司能够对每种处理错误类型进行分类，并立即将其发送到正确的目的地，而无需编写自定义路由代码。通过为安全、数据验证和系统错误分别使用单独的 EventBridge 规则，并将每种错误发送到其各自的 Amazon SNS 主题，该解决方案保持了完全托管、低延迟和操作更简单的特性，比引入 Lambda 逻辑、队列轮询或基于指标的警报更简便。

参 考：<https://docs.aws.amazon.com/eventbridge/latest/userguide/eb-event-patterns.html> <https://docs.aws.amazon.com/eventbridge/latest/userguide/eb-what-is.html> <https://docs.aws.amazon.com/sns/latest/dg/welcome.html>

问题 316

一家全球电子商务公司通过多个 AWS 服务处理客户交易、库存更新和用户活动日志。该公司需要一个可扩展、完全托管且基于事件驱动的编排解决方案来协调复杂的提取、转换和加载（ETL）工作流。该解决方案必须使用 AWS Glue 和 Amazon EMR 来处理数据。数据将存储在 Amazon Redshift 和 Amazon S3 中。该解决方案必须支持依赖项管理、自动重试和数据管道监控。

哪种解决方案能满足这些要求？

- A. 使用 AWS Step Functions 定义一个快速工作流，以调用在 Amazon EMR 和 AWS Glue 之间执行的数据转换和加载任务。
- B. 为工作流的每个步骤创建 AWS Lambda 函数。配置 Amazon EventBridge 以调用 AWS Glue 作业。配置 Lambda 函数以处理数据并通过管道传输数据。
- C. 使用亚马逊托管的 Apache Airflow 工作流服务（Amazon MWAA）中的 Apache Airflow 来创建有向无环图（DAG），以管理 ETL 工作流。
- D. 创建一个 AWS Lambda 函数来运行工作流中的每个步骤。创建一个 Amazon EventBridge 定时规则，每天调用该函数。

正确答案：C

部分：（无）

解释/参考：解释：

亚马逊托管的 Apache Airflow 工作流是一项完全托管的编排服务，专为协调具有依赖关系、重试、调度和监控功能的复杂 ETL 工作流而构建。Airflow 的有向无环图（DAG）能够原生编排 AWS Glue 和 Amazon EMR 作业，并管理数据移动到 Amazon Redshift 和 Amazon S3，使其成为满足可扩展、事件驱动的 ETL 编排需求的最佳选择。

问题 317

一家全球性公司目前使用亚马逊红移（Amazon Redshift）存储数据，并使用亚马逊快速套件（Amazon Quick Suite，之前称为亚马逊快速洞察 Amazon QuickSight）生成报告。

一个业务分析师团队的技术水平参差不齐。有些分析师缺乏 SQL 知识。所有分析师都需要频繁创建新的报告。公司希望使用自然编程语言查询来更高效地创建仪表板和报告。

哪种解决方案能以最少的操作努力满足这些要求？

- A. 使用 Quick Suite 仪表板，该仪表板可实现对 Amazon Redshift 的零 ETL 访问。
- B. 在 Quick Suite 中启用 Amazon Q。生成 Quick Suite 仪表板和报告。
- C. 将 Tableau 与 Amazon Redshift 集成，使 Tableau 能够直接访问数据。
- D. 使用具有对 Amazon Redshift 联合查询访问权限的 Quick Suite 仪表板。

正确答案：B

部分：（无）

解释/参考：

解释：

亚马逊 Q 在 QuickSight 中让用户能够通过自然语言查询创建仪表板和报告，无需具备 SQL 知识。它完全集成并托管在 QuickSight 内，为不同技能水平的分析师提供了最高效的运营方式，使其能够快速生成洞察，无需额外的工具或基础设施。

问题 318

一家公司正在建立一个新的亚马逊 SageMaker 统一工作室域。该公司的每个业务部门都需要对其自身的资产、项目和元数据进行独立控制。特定的数据集在获得批准后必须能够与其他业务部门共享。该公司还要求进行集中式用户身份验证和身份映射。

哪种解决方案能满足这些要求？

- A. 将每个业务部门配置为具有委托所有权和细粒度权限策略的域单元。赋予用户在域单元之间共享资产的能力，并实施明确的访问控制。为用户分配 API 密钥以进行身份验证，从而访问域门户。
- B. 将业务部门配置为具有所有者权限的独立域单位。仅允许所有者访问项目，以防止不同域之间的数据共享。配置 AWS IAM 身份中心以实现集中式身份验证。将用户配置文件映射到其各自的域单位。
- C. 配置业务部门以独立域的形式呈现。建立无共享管理策略的隔离环境。为集中式身份验证配置 AWS IAM 身份中心。在域级别委派管理权限。
- D. 将每个业务部门配置为独立的域单元，以管理资产、项目和元数据的权限。配置 AWS IAM 身份中心以实现集中式身份验证。将用户配置文件映射到其相应的域单元。通过访问请求实现跨业务部门的共享。指示域单元所有者批准或拒绝这些请求。

正确答案：D

部分：（无）

解释/参考：

解释：

SageMaker 统一工作室支持在单个域内使用域单元，以实现资产、项目和元数据的隔离，同时仍允许在单元之间进行受控共享。使用 AWS IAM 身份中心可提供集中式身份验证和身份映射。通过审批 workflow 实现跨单元共享，确保数据集能够安全共享，同时保持隔离和最小权限原则。

问题 319

一家大型公司的数据工程师需要创建针对亚马逊 Redshift 性能进行优化的集中式数据集。该公司有多个下游团队，每个团队都使用自己的 AWS 账户和配备 RA3 节点的专用亚马逊 Redshift 集群。所有下游团队都需要访问这些集中式数据集。

哪种解决方案能够立即访问数据集并保持当前的 Amazon Redshift 性能？

- A. 使用 UNLOAD 命令将数据集复制到 Amazon S3 存储桶。在专用的 AWS Glue 数据目录模式中注册表定义。使用 AWS Lake Formation 与其他 AWS 账户共享该模式。使用 Amazon Redshift Spectrum 访问数据。
- B. 创建一个每日提取、转换和加载（ETL）任务，将数据卸载到 Amazon S3 中转区域。指示各团队将数据复制到其他 Amazon Redshift 集群中。
- C. 在 Amazon Redshift 生产集群和消费集群之间设置数据共享，以提供对集中式数据集的访问。
- D. 设置一个 AWS DataSync 任务，自动在 Amazon Redshift 生产集群和消费集群之间同步数据。

正确答案：C

部分：（无）

解释/参考：

解释：

亚马逊 Redshift 数据共享功能使多个 Redshift 集群（包括跨 AWS 账户的集群）能够实时访问集中式数据集，而无需复制或移动数据。这提供了即时访问，同时保持了性能，因为查询直接在数据提供方集群的托管存储上运行，从而消除了数据重复和 ETL 开销。

问题 320

一家全球金融公司需要在 us-east-1 区域、eu-west-2 区域和 ap-northeast-1 区域的交易中心之间实现近乎实时的跨区域交易数据同步。该公司必须确保数据在传输过程中进行加密。解决方案必须保证数据的顺序和一致性，并且必须支持跨区域灾难恢复。该解决方案必须提供低于 500 毫秒的数据延迟。

哪种解决方案能以最少的操作努力满足这些要求？

- A. 在每个 AWS 区域部署 Apache Kafka Connect。使用自定义开发的连接器设置跨区域数据复制。配置 SSL 安全协议。
- B. 使用亚马逊托管的 Apache Kafka 流处理服务（Amazon MSK）复制器在三个 AWS 区域的 MSK 集群之间建立完全互联的复制关系。启用 TLS 加密和 IAM 身份验证。设置跨区域备份配置。
- C. 在每个 AWS 区域部署 Apache Kafka Mirror Maker 2.0。设置自定义复制策略以处理跨区域的数据同步。配置 SSL 安全协议。
- D. 使用 Amazon Kinesis Data Streams 从每个 AWS 区域接收交易数据。使用 Amazon Data Firehose 在每个区域的 Amazon Managed Streaming for Apache Kafka（Amazon MSK）集群之间复制数据。配置 AWS 密钥管理服务（AWS KMS）加密和 IAM 角色以管理访问权限。

正确答案：B

部分：（无）

解释/参考：

解释：

亚马逊 MSK 复制器是一项完全托管的服务，用于在不同 AWS 区域的 MSK 集群之间复制数据，这使其成为近乎实时跨区域同步和灾难恢复的最低成本选择。它支持安全加密连接，保留了有序流数据所需的 Kafka 复制行为，并且专为多区域弹性而设计，无需公司自行运营定制的复制基础设施。

参考：<https://docs.aws.amazon.com/msk/latest/developerguide/msk-replicator.html> <https://docs.aws.amazon.com/msk/latest/developerguide/msk-replicator-how-it-works.html>

问题 321

一家公司的应用程序需要近乎实时地搜索和分析数据。该应用程序每秒必须处理多达 1000 个请求，并且查询延迟要低。该公司希望找到一种解决方案，让各个数据团队能够自主拥有和配置，以满足每个团队的成本和性能优化需求。

哪种解决方案能满足这些要求？

- A. 使用亚马逊 S3 存储桶来存储数据。使用亚马逊 Athena 来查询和分析数据。为每个数据团队分配一个单独的 S3 存储桶前缀以优化查询。
- B. 使用亚马逊 Kinesis 数据流和亚马逊托管的 Apache Flink 服务中的流来查询和分析数据。为每个数据团队分配单独的流进行管理和使用。
- C. 使用带有索引功能的 Amazon OpenSearch Service 集群来查询数据。为每个数据团队分配一个单独的集群，以进行存储和查询的配置。
- D. 使用运行在 Aurora I/O 优化型实例上的 Amazon Aurora 集群。为每个数据团队分配一个单独的 Aurora 集群，以配置存储和查询。

正确答案：C

部分：（无）

解释/参考：

解释：

亚马逊 OpenSearch 服务专为近实时搜索和分析而构建，具有低查询延迟的特点，非常适合每秒必须处理约 1000 个请求的应用程序。为每个数据团队提供独立的 OpenSearch 集群，使每个团队能够根据自身工作负载需求独立调整存储、索引、扩展和成本/性能设置。

参考：<https://docs.aws.amazon.com/opensearch-service/latest/developerguide/bp.html> <https://docs.aws.amazon.com/opensearch-service/latest/developerguide/serverless-overview.html>

问题 322

一家公司使用亚马逊 Redshift 作为其数据仓库。一名数据工程师必须查询名为 orders.complete_orders_history 的表，该表包含 100 列。查询必须返回除名为 companyId 和 unique_system_id 的列之外的所有列。

哪条 Amazon Redshift SQL 语句能满足此要求？

- A.

```
SELECT * EXCLUDE company_id, unique_system_id
FROM
orders.complete_orders_history;
```
- B.

```
SELECT * NOT IN company_id, unique_system_id
FROM
orders.complete_orders_history;
```
- C.

```
SELECT * EXCEPT company_id, unique_system_id
FROM
orders.complete_orders_history;
```
- D.

```
SELECT * TRUNCATE company_id, unique_system_id
FROM
orders.complete_orders_history;
```

正确答案：A

部分：（无）

解释/参考：

解释：

Amazon Redshift 支持 SELECT * EXCLUDE 语法，该语法允许返回表中的所有列，但排除指定的列。这是排除特定列（如 company_id 和 unique_system_id）而不列出所有剩余列的最高效、最直接的方法。

问题 323

一家公司将敏感的交易数据存储在亚马逊 S3 存储桶中。一名数据工程师必须实施控制措施以防止意外删除。

哪种解决方案能满足这一要求？

- A. 在 S3 存储桶上启用版本控制并配置多因素身份验证删除。
- B. 配置一条 S3 存储桶策略规则，拒绝创建 S3 删除标记。
- C. 创建一个 S3 生命周期规则，将已删除的文件移至 S3 Glacier 深度存档。
- D. 设置 AWS Config 修复操作，以防止用户删除 S3 对象。

正确答案：A

部分：（无）

解释/参考：

解释：

启用 S3 版本控制可保留所有对象版本，以便在发生删除时恢复数据，而 MFA 删除则通过要求使用多因素身份验证来永久删除对象或更改版本控制设置，从而增加了一层保护，有效防止意外删除。

问题 324

一家公司将历史客户数据存储在 Amazon Redshift 表中。名为“Email”的列包含空值和非电子邮件地址的值。该列的质量对于多个下游流程至关重要。数据工程师必须创建一条 AWS Glue 数据质量规则，当“Email”列中有效电子邮件地址的百分比低于 90% 时，该规则应失败。

AWS Glue 数据质量规则的哪个组件能满足这些要求？

- A. 唯一性“电子邮件”与“[%@%.%]”匹配，阈值设置为大于 0.9
- B. 列值“电子邮件”与“[%@%.%]”匹配，阈值设置为大于 0.1
- C. 列值“电子邮件”与“[%@%.%]”匹配，阈值设置为大于 0.9
- D. 唯一值比率“电子邮件”与“[%@%.%]”匹配，阈值设置为大于 0.1

正确答案：C

部分：（无）

解释/参考：解释：

AWS Glue 数据质量使用带有模式匹配的“列值”规则来验证值是否符合所需的格式，例如电子邮件格式。将阈值设置为大于 0.9 可确保“电子邮件”列中至少 90% 的值符合预期的电子邮件格式，如果数据质量低于此水平，则该规则将失败。

问题 325

一家公司正在使用 AWS Glue 构建数据处理管道。这些管道访问存储在 Amazon S3 中的数据。该公司已将数据组织到具有代表不同分类级别的前缀的文件夹中。该公司需要限制 AWS Glue 作业仅访问特定的前缀，以符合数据分类的要求。该公司还必须限制访问时间仅在工作时间（上午 9 点至下午 5 点）。

公司必须在自定义 IAM 策略中包含哪些元素才能满足这些要求？

- A. 具有使用通配符表示每个前缀的 S3 对象 Amazon 资源名称（ARN）模式的资源元素，以及使用 \$util.time 变量和 TimeGreaterThan 与 TimeLessThan 操作符的条件元素
- B. 具有使用通配符表示每个前缀的 S3 对象 Amazon 资源名称（ARN）模式的资源元素，以及使用 aws:CurrentTime 条件键和 DateGreaterThan 与 DateLessThan 操作符的条件元素
- C. 一个使用 s3:prefix 条件键来限制文件夹访问权限，并使用 aws:CurrentTime 与 DateGreaterThanEquals 和 DateLessThanEquals 来限制运营时间的条件元素

D. 使用 s3:ResourceAccount 条件键来限制存储桶访问的条件元素以及在非工作时间应用的拒绝语句

正确答案：B

部分：（无）

解释/参考：解释：

IAM 策略可以通过在“资源”元素中定义带有通配符模式的对象 ARN 来限制对特定 S3 前缀的访问。使用“aws:CurrentTime”条件键以及“DateGreaterThan”和“DateLessThan”运算符来实施基于时间的访问控制，从而强制执行工作时间内的访问。

问题 326

一家公司需要收集 Amazon RDS for MySQL 数据库的日志，并使这些日志可供审计使用。这些日志必须记录每个修改数据库中数据或对数据库实例进行更改的用户。

哪种解决方案能满足这些要求？

- A. 启用 Amazon CloudWatch 日志。创建指标过滤器以监控数据库更改和实例级别的更改。配置自动通知系统，以便在出现可疑的数据库操作时发送近乎实时的警报。
- B. 配置一个 Amazon EventBridge 规则以监控数据库活动。创建一个 AWS Lambda 函数来处理 EventBridge 事件，并将其存储在 Amazon OpenSearch Service 中。
- C. 配置 AWS CloudTrail 以记录 API 调用。使用 Amazon CloudWatch Logs 进行基本监控。使用 IAM 策略控制对日志的访问。设置定期报告以进行日志审计。
- D. 启用并配置原生的 Amazon RDS 数据库审计日志记录。启用 Amazon CloudWatch Logs。配置指标筛选器和警报。配置 AWS CloudTrail 审计日志记录。

正确答案：D

部分：（无）

解释/参考：

解释：

原生的 Amazon RDS 数据库审计日志记录会捕获用户级别的数据库活动，例如数据修改，而 AWS CloudTrail 则会记录数据库实例的 API 级别更改。将日志发布到 Amazon CloudWatch Logs 可实现集中存储和监控，确保数据库和实例的更改都能满足审计要求。

问题 327

一家公司每天处理一个包含数百万条交易记录的 CSV 文件，该文件存储在亚马逊 S3 中。每条交易记录都必须经过验证才能更新数据库。该公司需要一个能够并行处理数据的解决方案。该解决方案必须采用错误处理机制，如果超过 15% 的记录验证失败，则停止整个处理过程。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 创建一个 AWS Batch 作业，以并行方式处理文件的各个部分，并采用自定义错误跟踪机制。
- B. 使用 AWS Step Functions 分布式 Map 状态，并将 ToleratedFailurePercentage 字段设置为 15%。
- C. 部署一个带有 Spark 的 Amazon EMR 集群来处理该文件，将自定义失败阈值配置为 15%。
- D. 使用 AWS Lambda 与 S3 批量操作来处理文件，并跟踪验证失败情况，使其低于 15%。

正确答案：B

部分：（无）

解释/参考：

解释：

AWS Step Functions 分布式映射旨在并行处理来自 Amazon S3 的大型数据集

只需进行最少的基础设施管理。ToleratedFailurePercentage 设置直接支持在超过 15% 的记录验证失败时停止整个工作流的要求，这使其成为此用例中开销最低的解决方案。

问题 328

一家公司需要通过整合存储在亚马逊 DynamoDB、亚马逊 RDS、亚马逊 Redshift 和亚马逊 S3 中的数据来生成一份一次性绩效报告。该公司希望避免不必要的数据移动，并尽量减少查询执行时间。

哪种解决方案能满足这些要求？

- A. 通过使用 DynamoDB 流从 DynamoDB 捕获数据。使用 AWS DMS 从 Amazon RDS 迁移数据。导出 Amazon Redshift 数据。将所有数据存储在 Amazon S3 中。使用 Redshift Spectrum 运行查询。
- B. 构建一个 AWS Glue ETL 管道，用于从数据源提取、转换数据，并将其集中存储在 Amazon S3 中。使用 Amazon Athena 运行分析查询。
- C. 部署由 Apache Spark 提供支持的 Amazon EMR 集群，以从多个来源摄取、处理和合并数据集。在合并后的数据上运行分析工作负载。
- D. 使用 Amazon Athena 联合查询在 DynamoDB、Amazon RDS、Amazon Redshift 和 Amazon S3 之间执行一次性连接和分析。

正确答案：D

部分：（无）

解释/参考：

解释：

亚马逊 Athena 联合查询可以通过使用数据源连接器在 Amazon S3 和外部数据源上运行 SQL 查询，而 AWS 为 Amazon DynamoDB、Amazon RDS 和 Amazon Redshift 提供了连接器。这使得公司能够一次性执行跨源连接和分析，而无需先集中或复制数据，从而最大程度地减少了不必要的数据移动和设置工作。

参 考： <https://docs.aws.amazon.com/athena/latest/ug/federated-queries.html> <https://docs.aws.amazon.com/athena/latest/ug/connectors-redshift.html> <https://docs.aws.amazon.com/athena/latest/ug/connectors-dynamodb.html>

问题 329

一位数据工程师正在构建一个无服务器的、多步骤的提取、转换和加载（ETL）管道。该管道从 Amazon S3 数据湖中提取数据，并使用 AWS Glue ETL 作业对数据进行转换。然后，该管道将结果加载到 Amazon Redshift 数据库中。数据工程师需要对无服务器的 ETL 工作流进行编排。

哪些解决方案能满足这些要求？（选择两项。）

- A. 使用 AWS Step Functions 实现工作流。配置 Step Functions 来协调 AWS Glue ETL 作业，并通过自动重试来处理错误情况。
- B. 使用 AWS Glue 工作流创建 ETL 任务的图形，该图形直观地表示作业之间的依赖关系以及作业触发器。
- C. 配置一个始终运行的亚马逊 EC2 实例。创建一个 cron 作业，根据预定义的时间表按顺序调用 AWS Glue ETL 作业。
- D. 使用 Amazon EventBridge 规则根据 S3 对象创建事件调用 AWS Glue ETL 作业。配置规则以按顺序链接 AWS Glue ETL 作业，并处理复杂的作业依赖关系。
- E. 利用 AWS CodePipeline 构建一个编排解决方案，根据依赖关系协调 ETL 管道和基础设施变更。

正确答案：AB

部分：（无）

解释/参考：

解释：

AWS Step Functions 是一项无服务器编排服务，能够协调多步骤的 ETL 工作流。

调用 AWS Glue 作业、管理依赖项，并提供内置的重试和错误处理逻辑。这使其非常适合端到端地编排无服务器 ETL 管道。

AWS Glue 工作流专门用于在基于依赖关系的 ETL 图中编排 AWS Glue 作业、爬虫和触发器。它们提供了一种原生方式来表示和管理无服务器 Glue 管道的任务顺序和工作流执行。

问题 330

一家媒体公司将大型视频文件上传至亚马逊 S3 进行处理。处理完成后，该公司需要将原始文件保留 90 天，以防文件需要重新处理。90 天后，该公司可以删除这些文件以降低存储成本。该公司将处理后的视频存储在不同的 S3 存储桶中。

哪种 S3 生命周期配置能以最经济高效的方式满足原始文件的这些要求？

- A. 将文件存储在 S3 标准存储中 90 天。然后将文件过渡到 S3 Glacier 随时检索存储进行长期存储。最后使文件过期。
- B. 将文件存储在 S3 标准存储类别中 90 天。启用版本控制。对文件启用 90 天的对象锁定。然后使文件过期。
- C. 将文件存储在 S3 标准存储类别中 90 天。实施 S3 生命周期管理以使文件过期。
- D. 将文件存储在 S3 智能分层存储中 90 天。启用版本控制。添加 S3 生命周期管理以使文件过期。

正确答案：C

部分：（无）

解释/参考：

解释：

在这些选项中，将文件保存在 S3 标准存储类别 90 天并使用 S3 生命周期过期规则是最具成本效益的选择，因为这些对象只需保留 90 天，然后删除即可。添加冰川灵活检索会引入针对长期存储的归档和恢复行为，而 AWS 指出 S3 冰川灵活检索是长期归档类别，存储时长至少为 90 天。S3 智能分层还会增加监控和自动化费用，而对象锁定/版本控制则会带来超出规定要求的额外成本和控制措施。

参考：<https://docs.aws.amazon.com/AmazonS3/latest/userguide/glacier-storage-classes.html> <https://docs.aws.amazon.com/AmazonS3/latest/userguide/lifecycle-expire-general-considerations.html> <https://docs.aws.amazon.com/AmazonS3/latest/userguide/intelligent-tiering.html>

问题 331

一所大学正在开发一款教育应用程序，用于分析学生的论文。该应用程序能够提供个性化反馈，并准确引用大学教材中的内容。该应用程序需要处理多种语言的论文。应用程序的回复必须直接引用课程材料中的特定章节，并且要使用学生所选的语言。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 使用 Amazon OpenSearch Serverless 构建自定义向量数据库。将教科书内容存储为多语言嵌入。创建一个 AWS Lambda 函数，在使用 Amazon Bedrock 生成响应时对数据库进行排队操作。
- B. 在亚马逊 Bedrock 知识库中使用该大学的教科书创建一个知识库。配置一个多语言模型以生成带有来源引用的回复。
- C. 使用 Amazon Comprehend 检测文章的语言和关键主题。使用 Amazon Kendra 搜索相关的教科书段落。创建一个 AWS Lambda 函数，将教科书段落格式化为反馈。
- D. 使用亚马逊 SageMaker 来托管一个在该大学教材上进行过微调的自定义训练的大语言模型（LLM），以生成带有引用的个性化反馈。

正确答案：B

部分：（无）

解释/参考：解释：

亚马逊 Bedrock 知识库是开销最低的解决方案，因为它为大学教材提供了一个托管的检索增强型生成工作流，并且能够返回带有来源材料引用的生成响应。RetrieveAndGenerate 功能旨在从检索到的教材内容中生成答案，并包含来源引用，这直接满足了对特定课程材料准确引用的要求。通过在 Bedrock 中选择多语言模型进行生成，应用程序可以使用学生选择的语言进行响应，而无需构建和运营自定义检索堆栈。

参 考： <https://docs.aws.amazon.com/bedrock/latest/userguide/knowledge-base.html> <https://docs.aws.amazon.com/bedrock/latest/userguide/kb-test-retrieve-generate.html> <https://docs.aws.amazon.com/bedrock/latest/userguide/kb-how-retrieval.html>

问题 332

一家公司需要一种解决方案，该方案能够限制对亚马逊 S3 数据的访问，并使用 AWS 管理的密钥对数据进行加密。该解决方案还必须管理 AWS Lambda 函数使用的数据库凭证，并且能够自动轮换这些凭证。

哪种解决方案能满足这些要求？

- A. 使用 S3 存储桶策略来控制访问。使用 Amazon S3 管理的密钥进行服务器端加密（SSE-S3）来加密数据。将数据库凭证存储为 Lambda 环境变量。
- B. 使用 IAM 策略来控制访问权限。使用 AWS KMS 密钥进行服务器端加密（SSE-KMS）来加密数据。配置 AWS Secrets Manager 来存储凭证，并通过使用 Lambda 函数自动轮换凭证。
- C. 使用 S3 访问控制列表（ACL）来控制访问权限。使用 AWS KMS 密钥进行服务器端加密（SSE-KMS）来加密数据。将凭证存储在 AWS 系统管理器参数存储中，并通过 Lambda 函数自动轮换凭证。
- D. 使用 IAM 策略控制访问权限。使用 Amazon S3 管理密钥的服务器端加密（SSE-S3）对数据进行加密。将凭证存储在 AWS Systems Manager 参数存储中。配置一个计划的 Lambda 函数来轮换凭证。

正确答案：B

部分：（无）

解释/参考：

解释：

IAM 策略可用于控制对 Amazon S3 数据的访问，而使用 AWS KMS 密钥的服务器端加密（SSE-KMS）支持通过使用诸如 aws/s3 之类的 AWS 管理的 KMS 密钥进行加密。AWS Secrets Manager 是一项托管服务，旨在存储数据库凭证并自动轮换它们，包括通过使用 Lambda 函数进行轮换。这种组合满足了基于 Lambda 的应用程序对 S3 访问控制、使用 AWS 管理的密钥进行加密以及自动凭证轮换的要求。

参 考： <https://docs.aws.amazon.com/AmazonS3/latest/userguide/UsingKMSEncryption.html> <https://docs.aws.amazon.com/AmazonS3/latest/userguide/access-policy-language-overview.html> <https://docs.aws.amazon.com/secretsmanager/latest/userguide/intro.html>

问题 333

一家公司需要在数据库中存储某个应用程序的半结构化事务数据。该数据库必须是无服务器的。应用程序写入数据的频率不高，但读取数据的频率很高。应用程序必须在几毫秒内检索到数据。

哪种解决方案能在操作开销最小的情况下满足这些要求？

- A. 将数据存储在 Amazon S3 标准存储桶中。启用 S3 传输加速。
- B. 将数据存储在 Amazon S3 的 Apache Iceberg 表中。启用 S3 传输加速。
- C. 将数据存储在 Amazon RDS for MySQL 集群中。为该集群配置 RDS 优化读取功能。
- D. 将数据存储在 Amazon DynamoDB 表中。配置一个 DynamoDB 加速器缓存。

正确答案：D

部分：（无）

解释/参考：

解释：

亚马逊 DynamoDB 是一种完全托管的无服务器数据库，专为实现毫秒级响应时间而设计，适用于半结构化应用程序数据。由于应用程序读取频繁而写入不频繁，添加 DynamoDB 加速器（DAX）可提供内存缓存，进一步降低读取延迟，且操作开销极小。

问题 334

一家公司每天多次在 Amazon Redshift 表上运行并发分析查询。这些查询每天需要三次一致的数据视图。该公司在查询运行期间执行提取、转换和加载（ETL）操作来更新维度表。

该公司已注意到，在 ETL 操作期间，查询会导致表级锁定。目前的解决方案在处理高峰期会出现查询超时和死锁的情况，这影响了分析报告和按需分析。

哪种解决方案能解决这个问题？

- A. 对于分析查询，请使用 Amazon Redshift 的物化视图。在非高峰时段安排 ETL 操作，以尽量减少锁争用。
- B. 配置 Amazon Redshift 联合查询以直接访问源数据。使用读取副本将分析工作负载与 ETL 操作隔离开来。
- C. 使用 Amazon Redshift Spectrum 查询 Amazon S3 中的数据以处理分析工作负载。在 Amazon Redshift 表上保持具有事务隔离的 ETL 操作。
- D. 为 ETL 和分析工作负载分别部署独立的 Amazon Redshift 集群。使用跨数据库查询和数据共享来保持数据一致性。

正确答案：D

部分：（无）

解释/参考：

解释：

使用单独的 Amazon Redshift 集群来处理 ETL 和分析任务，可以将写入密集型的 ETL 操作与读取密集型的分析工作负载隔离开来，从而消除导致超时和死锁的锁竞争。Redshift 数据共享功能提供了跨集群对相同数据的近乎实时且事务一致的访问，因此分析师可以查询到稳定的数据视图，而 ETL 进程则可以独立运行。

问题 335

一家公司将高频传感器遥测数据汇总到亚马逊 S3 数据湖中。每个传感器流每小时都会发出结构化记录。这些记录包含诸如传感器类别、设备 ID、运行状态、事件时间戳和站点位置等元数据。每天的数据量可高达数百万条记录。该公司每天都会运行复杂的查询，以挖掘特定于传感器类别的性能洞察。

哪种解决方案能以最快的查询执行时间满足这些要求？

- A. 以 Apache ORC 格式持久化数据。按日期对数据进行分区。按传感器类别对数据进行排序。
- B. 以 CSV 格式保存数据。按日期对数据进行分区。按运行状态对数据进行排序。
- C. 以 Parquet 格式持久化数据。按传感器类别对数据进行分区。按日期对数据进行排序。
- D. 以 CSV 格式保存数据。按日期对数据进行分区。按传感器类别对数据进行排序。

正确答案：C

部分：（无）

解释/参考：解释：

Parquet 是一种列式存储格式，能显著提升分析查询的性能。

通过仅读取所需列并应用高效压缩来减少工作负载。按传感器类别进行分区直接与主要查询筛选条件对齐，从而最大程度减少扫描的数据量。在每个分区中按日期排序进一步提高了基于时间筛选的查询效率，从而实现最快的查询执行速度。

问题 336

一家公司使用亚马逊 Redshift 来存储当天的订单交易数据。该公司有一个订单表，其中包含之前的订单数据。此外，该公司还有一个暂存表，用于存放新的或更新的订单记录。

公司需要从订单表中删除过时的记录，并将暂存表中的最新数据插入订单表。几个下游应用程序需要订单表显示最新的信息。

哪种解决方案能满足这些要求？

- A. 使用 Amazon Redshift Spectrum 从订单表中删除过时的记录，并将暂存表中的记录插入到订单表中。
- B. 将订单表和暂存表卸载到 Amazon S3。使用 Amazon Athena 删除过时的订单表数据，并将新的暂存表数据插入到 Amazon S3 中。将订单 S3 表复制到订单 Amazon Redshift 表。
- C. 使用 Amazon Athena 联合查询从订单表中读取过时记录。删除过时记录，并将暂存表中的记录插入订单表。
- D. 编写一个 Amazon Redshift 存储过程，用于从订单表中删除过时的记录，并从暂存表中插入新的记录。

正确答案：D

部分：（无）

解释/参考：

解释：

亚马逊 Redshift 存储过程可以在数据仓库内部直接执行删除和插入操作，这是一项受控的单一操作。这是从目标表中移除过时行并从暂存表加载最新记录，同时保持订单表对下游应用程序的时效性的最佳方式，无需引入不必要的数据移动或外部处理。

问题 337

一家公司正在开发一个日志流处理管道，该管道使用亚马逊数据火线服务。此管道将亚马逊 CloudWatch 日志数据流式传输到一个亚马逊 S3 存储桶。该公司的分析团队需要在审计中使用这些数据。该管道必须仅将相关的日志以团队分析所需的兼容格式交付到 S3 存储桶。

哪种解决方案能满足这些要求并保持可靠的性能？

- A. 将 S3 存储桶规则设置为仅允许特定时间范围内的日志。创建一个 AWS Lambda 函数将日志文件转换为所需的格式。使用 S3 触发器调用 Lambda 函数。
- B. 在 CloudWatch Logs 日志组中创建一个订阅筛选器，将其目的地设置为 Firehose 交付流。创建一个 AWS Lambda 函数，将日志文件转换为所需的格式。配置 Firehose 以调用该 Lambda 函数。
- C. 在 CloudWatch Logs 日志组中创建一个订阅筛选器。配置该筛选器以监控 Firehose 流。创建一个 AWS Lambda 函数将日志文件转换为所需的格式。配置 Firehose 调用该 Lambda 函数。
- D. 标记分析团队所需的 CloudWatch Logs 日志组。配置 Firehose 仅摄取已标记的日志组。配置 Firehose 以所需的格式写入输出。

正确答案：B

部分：（无）

解释/参考：

解释：

CloudWatch Logs 订阅筛选器仅能将日志组中的相关日志事件发送到 Amazon Data Firehose 交付流。然后，Firehose 可以调用 AWS Lambda 函数将记录转换为分析团队所需的格式，再将其交付到 Amazon S3。这种方法对于持续的日志交付而言，是经过管理、可扩展且可靠的。

问题 338

一家媒体公司希望构建一条实时分析管道，以处理其网站和移动应用程序上的客户活动事件。该公司希望打造一个解决方案，能够以最低的延迟处理数百万个事件。该解决方案必须具备足够的可扩展性和持久性，以确保不会丢失任何数据。

哪种解决方案能以最经济的方式满足这些要求？

- A. 构建一个 Amazon Kinesis Data Streams 管道来摄取数据，使用 AWS Lambda 函数处理数据，并将结果存储在 Amazon Redshift 中以进行分析。
- B. 安排一个 AWS Glue 作业，每 10 分钟从 Amazon S3 获取一次用户交互日志。配置 AWS Glue 作业以转换数据并将其存储在 Amazon Redshift 中以供分析。
- C. 配置 Amazon S3 事件通知以调用 AWS Lambda 函数来处理每个新的交互日志文件。将结果存储在 Amazon Redshift 中以进行分析。
- D. 部署一个亚马逊托管的 Apache Kafka 集群（Amazon MSK）。使用自管理的消费者来实时处理和分发数据。与 Amazon Redshift 集成以增强分析功能。

正确答案：A

部分：（无）

解释/参考：

解释：

亚马逊 Kinesis 数据流专为持久、可扩展、实时摄取流事件而构建，能够在高吞吐量的情况下以极低的延迟处理数据。AWS 文档指出，Kinesis 数据流支持实时流处理，并可直接与 Amazon Redshift 集成以实现流式摄取，这适用于每秒处理数百万个事件且无需等待批处理间隔的管道。使用 AWS Lambda 进行流处理可使解决方案易于管理且成本效益高，而 Amazon MSK 则会因该需求而带来更高的集群成本和操作复杂性。

参考：<https://docs.aws.amazon.com/streams/latest/dev/introduction.html>

问题 339

一家公司将大量数据集存储在 Amazon S3 存储桶中。一名数据工程师经常使用 Amazon Athena 对该数据集运行复杂查询。该数据工程师需要优化查询性能，并为使用相同参数多次运行的查询优化成本。

哪种解决方案能满足这些要求？

- A. 在运行 Athena 查询之前，将数据集转换为 JSON 格式。
- B. 在运行 Athena 查询之前，使用 Amazon EMR 对数据进行预处理。
- C. 在 Athena 工作组中配置查询结果重用设置。
- D. 使用 Amazon Redshift Spectrum 查询 Amazon S3 中的数据。

正确答案：C

部分：（无）

解释/参考：

解释：

Athena 查询结果复用功能使得具有相同文本和参数的重复查询能够返回先前计算的结果，而无需再次扫描源数据。这提高了重复查询的性能，并通过避免不必要的数据扫描降低了查询成本。

问题 340

一家公司将原始点击流数据存储在 Amazon S3 存储桶中。该公司需要一个解决方案，每天使用复杂的 PySpark 转换来处理这些数据，这些转换依赖于自定义的内部库。在数据转换完成后，该公司必须将数据存储在 Amazon Redshift 中以进行分析。

该解决方案必须具有高度的可扩展性，以处理大规模的数据工作负载。

哪种解决方案能在运营开销最小的情况下满足这些要求？

- A. 使用 AWS Glue Studio 构建和安排 PySpark 作业。配置包含自定义库的 AWS Glue 数据连接。
- B. 使用包含自定义库的自定义 AMI 创建 Amazon EC2 Auto Scaling 组，以运行 PySpark 应用程序。
- C. 使用 Amazon EMR 运行 PySpark 作业。使用引导操作安装自定义库
- D. 使用 Amazon SageMaker 处理作业来运行使用原生 SageMaker 库的 PySpark 代码。

正确答案：A

部分：（无）

解释/参考：

解释：

AWS Glue 是一项完全托管且高度可扩展的无服务器服务，用于运行 PySpark ETL 作业，它支持通过使用诸如 `--additional-python-modules` 和 `--extra-py-files` 等作业参数从 Amazon S3 向 Glue 作业添加自定义 Python 库。AWS Glue 还能够向 Amazon Redshift 写入数据，因此与管理 EC2 实例或 EMR 集群相比，它最适合每天进行大规模的 PySpark 转换，且运营开销最小。

参考：<https://docs.aws.amazon.com/glue/latest/dg/aws-glue-programming-python-libraries.html> <https://docs.aws.amazon.com/glue/latest/dg/aws-glue-programming-etl-connect-redshift-home.html>

问题 341

一个应用程序使用了配置了托管运行时的 AWS Lambda 函数。该 Lambda 函数能够成功地将日志写入默认的 Amazon CloudWatch Logs 日志组。一位数据工程师想要修改日志记录行为，以便仅显示应用程序日志中的 ERROR 级别日志和系统日志中的 WARN 级别日志。

哪种解决方案能满足这些要求？

- A. 为 Lambda 执行角色添加更多权限。
- B. 在 Lambda 函数代码中将日志级别设置为 ERROR。
- C. 将 Lambda 函数配置为使用 JSON 日志格式。
- D. 将 Lambda 函数配置为将日志发送到自定义日志组。

正确答案：C

部分：（无）

解释/参考：

解释：

当使用结构化的 JSON 日志格式时，AWS Lambda 支持为托管运行时配置高级日志记录控制。这允许为应用程序日志和系统日志分别设置不同的日志级别，从而可以在不修改权限或日志目标的情况下，将应用程序日志设置为 ERROR 级别，将系统日志设置为 WARN 级别。